
线性代数之旁门左道

Linear Algebra Done Wrong

作者：[美] Sergei Treil

译者：吴俊达

仅供个人学习使用，禁止传播

2025 年 9 月 4 日

译者序

本书是对布朗大学 Sergei Treil 教授的著作《Linear Algebra Done Wrong》(更新于 2025 年 8 月 25 日) 的翻译. 全书共分为 9 章, 具体内容见后文“前言”一节, 建议读者仔细阅读之, 调整好阅读本书的心态和目标.

待完成: 本书内容概要

本翻译使用的模板是在 andy123t 编写的 zhbook 基础上修改而成的, 感谢 andy123t 精心打造这一美观的模板.

英文的表达习惯与中文有诸多不同, 且原书语言生动, 若直译难免生硬别扭、失其神韵. 因此, 译者在充分尊重原文句意的前提下, 对其部分字眼不求字字对应, 而根据自己的理解作了补充, 必要时在脚注中作出解释. 翻译本质上是一种再创作, 无法代替原著. 希望读者不仅阅读翻译, 更要能独立阅读原著, 或者至少对照阅读一遍, 想必会有收获.

由于译者只能利用业余时间进行翻译且水平有限, 本翻译一定有不妥之处甚至错误, 欢迎读者们多提意见和建议.

原书基于 CC-BY-NC-ND 3.0 许可协议发布, 按照规定是不允许再创作的, 此翻译版只是译者怀着帮助读者跨越“语言关”、更深入地掌握书中内容的朴素想法所作, 译者不希望因此招致麻烦. 所以, 希望各位仅在课程群内交流, 不要外传. 谢谢大家.

译者

2026 年 3 月

前 言

前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容
前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容
内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言
前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容
内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言
前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容前言内容
内容.

翻译中更正的原书笔误

第 6 章

原书 165 页最后一行: $\det(A - \lambda I) = (\lambda_1 - \lambda) \det(A_1 - \lambda)$ 应为 $\det(A - \lambda I) = (\lambda_1 - \lambda) \det(A_1 - \lambda I)$

原书 197 页习题 6.4 第一行: $A = A^* > O$ 应为 $A = A^* > 0$

第 7 章

原书 200 页第 2 节第 4 段第 4 行: $Q[x] = a_1x_1^2 + a_2x_2^2 + \dots + a_nx_n^2$ 应为 $Q[\mathbf{x}] = a_1x_1^2 + a_2x_2^2 + \dots + a_nx_n^2$

原书 214 页定理 4.3 证明第三段第一行: $\mathbf{x}$ 应为 $\mathbf{x}_0$

原书 216 页最后一行: $G = \{g_{j,k}\}_{j,k=1}^n$ 应为 $G = \{g_{j,k}\}_{j,k=1}^n$

第 9 章

原书 261 页第三段: $P(A)E \subset E$ 应为 $p(A)E \subset E$

目 录

译者序	i
前 言	ii
目 录	iv
第 1 章 基本概念	1
§1 向量空间	1
§2 线性组合、基	5
§3 线性变换、矩阵-向量乘法	10
§4 线性变换作为向量空间的元素	16
§5 线性变换的复合与矩阵乘法	17
§6 可逆变换与矩阵、同构	21
§7 子空间	28
§8 在计算机图形学中的应用	29
第 2 章 线性方程组	35
§1 线性方程组的多副面孔	35
§2 线性方程组的解、阶梯形和简化阶梯形	36
§3 主元分析	42
§4 通过行化简求 A^{-1}	47
§5 维数、有限维向量空间	48
§6 线性方程组的通解	51
§7 矩阵的基本子空间、秩	54
§8 线性变换在任意基下的表示、坐标变换公式	62
第 3 章 行列式	68
§1 引入	68
§2 行列式应具备的性质	69
§3 构造行列式	72

§4	正式定义、行列式的存在性与唯一性	79
§5	余子式展开	82
§6	子式与秩	87
§7	第3章复习题	88
第4章	谱理论初步 (特征值与特征向量)	90
§1	主要定义	90
§2	对角化	95
第5章	内积空间	106
§1	$\mathbb{R}^n$ 和 $\mathbb{C}^n$ 上的内积、内积空间	106
§2	正交性、正交基与规范正交基	114
§3	正交投影与格拉姆-施密特正交化	117
§4	最小平方解、正交投影的公式	122
§5	线性变换的伴随、再探基本子空间	129
§6	等距变换和幺正变换、幺正矩阵和正交矩阵	133
§7	$\mathbb{R}^n$ 中的刚体运动	138
§8	复化和实化	140
第6章	内积空间上算子的结构	141
§1	算子的上三角 (舒尔) 表示	141
§2	自伴算子和正规算子的谱定理	143
§3	极分解和奇异值分解	148
§4	奇异值分解的应用	156
§5	正交矩阵的结构	164
§6	取向	169
第7章	双线性型和二次型	173
§1	主要定义	173
§2	二次型的对角化	175
§3	西尔维斯特惯性定律	181
§4	正定型、特征值的极小极大刻画和西尔维斯特正定性判据	183
§5	正定型和内积	189

第 8 章 对偶空间和张量	190
§1 对偶空间	190
§2 内积空间的对偶	190
§3 伴随（对偶）变换和转置、三探基本子空间	190
§4 向量空间与其对偶有什么差异?	190
§5 多重线性函数、张量	190
§6 张量的坐标变换公式	190
第 9 章 谱理论进阶	191
§1 凯莱-哈密尔顿定理	191
§2 谱映射定理	194
§3 广义特征空间、代数重数的几何意义	196
§4 幂零算子的结构	200
§5 若当分解定理	200
索 引	201

第 1 章 基本概念

1. 向量空间

向量空间 V 是一系列对象所构成的（非空）集合，这些对象称为向量（本书中以粗体小写字母表示，例如 $\mathbf{v}$ ）。其上还定义了两种运算——向量的加法以及向量与数（标量）的乘法¹，这两种运算满足所得结果总属于 V ，以及以下的八条性质（所谓向量空间的公理）：

前 4 条性质是关于加法的：

1. 交换律：对于所有 $\mathbf{v}, \mathbf{w} \in V$ ，都有 $\mathbf{v} + \mathbf{w} = \mathbf{w} + \mathbf{v}$ ；
2. 结合律：对于所有 $\mathbf{u}, \mathbf{v}, \mathbf{w} \in V$ ，都有 $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$ ；
3. 零向量：存在一个特殊的向量，记作 $\mathbf{0}$ ，其满足 $\mathbf{v} + \mathbf{0} = \mathbf{v}$ 对于所有 $\mathbf{v} \in V$ 都成立；
4. 加法逆元：对于每个向量 $\mathbf{v} \in V$ ，都存在向量 $\mathbf{w} \in V$ 使得 $\mathbf{v} + \mathbf{w} = \mathbf{0}$ 。这一加法逆元常记作 $-\mathbf{v}$ ；

问题来了：“这些性质怎么记得住呢？”
回答是，并不需要记忆，详见后文！

接下来两条性质是有关乘法的：

5. 乘法恒等元：对于所有 $\mathbf{v} \in V$ ，都有 $1\mathbf{v} = \mathbf{v}$ ；
6. 乘法结合律：对于所有 $\mathbf{v} \in V$ 和所有标量 α, β ，都有 $(\alpha\beta)\mathbf{v} = \alpha(\beta\mathbf{v})$ ；

最后两条分配性质，它们将乘法与加法联系起来：

7. 对于所有 $\mathbf{u}, \mathbf{v} \in V$ 和所有标量 α ，都有 $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$ ；
8. 对于所有 $\mathbf{v} \in V$ 和所有标量 α, β ，都有 $(\alpha + \beta)\mathbf{v} = \alpha\mathbf{v} + \beta\mathbf{v}$ 。

注. 上述性质看起来很难记忆，但其实没必要记——它们就是标量代数的运算律，而这些内容你在中学期间就已经知道了。唯一新出现的难点是，你需要理解运算可作用的对象。你可以将向量相加，也可以将向量与数（标量）相乘。当然，你还可以对于数进行之前你学过的所有运算。然而，你不能将两个向量相乘，或将向量和数加在一起。

¹我们需要让向量和其他对象看起来有些区别，因此在本书中我们使用粗体小写字母来表示向量，并用正体小写字母来表示数（标量）。一些（进阶的）教材中，拉丁字母用于表示向量而希腊字母用于表示标量；更为进阶的教材里，任意字母可用于表示任意对象，而读者须从上下文推断每个符号的含义。我认为，尤其对于初学者而言，对不同对象加以视觉上的区分是有助于理解的，因此总用粗体小写字母来表示向量。在黑板上，则用箭头来标识向量（如 $\vec{v}$ 所示）。

注. 容易证明, 零向量 $\mathbf{0}$ 是唯一的, 并且对于给定 $\mathbf{v} \in V$, 其加法逆元 $-\mathbf{v}$ 也是唯一的.

同样, (利用性质 5、6 和 8) 不难证明 $\mathbf{0} = 0\mathbf{v}$ 对所有 $\mathbf{v} \in V$ 都成立, 且有 $-\mathbf{v} = (-1)\mathbf{v}$. 注意, 在证明过程中, 我们还需用到向量空间的其他性质, 特别是性质 3 和 4.

若标量为实数, 那么我们称 V 为**实**向量空间. 若标量为复数, 意即我们可将向量与复数相乘, 那么我们称 V 为**复**向量空间.

注意, 任何的复向量空间也是实向量空间 (如果我们可以做复数乘法, 那么也可以做实数乘法), 但反之不成立.

如果你不知道什么是域也不必担心, 因为在这本书中我们只考虑实向量空间和复向量空间.

还可以考虑标量为任意的域 $\mathbb{F}$ 中的元素的情况. 在这种情况下, 我们说 V 是域 $\mathbb{F}$ 上的向量空间. 尽管本书的许多章节 (特别地, 第 1 至 3 章的全部内容) 对于一般的域都适用, 在本书中我们只考虑实向量空间和复向量空间.

如果我们不指明标量集合或使用 $\mathbb{F}$ 来指代之, 那么有关结论就对实向量空间和复向量空间都成立. 如果需要区分实向量空间和复向量空间, 那么我们会说清楚到底在考虑何种情况.

注意, 在“任意的域上的向量空间”这一定义中, 我们**要求**标量集合为域, 这样我们总是可以与非零标量做除法 (并且不产生余数). 于是, 向量空间的标量集可以取为有理数集, 但不能取为整数集.

1.1. 例子

例. 向量空间 $\mathbb{R}^n$ 由长度为 n 的列向量 (如下) 所构成:

$$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix}$$

其中各项为实数. 加法和乘法是逐项定义的, 也即

$$\alpha \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} = \begin{pmatrix} \alpha v_1 \\ \alpha v_2 \\ \vdots \\ \alpha v_n \end{pmatrix}, \quad \begin{pmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{pmatrix} + \begin{pmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{pmatrix} = \begin{pmatrix} v_1 + w_1 \\ v_2 + w_2 \\ \vdots \\ v_n + w_n \end{pmatrix}$$

例. 向量空间 $\mathbb{C}^n$ 同样由长度为 n 的列向量所构成, 只是向量中各项为复数. 加法和乘法与 $\mathbb{R}^n$ 中的定义相同, 唯一的区别在于如今可以将向量与**复**数相乘, 也即, $\mathbb{C}^n$ 为**复**向量空间.

本书中许多结论对于 $\mathbb{R}^n$ 和 $\mathbb{C}^n$ 都成立, 在这样的情况下, 我们将使用 $\mathbb{F}^n$ 这个记号.

例. 向量空间 $M_{m \times n}$ (也记作 $M_{m,n}$) 由 $m \times n$ 矩阵构成, 加法和标量乘法是逐项定义的. 如果我们限制各项为实数 (并且只允许与实数相乘), 那么我们就得到了一个实向量空间; 如果我们允许各项为复数 (并且允许与复数相乘), 那么我们就得到了一个复向量空间.

正式而言, 我们需要区分实数与复数情形, 也即分别写为 $M_{m,n}^{\mathbb{R}}$ 和 $M_{m,n}^{\mathbb{C}}$. 然而, 在大多数场合中, 实数和复数情形并没有区别, 于是也没有必要明确到底在考虑哪种情形. 如果有所区别, 我们会说清楚考虑的是哪种情况.

注. 如上所提到的, 向量空间的公理仅仅是实数或复数的通常代数运算规则, 因此如果我们将标量 (数) 视作向量, 那么所有的公理都是成立的. 于是, 实数集合 $\mathbb{R}$ 是实向量空间, 复数集合 $\mathbb{C}$ 是复向量空间.

更重要的是, 由于在上面的例子中, 所有的向量运算 (加法和标量乘法) 都是逐项进行的, 因此在这些例子中向量空间的公理是自动满足的, 因为这些公理对标量成立 (你能看出原因吗?). 因此, 无需检验这些公理, 我们就能得知上述例子中的集合的确是向量空间!

同样的道理也适用于下面的例子, 此处多项式的系数充当了 (上述列向量或矩阵中) 各项的角色.

例. 由次数至多为 n 的多项式所构成的向量空间 $\mathbb{P}_n$, 其中各元素 p 都是多项式, 形式如下:

$$p(t) = a_0 + a_1 t + a_2 t^2 + \cdots + a_n t^n,$$

其中 t 为自变量. 注意, 有些 (甚至全部) 系数 a_k 可以取 0.

系数 a_k 为实数时, 我们就得到了一个实向量空间; 系数 a_k 为复数时, 此空间则为复向量空间. 同样, 仅在有必要的时候我们才说明考虑的是实数情形还是复数情形, 否则所讨论的内容在两种情况下都适用.

问题: 上面这几个例子中的零向量是什么?

1.2. 矩阵记号

一个 $m \times n$ 的矩阵是一个有 m 行 n 列的数阵. 这个阵列中的元素称为矩阵的项.

将矩阵的项记作带下标的字母是很方便的：第一个下标代表该项的行号，而第二个下标则代表列号。例如

$$(1.1) \quad A = (a_{j,k})_{j=1,k=1}^{m,n} = \begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{m,1} & a_{m,2} & \cdots & a_{m,n} \end{pmatrix}$$

就是 $m \times n$ 矩阵的通常表示形式。

矩阵 A 中的第 j 行第 k 列的项往往表示为 $A_{j,k}$ 或 $(A)_{j,k}$ ，有时也像上面的式 (1.1) 那样用小写字母加下标来表示。

给定一矩阵 A ，其**转置**（或转置矩阵） A^T 定义为将 A 的行变为列所得的矩阵。例如

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}^T = \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}.$$

因此， A^T 的各列就是 A 的各行。反之亦然： A^T 的各行就是 A 的各列。

正式的定义是： $(A^T)_{j,k} = (A)_{k,j}$ ，意为： A^T 的第 j 行第 k 列的项等于 A 的第 k 行第 j 列的项。

就线性变换而言，矩阵的转置有一种很优美的阐释，也即其能导出所谓**伴随**变换，我们将在后面详细研究它，目前转置仅仅是一种有用且正式的运算。

转置的用处首先在于使我们得以将列向量 $\mathbf{x} \in \mathbb{F}^n$ （回想一下， $\mathbb{F}$ 是指 $\mathbb{R}$ 或 $\mathbb{C}$ ）写为 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 。如果我们将列向量竖着写，那么其占据的空间就会大大增加。

习题

- 1.1. 令 $\mathbf{x} = (1, 2, 3)^T$, $\mathbf{y} = (y_1, y_2, y_3)^T$, $\mathbf{z} = (4, 2, 1)^T$. 计算 $2\mathbf{x}$, $3\mathbf{y}$, $\mathbf{x} + 2\mathbf{y} - 3\mathbf{z}$.
- 1.2. 下面哪些集合（具有自然的加法和标量乘法运算）是向量空间？论证你的回答。
 - a) 所有区间 $[0, 1]$ 上的连续函数所成的集合；
 - b) 所有区间 $[0, 1]$ 上的非负函数所成的集合；
 - c) 所有次数**恰**为 n 的多项式所成的集合；
 - d) 所有 $n \times n$ 对称矩阵所成的集合，即所有满足 $A^T = A$ 的矩阵 $A = \{a_{j,k}\}_{j,k=1}^n$ 所成的集合。
- 1.3. 判断正误：
 - a) 每个向量空间都包含零向量；
 - b) 一向量空间可包含多个零向量；

- c) $m \times n$ 矩阵有 m 行 n 列;
- d) 若 f 和 g 是次数为 n 的多项式, 那么 $f + g$ 也是次数为 n 的多项式;
- e) 若 f 和 g 是次数至多为 n 的多项式, 那么 $f + g$ 也是次数至多为 n 的多项式.

- 1.4. 证明: 向量空间 V 的零向量 $\mathbf{0}$ 唯一.
- 1.5. 向量空间 $M_{2 \times 3}$ 的零向量是何矩阵?
- 1.6. 证明: 向量空间公理 4 所定义的加法逆元是唯一的.
- 1.7. 证明: $0\mathbf{v} = \mathbf{0}$ 对于所有向量 $\mathbf{v} \in V$ 都成立.
- 1.8. 证明: 对于所有向量 $\mathbf{v}$, 其加法逆元 $-\mathbf{v}$ 由 $(-1)\mathbf{v}$ 给出.

2. 线性组合、基

令 V 为一向量空间, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 为一系列向量. 向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 的**线性组合**是形式如下的求和式:

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_p \mathbf{v}_p = \sum_{k=1}^p \alpha_k \mathbf{v}_k.$$

定义 2.1. 称一组向量² $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n \in V$ 为 (向量空间 V 的) **基**, 若任意向量 $\mathbf{v} \in V$ 都能被**唯一**写成线性组合的形式:

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_n \mathbf{v}_n = \sum_{k=1}^n \alpha_k \mathbf{v}_k.$$

系数 $\alpha_1, \alpha_2, \dots, \alpha_n$ 称为向量 $\mathbf{v}$ (在基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 下, 或者说关于基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$) 的**坐标**.

$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是基的另一种表述是, 方程 $x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \dots + x_n \mathbf{v}_n = \mathbf{v}$ (未知数为各 x_k) 对于任意右端项 $\mathbf{v}$ 皆有唯一解.

在讨论基的性质之前, 首先给出一些例子来说明“基”这种对象确实存在, 并且研究它们是有意义的.

例 2.2. 在这第一个例子当中, 向量空间 V 等于 $\mathbb{F}^n$, 其中 $\mathbb{F}$ 是 $\mathbb{R}$ 或 $\mathbb{C}$. 考虑向量

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \quad \mathbf{e}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \dots, \quad \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix},$$

²原书对于若干向量有两种表达: “a system of vectors” 和 “a set of vectors”, 此处一律采用国内通行翻译“向量组”. ——译者注

(向量 $\mathbf{e}_k$ 除第 k 项为 1 外, 其余各项均为 0).

向量组 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{F}^n$ 的基. 的确, 任意向量

$$\mathbf{v} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{F}^n$$

都能被表示成线性组合

$$\mathbf{v} = x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \dots + x_n\mathbf{e}_n = \sum_{k=1}^n x_k\mathbf{e}_k$$

且该表示唯一. 向量组 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n \in \mathbb{F}^n$ 称为 $\mathbb{F}^n$ 的**标准基**.

例 2.3. 本例中考虑的是次数至多为 n 的多项式所构成的向量空间 $\mathbb{P}_n$.

考虑定义如下的向量 (多项式) $\mathbf{e}_0, \mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n \in \mathbb{P}_n$

$$\mathbf{e}_0 := 1, \quad \mathbf{e}_1 := t, \quad \mathbf{e}_2 := t^2, \quad \mathbf{e}_3 := t^3, \quad \dots, \quad \mathbf{e}_n := t^n.$$

显然, 对任意多项式 p , $p(t) = a_0 + a_1t + a_2t^2 + \dots + a_nt^n$, 其均能被唯一表示为

$$p = a_0\mathbf{e}_0 + a_1\mathbf{e}_1 + \dots + a_n\mathbf{e}_n.$$

因此向量组 $\mathbf{e}_0, \mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n \in \mathbb{P}_n$ 是 $\mathbb{P}_n$ 的基. 我们称其为 $\mathbb{P}_n$ 的**标准基**.

这个注记很重要, 整本书都会用到它. 它使我们得以将适用于标准向量空间 $\mathbb{F}^n$ 的各种表述迁移至具有基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的向量空间 V .

注 2.4. 若向量空间 V 有基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 那么任意向量 $\mathbf{v}$ 都能被线性组合式 $\mathbf{v} = \sum_{k=1}^n \alpha_k \mathbf{v}_k$ 中的系数唯一决定. 因此, 如果我们将各系数 α_k 写在一列中, 那么我们处理任意向量就如同处理列向量一样, 也就是如同处理 $\mathbb{F}^n$ 中的元素一样 (此处 $\mathbb{F}$ 仍然代表 $\mathbb{R}$ 或 $\mathbb{C}$, 不过此处的结论对于任意的域 $\mathbb{F}$ 也是成立的).

这就是说, 若 $\mathbf{v} = \sum_{k=1}^n \alpha_k \mathbf{v}_k$ 且 $\mathbf{w} = \sum_{k=1}^n \beta_k \mathbf{v}_k$, 则

$$\mathbf{v} + \mathbf{w} = \sum_{k=1}^n \alpha_k \mathbf{v}_k + \sum_{k=1}^n \beta_k \mathbf{v}_k = \sum_{k=1}^n (\alpha_k + \beta_k) \mathbf{v}_k,$$

即为了得到求和结果的坐标所构成的列向量, 只需将各求和项的坐标所构成的列向量相加. 类似地, 为了得到 $\alpha\mathbf{v}$ 的坐标, 我们只需将 $\mathbf{v}$ 的坐标所构成的列向量乘以 α .

2.1. 生成组与线性无关组

基的定义中说到, 任意向量都能被唯一表示成基向量的线性组合. 这个说法其实包含两方面: 一是表达式存在, 二是表达式唯一. 让我们分开来分析这两个方面.

如果我们只考虑存在性，我们就得到下面的概念：

定义 2.5. 称一组向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 为 V 中的生成组（也称为**张成组**或**完备组**），若任意向量 $\mathbf{v} \in V$ 都能被写成线性组合的形式：

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_p \mathbf{v}_p = \sum_{k=1}^p \alpha_k \mathbf{v}_k.$$

该定义与基的定义的唯一区别在于，我们并不假设上述表示唯一。

此处**生成**、**张成**和**完备**是同义词。我本人更喜欢“完备”这个词，这是由于我在算子理论方面的专业背景。“生成”和“张成”则更经常用于线性代数教材中。

显然，任一基都是张成（完备）向量组。并且，如果我们向基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 中加入若干向量 $\mathbf{v}_{n+1}, \dots, \mathbf{v}_p$ ，那么新的向量组是张成（完备）向量组。的确如此：我们可以将任意向量表示成 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的线性组合，并直接忽略新加入的向量（取对应的系数 $\alpha_k = 0$ ）。

现在，让我们将注意力转向唯一性。我们不想产生存在性方面的顾虑，因此我们考虑零向量 $\mathbf{0}$ ，其总是能够以线性组合式表出。

定义. 称线性组合 $\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_p \mathbf{v}_p$ 是**平凡的**，若 $\alpha_k = 0 \forall k$ 。

平凡的线性组合总等于 $\mathbf{0}$ （无论向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 是什么），这可能也是其名称的来历。

定义. 称一组向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 为**线性无关的**，若 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 只有平凡线性组合（ $\sum_{k=1}^p \alpha_k \mathbf{v}_k$ ，其中 $\alpha_k = 0 \forall k$ ）等于 $\mathbf{0}$ 。

换言之，向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 是线性无关的，当且仅当方程 $x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \dots + x_p \mathbf{v}_p = \mathbf{0}$ （未知数为 x_k ）仅有平凡解（ $x_1 = x_2 = \dots = x_p = 0$ ）。

若一向量组不是线性无关的，就称其为**线性相关的**。通过取线性无关定义的否定，我们得到以下定义：

定义. 称一组向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 为**线性相关的**，若 $\mathbf{0}$ 可被表示为非平凡的线性组合 $\mathbf{0} = \sum_{k=1}^p \alpha_k \mathbf{v}_k$ 。此处的“非平凡”是指至少一个系数 α_k 是非零的。这可以写为（也通常表示为） $\sum_{k=1}^p |\alpha_k| \neq 0$ 。

换种方式表述该定义，我们可以说，向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 是线性相关的，当且仅当存在标量 $\alpha_1, \alpha_2, \dots, \alpha_p$ 且 $\sum_{k=1}^p |\alpha_k| \neq 0$ 使得

$$\sum_{k=1}^p \alpha_k \mathbf{v}_k = \mathbf{0}.$$

还有一种定义 (以方程的语言表述) 是: 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 是线性相关的, 当且仅当方程

$$x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \dots + x_p \mathbf{v}_p = \mathbf{0}$$

(未知数为 x_k) 有非平凡解. 此处的“非平凡”还是指至少一个 x_k 是非零的, 并可写作 $\sum_{k=1}^p |x_k| \neq 0$.

以下命题给出了线性相关组的又一种描述.

命题 2.6. 一组向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 是线性相关的, 当且仅当其中有一向量 $\mathbf{v}_k$ 可被表示成其他向量的线性组合

$$(2.1) \quad \mathbf{v}_k = \sum_{\substack{j=1 \\ j \neq k}}^p \beta_j \mathbf{v}_j.$$

证明: 假设向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 是线性相关的. 那么存在标量 α_k , $\sum_{k=1}^p |\alpha_k| \neq 0$ 使得

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_p \mathbf{v}_p = \mathbf{0}.$$

令 k 为使得 $\alpha_k \neq 0$ 的下标. 于是, 将除了 $\alpha_k \mathbf{v}_k$ 之外的项移到右端可得

$$\alpha_k \mathbf{v}_k = - \sum_{\substack{j=1 \\ j \neq k}}^p \alpha_j \mathbf{v}_j.$$

将两边都除以 α_k 可得式 (2.1), 其中 $\beta_j = -\alpha_j / \alpha_k$.

另一方面, 若 (2.1) 成立, 那么 $\mathbf{0}$ 可被表示为非平凡线性组合

$$\mathbf{v}_k - \sum_{\substack{j=1 \\ j \neq k}}^p \beta_j \mathbf{v}_j = \mathbf{0}.$$

□

显然, 任一基都是线性无关组. 的确如此: 若向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是基, 那么 $\mathbf{0}$ 可被唯一表示为

$$\mathbf{0} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_n \mathbf{v}_n = \sum_{k=1}^n \alpha_k \mathbf{v}_k.$$

由于 $\mathbf{0}$ 总可被平凡线性组合表出, 所以平凡线性组合必为**唯一**线性表出 $\mathbf{0}$ 的方法.

在许多教材中, 基被定义为既完备又线性无关的向量组. 由命题 2.7, 这种定义和本书的定义是等价的.

所以, 如我们已经讨论的, 若一向量组是基, 则其是完备 (生成) 组, 也是线性无关组. 下面命题表明, 这句话反过来也是成立的.

命题 2.7. 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n \in V$ 是基, 当且仅当其既是完备 (生成) 组又线性无关.

证明: 我们已经知道基一定是既完备又线性无关的, 所以该命题的一个方向已经得证了.

让我们证明另一个方向. 设向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是线性无关且完备的. 取任意向量 $\mathbf{v} \in V$. 因为向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是完备 (生成) 组, 因此 $\mathbf{v}$ 可表示为

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_n \mathbf{v}_n = \sum_{k=1}^n \alpha_k \mathbf{v}_k.$$

我们只需证明此表达式是唯一的.

设 $\mathbf{v}$ 还可被表示为

$$\mathbf{v} = \sum_{k=1}^n \tilde{\alpha}_k \mathbf{v}_k.$$

那么

$$\sum_{k=1}^n (\alpha_k - \tilde{\alpha}_k) \mathbf{v}_k = \sum_{k=1}^n \alpha_k \mathbf{v}_k - \sum_{k=1}^n \tilde{\alpha}_k \mathbf{v}_k = \mathbf{v} - \mathbf{v} = \mathbf{0}.$$

因为该组是线性无关的, 所以 $\alpha_k - \tilde{\alpha}_k = 0 \forall k$, 从而表达式 $\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_n \mathbf{v}_n$ 唯一. $\square$

注. 在许多教材中, 基被定义为既完备又线性无关的向量组 (由命题 2.7, 这种定义和本书的定义是等价的). 尽管这种定义比本书所示的定义更为常见, 我还是更喜欢后者. 它强调了基的主要性质, 即任意向量都能被基向量的线性组合唯一表出.

命题 2.8. 任意 (有限) 生成组包含一个基.

证明: 设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p \in V$ 是生成 (完备) 组. 若它是线性无关的, 它就是基, 则我们已经达成目标.

设它不是线性无关的, 即它是线性相关的. 那么存在向量 $\mathbf{v}_k$, 其可被表示为向量 $\mathbf{v}_j, j \neq k$ 的线性组合.

因为 $\mathbf{v}_k$ 可被表示为向量 $\mathbf{v}_j, j \neq k$ 的线性组合, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_p$ 的任意线性组合都可被除了 $\mathbf{v}_k$ 之外的向量 (即 $\mathbf{v}_j, 1 \leq j \leq p, j \neq k$) 的线性组合表示. 因此, 如果我们去除向量 $\mathbf{v}_k$, 新向量组将仍是完备的.

若新向量组是线性无关的, 那么我们达成了目标. 若仍不是, 则重复上述过程.

在重复上述过程有限多次后, 我们必得到一线性无关且完备的向量组, 否则我们会删除所有向量并且得到空组了.

因此, 任意有限的完备 (生成) 组都包含一完备的线性无关子集, 也就是基. $\square$

习题

- 2.1. 求出 3×2 矩阵所成的向量空间 $M_{3 \times 2}$ 的基.
- 2.2. 判断正误:
 - a) 任意包含零向量的向量组都是线性相关的;
 - b) 基必包含 $\mathbf{0}$;
 - c) 线性相关向量集合的子集是线性相关的;
 - d) 线性无关向量集合的子集是线性无关的;
 - e) 若 $\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_n \mathbf{v}_n = \mathbf{0}$, 那么所有标量 α_k 都为零.
- 2.3. 回想一下, 称矩阵 A 是对称的, 若 $A^T = A$. 写出由 2×2 对称矩阵所构成的向量空间的一个基 (有很多可能的答案). 该基中包含几个元素?
- 2.4. 写出由下列元素构成的空间的基:
 - a) 3×3 对称矩阵;
 - b) $n \times n$ 对称矩阵;
 - c) $n \times n$ 反对称矩阵 ($A^T = -A$).
- 2.5. 设向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是线性无关的, 但不是生成组. 证明: 可以找到向量 $\mathbf{v}_{r+1}$ 使得向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r, \mathbf{v}_{r+1}$ 是线性无关的. 提示: 取 $\mathbf{v}_{r+1}$ 为任一无法被表示为线性组合 $\sum_{k=1}^r \alpha_k \mathbf{v}_k$ 的向量, 再证明向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r, \mathbf{v}_{r+1}$ 是线性无关的.
- 2.6. 是否可能出现这样的情况: 向量 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 是线性相关的, 但向量 $\mathbf{w}_1 = \mathbf{v}_1 + \mathbf{v}_2, \mathbf{w}_2 = \mathbf{v}_2 + \mathbf{v}_3$ 与 $\mathbf{w}_3 = \mathbf{v}_3 + \mathbf{v}_1$ 是线性无关的?

3. 线性变换、矩阵-向量乘法

“变换”、“映射”、“算子”、“函数”都是指同类对象.³ 从集合 X 到集合 Y 的变换 T 是一种对应关系, 将任意自变量 (输入) $x \in X$ 对应到一值 (输出) $y = T(x) \in Y$.

集合 X 称为 T 的定义域, 集合 Y 称为 T 的目标空间或陪域.

我们记 $T: X \rightarrow Y$ 表示 T 是定义域为 X 而目标空间为 Y 的变换.

定义 3.1. 令 V, W 为 (同一域 $\mathbb{F}$ 上的) 向量空间. 称变换 $T: V \rightarrow W$ 是线性的, 若

³一般来说, 算子的定义域和陪域一样. 本书有些地方的“算子”实为一般的变换, 翻译将予以区分. ——译者注

1. $T(\mathbf{u} + \mathbf{v}) = T(\mathbf{u}) + T(\mathbf{v}) \quad \forall \mathbf{u}, \mathbf{v} \in V$;
2. $T(\alpha \mathbf{v}) = \alpha T(\mathbf{v})$ 对所有 $\mathbf{v} \in V$ 和所有标量 $\alpha \in \mathbb{F}$ 都成立.

性质 1、2 合起来等价于下面说法：

对于所有标量 α, β 和所有 $\mathbf{u}, \mathbf{v} \in V$ ，有 $T(\alpha \mathbf{u} + \beta \mathbf{v}) = \alpha T(\mathbf{u}) + \beta T(\mathbf{v})$.

3.1. 例子

你之前已经和线性变换打过交道了——可能你还未曾意识到这一点. 请看下面示出的例子.

例. 微分：令 $V = \mathbb{P}_n$ (次数至多为 n 的多项式所成的集合), $W = \mathbb{P}_{n-1}$, 并令 $T: \mathbb{P}_n \rightarrow \mathbb{P}_{n-1}$ 为微分算子

$$T(p) := p' \quad \forall p \in \mathbb{P}_n.$$

因为 $(f + g)' = f' + g'$ 且 $(\alpha f)' = \alpha f'$ ，所以这是一个线性变换.

例. 旋转：在本例中 $V = W = \mathbb{R}^2$ (即通常的坐标平面), 变换 $T_\gamma: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 将 $\mathbb{R}^2$ 中的向量逆时针旋转 γ 弧度. 因为 T_γ 是将平面整体做旋转, 所以它会将用于定义两向量之和 (平行四边形法则) 的平行四边形整体做旋转 (见图). 因此, 其满足线性变换的性质 1. 容易看出, 性质 2 也是成立的.




图 1 旋转

例. 反射: 在本例中 $V = W = \mathbb{R}^2$, 变换 $T_\gamma: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 是关于第一轴的反射. 可以从几何的角度证明该变换为线性的, 但我们将用另一种方法来证明.

方法是: 写出 T 的表达式

$$T\left(\begin{pmatrix} x_1 \\ x_2 \end{pmatrix}\right) = \begin{pmatrix} x_1 \\ -x_2 \end{pmatrix}$$

根据该式, 我们很容易检验该变换是线性的.

例. 考察线性变换 $T: \mathbb{R} \rightarrow \mathbb{R}$. 任一此类变换都由下式给出

$$T(x) = ax \quad \text{其中 } a = T(1).$$

的确如此:

$$T(x) = T(x \times 1) = xT(1) = xa = ax.$$

因此, $\mathbb{R}$ 上的任一线性变换仅仅是与常数的乘法.

3.2. $\mathbb{F}^n \rightarrow \mathbb{F}^m$ 的线性变换、矩阵-列向量乘法

线性变换 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 也可用一乘法表示, 不过不是与标量相乘, 而是与矩阵相乘.

我们来看看是如何乘的. 令 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 为一线性变换. 为了对所有向量 $\mathbf{x} \in \mathbb{F}^n$ 计算 $T(\mathbf{x})$, 我们需要什么信息呢? 我的观点是, 知道 T 作用于 $\mathbb{F}^n$ 的标准基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 的结果就足够了. 也即, 知道 $\mathbb{F}^m$ 中的这 n 个向量 (即若干长度为 m 的向量) 就足够了:

$$\mathbf{a}_1 := T(\mathbf{e}_1), \quad \mathbf{a}_2 := T(\mathbf{e}_2), \quad \dots, \quad \mathbf{a}_n := T(\mathbf{e}_n).$$

的确如此: 令

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}.$$

那么 $\mathbf{x} = x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \dots + x_n\mathbf{e}_n = \sum_{k=1}^n x_k\mathbf{e}_k$, 且有

$$T(\mathbf{x}) = T\left(\sum_{k=1}^n x_k\mathbf{e}_k\right) = \sum_{k=1}^n T(x_k\mathbf{e}_k) = \sum_{k=1}^n x_k T(\mathbf{e}_k) = \sum_{k=1}^n x_k \mathbf{a}_k.$$

因此, 如果我们将列向量 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ 一起放入一矩阵 $A = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n]$ ($\mathbf{a}_k$ 是 A 的第 k 列, $k = 1, 2, \dots, n$), 该矩阵就包含了 T 的所有信息.

下面我们说明如何定义矩阵和列向量的乘积才能将变换 T 表示为乘积 $T(\mathbf{x}) = A\mathbf{x}$. 令

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{m,1} & a_{m,2} & \cdots & a_{m,n} \end{pmatrix}.$$

回想一下, A 的第 k 列是向量 $\mathbf{a}_k$, 即

$$\mathbf{a}_k = \begin{pmatrix} a_{1,k} \\ a_{2,k} \\ \vdots \\ a_{m,k} \end{pmatrix}.$$

于是, 如果我们要使 $A\mathbf{x} = T(\mathbf{x})$, 我们就有

$$A\mathbf{x} = \sum_{k=1}^n x_k \mathbf{a}_k = x_1 \begin{pmatrix} a_{1,1} \\ a_{2,1} \\ \vdots \\ a_{m,1} \end{pmatrix} + x_2 \begin{pmatrix} a_{1,2} \\ a_{2,2} \\ \vdots \\ a_{m,2} \end{pmatrix} + \cdots + x_n \begin{pmatrix} a_{1,n} \\ a_{2,n} \\ \vdots \\ a_{m,n} \end{pmatrix}.$$

因此, 矩阵-向量乘法应该按照下述“**列乘以坐标**”法则来进行:

将矩阵的各列与向量的对应坐标相乘.

例.

$$\begin{pmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = 1 \begin{pmatrix} 1 \\ 3 \end{pmatrix} + 2 \begin{pmatrix} 2 \\ 2 \end{pmatrix} + 3 \begin{pmatrix} 3 \\ 1 \end{pmatrix} = \begin{pmatrix} 14 \\ 10 \end{pmatrix}.$$

“列乘以坐标”法则很适于并行计算, 在之后的一些理论推导中也很重要.

不过, 当手工进行计算时, 逐项计算更为方便. 这种计算可按以下“**行乘以列**”法则来进行:

要得到结果的第 k 项, 我们需要将矩阵的第 k 行与向量相乘. 也就是说, 若 $A\mathbf{x} = \mathbf{y}$, 那么 $y_k = \sum_{j=1}^n a_{k,j}x_j, k = 1, 2, \dots, m$.

此处 x_j 和 y_k 分别是向量 $\mathbf{x}$ 和 $\mathbf{y}$ 的坐标, $a_{j,k}$ 则为矩阵 A 的项.

例.

$$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \cdot 1 + 2 \cdot 2 + 3 \cdot 3 \\ 4 \cdot 1 + 5 \cdot 2 + 6 \cdot 3 \end{pmatrix} = \begin{pmatrix} 14 \\ 32 \end{pmatrix}$$

3.3. 线性变换与生成组

我们上面讨论过, 从 $\mathbb{F}^n$ 到 $\mathbb{F}^m$ 的线性变换 T 完全决定于其在 $\mathbb{F}^n$ 的标准基上的取值.

其实, 我们并不一定要考虑标准基, 而是可以考虑任意的基, 甚至可以考虑任意生成 (张成) 组. 即

线性变换 $T: V \rightarrow W$ 完全由其在生成组上的取值所决定 (特别地, 由其在基上的取值所决定).

所以, 若 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 中的生成组 (特别地, 若其是 V 的基), 并且 T 与 T_1 是线性变换, $T, T_1: V \rightarrow W$, 使得

$$T\mathbf{v}_k = T_1\mathbf{v}_k, \quad k = 1, 2, \dots, n$$

那么 $T = T_1$.

此结论的证明很简单, 留作习题.

3.4. 结论

- 要得到线性变换 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 的矩阵, 我们需要将向量 $\mathbf{a}_k = T\mathbf{e}_k$ (其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{F}^n$ 的标准基) 组合成一个矩阵: 该矩阵的第 k 列是 $\mathbf{a}_k, k = 1, 2, \dots, n$.
- 若线性变换 T 的矩阵 A 是已知的, 那么 $T(\mathbf{x})$ 能通过矩阵-向量乘法 $T(\mathbf{x}) = A\mathbf{x}$ 求出. 矩阵-向量乘法可用“列乘以坐标”或“行乘以列”法则来运算.

后者更适于手工运算, 而前者更适用于并行计算机且将被用于各种理论推导中.

对线性变换 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$, 其矩阵常记作 $[T]$. 不过, 人们往往不区分线性变换及其矩阵, 并常对两者用相同的记号. 不致混淆时, 我们也会用同样的符号来表示线性变换和其矩阵.

因为线性变换本质上就是乘法, 因此常用记号 $T\mathbf{v}$ 而不是 $T(\mathbf{v})$ 表示. 我们也会用前者. 注意, 代数运算的一般顺序仍然适用, 也即, $T\mathbf{v} + \mathbf{u}$ 意为 $T(\mathbf{v}) + \mathbf{u}$, 而非 $T(\mathbf{v} + \mathbf{u})$.

注. 在矩阵-向量乘法 $A\mathbf{x}$ 中, 矩阵 A 的列数必须与向量 $\mathbf{x}$ 的长度相同, 即 $\mathbb{F}^n$ 中的向量只能被 $m \times n$ 矩阵所乘.

这是合理的, 因为 $m \times n$ 矩阵定义了 $\mathbb{F}^n \rightarrow \mathbb{F}^m$ 的线性变换, 所以向量 $\mathbf{x}$ 必须属于 $\mathbb{F}^n$.

记住这一点的最简单方法，就是记住如果在做乘法的时候有某种元素先被用光了，那么此乘法就是未定义的。例如，如果用“行乘以列”法则时，你将矩阵的行中各项都用尽了，而列向量中的项仍有未用到的，那么所做的乘法就是未定义的。同样，如果你先用尽列向量中的项，而矩阵的行中各项尚有未用到的，那么该乘法也是未定义的。

在用“行乘以列”法则计算矩阵-向量乘法时，确保矩阵的行中的项数和列向量中的项数相同。行中的项和列向量中的项应该被同时用尽；否则所做的乘法未定义。

注. 不要将自己束缚在 $\mathbb{R}^n$ 及其标准基的情形中：本节陈述的所有内容适用于任意向量空间之间的线性变换——只要定义域和目标空间中都有基。当然，如果基改变了，那么线性变换的矩阵也会相应变化。这将在第2章第8节中讨论。

习题

3.1. 做乘法：

$$\begin{aligned} \text{a)} & \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \\ 2 \end{pmatrix}; \\ \text{b)} & \begin{pmatrix} 1 & 2 \\ 0 & 1 \\ 2 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 3 \end{pmatrix}; \\ \text{c)} & \begin{pmatrix} 1 & 2 & 0 & 0 \\ 0 & 1 & 2 & 0 \\ 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}; \\ \text{d)} & \begin{pmatrix} 1 & 2 & 0 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix}. \end{aligned}$$

3.2. 设 $\mathbb{R}^2$ 上的线性变换为关于直线 $x_1 = x_2$ 的反射。求其矩阵。

3.3. 对于下述线性变换，求其矩阵：

- $T: \mathbb{R}^2 \rightarrow \mathbb{R}^3$, 定义为 $T(x, y)^T = (x + 2y, 2x - 5y, 7y)^T$;
- $T: \mathbb{R}^4 \rightarrow \mathbb{R}^3$, 定义为 $T(x_1, x_2, x_3, x_4)^T = (x_1 + x_2 + x_3 + x_4, x_2 - x_4, x_1 + 3x_2 + 6x_4)^T$;
- $T: \mathbb{P}_n \rightarrow \mathbb{P}_n, Tf(t) = f'(t)$ (求其关于标准基 $1, t, t^2, \dots, t^n$ 的矩阵);
- $T: \mathbb{P}_n \rightarrow \mathbb{P}_n, Tf(t) = 2f(t) + 3f'(t) - 4f''(t)$ (仍求其关于标准基 $1, t, t^2, \dots, t^n$ 的矩阵)。

3.4. 求出表示下列 $\mathbb{R}^3$ 上的线性变换的 3×3 矩阵：

- 将所有向量投影至 x - y 平面；
- 将所有向量关于 x - y 平面反射；
- 将 x - y 平面旋转 30° ，并保持 z 轴不变。

3.5. 令 A 为线性变换。若 $\mathbf{z}$ 是直线区间 $[\mathbf{x}, \mathbf{y}]$ 的中点，证明： $A\mathbf{z}$ 是区间 $[A\mathbf{x}, A\mathbf{y}]$ 的中点。提示：“ $\mathbf{z}$ 是区间 $[\mathbf{x}, \mathbf{y}]$ 的中点”意味着什么？

3.6. 复数集合 $\mathbb{C}$ 可与向量空间 $\mathbb{R}^2$ 自然对应——视任一 $z = x + iy \in \mathbb{C}$ 为列向量 $(x, y)^T \in \mathbb{R}^2$.

- 视 $\mathbb{C}$ 为复向量空间，证明与 $\alpha = a + ib \in \mathbb{C}$ 的乘法是 $\mathbb{C}$ 上的线性变换. 该变换的矩阵是什么？
- 视 $\mathbb{C}$ 为实向量空间 $\mathbb{R}^2$ ，证明与 $\alpha = a + ib$ 的乘法是其上的线性变换. 该变换的矩阵是什么？
- 定义 $T(x + iy) = 2x - y + i(x - 3y)$. 证明：该变换不是复向量空间 $\mathbb{C}$ 上的线性变换，但如果我们把 $\mathbb{C}$ 视为实向量空间 $\mathbb{R}^2$ ，那么该变换是其上的线性变换（即 T 是实线性变换而非复线性变换）. 求出该实线性变换 T 的矩阵.

3.7. 证明： $\mathbb{C}$ （视为复向量空间）中的任意线性变换都是与 $\alpha \in \mathbb{C}$ 的乘法.

4. 线性变换作为向量空间的元素

我们可以对线性变换做什么运算呢？我们总可以将线性变换乘以一标量，也即，设有线性变换 $T: V \rightarrow W$ 与标量 α ，我们可定义一新的变换 αT 为

$$(\alpha T)\mathbf{v} = \alpha(T\mathbf{v}) \quad \forall \mathbf{v} \in V.$$

容易检验， αT 亦为线性变换：

$$\begin{aligned} (\alpha T)(\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2) &= \alpha(T(\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2)) \quad \text{由 } \alpha T \text{ 的定义} \\ &= \alpha(\alpha_1 T\mathbf{v}_1 + \alpha_2 T\mathbf{v}_2) \quad \text{由 } T \text{ 的线性} \\ &= \alpha_1 \alpha T\mathbf{v}_1 + \alpha_2 \alpha T\mathbf{v}_2 = \alpha_1 (\alpha T)\mathbf{v}_1 + \alpha_2 (\alpha T)\mathbf{v}_2 \end{aligned}$$

若 T_1 和 T_2 是具有相同的定义域和目标空间的线性变换 ($T_1: V \rightarrow W$ 并且 $T_2: V \rightarrow W$ ，或者简写作 $T_1, T_2: V \rightarrow W$)，那么我们可以将这两个线性变换相加，并定义新的变换 $T = (T_1 + T_2): V \rightarrow W$ 为

$$(T_1 + T_2)\mathbf{v} = T_1\mathbf{v} + T_2\mathbf{v} \quad \forall \mathbf{v} \in V.$$

容易检验，变换 $T_1 + T_2$ 也是线性的——只需重复上面用于说明 αT 之线性的推理过程即可.

所以，如果我们固定向量空间 V 和 W ，并且考虑所有从 V 到 W 的线性变换所成的集合（将其记为 $\mathcal{L}(V, W)$ ），那么我们可以在 $\mathcal{L}(V, W)$ 上定义两种运算：标量乘法和加法. 容易证明，这些运算符合向量空间的所有公理——见第 1 节.

读者应该不会对此感到意外，因为向量空间的公理本质上意味着向量的运算符合代数的一般规则，而线性变换的运算的定义天然满足这些规则！

作为演示，我们写出向量空间第一条分配性质（公理 7）的正式证明。待证命题是 $\alpha(T_1 + T_2) = \alpha T_1 + \alpha T_2$ 。对任意 $\mathbf{v} \in V$ 都有

$$\begin{aligned}\alpha(T_1 + T_2)\mathbf{v} &= \alpha((T_1 + T_2)\mathbf{v}) \quad \text{由乘法的定义} \\ &= \alpha(T_1\mathbf{v} + T_2\mathbf{v}) \quad \text{由加法的定义} \\ &= \alpha T_1\mathbf{v} + \alpha T_2\mathbf{v} \quad \text{由 } W \text{ 的公理 7} \\ &= (\alpha T_1 + \alpha T_2)\mathbf{v} \quad \text{由加法的定义}\end{aligned}$$

因此，的确有 $\alpha(T_1 + T_2) = \alpha T_1 + \alpha T_2$ 。

注. 适用于线性变换 $T: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 的线性运算（加法和标量乘法）与适用于其矩阵的运算相对应。因为我们知道 $m \times n$ 矩阵所成的集合是向量空间，所以立刻可知 $\mathcal{L}(\mathbb{F}^n, \mathbb{F}^m)$ 是向量空间。

上面我们演示了抽象的证明，原因之一是其适用于一般的空间（例如，不存在基的空间，这种情况我们无法利用坐标来处理），原因之二则是类似于此处抽象证明的推理过程会在许多场合被用到，因此理解它对于读者而言是有益的。

并且，随着读者愈来愈精通数学，他/她将发现此处的抽象推理其实非常简单——几乎是不假思索就能做出。

5. 线性变换的复合与矩阵乘法

5.1. 矩阵乘法的定义

在了解矩阵-向量乘法后，很容易猜出两矩阵乘积 AB 的一种自然的定义方式：将 B 的各列乘以 A （用矩阵-向量乘法），再将所得各列向量组成矩阵。正式而言，

若 B 的各列是 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_r$ ，那么 $A\mathbf{b}_1, A\mathbf{b}_2, \dots, A\mathbf{b}_r$ 是矩阵 AB 的各列。

回忆矩阵-向量乘法的“行乘以列”规则，我们得到了下述矩阵的“行乘以列”规则：

乘积 AB 的项 $(AB)_{j,k}$ （第 j 行第 k 列中的项）定义为

$$(AB)_{j,k} = (A \text{ 的第 } j \text{ 行}) \cdot (B \text{ 的第 } k \text{ 列})$$

正式而言，其可写为

$$(AB)_{j,k} = \sum_l a_{j,l} b_{l,k},$$

其中 $a_{j,k}$ 和 $b_{j,k}$ 分别表示矩阵 A 和 B 的项.

我特地没说明矩阵 A 和 B 的大小, 但是如果我们回想一下矩阵-向量乘法的“行乘以列”规则, 我们就能看出, 如果一个乘积是有定义的, 那么 A 的行的长度应该等于 B 的列的长度.

换言之, 乘积 AB 是有定义的, 当且仅当 A 是 $m \times n$ 矩阵且 B 是 $n \times r$ 矩阵.

5.2. 缘起: 线性变换的复合

这里, 我们不妨问问自己: 为什么要用如此复杂的方式定义乘法呢? 为什么我们不直接将矩阵逐项相乘呢?

回答是: 定义如上的这种乘法, 是从线性变换的复合中自然产生的.

假设我们有两个线性变换 $T_1: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 和 $T_2: \mathbb{F}^r \rightarrow \mathbb{F}^n$. 定义线性变换 T_1, T_2 的复合 $T = T_1 \circ T_2$ 为

$$T(\mathbf{x}) = T_1(T_2(\mathbf{x})) \quad \forall \mathbf{x} \in \mathbb{F}^r.$$

注意 $T_2(\mathbf{x}) \in \mathbb{F}^n$. 由于 $T_1: \mathbb{F}^n \rightarrow \mathbb{F}^m$, 所以表达式 $T_1(T_2(\mathbf{x}))$ 是定义完善的, 且变换后的结果属于 $\mathbb{F}^m$. 因此 $T: \mathbb{F}^r \rightarrow \mathbb{F}^m$.

我们通常会把线性变换与其矩阵等同起来看, 不过在下面几段中我们会将它们区分开.

容易证明, T 是线性变换 (留作习题), 因此其由一 $m \times r$ 矩阵所确定. 如何在已知 T_1 和 T_2 的矩阵的情况下求出这个矩阵呢?

令 A 是 T_1 的矩阵, B 是 T_2 的矩阵. 在之前的小节中我们讨论过, T 的各列是向量 $T(\mathbf{e}_1), T(\mathbf{e}_2), \dots, T(\mathbf{e}_r)$, 其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_r$ 是 $\mathbb{F}^r$ 的标准基. 对 $k = 1, 2, \dots, r$ 我们有

$$T(\mathbf{e}_k) = T_1(T_2(\mathbf{e}_k)) = T_1(B\mathbf{e}_k) = T_1(\mathbf{b}_k) = A\mathbf{b}_k$$

(变换 T_2 和 T_1 分别是与 B 和 A 做乘法)

因此, T 的矩阵各列是 $A\mathbf{b}_1, A\mathbf{b}_2, \dots, A\mathbf{b}_r$, 而这就是矩阵 AB 的定义!

我们重新将线性变换与其矩阵等同起来看. 由于矩阵乘法与线性变换的复合是一致的, 我们可以 (并且将要) 用 $T_1 T_2$ 这种写法取代 $T_1 \circ T_2$, 并且用 $T_1 T_2 \mathbf{x}$ 这种写法取代 $T_1(T_2(\mathbf{x}))$.

注意: 变换的顺序!

注意, 在复合 $T_1 T_2$ 中, 首先作用的是变换 T_2 ! 记住这一点的方法是, 注意到在 $T_1 T_2 \mathbf{x}$ 中, 首先碰上 $\mathbf{x}$ 的是变换 T_2 .

注. 除“行乘以列”法则以外, 还有一种检验矩阵乘积中各矩阵大小的方法: 要使复合 T_1T_2 有定义, T_2x 必须属于 T_1 的定义域. 若 T_2 从某个空间 (比如说 $\mathbb{F}^r$) 映射到 $\mathbb{F}^n$, 那么 T_1 一定要从 $\mathbb{F}^n$ 映射到某个空间 (比如说 $\mathbb{F}^m$). 所以, 要使 T_1T_2 有定义, T_1 和 T_2 的矩阵的大小必须分别是 $m \times n$ 和 $n \times r$ ——这和我们由“行乘以列”法则所得到的条件是一样的.

例. 令 $T: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 是关于直线 $x_1 = 3x_2$ 的反射. 它是线性变换, 现在来求其矩阵. 要求这个矩阵, 我们需计算 Te_1 和 Te_2 . 然而, 直接计算 Te_1 和 Te_2 所需的三角学知识远远超出了一个正常人愿意记忆的范畴.

T 的矩阵的一个更为简便的求法是, 将 T 表示成若干简单线性变换的复合. 具体而言, 令 γ 为 x_1 轴和直线 $x_1 = 3x_2$ 之间的夹角, 并令 T_0 为沿 x_1 轴的反射. 那么, 要得到反射 T , 我们可以首先将平面旋转 $-\gamma$ 以将直线 $x_1 = 3x_2$ 转到 x_1 轴上, 然后将向量沿 x_1 轴反射, 最后将平面旋转 γ 以恢复原状. 正式而言, 这三步可以写成

$$T = R_\gamma T_0 R_{-\gamma}$$

(注意各项的顺序!) 其中 R_γ 表示旋转 γ 弧度. T_0 的矩阵很容易计算:

$$T_0 = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix},$$

而旋转矩阵是我们已知的:

$$R_\gamma = \begin{pmatrix} \cos \gamma & -\sin \gamma \\ \sin \gamma & \cos \gamma \end{pmatrix},$$

$$R_{-\gamma} = \begin{pmatrix} \cos(-\gamma) & -\sin(-\gamma) \\ \sin(-\gamma) & \cos(-\gamma) \end{pmatrix} = \begin{pmatrix} \cos \gamma & \sin \gamma \\ -\sin \gamma & \cos \gamma \end{pmatrix}$$

为计算 $\sin \gamma$ 和 $\cos \gamma$, 可在直线 $x_1 = 3x_2$ 上取一向量, 比如向量 $(3, 1)^T$. 那么

$$\cos \gamma = \frac{\text{第一个坐标}}{\text{长度}} = \frac{3}{\sqrt{3^2 + 1^2}} = \frac{3}{\sqrt{10}}$$

类似地

$$\sin \gamma = \frac{\text{第二个坐标}}{\text{长度}} = \frac{1}{\sqrt{3^2 + 1^2}} = \frac{1}{\sqrt{10}}$$

将上面这些组合起来可得

$$\begin{aligned} T = R_\gamma T_0 R_{-\gamma} &= \frac{1}{\sqrt{10}} \begin{pmatrix} 3 & -1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \frac{1}{\sqrt{10}} \begin{pmatrix} 3 & 1 \\ -1 & 3 \end{pmatrix} \\ &= \frac{1}{10} \begin{pmatrix} 3 & -1 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 3 & 1 \\ -1 & 3 \end{pmatrix} \end{aligned}$$

只需计算矩阵乘法, 即可得到最终结果.

5.3. 矩阵乘法的性质

矩阵乘法有许多性质，而这些性质我们在高中代数课就已熟悉：

1. 结合律： $A(BC) = (AB)C$ ——前提是左侧或右侧的乘积都是定义完善的。从而我们就能（并且将会）把这种情况简记作 ABC 。
2. 分配律： $A(B + C) = AB + AC$, $(A + B)C = AC + BC$ ——前提是左侧或右侧的乘积都是定义完善的。
3. 标量可以提出： $A(\alpha B) = (\alpha A)B = \alpha(AB) = \alpha AB$ 。

这些性质很容易证明。你应该证明线性变换的对应性质——由定义即很容易得到，然后再由线性变换的这些性质推出矩阵乘法的对应性质。

此处新出现的难点是，交换律不成立：

矩阵乘法是不可交换的，即一般来说 $AB \neq BA$ 。

容易看出，期望矩阵乘法的交换律成立是不合理的。的确如此：令 A 和 B 分别为 $m \times n$ 和 $n \times r$ 矩阵。那么乘积 AB 是定义完善的，但若 $m \neq r$ 则 BA 是未定义的。

即便两个乘积都有定义，比如说 A 和 B 都是 $n \times n$ 方阵的情况，乘法仍然不是可交换的。如果我们随机选择矩阵 A 和 B ，那么大概率 $AB \neq BA$ ，运气很好的时候才会恰巧得到 $AB = BA$ 的结果。

5.4. 转置矩阵与乘法

简单分析“行乘以列”规则可得

$$(AB)^T = B^T A^T,$$

即，当对乘积取转置时，需更改各项的顺序。⁴

5.5. 迹与矩阵乘法

对于方阵 ($n \times n$ 矩阵) $A = (a_{j,k})$ ，其迹（记为 $\text{trace } A$ ）是对角项之和：

$$\text{trace } A = \sum_{k=1}^n a_{k,k}.$$

定理 5.1. 令 A 和 B 分别为 $m \times n$ 和 $n \times m$ 矩阵（则乘积 AB 和 BA 都是定义完善的）。那么

$$\text{trace}(AB) = \text{trace}(BA)$$

⁴原书中本节的大多数内容在 1.2 节中已经陈述过了，此处将重复的部分略去。——译者注

此定理的证明留作习题（见下习题 5.6）。其实，这个定理有两种证法。第一种方法是计算 AB 与 BA 的对角项并比较两者的和。这种方法对于操作嵌套的求和有较高的要求。

如果你不擅长代数运算，还可用另一种方法。我们可以考虑两个从 $M_{n \times m}$ 到 $\mathbb{F} = \mathbb{F}^1$ 的线性变换 T 和 T_1 ，定义为：

$$T(X) = \text{trace}(AX), \quad T_1(X) = \text{trace}(XA)$$

只需证明 $T = T_1$ 即可得证——代入 $X = B$ 可得到原定理。

由于线性变换完全由其在生成组上的取值所决定，我们只需对一些简单的矩阵检验 $T = T_1$ ——比如考虑矩阵 $X_{j,k}$ ，其中除了第 j 列第 k 行的项为 1 外，其余各项均为 0。

习题

5.1. 令

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 1 \end{pmatrix}, B = \begin{pmatrix} 1 & 0 & 2 \\ 3 & 1 & -2 \end{pmatrix}, C = \begin{pmatrix} 1 & -2 & 3 \\ -2 & 1 & -1 \end{pmatrix}, D = \begin{pmatrix} -2 \\ 2 \\ 1 \end{pmatrix}$$

- a) 选出所有有定义的乘积，并给出乘积的大小： $AB, BA, ABC, ABD, BC, BC^T, B^T C, DC, D^T C^T$.
 - b) 计算 $AB, A(3B + C), B^T A, A(BD), (AB)D$.
- 5.2. 令 T_γ 为 $\mathbb{R}^2$ 中旋转 γ 弧度的矩阵。用矩阵乘法检验 $T_\gamma T_{-\gamma} = T_{-\gamma} T_\gamma = I$.
- 5.3. 将两个旋转矩阵 T_α 和 T_β 相乘（该乘法是罕见的可交换乘法，即 $T_\alpha T_\beta = T_\beta T_\alpha$ ，故顺序不重要）。据此推导 $\sin(\alpha + \beta)$ 和 $\cos(\alpha + \beta)$ 的公式。
- 5.4. 求出 $\mathbb{R}^2$ 中向直线 $x_1 = -2x_2$ 上正交投影的矩阵。提示：向坐标轴 x_1 上投影的矩阵是什么？
- 5.5. 求出线性变换 $A, B: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ 使得 $AB = \mathbf{0}$ 但 $BA \neq \mathbf{0}$.
- 5.6. 证明定理 5.1，即证明 $\text{trace}(AB) = \text{trace}(BA)$.
- 5.7. 构造非零矩阵 A 使得 $A^2 = \mathbf{0}$.
- 5.8. 求出关于直线 $y = -2x/3$ 的反射的矩阵。请将所有乘法都算到最终结果。

6. 可逆变换与矩阵、同构

6.1. 恒等变换和恒等矩阵

在所有线性变换中，有个很特殊的线性变换——恒等变换（恒等算子） I ， $I\mathbf{x} = \mathbf{x}, \forall \mathbf{x}$.

准确地说，恒等变换有无数多个：对任意向量空间 V ，都有一个恒等变换 $I = I_V: V \rightarrow V, I_V \mathbf{x} = \mathbf{x}, \forall \mathbf{x} \in V$ 。然而，不致混淆时，我们将

用同一符号 I 表示所有的恒等算子（恒等变换）. 只有在强调该变换作用于哪个空间时，我们才用记号 I_V .

通常，线性代数教材中用符号 E 表示恒等矩阵. 我更中意 I ，因为在算子理论中用的是它.

显然，如果 $I: \mathbb{F}^n \rightarrow \mathbb{F}^n$ 是 $\mathbb{F}^n$ 上的恒等变换，则其矩阵为 $n \times n$ 矩阵

$$I = I_n = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

(主对角线上全为 1，而其余地方全为 0). 当我们需要强调矩阵的大小时，就用 I_n 做个记号；否则我们用 I 即可.

显然，对于任意线性变换 A ，等式

$$AI = A, \quad IA = A$$

成立（只要乘积是有定义的）.

6.2. 可逆变换

定义. 令 $A: V \rightarrow W$ 为一线性变换. 称变换 A 是**左可逆的**，若存在线性变换 $B: W \rightarrow V$ 使得

$$BA = I \quad (\text{此处 } I = I_V).$$

称变换 A 是**右可逆的**，若存在线性变换 $C: W \rightarrow V$ 使得

$$AC = I \quad (\text{此处 } I = I_W).$$

线性变换 B 和 C 分别称为 A 的**左逆**和**右逆**. 注意，我们并没有假设 B 和 C 的唯一性，并且通常左逆和右逆也不是唯一的.

定义. 称线性变换 $A: V \rightarrow W$ 是**可逆的**，若其既是左可逆的又是右可逆的.

定理 6.1. 若线性变换 $A: V \rightarrow W$ 是可逆的，那么其左逆 B 和右逆 C 是唯一且相等的.

这条性质往往被用作可逆线性变换的定义. **推论.** 线性变换 $A: V \rightarrow W$ 是可逆的，当且仅当存在唯一的线性变换（记为 A^{-1} ）， $A^{-1}: W \rightarrow V$ 使得

$$A^{-1}A = I_V, \quad AA^{-1} = I_W.$$

变换 A^{-1} 称作 A 的**逆**.

定理 6.1 的证明: 令 $BA = I$ 且 $AC = I$. 那么

$$BAC = B(AC) = BI = B.$$

另一方面,

$$BAC = (BA)C = IC = C,$$

因此 $B = C$.

假设对于某个线性变换 B_1 有 $B_1A = I$. 将上面对 B 所做的推理作用于 B_1 , 可得 $B_1 = C$. 因此, 左逆 B 是唯一的. 类似可证 C 的唯一性. $\square$

定义. 称矩阵是**可逆的** (意即**左可逆且右可逆**), 如果相应的线性变换是可逆的 (意即**左可逆且右可逆**).

定理 6.1 表明若存在唯一的矩阵 A^{-1} 使得 $A^{-1}A = I, AA^{-1} = I$, 则矩阵 A 是可逆的. 矩阵 A^{-1} 称作 A 的**逆**.

例子

1. 恒等变换 (恒等矩阵) 是可逆的, $I^{-1} = I$;
2. 旋转 R_γ

$$R_\gamma = \begin{pmatrix} \cos \gamma & -\sin \gamma \\ \sin \gamma & \cos \gamma \end{pmatrix}$$

是可逆的, 且其逆为 $(R_\gamma)^{-1} = R_{-\gamma}$. 从 R_γ 的几何描述很容易得到该等式, 也可以通过矩阵乘法来检验它.

3. 列向量 $(1, 1)^T$ 是左可逆的但不是右可逆的. 其左逆可以是行向量 $(1/2, 1/2)$.

为了说明该矩阵不是右可逆的, 只需注意到该矩阵存在不止一个左逆. **习题:** 描述该矩阵的所有左逆.

4. 行向量 $(1, 1)$ 是右可逆的, 但不是左可逆的. 可能的右逆之一是列向量 $(1/2, 1/2)^T$.

注 6.2. 可逆矩阵**必为**方阵 ($n \times n$). 此外, 若方阵 A 有左逆或右逆, 那么其为可逆的. 因此, 只需检验等式 $AA^{-1} = I, A^{-1}A = I$ 其中之一.

该结论会在后面证明. 在证明该结论之前, 我们将不会使用它. 我在此处先提及它只是为了防止学生误入歧途.

6.2.1. 逆变换的性质

定理 6.3 (乘积的逆). 若线性变换 A 和 B 是可逆的 (并且乘积 AB 是有定义的), 那么乘积 AB 是可逆的, 且

$$(AB)^{-1} = B^{-1}A^{-1}$$

(注意顺序的变化!)

证明: 直接计算有

$$(AB)(B^{-1}A^{-1}) = A(BB^{-1})A^{-1} = AIA^{-1} = AA^{-1} = I$$

类似地

$$(B^{-1}A^{-1})(AB) = B^{-1}(A^{-1}A)B = B^{-1}IB = B^{-1}B = I$$

□

注 6.4. 乘积 AB 的可逆性并不蕴涵 A 和 B 的可逆性 (你能举出一个例子吗?). 然而, 如果因子之一 (A 或 B) 是可逆的, 且乘积 AB 可逆, 那么另一个因子也是可逆的.

我们将这一结论的证明留作习题.

定理 6.5 (A^T 的逆). 若矩阵 A 可逆, 那么 A^T 也可逆, 且

$$(A^T)^{-1} = (A^{-1})^T$$

证明: 利用 $(AB)^T = B^T A^T$, 我们有

$$(A^{-1})^T A^T = (AA^{-1})^T = I^T = I,$$

类似地,

$$A^T (A^{-1})^T = (A^{-1}A)^T = I^T = I.$$

□

最后, 若 A 可逆, 那么 A^{-1} 也可逆, 且 $(A^{-1})^{-1} = A$.

让我们总结逆的主要性质:

1. 若 A 可逆, 那么 A^{-1} 也可逆, 且 $(A^{-1})^{-1} = A$;
2. 若 A 和 B 是可逆的, 并且乘积 AB 是有定义的, 那么 AB 是可逆的, 且 $(AB)^{-1} = B^{-1}A^{-1}$;
3. 若 A 可逆, 那么 A^T 也可逆, 且 $(A^T)^{-1} = (A^{-1})^T$.

6.3. 同构、同构向量空间

称可逆线性变换 $A: V \rightarrow W$ 为**同构**. 我们并未引入任何新概念, 只是给我们已研究过的对象取了一个新名字而已.

称两个向量空间 V 和 W 是**同构的** (记作 $V \cong W$), 若存在同构 $A: V \rightarrow W$.

同构的向量空间可视作同一向量空间的不同表达, 意即涉及向量空间运算的所有性质和推导在同构下都是保持不变的.

以下定理形象展示了这一说法.

定理 6.6. 令 $A: V \rightarrow W$ 是同构, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的基. 那么向量组 $A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_n$ 是 W 的基.

此定理的证明留作习题.

注. 可以将上述定理中的“基”换成“线性无关组”、“生成组”或“线性相关组”——所有这些性质在同构下都是保持不变的.

注. 若 A 为同构, 那么 A^{-1} 也是同构. 因此我们可以把上述定理表述成 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是基当且仅当 $A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_n$ 是基.

定理 6.6 的逆命题也是成立的.

定理 6.7. 令 $A: V \rightarrow W$ 是线性映射, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n$ 分别为 V 和 W 的基. 若 $A\mathbf{v}_k = \mathbf{w}_k, k = 1, 2, \dots, n$, 那么 A 是同构.

证明: 定义逆变换 A^{-1} 为 $A^{-1}\mathbf{w}_k = \mathbf{v}_k, k = 1, 2, \dots, n$ (我们知道, 线性变换由其基上的取值所决定). $\square$

例子

1. 令 $A: \mathbb{F}^{n+1} \rightarrow \mathbb{P}_n^{\mathbb{F}}$ ($\mathbb{P}_n^{\mathbb{F}}$ 是次数最高为 n 的多项式 $\sum_{k=0}^n \alpha_k t^k, \alpha_k \in \mathbb{F}$ 所成的集合) 定义为

$$A\mathbf{e}_1 = 1, A\mathbf{e}_2 = t, \dots, A\mathbf{e}_n = t^{n-1}, A\mathbf{e}_{n+1} = t^n$$

由定理 6.7, A 为同构, 故 $\mathbb{P}_n^{\mathbb{F}} \cong \mathbb{F}^{n+1}$.

2. 令 V 为 $\mathbb{F}$ 上的向量空间, 基为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$. 定义变换 $A: \mathbb{F}^n \rightarrow V$ 任一具有基的实向量空间都与 $\mathbb{R}^n$ (n 为适当的数) 同构.

$$A\mathbf{e}_k = \mathbf{v}_k, \quad k = 1, 2, \dots, n,$$

其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{F}^n$ 的标准基. 同样由定理 6.7, A 为同构, 故 $V \cong \mathbb{F}^n$. 类似地, 任一具有基的复向量空间都与 $\mathbb{C}^n$ 同构.

3. 由 2×3 矩阵 (各项属于 $\mathbb{F}$) 所构成的向量空间 $M_{2 \times 3}^{\mathbb{F}}$ 同构于 $\mathbb{F}^6$;
4. 更一般地, $M_{m \times n}^{\mathbb{F}} \cong \mathbb{F}^{m \cdot n}$.

6.4. 可逆性与方程

这是不是让你想起了基? **定理 6.8.** 令 $A: X \rightarrow Y$ 为线性变换. 那么 A 可逆, 当且仅当对任意右端项 $\mathbf{b} \in Y$, 方程

$$A\mathbf{x} = \mathbf{b}$$

有唯一解 $\mathbf{x} \in X$.

证明: 设 A 是可逆的. 那么 $\mathbf{x} = A^{-1}\mathbf{b}$ 是方程 $A\mathbf{x} = \mathbf{b}$ 的解. 为证明该解是可逆的, 设另一向量 $\mathbf{x}_1 \in X$ 满足

$$A\mathbf{x}_1 = \mathbf{b}$$

将此等式两端左乘 A^{-1} , 可得

$$A^{-1}A\mathbf{x}_1 = A^{-1}\mathbf{b},$$

因此 $\mathbf{x}_1 = A^{-1}\mathbf{b} = \mathbf{x}$. 注意, $AA^{-1} = I$ 和 $A^{-1}A = I$ 这两个等式都用到了.

现在假设方程 $A\mathbf{x} = \mathbf{b}$ 对于任意 $\mathbf{b} \in Y$ 有唯一解. 下面用符号 $\mathbf{y}$ 而不用 $\mathbf{b}$. 我们知道, 给定 $\mathbf{y} \in Y$, 方程

$$A\mathbf{x} = \mathbf{y}$$

有唯一解 $\mathbf{x} \in X$. 记此解为 $B(\mathbf{y})$.

注意 $B(\mathbf{y})$ 对于所有 $\mathbf{y} \in Y$ 都有定义, 因此我们定义了一个变换 $B: Y \rightarrow X$.

下面检验 B 是线性变换. 我们需要证明 $B(\alpha\mathbf{y}_1 + \beta\mathbf{y}_2) = \alpha B(\mathbf{y}_1) + \beta B(\mathbf{y}_2)$. 令 $\mathbf{x}_k := B(\mathbf{y}_k)$, $k = 1, 2$, 即 $A\mathbf{x}_k = \mathbf{y}_k$, $k = 1, 2$. 那么

$$A(\alpha\mathbf{x}_1 + \beta\mathbf{x}_2) = \alpha A\mathbf{x}_1 + \beta A\mathbf{x}_2 = \alpha\mathbf{y}_1 + \beta\mathbf{y}_2,$$

这表明

$$B(\alpha\mathbf{y}_1 + \beta\mathbf{y}_2) = \alpha B(\mathbf{y}_1) + \beta B(\mathbf{y}_2).$$

最后, 我们证明 B 的确是 A 的逆. 取 $\mathbf{x} \in X$ 并令 $\mathbf{y} = A\mathbf{x}$, 则根据 B 的定义, 我们有 $\mathbf{x} = B\mathbf{y}$. 那么对所有 $\mathbf{x} \in X$ 有

$$BA\mathbf{x} = B\mathbf{y} = \mathbf{x},$$

故 $BA = I$. 类似地, 对任意 $\mathbf{y} \in Y$ 令 $\mathbf{x} = B\mathbf{y}$, 故 $\mathbf{y} = A\mathbf{x}$. 则对所有 $\mathbf{y} \in Y$ 均有

$$AB\mathbf{y} = A\mathbf{x} = \mathbf{y},$$

故 $AB = I$. □

回忆一下基的定义, 我们可得定理 6.6 和 6.7 的如下推论.

推论 6.9. $m \times n$ 矩阵是可逆的, 当且仅当它的列形成 $\mathbb{F}^m$ 的基.

习题

- 6.1. 证明: 若 $A: V \rightarrow W$ 是同构 (即可逆线性变换), 且 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的基. 那么 $A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_n$ 是 W 的基.
- 6.2. 求出 1×2 矩阵 (行向量) $A = (1, 1)$ 的所有右逆, 并由此得出结论: 行向量 A 不是左可逆的.
- 6.3. 求出列向量 $(1, 2, 3)^T$ 的所有左逆.
- 6.4. 列向量 $(1, 2, 3)^T$ 是右可逆的吗? 论证之.
- 6.5. 找出两个矩阵 A 和 B , 满足 AB 是可逆的, 但 A 和 B 不是. **提示:** 方阵 A 和 B 并不能用于举例. **注:** 在 AB 是 1×1 矩阵 (标量) 时, 很容易构造 A 和 B . 但你能否对于 AB 为 2×2 矩阵的情况进行构造? 3×3 和 $n \times n$ 呢?
- 6.6. 设乘积 AB 可逆. 证明: A 是右可逆的且 B 是左可逆的. **提示:** 写出右逆和左逆的表达式.
- 6.7. 设 A 和 AB 都可逆 (假设乘积 AB 是定义完善的). 证明: B 是可逆的.
- 6.8. 设 A 是 $n \times n$ 矩阵. 证明: 若 $A^2 = \mathbf{0}$, 那么 A 不可逆.
- 6.9. 设 $AB = \mathbf{0}$ 对某非零矩阵 B 成立. A 可能是可逆的吗? 论证之.
- 6.10. 写出 $\mathbb{F}^5$ 中线性变换 T_1 和 T_2 的矩阵. 这两个变换的定义是: T_1 将向量 $\mathbf{x}$ 的坐标 x_2 和 x_4 互换, 而 T_2 将 x_4 的 a 倍加到 x_2 , 并不改变其他坐标, 即

$$T_1 \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_4 \\ x_3 \\ x_2 \\ x_5 \end{pmatrix}, \quad T_2 \begin{pmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix} = \begin{pmatrix} x_1 \\ x_2 + ax_4 \\ x_3 \\ x_4 \\ x_5 \end{pmatrix};$$

此处 a 为某固定的数.

证明: T_1 和 T_2 是可逆变换, 并写出它们的逆的矩阵. **提示:** 比起猜想 (或计算) T_1, T_2 这两个矩阵的逆, 先描述出逆变换再求出逆变换的矩阵可能更为容易.

- 6.11. 求出 $\mathbb{R}^3$ 中绕向量 $(1, 2, 3)^T$ 旋转 α 角度这一变换的矩阵. 我们假设从向量的尾端看向原点时, 所做的旋转为逆时针方向.

你可以将答案写成若干矩阵相乘的形式, 而不需要计算所有的乘法.

6.12. 给出满足下面条件的矩阵（比如 2×2 矩阵）的例子：

- a) $A + B$ 不可逆，尽管 A 和 B 都可逆；
- b) $A + B$ 可逆，尽管 A 和 B 都不可逆；
- c) A 、 B 、 $A + B$ 都可逆。

6.13. 令 A 为可逆的对称矩阵 ($A^T = A$)。 A 的逆还是对称的吗？论证之。

7. 子空间

向量空间 V 的**子空间**是 V 的非空子集 $V_0 \subset V$ ，它对于向量加法和标量乘法都是封闭的，也即：

- 1. 若 $\mathbf{v} \in V_0$ ，那么对于所有标量 α 都有 $\alpha\mathbf{v} \in V_0$ ；
- 2. 对于任意 $\mathbf{u}, \mathbf{v} \in V_0$ ，都有求和结果 $\mathbf{u} + \mathbf{v} \in V_0$ ；

同样，这两个条件可替换成下面这一个：

对于所有标量 α, β 和所有 $\mathbf{u}, \mathbf{v} \in V_0$ ，都有 $\alpha\mathbf{u} + \beta\mathbf{v} \in V_0$ 。

注意，具有继承自 V 的运算（向量加法和标量乘法）的子空间 $V_0 \subset V$ 是向量空间。的确如此：由于 V 非空，它至少包含一个向量 $\mathbf{v}$ ，又因为 $\mathbf{0} = 0\mathbf{v}$ ，上述条件 1 表明零向量 $\mathbf{0}$ 属于 V 。并且对于任意 $\mathbf{v} \in V$ ，其加法逆元 $-\mathbf{v}$ 由 $-\mathbf{v} = (-1)\mathbf{v}$ 给出，所以同样由性质 1 可得 $-\mathbf{v} \in V$ 。向量空间的其余公理也都成立，因为所有运算都继承自 V 。唯一可能出问题的一点，就是运算的结果可能不属于 V_0 。但是子空间的定义规避了这种情况！

现在我们考虑一些例子：

- 1. 向量空间 V 的**平凡子空间**，即 V 自身和 $\{\mathbf{0}\}$ （仅包含零向量的子空间）。注意，空集 $\emptyset$ 不是向量空间（因为不包含零向量），因此它不是子空间。

对于每个线性变换 $A: V \rightarrow W$ ，有以下两个子空间与之关联：

- 2. A 的**零空间或核**，记为 $\text{Null } A$ 或 $\text{Ker } A$ ，由所有满足 $A\mathbf{v} = \mathbf{0}$ 的向量 $\mathbf{v} \in V$ 所构成。
- 3. **值域** $\text{Ran } A$ 定义为由所有可被表示成 $\mathbf{w} = A\mathbf{v}$ （其中 $\mathbf{v} \in V$ ）的向量 $\mathbf{w} \in W$ 所构成的集合。

若 A 为矩阵，即 $A: \mathbb{F}^m \rightarrow \mathbb{F}^n$ ，回想一下矩阵-向量乘法的“**列乘以坐标**”规则，我们可看出，任意向量 $\mathbf{w} \in \text{Ran } A$ 可表示成矩阵 A 各列的线性组合。这就能解释为何常使用列空间（记号为 $\text{Col } A$ ）这个术语来指代矩阵的值域。因此，对于矩阵 A ，更常用记号 $\text{Col } A$ 而非 $\text{Ran } A$ 。

最后一个例子是：

4. 给定向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r \in V$ ，其**线性张成空间**（有时可简称为**张成空间**） $\mathcal{L}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ 是可被表示为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 的线性组合 $\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_r \mathbf{v}_r$ 的所有向量 $\mathbf{v} \in V$ 所构成的集合。除 $\mathcal{L}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ 外，也用记号 $\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ 来表示。

容易检验，这些例子中的向量空间的确是子空间——留给读者作为习题。其中有些结论会在后文得到证明。

习题

- 7.1. 令 X 和 Y 是向量空间 V 的子空间。证明 $X \cap Y$ 是 V 的子空间。
- 7.2. 令 V 是向量空间。对于 $X, Y \subset V$ ， $X + Y$ 是所有可被表示为 $\mathbf{v} = \mathbf{x} + \mathbf{y}$, $\mathbf{x} \in X, \mathbf{y} \in Y$ 的向量 $\mathbf{v}$ 所构成的集合。证明若 X 和 Y 是 V 的子空间，那么 $X + Y$ 也是 V 的子空间。
- 7.3. 令 X 是向量空间 V 的子空间，并令 $\mathbf{v} \in V, \mathbf{v} \notin X$ 。证明：若 $\mathbf{x} \in X$ 则 $\mathbf{x} + \mathbf{v} \notin X$ 。
- 7.4. 令 X 和 Y 是向量空间 V 的子空间。利用上一题的结论证明： $X \cup Y$ 是子空间，当且仅当 $X \subset Y$ 或 $Y \subset X$ 。
- 7.5. 由 4×4 矩阵所构成的空间的所有子空间里，包含所有上三角矩阵（对于所有 $j > k$ 有 $a_{j,k} = 0$ ）的最小子空间是什么？包含所有对称矩阵（ $A^T = A$ ）的最小子空间是什么？这两个子空间所共同包含的最大子空间是什么？

8. 在计算机图形学中的应用

本节我们给出线性代数在计算机图形学中的一些实际应用。我们并不会深究细节，而只是陈述一些基本思想。我们会重点解释为什么对于 3 维图像的运算可简化为 4×4 矩阵的乘法。

8.1. 2 维图形

计算机显示屏可建模为 x - y 平面（更准确地说，其中的一个矩形）。显示屏上出现的任意图形都可用一系列**像素**来表示，而每个像素都被赋予了特定的颜色。每个像素的位置都由行号和列号所确定，二者充当了平面上 x 和 y 坐标的角色。因此，用带 x - y 坐标的平面中的矩形来表示计算机屏幕是很合适的——而一个图形只不过是一系列点。

注。 图形分为两类：位图（会给出每个像素的信息）和矢量图（只给出**关键点**的信息，而绘图引擎将这些点连接起来以重构出完整图形）。位图的一个很好的例子是数字相片：其中每个像素都会被描述。位图可能

包含大量的点，因此对于位图进行运算需要大量的算力。用位图处理程序（比如 Adobe Photoshop）编辑过数字相片的人都知道程序的运行需要很强大的计算机，而且即便用了很现代也很强大的计算机，运算还是需要花费一定的时间。

这就是计算机屏幕上的图形中矢量图占大多数的原因：计算机只需要存储关键点。例如，为了描绘一个多边形，只需要给出其顶点的坐标，以及顶点之间的连接关系。当然，计算机屏幕上并非所有图形都可被表示为多边形，有些图形（例如字母）具有弯曲而光滑的边界。不过，绘制经过一系列点的光滑曲线已有成熟的方法（例如贝塞尔曲线），这些方法被用于 PostScript 与 Adobe PDF（以及许多其他格式的文件）中。

无论如何，这是其他（与本书内容迥异的）书籍所涉及的主题，此处我们不做讨论。对我们来说，图形就是一系列的点（无论是线框模型⁵还是位图），并且我们将要展示可以对这样的对象进行何种运算。

最简单的变换是平移，其中每个点（向量） $\mathbf{v}$ 的平移量为 $\mathbf{a}$ ，也即向量 $\mathbf{v}$ 会被 $\mathbf{v} + \mathbf{a}$ 所取代（用 $\mathbf{v} \mapsto \mathbf{v} + \mathbf{a}$ 这个记法来表示）。向量加法很适于计算机运算，因此平移是很容易实现的。

注意，平移并不是线性变换（若 $\mathbf{a} \neq \mathbf{0}$ ）：经此变换直线仍为直线，但 $\mathbf{0}$ 不再为 $\mathbf{0}$ 。

计算机图形学中要用到的其他变换都是线性的。首先是旋转。绕原点 $\mathbf{0}$ 旋转 γ 可表示为与旋转矩阵 R_γ 的乘法（我们之前讨论过）：

$$R_\gamma = \begin{pmatrix} \cos \gamma & -\sin \gamma \\ \sin \gamma & \cos \gamma \end{pmatrix}.$$

如果我们要绕点 $\mathbf{a}$ 旋转，我们首先需要将图形平移 $-\mathbf{a}$ 以将点 $\mathbf{a}$ 移到 $\mathbf{0}$ ，然后绕着 $\mathbf{0}$ 旋转（乘以 R_γ ），再平移 $\mathbf{a}$ 以消去之前的平移。

另一个很有用的变换是缩放，其由下述矩阵给出

$$\begin{pmatrix} a & 0 \\ 0 & b \end{pmatrix},$$

其中 $a, b \geq 0$ 。若 $a = b$ ，则其为**等倍缩放**，将图形放大或缩小的同时保持其形状。若 $a \neq b$ ，则 x 和 y 坐标缩放比例不同，图形会变得“更高”或“更宽”。

另一个常用的变换是**反射**：例如矩阵

$$\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

⁵就是上面所说的用“关键点”和“连接关系”来描述图形的方法。——译者注

定义了沿 x 轴的反射.

在本书的后续部分, 我们将证明 $\mathbb{R}^2$ 中的所有线性变换都是伸缩、旋转和反射的复合. 然而, 有时考虑别的变换也可带来便利. 例如由下面矩阵所给出的剪切变换:

$$\begin{pmatrix} 1 & \tan \varphi \\ 0 & 1 \end{pmatrix}.$$

这个变换会使图形倾斜——水平线仍然保持水平, 但是垂直线变成了与水平线夹角为 φ 的斜线.

8.2. 3 维图形

三维图形学更为复杂. 首先我们需要能够对三维的图形对象进行运算, 然后我们还需要将其在二维平面 (显示器) 上显示出来.

对三维图形对象的运算是很直截了当的, 我们仍然是用基本的几种变换: 平移、关于平面的反射、缩放和旋转. 这些变换的矩阵很类似于 2×2 时的对应情形. 例如, 矩阵

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{pmatrix}, \quad \begin{pmatrix} a & 0 & 0 \\ 0 & b & 0 \\ 0 & 0 & c \end{pmatrix}, \quad \begin{pmatrix} \cos \gamma & -\sin \gamma & 0 \\ \sin \gamma & \cos \gamma & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

就分别表示关于 x - y 平面的反射、缩放和绕 z 轴的旋转.

注意, 上述旋转实际上是 2 维旋转——它并不改变 z 坐标. 类似地, 也可写出另外两种**基本旋转**——关于 x 轴和 y 轴的旋转——的矩阵. 后面会证明, 关于任意轴的旋转都可表示为一系列基本旋转的复合.

这样, 我们就知道如何对 3 维图形进行运算了. 下面讨论如何将它在 2 维平面上显示出来. 最简单的方法就是将其投影到一个平面上, 例如 x - y 平面. 为进行这一投影, 只需将 z 坐标置 0. 该**投影**的矩阵是

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix}.$$

此种方法常用于技术示意图中. 将一个物体旋转再投影, 就等价于从不同的视点观察它. 然而, 这种方法并不能给出非常逼真的图形, 因为它没有考虑视角——即“近大远小”的规律.

为了得到更为逼真的图像, 需要使用所谓**透视投影**. 为确定透视投影, 我们需要选择一个点 (投影中心, 或称焦点) 以及需要投射到的平面. 那么 $\mathbb{R}^3$ 中的每个点都会被投影到该平面中的一个像点上, 且满足原来的点、像点和**投影中心**处于同一直线上——见图 2.




图 2 到 x - y 平面上的透视投影: F 是投影中心 (焦点)

这就是照相机的工作原理, 也是对我们眼球运作方式的合理且初步的近似.




图 3 求出点 $(x, y, z)^T$ 的透视投影的坐标 x^*, y^*

下面推导这种投影的公式. 假设焦点是 $(0, 0, d)^T$, 并且是向 x - y 平面上投影——见图 3 a). 考虑点 $\mathbf{v} = (x, y, z)^T$, 并令 $\mathbf{v}^* = (x^*, y^*, 0)^T$ 是其投影. 如图 3 b), 分析相似三角形可得

$$\frac{x^*}{d} = \frac{x}{d-z},$$

故

$$x^* = \frac{xd}{d-z} = \frac{x}{1-z/d},$$

类似有

$$y^* = \frac{y}{1-z/d}.$$

注意, 此公式同样适用于 $z > d$ 和 $z < 0$ 的情况: 你可以自行绘制对应的相似三角形来检验.

于是透视投影将点 $(x, y, z)^T$ 映射到点 $\left(\frac{x}{1-z/d}, \frac{y}{1-z/d}, 0\right)^T$.

该变换显然不是线性的 (由于分母中的 z). 然而, 可以将它表示为线性变换. 为此, 我们引入所谓**齐次坐标**.

在齐次坐标中, $\mathbb{R}^3$ 中的每个点都用 4 个坐标来表示, 其中最后一个 (即第 4 个) 坐标充当缩放系数的角色. 从而, 要从向量 $\mathbf{v}$ 的齐次坐标 $(x_1, x_2, x_3, x_4)^T$ 恢复出通常的 3 维坐标 $(x, y, z)^T$, 我们需要将每项都除以最后一个坐标 x_4 , 再取前三个坐标⁶ (若 $x_4 = 0$, 那么此办法就不奏效了, 因此我们假设 $x_4 \neq 0$ 对应的是处于无穷远处的点).

于是在齐次坐标中, 向量 $\mathbf{v}^*$ 可表示为 $(x, y, 0, 1 - z/d)^T$, 因此在齐次坐标中, 透视投影是线性变换:

$$\begin{pmatrix} x \\ y \\ 0 \\ 1 - z/d \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & -1/d & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix}.$$

注意在齐次坐标中, 平移也是线性变换:

$$\begin{pmatrix} x + a_1 \\ y + a_2 \\ z + a_3 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 & a_1 \\ 0 & 1 & 0 & a_2 \\ 0 & 0 & 1 & a_3 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \\ 1 \end{pmatrix}.$$

不过, 如果投影中心不是 $(0, 0, d)^T$, 而是任意的点 $(d_1, d_2, d_3)^T$ 呢? 那么, 我们需要首先做平移量为 $-(d_1, d_2, 0)^T$ 的平移, 将投影中心移到 $(0, 0, d_3)^T$ (同时保持 x - y 平面不变), 再作用该投影, 然后再用平移量为 $(d_1, d_2, 0)^T$ 的平移来抵消之前的平移. 类似地, 如果投影平面不是 x - y 平面, 就需要通过旋转和平移将投影平面转到 x - y 平面上, 之后的逻辑类似上述过程.

所有这些运算都仅仅是与 4×4 矩阵的乘法. 这就能够解释为何现代的显卡在处理器中内置了 4×4 矩阵运算.

当然, 此处我们只是对 3 维图形学背后的数学有了粗浅的认识, 还有许多可供了解的地方. 例如, 怎样确定一个物体的哪些部分是可见或不可见的, 如何制造逼真的光影, 等等.

⁶如果我们将 $\mathbb{R}^3$ 中一个点的齐次坐标乘以一个非零标量, 这个点不会改变. 换言之, 在齐次坐标中, $\mathbb{R}^3$ 中的点是用 $\mathbb{R}^4$ 中过 $\mathbf{0}$ 的直线来表示的.

习题

8.1. $\mathbb{R}^3$ 中的哪个向量具有齐次坐标 $(10, 20, 30, 5)$?

8.2. 证明: 旋转 γ 可表示为以下这两个“剪切与缩放”变换的复合:

$$T_1 = \begin{pmatrix} 1 & 0 \\ \sin \gamma & \cos \gamma \end{pmatrix}, \quad T_2 = \begin{pmatrix} \sec \gamma & -\tan \gamma \\ 0 & 1 \end{pmatrix}.$$

两变换的顺序应该是什么样?

8.3. 将 2 维向量乘以任意 2×2 矩阵通常需要做 4 次乘法.

假设 2×1000 矩阵 D 包含 $\mathbb{R}^2$ 中的 1000 个点. 利用两个任意的 2×2 矩阵来变换这些点, 需要做多少次乘法? 请比较两种可能的算法, $A(BD)$ 和 $(AB)D$.

8.4. 写出表征投影中心为 $(d_1, d_2, d_3)^T$ 、投影平面为 x - y 平面的透视投影的矩阵.

8.5. $\mathbb{R}^3$ 中的变换 T 将向量绕 x - y 平面中的直线 $y = x + 3$ 旋转 γ . 写出对应于该变换的 4×4 矩阵.

你可将答案保留为若干矩阵相乘的形式.

第 2 章 线性方程组

1. 线性方程组的多副面孔

关于线性方程组为何物，有多种视角. 第一种（也是最朴素的一种），就是将其视作含有 n 个未知数 $x_1, x_2, \dots, x_n$ 的 m 个线性方程，

$$\begin{cases} a_{1,1}x_1 + a_{1,2}x_2 + \dots + a_{1,n}x_n = b_1 \\ a_{2,1}x_1 + a_{2,2}x_2 + \dots + a_{2,n}x_n = b_2 \\ \dots \\ a_{m,1}x_1 + a_{m,2}x_2 + \dots + a_{m,n}x_n = b_m \end{cases}.$$

求解该方程组即求出**所有**同时满足这 m 个方程的数 $x_1, x_2, \dots, x_n$ 构成的 n 元组.

如果记 $\mathbf{x} := (x_1, x_2, \dots, x_n)^T \in \mathbb{F}^n$, $\mathbf{b} = (b_1, b_2, \dots, b_m)^T \in \mathbb{F}^m$, 且记

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & \dots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{m,1} & a_{m,2} & \dots & a_{m,n} \end{pmatrix},$$

那么上述线性方程组可以写成**矩阵形式**（也即**矩阵-向量方程**）

$$A\mathbf{x} = \mathbf{b}.$$

求解上述方程即求出所有满足 $A\mathbf{x} = \mathbf{b}$ 的向量 $\mathbf{x} \in \mathbb{F}^n$.

最后，回想一下矩阵-向量乘法的“列乘以坐标”规则，我们可以将原方程组写为**向量方程**

$$x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \dots + x_n\mathbf{a}_n = \mathbf{b},$$

其中 $\mathbf{a}_k$ 是矩阵 A 的第 k 列， $\mathbf{a}_k = (a_{1,k}, a_{2,k}, \dots, a_{m,k})^T, k = 1, 2, \dots, n$.

注意，上面三例本质上只是同种数学对象的不同表达而已.

在开始解释如何求解线性方程组之前，我们首先要注意，未知数的记法——比如 x_k, y_k 或者其他名称——都无关紧要. 所以，求解线性方程组所必需的信息全部包含于两者：矩阵 A （称为线性方程组的**系数矩阵**）和（右端）向量 $\mathbf{b}$. 进而，我们所需的全部信息都包含于以下矩阵

$$\left(\begin{array}{cccc|c} a_{1,1} & a_{1,2} & \cdots & a_{1,n} & b_1 \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} & b_2 \\ \vdots & \vdots & & \vdots & \vdots \\ a_{m,1} & a_{m,2} & \cdots & a_{m,n} & b_m \end{array} \right)$$

该矩阵是通过将列向量 $\mathbf{b}$ 增加到矩阵 A 右端获得的，称为线性方程组的**增广矩阵**。我们通常会在 A 和 $\mathbf{b}$ 之间插入一条竖线来区分增广矩阵和系数矩阵。

2. 线性方程组的解、阶梯形和简化阶梯形

线性方程组是用**高斯-若当消元法**（有时也称为**行化简**）来求解的。通过对线性方程组的增广矩阵的行做变换（也即对方程做变换），我们将其化为一简单的形式——即所谓**阶梯形**。当线性方程组具有**阶梯形**时，我们就很容易写出其解。

2.1. 行变换

行变换有三种：

1. 行交换：交换矩阵的两行；
2. 缩放：将一行乘以非零标量 a ；
3. 行替换：将第 k 行换为它与第 j 行的常数倍之和，而保持其他行不变。

显然，变换 1 和 2 并不会改变线性方程组的解集——它们实质上就没有改变原方程组。

至于变换 3，我们容易看出它不会使方程组的解减少。意即，令“新”方程组由“旧”方程组经过第 3 种行变换得来。那么“旧”方程组的每个解都是“新”方程组的解。

要看出为什么变换 3 不会导致解增加，也就是“新”方程组的任一解也是“旧”方程组的解，我们只需注意到第 3 种行变换是**可逆的**，也即，“旧”方程组也可以通过“新”方程组进行第 3 种行变换得来（你能说出是什么样的变换吗？）

2.1.1. 行变换与乘以初等矩阵

关于上述行变换为何不改变方程组的解集，还有一种更为“高级”的解释，也即，每种行变换都等价于左乘一种特殊的初等矩阵。

通过将 a 换成 $-a$ 可得第三个矩阵的逆. 这些逆的正确性同样可通过观察列向量乘以这些矩阵会发生何种变化来检验.

因此, 对方程组 $A\mathbf{x} = \mathbf{b}$ 的增广矩阵做行变换等价于向该方程组左端乘上一个特殊的可逆矩阵 E . 在等式 $A\mathbf{x} = \mathbf{b}$ 两端左乘 E 可得, 方程

$$A\mathbf{x} = \mathbf{b}$$

的任意解也是方程

$$EA\mathbf{x} = E\mathbf{b}$$

的解. 将这个方程左乘 E^{-1} 可得, 其任意解是下述方程

$$E^{-1}EA\mathbf{x} = E^{-1}E\mathbf{b}$$

的解, 也就是原方程 $A\mathbf{x} = \mathbf{b}$ 的解. 因此, 行变换不改变方程组的解集.

2.2. 行化简

行化简的主要步骤包含下面三步:

1. 找到矩阵最左侧的非零列;
2. 如有必要, 通过施加第一类行变换 (行交换), 确保该列的第一个 (最上方的) 项是非零的. 该项将被称为主元;
3. 通过向第 $2, 3, \dots, m$ 行加 (或减) 第一行的适当倍数, “消去” 主元之下的所有非零项 (就是将它们都变为 0).

我们先将这些步骤作用于整个矩阵, 然后保持第一行不变并将这些步骤作用于第 $2, \dots, m$ 行, 然后是第 $3, \dots, m$ 行, 以此类推.

关键是记住在把某一行下方的所有行都减去该行的若干倍后 (步骤 3), 我们就不再改变该行 (甚至不会将该行与其他行进行交换).

在有限次 (至多 m 次) 应用这些步骤后, 我们就得到了矩阵的**阶梯形**.

2.2.1. 行化简实例

考虑如下线性方程组:

$$\begin{cases} x_1 + 2x_2 + 3x_3 = 1 \\ 3x_1 + 2x_2 + x_3 = 7 \\ 2x_1 + x_2 + 2x_3 = 1 \end{cases}$$

该方程组的增广矩阵是

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 3 & 2 & 1 & 7 \\ 2 & 1 & 2 & 1 \end{array} \right)$$

将第二行减去第一行的 3 倍, 并将第三行减去第一行的 2 倍, 我们得到:

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 3 & 2 & 1 & 7 \\ 2 & 1 & 2 & 1 \end{array}\right) \begin{array}{l} -3R_1 \\ -2R_1 \end{array} \sim \left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 0 & -4 & -8 & 4 \\ 0 & -3 & -4 & -1 \end{array}\right)$$

将第二行乘以 $-1/4$ 可得

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 0 & 1 & 2 & -1 \\ 0 & -3 & -4 & -1 \end{array}\right)$$

将第二行的 3 倍加到第三行, 可得

$$\left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 0 & 1 & 2 & -1 \\ 0 & -3 & -4 & -1 \end{array}\right) +3R_2 \sim \left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 0 & 1 & 2 & -1 \\ 0 & 0 & 2 & -4 \end{array}\right)$$

现在, 我们就可用所谓**回代法**解此方程组了. 也就是说, 从最后一行 (最后一个方程) 得出 $x_3 = -2$. 接下来从第二个方程得到

$$x_2 = -1 - 2x_3 = -1 - 2(-2) = 3,$$

最后从第一行 (第一个方程) 得到

$$x_1 = 1 - 2x_2 - 3x_3 = 1 - 6 + 6 = 1.$$

因此原方程组的解为

$$\begin{cases} x_1 = 1, \\ x_2 = 3, \\ x_3 = -2, \end{cases}$$

或用向量形式表示为

$$\mathbf{x} = \begin{pmatrix} 1 \\ 3 \\ -2 \end{pmatrix}$$

或写为 $\mathbf{x} = (1, 3, -2)^T$. 我们可以通过做乘法 $A\mathbf{x}$ 来检验该解, 其中 A 为系数矩阵.

我们也可以不用回代法, 而是从下到上做行变换, 将系数矩阵主对角线上方的所有项全部变为 0: 首先将最后一行乘以 $1/2$, 后续过程则不言而喻:

$$\begin{aligned} \left(\begin{array}{ccc|c} 1 & 2 & 3 & 1 \\ 0 & 1 & 2 & -1 \\ 0 & 0 & 1 & -2 \end{array}\right) & \begin{array}{l} -3R_3 \\ -2R_3 \end{array} \sim \left(\begin{array}{ccc|c} 1 & 2 & 0 & 7 \\ 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & -2 \end{array}\right) \begin{array}{l} -2R_2 \\ \end{array} \\ & \sim \left(\begin{array}{ccc|c} 1 & 0 & 0 & 1 \\ 0 & 1 & 0 & 3 \\ 0 & 0 & 1 & -2 \end{array}\right) \end{aligned}$$

然后从增广矩阵一眼可知解为 $\mathbf{x} = (1, 3, -2)^T$.

留给读者一道习题：梳理从下到上阶段的行化简算法.

2.3. 阶梯形

矩阵具有**阶梯形**，若其满足如下两个条件：

1. 所有的零行（即全部的项都等于 0 的行）位于所有非零行的下方；

对于非零行，我们称最左边的非零项为**先导元**. 那么阶梯形的第二个性质可表述为：

2. 任意非零行的先导元必定严格处于前一行先导元的右侧.

主元：一行中的先导元（最左侧的非零项）.

阶梯形中每行的先导元也称为**主元**，因为这些项恰为行化简时所用的**主元**.

阶梯形有个特例是所谓**三角形**. 在上面的例子中我们就得到了这种形式. 在这种形式中，系数矩阵是方阵 ($n \times n$ 矩阵)，其主对角项均不为零，而主对角线之下的所有项都为零. 右端项，或者说增广矩阵的最右列可以是任意的.

在行化简的从下到上阶段之后，我们就得到了矩阵的所谓**简化阶梯形**：系数矩阵等于 I （如上例所示）是简化阶梯形的一个特例.

一般的定义是：称矩阵具有**简化阶梯形**，若其具有阶梯形且

3. 所有主元都等于 1；
4. 主元之上的所有项都为 0. 注意，主元之下的所有项也都是 0，因为该矩阵具有阶梯形.

为了从阶梯形得到简化阶梯形，我们按从下到上、从右到左的次序，利用行替换消去主元之上的所有项.

简化阶梯形的一个例子是系数矩阵等于 I 的方程组. 在这种情况下，从简化阶梯形就很容易看出解. 在一般的情形下，从简化阶梯形看出解也很容易. 例如，令方程组（增广矩阵）的简化阶梯形是

$$\left(\begin{array}{ccccc|c} \boxed{1} & 2 & 0 & 0 & 0 & 1 \\ 0 & 0 & \boxed{1} & 5 & 0 & 2 \\ 0 & 0 & 0 & 0 & \boxed{1} & 3 \end{array} \right);$$

此处我们将主元框出来了. 求解思路是，将没有主元的列所对应的变量（所谓**自由变量**）移到右侧. 然后我们可直接写出解为

$$\begin{cases} x_1 = 1 - 2x_2 \\ x_2 \text{ 为自由变量} \\ x_3 = 2 - 5x_4 \\ x_4 \text{ 为自由变量} \\ x_5 = 3 \end{cases}$$

或者写成向量形式

$$\mathbf{x} = \begin{pmatrix} 1 - 2x_2 \\ x_2 \\ 2 - 5x_4 \\ x_4 \\ 3 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 2 \\ 0 \\ 3 \end{pmatrix} + x_2 \begin{pmatrix} -2 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} + x_4 \begin{pmatrix} 0 \\ 0 \\ -5 \\ 1 \\ 0 \end{pmatrix}, \quad x_2, x_4 \in \mathbb{F}.$$

也可用回代法从阶梯形求出解：基本思路是从下到上操作，将所有自由变量移到右侧。

习题

2.1. 将下列线性方程组写成矩阵形式和向量方程形式：

$$\begin{aligned} \text{a)} \quad & \begin{cases} x_1 + 2x_2 - x_3 = -1 \\ 2x_1 + 2x_2 + x_3 = 1 \\ 3x_1 + 5x_2 - 2x_3 = -1 \end{cases} \\ \text{b)} \quad & \begin{cases} x_1 - 2x_2 - x_3 = 1 \\ 2x_1 - 3x_2 + x_3 = 6 \\ 3x_1 - 5x_2 = 7 \\ x_1 + 5x_3 = 9 \end{cases} \\ \text{c)} \quad & \begin{cases} x_1 + 2x_2 + 2x_4 = 6 \\ 3x_1 + 5x_2 - x_3 + 6x_4 = 17 \\ 2x_1 + 4x_2 + x_3 + 2x_4 = 12 \\ 2x_1 - 7x_3 + 11x_4 = 7 \end{cases} \\ \text{d)} \quad & \begin{cases} x_1 - 4x_2 - x_3 + x_4 = 3 \\ 2x_1 - 8x_2 + x_3 - 4x_4 = 9 \\ -x_1 + 4x_2 - 2x_3 + 5x_4 = -6 \end{cases} \\ \text{e)} \quad & \begin{cases} x_1 + 2x_2 - x_3 + 3x_4 = 2 \\ 2x_1 + 4x_2 - x_3 + 6x_4 = 5 \\ x_2 + 2x_4 = 3 \end{cases} \\ \text{f)} \quad & \begin{cases} 2x_1 - 2x_2 - x_3 + 6x_4 - 2x_5 = 1 \\ x_1 - x_2 + x_3 + 2x_4 - x_5 = 2 \\ 4x_1 - 4x_2 + 5x_3 + 7x_4 - x_5 = 6 \end{cases} \\ \text{g)} \quad & \begin{cases} 3x_1 - x_2 + x_3 - x_4 + 2x_5 = 5 \\ x_1 - x_2 - x_3 - 2x_4 - x_5 = 2 \\ 5x_1 - 2x_2 + x_3 - 3x_4 + 3x_5 = 10 \\ 2x_1 - x_2 - 2x_4 + x_5 = 5 \end{cases} \end{aligned}$$

解这些方程组。将解写成向量形式。

2.2. 求出向量方程

$$x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + x_3 \mathbf{v}_3 = \mathbf{0},$$

的全部解, 其中 $\mathbf{v}_1 = (1, 1, 0)^T$, $\mathbf{v}_2 = (0, 1, 1)^T$, $\mathbf{v}_3 = (1, 0, 1)^T$. 关于向量组 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 的线性无关性 (线性相关性), 你可以得出什么结论?

3. 主元分析

通过分析线性方程组增广矩阵的阶梯形 (简化阶梯形) 的主元, 可以回答所有关于解的存在性和唯一性的问题. 首先要分析的问题是: 方程 $A\mathbf{x} = \mathbf{b}$ 何时会**不相容** (无解). 稍加思索可立得答案:

方程组不相容 (无解), 当且仅当**增广**矩阵的阶梯形的最后一列存在主元, 也就是, 当且仅当增广矩阵的阶梯形有一行是 $(0 \ 0 \ \dots \ 0 \mid b), b \neq 0$.

的确如此: 这样一行对应于方程 $0x_1 + 0x_2 + \dots + 0x_n = b \neq 0$, 而该方程无解. 如果不存在这样的行, 我们就可以将增广矩阵化为简化阶梯形并直接看出方程组的解.

下面再列出三个结论. 注意, 它们是与方程组的**系数矩阵**而非增广矩阵相关.

1. 方程组的解 (若存在) 是唯一的, 当且仅当没有自由变量, 也就是当且仅当系数矩阵的阶梯形在每列中都有主元;
2. 方程 $A\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都是相容的, 当且仅当系数矩阵的阶梯形在每行中都有主元;
3. 方程 $A\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都有**唯一解**, 当且仅当系数矩阵 A 的阶梯形在每行和每列中都有主元.

第一个结论很平凡, 因为自由变量对应于非唯一性. 只是要强调, 这一结论**并不保证**存在性.

第二个结论稍复杂些. 若系数矩阵的每行都有主元, **增广**矩阵的最后一列就不会有主元, 因此无论右端项 $\mathbf{b}$ 是什么, 方程组都是相容的.

下面证明, 如果系数矩阵 A 的阶梯形中有零行, 那么可以选择一个右端项 $\mathbf{b}$ 使得方程组 $A\mathbf{x} = \mathbf{b}$ 是不相容的. 令 A_e 为系数矩阵 A 的阶梯形. 那么

$$A_e = EA$$

其中 E 是一系列初等矩阵之积, 对应于一系列行变换, $E = E_N \dots E_2 E_1$. 若 A_e 有零行, 那么其最后一行也为零. 因此, 如果取 $\mathbf{b}_e = (0, \dots, 0, 1)^T$

(除了最后一项以外各项全为 0) 那么方程

$$A_e \mathbf{x} = \mathbf{b}_e$$

无解. 方程两端同时左乘 E^{-1} , 并运用 $E^{-1}A_e = A$, 可得方程

$$A\mathbf{x} = E^{-1}\mathbf{b}_e$$

无解.

最后, 由结论 1 和 2 可立得结论 3. □

从以上对于主元的分析可得若干重要推论. 为此我们需要注意到

在阶梯形中, 任一行和任一列中至多存在一个主元 (可以没有主元).

3.1. 有关线性无关性和基的推论、维数

通过行化简, 很容易回答 $\mathbb{F}^n$ 中的向量组何时为基、线性无关组或张成组的问题.

命题 3.1. 设有向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in \mathbb{F}^n$, 并令 $A = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m]$ 是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 的 $n \times m$ 矩阵. 那么

1. 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 是线性无关的, 当且仅当 A 的阶梯形的每列都有主元;
2. 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 是 $\mathbb{F}^n$ 中的完备组 (张成组、生成组), 当且仅当 A 的阶梯形的每行都有主元;
3. 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 是 $\mathbb{F}^n$ 的基, 当且仅当 A 的阶梯形的每行与每列都有主元.

证明: 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in \mathbb{F}^n$ 线性无关, 当且仅当方程

$$x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \dots + x_m \mathbf{v}_m = \mathbf{0}$$

具有唯一 (平凡) 解 $x_1 = x_2 = \dots = x_m = 0$, 或等价于, 方程 $A\mathbf{x} = \mathbf{0}$ 具有唯一解 $\mathbf{x} = \mathbf{0}$. 根据前述结论 1, 这些等价于矩阵的阶梯形每列都有主元.

类似地, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in \mathbb{F}^n$ 是 $\mathbb{F}^n$ 中的完备组, 当且仅当方程

$$x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \dots + x_m \mathbf{v}_m = \mathbf{b}$$

对任意右端项 $\mathbf{b} \in \mathbb{F}^n$ 都有解. 根据前述结论 2, 这等价于矩阵的阶梯形的每行都有主元.

最后, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in \mathbb{F}^n$ 是 $\mathbb{F}^n$ 的基, 当且仅当方程

$$x_1 \mathbf{v}_1 + x_2 \mathbf{v}_2 + \cdots + x_m \mathbf{v}_m = \mathbf{b}$$

对任意右端项 $\mathbf{b} \in \mathbb{F}^n$ 都有唯一解. 根据前述结论 3, 这等价于 A 的阶梯形的每行和每列都有主元. $\square$

命题 3.2. $\mathbb{F}^n$ 中的任意线性无关组不能含有超过 n 个向量.

证明: 设向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in \mathbb{F}^n$ 线性无关, 并令 $A = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m]$ 是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 的 $n \times m$ 矩阵. 由命题 3.1, A 的阶梯形的每列都必有主元, 而这在 $m > n$ 时是不可能的 (主元的数目不会超过行数). $\square$

命题 3.3. 向量空间 V 中的任意两个基都有相同个数的向量.

证明: 设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m$ 是 V 中两个不同的基. 不失一般性, 可假设 $n \leq m$. 考虑定义如下的同构 $A: \mathbb{F}^n \rightarrow V$:

$$A\mathbf{e}_k = \mathbf{v}_k, \quad k = 1, 2, \dots, n,$$

其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{R}^n$ 的标准基.

由于 A^{-1} 也是同构, 因此向量组

$$A^{-1}\mathbf{w}_1, A^{-1}\mathbf{w}_2, \dots, A^{-1}\mathbf{w}_m$$

也是基 (见第 1 章的定理 6.6). 因此它是线性无关的, 则由命题 3.2 可知 $m \leq n$. 结合 $n \leq m$ 的假设即得 $m = n$. $\square$

接下来的结论是上述命题的一个特殊情况.

命题 3.4. $\mathbb{F}^n$ 中的任意一个基都恰有 n 个向量.

证明: 从上个命题可立即得到此结论, 不过也可以直接证明. 设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 是 $\mathbb{F}^n$ 的基, 并令 A 是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 的 $n \times m$ 矩阵. 该向量组是基, 意味着方程

$$A\mathbf{x} = \mathbf{b}$$

对任意 (所有可能的) 右端项 $\mathbf{b}$ 都有唯一解. 解的存在性表明该矩阵的简化阶梯形每行都有主元, 因此主元的数目恰为 n , 唯一性则表明系数矩阵 (的阶梯形) 每列都有主元. 因此

$$m = \text{列数} = \text{主元数} = n$$

$\square$

命题 3.5. $\mathbb{F}^n$ 中的任意张成 (生成) 组都至少包含 n 个向量.

证明: 设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 是 $\mathbb{F}^n$ 中的完备组, 并令 A 是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m$ 的 $n \times m$ 矩阵. 命题 3.1 的结论 2 表明, A 的阶梯形的每行都有主元. 因为主元数目不超过列数, 所以 $n \leq m$. $\square$

3.2. 有关可逆矩阵的推论

命题 3.6. 矩阵 A 可逆, 当且仅当其阶梯形的每行和每列都有主元.

证明: 我们在本节开头已讨论过, 方程 $A\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都有唯一解, 当且仅当 A 的阶梯形在每行和每列中都有主元. 又由第 1 章定理 6.8 知, 矩阵 (线性变换) A 是可逆的, 当且仅当方程 $A\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都有唯一解.

还有另一种证法: 我们知道矩阵可逆当且仅当它的各列形成一个基 (见第 1 章 6.4 小节的推论 6.9). 而上述命题 3.4 表明这等价于矩阵的阶梯形每行和每列都有主元. $\square$

由上述命题立得下述结论:

推论 3.7. 可逆矩阵必为方阵 ($n \times n$ 矩阵).

命题 3.8. 若方阵 ($n \times n$ 矩阵) 是左可逆的或右可逆的, 那么它是可逆的. 换言之, 为检验方阵 A 的可逆性, 只需检验 $AA^{-1} = I, A^{-1}A = I$ 之一.

注意, 此命题只适用于方阵!

证明: 我们知道矩阵 A 可逆当且仅当方程 $A\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都有唯一解. 而这又等价于矩阵 A 的阶梯形在每行和每列中都有主元.

若矩阵 A 是左可逆的, 那么方程 $A\mathbf{x} = \mathbf{0}$ 有唯一解 $\mathbf{x} = \mathbf{0}$. 的确如此: 若 B 是 A 的左逆 (也即 $BA = I$), 而 $\mathbf{x}$ 满足

$$A\mathbf{x} = \mathbf{0},$$

那么将此等式两端同时左乘 B , 即得到 $\mathbf{x} = \mathbf{0}$, 则此解唯一. 因此, A 的阶梯形在每列中都有主元 (无自由变量). 若矩阵 A 是方阵 ($n \times n$ 矩阵), 那么其阶梯形的每行也必有主元 (共 n 个主元, 而且每行至多有 1 个主元), 因此该矩阵是可逆的.

若矩阵 A 是右可逆的, 且 C 是 A 的右逆 ($AC = I$), 那么对于 $\mathbf{x} = C\mathbf{b}, \mathbf{b} \in \mathbb{F}^n$, 有

$$A\mathbf{x} = AC\mathbf{b} = I\mathbf{b} = \mathbf{b}.$$

因此, 对任意右端项 $\mathbf{b}$, 方程 $A\mathbf{x} = \mathbf{b}$ 都有解 $\mathbf{x} = C\mathbf{b}$. 于是 A 的阶梯形每行都有主元. 若 A 是方阵, 那么它的每列也都有主元, 故 A 可逆. $\square$

习题

3.1. b 取何值时, 方程组

$$\begin{pmatrix} 1 & 2 & 2 \\ 2 & 4 & 6 \\ 1 & 2 & 3 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ 4 \\ b \end{pmatrix}$$

有解? 对于该 b , 求方程组的通解.

3.2. 判断向量组

$$\begin{pmatrix} 1 \\ 1 \\ 0 \\ 0 \end{pmatrix}, \begin{pmatrix} 1 \\ 0 \\ 1 \\ 0 \end{pmatrix}, \begin{pmatrix} 0 \\ 0 \\ 1 \\ 1 \end{pmatrix}, \begin{pmatrix} 0 \\ 1 \\ 0 \\ 1 \end{pmatrix}$$

是否为线性无关的.

这四个向量能张成 $\mathbb{R}^4$ 吗? (换言之, 它是生成组吗?) $\mathbb{C}^4$ 呢?

3.3. 判断下面哪些向量组是 $\mathbb{R}^3$ 的基?

- a) $(1, 2, -1)^T, (1, 0, 2)^T, (2, 1, 1)^T$;
- b) $(-1, 3, 2)^T, (-3, 1, 3)^T, (2, 10, 2)^T$;
- c) $(67, 13, -47)^T, (\pi, -7.84, 0)^T, (3, 0, 0)^T$.

哪些向量组是 $\mathbb{C}^3$ 的基?

3.4. 多项式 $x^3 + 2x, x^2 + x + 1, x^3 + 5$ 能否生成 (张成) $\mathbb{P}_3$? 证明你的结论.

3.5. $\mathbb{F}^4$ 中的 5 个向量是否线性无关? 证明你的结论.

3.6. 证明或证伪: 若方阵 ($n \times n$ 矩阵) A 的列是线性无关的, 那么 $A^2 = AA$ 的列也是.

3.7. 证明或证伪: 若方阵 ($n \times n$ 矩阵) A 的列是线性无关的, 那么 $A^3 = AAA$ 的列也是.

3.8. 证明: 如果方程 $A\mathbf{x} = \mathbf{0}$ 有唯一解 (即 A 的阶梯形每列都有主元), 那么 A 是左可逆的.

提示: 初等矩阵可能有用处.

注意: 正文中已经证明, 若 A 是左可逆的则方程 $A\mathbf{x} = \mathbf{0}$ 具有唯一解. 此处你需要证明的是该结论的逆命题, 而正文中并未给出证明.

注: 这题可能很难, 因为它需要对书本内容有深刻的理解. 然而, 当理解需要做什么之后, 这道题就非常简单了.

3.9. 矩阵的简化阶梯形是唯一的吗？证明你的结论。

即，假设我们通过做任意行变换（不按照特定的算法）得到简化阶梯形矩阵。究竟是每次都会得到相同的矩阵，还是可能得到不同的矩阵？注意，只能做行变换，不允许做列变换。

提示：如果你是从可逆矩阵开始做变换呢？另外，主元是始终在同样的列中，还是根据所做的行变换不同而处于不同的列？如果你可以不通过（对简化阶梯形）做相反的行变换来推知主元列的位置，那么主元列的位置就不取决于行变换。

4. 通过行化简求 A^{-1}

如上面所讨论的，可逆矩阵必为方阵，并且其阶梯形必定在每行和每列中都有主元。所以可逆矩阵的简化阶梯形是恒等矩阵 I 。因此

任意可逆矩阵都行等价于（即可通过行变换化为）恒等矩阵。

下面陈述一个用于求出 $n \times n$ 矩阵的逆的简便算法：

1. 向 A 的右侧附上 $n \times n$ 恒等矩阵，将其**扩充**成 $n \times 2n$ 的矩阵 $(A|I)$ ；
2. 对扩充后的矩阵做行变换，将 A 变换为恒等矩阵 I ；
3. 我们添加的矩阵 I 在此过程中自动转化为 A^{-1} ；
4. 如果通过行变换不能把 A 变换为恒等矩阵，那么 A 不可逆。

上述算法有好几种解释。第一种（也是比较朴素的一种）是：我们知道对于可逆矩阵 A ，向量 $A^{-1}\mathbf{b}$ 是方程 $A\mathbf{x} = \mathbf{b}$ 的解。所以为了求出 A^{-1} 的第 k 列，我们需要求出 $A\mathbf{x} = \mathbf{e}_k$ 的解，其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{R}^n$ 的标准基。上述算法就是同时求解了如下 n 个方程

$$A\mathbf{x} = \mathbf{e}_k, \quad k = 1, 2, \dots, n$$

我们再展示一种更为“高级”的解释。之前我们讨论过，每次行变换都可通过左乘初等矩阵来实现。令 $E_1, E_2, \dots, E_N$ 是对应于我们所做的行变换的初等矩阵，并令 $E = E_N \cdots E_2 E_1$ 为它们的乘积¹。我们知道行变换可将 A 变为恒等矩阵，也即 $EA = I$ ，故 $E = A^{-1}$ 。而同样的行变换作用于扩充的矩阵 $(A|I)$ ，会将其变为 $(EA|E) = (I|A^{-1})$ 。□

这种运用初等矩阵的“高级”解释蕴涵了之后常用到的一个重要命题：

¹尽管此处顺序无关紧要，但请注意，若行变换 E_1 是最先进行的，那么在乘积中 E_1 是最右侧的一项。

定理 4.1. 任意可逆矩阵都可表示成若干初等矩阵之积.

证明: 如前两段所讨论的, $A^{-1} = E_N \cdots E_2 E_1$, 所以

$$A = (A^{-1})^{-1} = E_1^{-1} E_2^{-1} \cdots E_N^{-1}.$$

□

例. 假设我们要求出以下矩阵的逆.

$$\begin{pmatrix} 1 & 4 & -2 \\ -2 & -7 & 7 \\ 3 & 11 & -6 \end{pmatrix}.$$

向其右侧附上恒等矩阵, 并做行化简可得

$$\begin{aligned} & \left(\begin{array}{ccc|ccc} 1 & 4 & -2 & 1 & 0 & 0 \\ -2 & -7 & 7 & 0 & 1 & 0 \\ 3 & 11 & -6 & 0 & 0 & 1 \end{array} \right) \begin{array}{l} \\ +2R_1 \\ -3R_1 \end{array} \sim \left(\begin{array}{ccc|ccc} 1 & 4 & -2 & 1 & 0 & 0 \\ 0 & 1 & 3 & 2 & 1 & 0 \\ 0 & -1 & 0 & -3 & 0 & 1 \end{array} \right) \begin{array}{l} \\ \\ +R_2 \end{array} \sim \\ & \left(\begin{array}{ccc|ccc} 1 & 4 & -2 & 1 & 0 & 0 \\ 0 & 1 & 3 & 2 & 1 & 0 \\ 0 & 0 & 3 & -1 & 1 & 1 \end{array} \right) \begin{array}{l} \times 3 \\ \\ \end{array} \sim \left(\begin{array}{ccc|ccc} 3 & 12 & -6 & 3 & 0 & 0 \\ 0 & 1 & 3 & 2 & 1 & 0 \\ 0 & 0 & 3 & -1 & 1 & 1 \end{array} \right) \begin{array}{l} +2R_3 \\ -R_3 \\ \end{array} \sim \end{aligned}$$

在最后一次行变换中, 我们将第一行乘以 3 是为了在行化简的从下到上阶段中不出现分数. 继续做行化简有

$$\left(\begin{array}{ccc|ccc} 3 & 12 & 0 & 1 & 2 & 2 \\ 0 & 1 & 0 & 3 & 0 & -1 \\ 0 & 0 & 3 & -1 & 1 & 1 \end{array} \right) \begin{array}{l} -12R_2 \\ \\ \end{array} \sim \left(\begin{array}{ccc|ccc} 3 & 0 & 0 & -35 & 2 & 14 \\ 0 & 1 & 0 & 3 & 0 & -1 \\ 0 & 0 & 3 & -1 & 1 & 1 \end{array} \right)$$

将第一行和第三行除以 3, 就得到了逆矩阵

$$\begin{pmatrix} -35/3 & 2/3 & 14/3 \\ 3 & 0 & -1 \\ -1/3 & 1/3 & 1/3 \end{pmatrix}$$

习题

4.1. 求出下列矩阵的逆:

$$\begin{pmatrix} 1 & 2 & 1 \\ 3 & 7 & 3 \\ 2 & 3 & 4 \end{pmatrix}, \quad \begin{pmatrix} 1 & -1 & 2 \\ 1 & 1 & -2 \\ 1 & 1 & 4 \end{pmatrix}.$$

给出所有的步骤.

5. 维数、有限维向量空间

定义. 向量空间 V 的维数 $\dim V$ 是基所具有的向量个数.

对于只包含零向量 $\mathbf{0}$ 的向量空间, 规定 $\dim V = 0$; 若 V 不存在 (有限的) 基, 则规定 $\dim V = \infty$.

若 $\dim V$ 是有限值, 则称 V 是**有限维的**; 否则称其为**无限维的**.

命题 3.3 确保了维数是定义完善的, 也即, 它并不依赖于基的选取.

第 1 章的命题 2.8 表明, 向量空间 V 的任意有限张成组都包含一个基. 由此立得

命题 5.1. 向量空间 V 是有限维的, 当且仅当其具备有限张成组.

假设我们想检验有限维向量空间中的某向量组是否为基 (或者检验其是否为线性无关的, 或检验其是否完备). 最简单的方法大概是, 利用同构 $A: V \rightarrow \mathbb{R}^n, n = \dim V$ 将原问题转化到 $\mathbb{R}^n$ 中, 然后就可利用行化简 (分析主元) 来回答这样的问题.

注意, 若 $\dim V = n$, 那么同构 $A: V \rightarrow \mathbb{R}^n$ 总是存在的. 的确如此: 若 $\dim V = n$, 那么存在基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n \in V$, 于是可定义同构 $A: V \rightarrow \mathbb{R}^n$ 为

$$A\mathbf{v}_k = \mathbf{e}_k, \quad k = 1, 2, \dots, n.$$

下面给出命题 3.2 和 3.5 的两个推论, 作为上述方法的示例.

命题 5.2. 有限维向量空间 V 中的任意线性无关组不会具有超过 $\dim V$ 个向量.

证明: 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in V$ 为线性无关组, 并令 $A: V \rightarrow \mathbb{R}^n$ 为同构. 那么 $A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_m$ 是 $\mathbb{R}^n$ 中的线性无关组, 则由命题 3.2 知 $m \leq n$. $\square$

命题 5.3. 有限维向量空间 V 中的任意生成组一定具有至少 $\dim V$ 个向量.

证明: 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_m \in V$ 为 V 中的完备组, 并令 $A: V \rightarrow \mathbb{R}^n$ 为同构. 那么 $A\mathbf{v}_1, A\mathbf{v}_2, \dots, A\mathbf{v}_m$ 是 $\mathbb{R}^n$ 中的完备组, 则由命题 3.5 知 $m \geq n$. $\square$

5.1. 将线性无关组补全为基

下面结论将在后文发挥重要作用.

命题 5.4 (补全为基). 有限维向量空间中的线性无关组可被补全为基, 也即, 若 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是有限维向量空间 V 中的线性无关组, 那么可以找到向量 $\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n$, 使得向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的基.

证明: 令 $n = \dim V$. 取任意不属于 $\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$ 的向量, 记其为 $\mathbf{v}_{r+1}$ (这总是可以完成的, 因为向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 不是生成组). 由第 1 章的习题 2.5, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r, \mathbf{v}_{r+1}$ 是线性无关的 (注意, 由命题 5.2, $r < n$). 对新构造的向量组重复此步骤, 可得到向量 $\mathbf{v}_{r+2}$, 以此类推.

当我们得到生成组时, 就停止此过程. 注意, 这一过程不会无限持续下去, 因为 V 中的线性无关组不会具有超过 $n = \dim V$ 个向量. $\square$

5.2. 有限维向量空间的子空间

定理 5.5. 令 V 是向量空间 W 的子空间, 且 $\dim W < \infty$. 那么 V 是有限维的, 且 $\dim V \leq \dim W$.

此外, 若 $\dim V = \dim W$, 则 $V = W$ (仍假设 V 是 W 的子空间).

注. 这定理初看上去没什么意思——似乎只是命题 5.2 的简单推论. 然而, 仅在已有 V 的基时, 才能应用命题 5.2. 但此处我们只有 W 的基, 并且无法确定该基中有多少向量属于 V . 事实上, W 的这个基中可能没有一个向量属于 V ——很容易举出这样的例子.

定理 5.5 的证明: $V = \{0\}$ 为该定理的平凡情形. 现在假设 $V \neq \{0\}$.

我们的目标是找到 V 的一个基. 取非零向量 $\mathbf{v}_1 \in V$. 若 $V = \text{span}\{\mathbf{v}_1\}$, 我们就得到了所需的基 (包含单一向量 $\mathbf{v}_1$).

如若不然, 则用归纳法. 假设我们已经构造了 r 个线性无关的向量 $\mathbf{v}_1, \dots, \mathbf{v}_r \in V$. 若 $V = \text{span}\{\mathbf{v}_k : 1 \leq k \leq r\}$, 那么我们就寻得了 V 的基. 否则, 就存在向量 $\mathbf{v}_{r+1} \in V$, 满足 $\mathbf{v}_{r+1} \notin \text{span}\{\mathbf{v}_k : 1 \leq k \leq r\}$. 由第 1 章的习题 2.5, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r, \mathbf{v}_{r+1}$ 是线性无关的. $\square$

习题

5.1. 判断正误:

- 每个由有限向量组生成的向量空间都有基;
- 每个向量空间都有 (有限) 基;
- 一向量空间不会含有超过一个基;
- 若一向量空间包含有限基, 那么每个基所具有的向量数目都相同;
- $\mathbb{P}_n$ 的维数是 n ;
- $M_{m \times n}$ 的维数是 $m + n$;
- 若向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 生成 (张成) 向量空间 V , 那么 V 中每个向量都可唯一写成向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的线性组合;

- h) 有限维向量空间的每个子空间都是有限维的;
- i) 如果 V 是维数为 n 的向量空间, 那么 V 恰有一个维数为 0 和一个维数为 n 的子空间.
- 5.2. 证明: 若 V 是维数为 n 的向量空间, 那么 V 中的向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是线性无关的, 当且仅当其张成 V .
- 5.3. 证明: 向量空间 V 中的线性无关组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是基, 当且仅当 $n = \dim V$.
- 5.4. (旧题重温: 现在这道题应该很简单了) 是否可能出现这样的情况: 向量 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 是线性相关的, 但向量 $\mathbf{w}_1 = \mathbf{v}_1 + \mathbf{v}_2, \mathbf{w}_2 = \mathbf{v}_2 + \mathbf{v}_3$ 与 $\mathbf{w}_3 = \mathbf{v}_3 + \mathbf{v}_1$ 是线性无关的? 提示: 子空间 $\text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$ 的维数是多少?
- 5.5. 设向量组 $\mathbf{u}, \mathbf{v}, \mathbf{w}$ 是 V 的基. 证明: $\mathbf{u} + \mathbf{v} + \mathbf{w}, \mathbf{v} + \mathbf{w}, \mathbf{w}$ 也是 V 的基.
- 5.6. 考虑向量空间 $\mathbb{R}^5$ 中的向量 $\mathbf{v}_1 = (2, -1, 1, 5, -3)^T, \mathbf{v}_2 = (3, -2, 0, 0, 0)^T, \mathbf{v}_3 = (1, 1, 50, -921, 0)^T$.
- a) 证明: 这些向量是线性无关的;
- b) 将这个向量补全为基.
- 如果你先解 b), 那么你可以不做任何计算就完成整道题.

6. 线性方程组的通解

在接下来这短短一节中, 我们讨论线性方程组的通解 (即解集) 的结构.

称方程组 $A\mathbf{x} = \mathbf{b}$ 是齐次的, 若右端项 $\mathbf{b} = \mathbf{0}$, 即齐次方程组形式为 $A\mathbf{x} = \mathbf{0}$.

每个方程组

$$A\mathbf{x} = \mathbf{b}$$

都可通过取 $\mathbf{b} = \mathbf{0}$ 关联到一个齐次方程组.

定理 6.1 (线性方程组的通解). 令向量 $\mathbf{x}_1$ 满足方程 $A\mathbf{x} = \mathbf{b}$, 并令 H 为原方程所关联的齐次方程组

$$A\mathbf{x} = \mathbf{0}$$

的解集. 那么集合

$$\{\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_h : \mathbf{x}_h \in H\}$$

是方程 $A\mathbf{x} = \mathbf{b}$ 的解集.

该定理还可陈述为

$$\boxed{A\mathbf{x} = \mathbf{b} \text{ 的通解}} = \boxed{A\mathbf{x} = \mathbf{b} \text{ 的一个特解}} + \boxed{A\mathbf{x} = \mathbf{0} \text{ 的通解}}.$$

证明: 取定向量 $\mathbf{x}_1$ 满足 $A\mathbf{x}_1 = \mathbf{b}$. 令向量 $\mathbf{x}_h$ 满足 $A\mathbf{x}_h = \mathbf{0}$. 那么对于 $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_h$ 有

$$A\mathbf{x} = A(\mathbf{x}_1 + \mathbf{x}_h) = A\mathbf{x}_1 + A\mathbf{x}_h = \mathbf{b} + \mathbf{0} = \mathbf{b},$$

因此任意形如

$$\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_h, \quad \mathbf{x}_h \in H$$

的 $\mathbf{x}$ 都是 $A\mathbf{x} = \mathbf{b}$ 的解.

现设 $\mathbf{x}$ 满足 $A\mathbf{x} = \mathbf{b}$. 那么对于 $\mathbf{x}_h := \mathbf{x} - \mathbf{x}_1$ 有

$$A\mathbf{x}_h = A(\mathbf{x} - \mathbf{x}_1) = A\mathbf{x} - A\mathbf{x}_1 = \mathbf{b} - \mathbf{b} = \mathbf{0},$$

所以 $\mathbf{x}_h \in H$. 因此 $A\mathbf{x} = \mathbf{b}$ 的任意解 $\mathbf{x}$ 都能表示为 $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_h$, 其中 $\mathbf{x}_h \in H$. $\square$

这个定理的强大之处在于其普遍性. 它适用于所有的线性方程, 而且我们不需要假设向量空间是有限维的. 你还会在微分方程、积分方程、偏微分方程等各种场合与这个定理重逢. 除了表明解集的结构, 这个定理还使我们得以将对唯一性的分析与对存在性的研究分开. 也就是说, 要研究唯一性, 只需要分析齐次方程 $A\mathbf{x} = \mathbf{0}$ 解的唯一性 (这个方程总有解).

就本书内容而言, 这个定理有个直接的应用: 我们可借以检验方程组 $A\mathbf{x} = \mathbf{b}$ 的解. 例如, 考虑方程组

$$\begin{pmatrix} 2 & 3 & 1 & 4 & -9 \\ 1 & 1 & 1 & 1 & -3 \\ 1 & 1 & 1 & 2 & -5 \\ 2 & 2 & 2 & 3 & -8 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 17 \\ 6 \\ 8 \\ 14 \end{pmatrix}.$$

做行变换, 可求出该方程组的解

$$(6.1) \quad \mathbf{x} = \begin{pmatrix} 3 \\ 1 \\ 0 \\ 2 \\ 0 \end{pmatrix} + x_3 \begin{pmatrix} -2 \\ 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + x_5 \begin{pmatrix} 2 \\ -1 \\ 0 \\ 2 \\ 1 \end{pmatrix}, \quad x_3, x_5 \in \mathbb{F}.$$

此处的参数 x_3 和 x_5 可用任意其他字母替代, 比如说 t 和 s . 用 x_3 和 x_5 来表示, 只是为了提醒我们, 这些参数来自相应的自由变量.

现在假设这个解已给出, 并要检验其是否正确. 当然, 我们可以重做行变换, 但这太费时了. 并且, 如果解不是通过标准的方法获得的, 那么它可能与从行化简得到的解看起来不同. 例如,

$$(6.2) \quad \mathbf{x} = \begin{pmatrix} 3 \\ 1 \\ 0 \\ 2 \\ 0 \end{pmatrix} + s \begin{pmatrix} -2 \\ 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + t \begin{pmatrix} 0 \\ 0 \\ 1 \\ 2 \\ 1 \end{pmatrix}, \quad s, t \in \mathbb{F}$$

与 (6.1) 表示同样的解集 (你能看出为什么吗?), 这里我们只是将 (6.1) 中的最后一个向量替换成了它和第二个向量之和. 因此, 虽然这个式子和我们根据行化简得到的解不同, 但它是正确的.

检验 (6.1) 和 (6.2) 给出了正确解的最简单方法, 就是检验第一个向量 $(3, 1, 0, 2, 0)^T$ 满足方程 $A\mathbf{x} = \mathbf{b}$, 并且其余两个向量 (前面有参数的那两个向量) 满足原方程组所关联的齐次方程组 $A\mathbf{x} = \mathbf{0}$.

如果这些检验都通过了, 那么我们就可确信由 (6.1) 或 (6.2) 所确定的任意向量 $\mathbf{x}$ 都是原方程的解.

注意, 这种检验解的方法并不能保证 (6.1) 或 (6.2) 给出所有的解. 例如, 如果我们漏掉了系数为 x_3 的那一项, 上面的检验仍会全部通过.

所以, 如何保证在 (6.1) 中, 我们没有漏掉或是多出任何一个自由变量?

这就要重新数一下主元的数目. 在本例中, 做行变换可知主元数目为 3. 因此, 的确应有 2 个自由变量, 这样 (6.1) 中就没有任何遗漏.

如果要**证明**解的正确性, 我们就需要新的概念——矩阵的基本子空间和秩. 还要指出, 在本例中, 没必要做完整的行变换来检验的确只有 2 个自由变量, (6.1) 和 (6.2) 也都是正确的通解表达式.

习题

6.1. 判断正误:

- 任意线性方程组都至少有一个解;
- 任意线性方程组都至多有一个解;
- 任意齐次线性方程组都至少有一个解;
- 任意具有 n 个方程 n 个未知数的线性方程组都至少有一个解;
- 任意具有 n 个方程 n 个未知数的线性方程组都至多有一个解;
- 如果对应于给定线性方程组的齐次方程组有解, 那么原方程组有解;
- 如果具有 n 个方程 n 个未知数的齐次线性方程组的系数矩阵是可逆的, 那么该方程组没有非零解;
- 任意具有 m 个方程 n 个未知数的线性方程组的解集都是 $\mathbb{R}^n$ 的子空间;
- 任意具有 m 个方程 n 个未知数的齐次线性方程组的解集都是 $\mathbb{R}^n$ 的子空间.

6.2. 求出通解如下的 2×3 线性方程组 (具有 2 个方程、3 个未知数).

$$\begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix} + s \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}, \quad s \in \mathbb{R}.$$

7. 矩阵的基本子空间、秩

我们在第 1 章第 7 节讨论过, 每个线性变换 $A: V \rightarrow W$ 都与两个子空间相关联, 一个是它的核 (零空间)

$$\text{Ker } A = \text{Null } A := \{\mathbf{v} \in V : A\mathbf{v} = \mathbf{0}\} \subset V,$$

另一个是它的值域

$$\text{Ran } A = \{\mathbf{w} \in W : \mathbf{w} = A\mathbf{v}, \mathbf{v} \in V\} \subset W.$$

换言之, 核 $\text{Ker } A$ 是齐次方程 $A\mathbf{x} = \mathbf{0}$ 的解集, 值域 $\text{Ran } A$ 是使得方程 $A\mathbf{x} = \mathbf{b}$ 有解的所有右端项 $\mathbf{b} \in W$ 所成的集合.

若 A 是 $m \times n$ 矩阵, 即从 $\mathbb{F}^n$ 到 $\mathbb{F}^m$ 的映射, 那么由矩阵-向量乘法的“列乘以坐标”法则, 任意向量 $\mathbf{w} \in \text{Ran } A$ 可表示为 A 的列的线性组合. 这就能解释**列空间** (记号为 $\text{Col } A$) 这一名称的来历, 它常用作 $\text{Ran } A$ 的另一种表达.

对于矩阵 A , 在 $\text{Ran } A$ 和 $\text{Ker } A$ 以外, 还常讨论转置矩阵 A^T 的核与值域. 通常, $\text{Ran } A^T$ 称为**行空间**, 而 $\text{Ker } A^T$ 称为**左零空间** (但往往不用特别的记号来表示它们).

称 $\text{Ran } A, \text{Ker } A, \text{Ran } A^T, \text{Ker } A^T$ 这四个子空间是矩阵 A 的**基本子空间**. 本节我们将研究四个基本子空间维数上的重要关系.

我们将会用到下面定义——它是线性代数中基础性的定义之一.

定义. 对于线性变换 (矩阵) A , 其秩 $\text{rank } A$ 是 A 的值域的维数

$$\text{rank } A := \dim \text{Ran } A.$$

7.1. 计算基本子空间和秩

为计算矩阵的基本子空间和秩, 需要做行化简. 也即, 令 A 为矩阵, A_e 为其阶梯形:

1. 原矩阵 A 的主元列 (即做行变换之后, 所得阶梯形中具有主元的那些列) 就是 $\text{Ran } A$ 的一个基.

2. 阶梯形 A_e 的主元行给出了行空间的一个基. 当然, 也可以取原矩阵的转置并做行变换. 但是, 如果我们已经得到 A 的阶梯形 (比如说在计算 $\text{Ran } A$ 的过程中), 那么我们就可马上得到 $\text{Ran } A^T$.
3. 为了求出零空间 $\text{Ker } A$ 的基, 需要求解齐次方程 $A\mathbf{x} = \mathbf{0}$: 细节参见下面示例.

例. 考虑矩阵

$$\begin{pmatrix} 1 & 1 & 2 & 2 & 1 \\ 2 & 2 & 1 & 1 & 1 \\ 3 & 3 & 3 & 3 & 2 \\ 1 & 1 & -1 & -1 & 0 \end{pmatrix}.$$

做行变换可得阶梯形

$$\begin{pmatrix} \boxed{1} & 1 & 2 & 2 & 1 \\ 0 & 0 & \boxed{-3} & -3 & -1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

(这里框出了主元). 因此, 原矩阵的第 1、3 列, 也即

$$\begin{pmatrix} 1 \\ 2 \\ 3 \\ 1 \end{pmatrix}, \quad \begin{pmatrix} 2 \\ 1 \\ 3 \\ -1 \end{pmatrix}$$

给出了 $\text{Ran } A$ 的一个基. 我们还可马上得到行空间 $\text{Ran } A^T$ 的基: A 的阶梯形的第一、二行, 即向量

$$\begin{pmatrix} 1 \\ 1 \\ 2 \\ 2 \\ 1 \end{pmatrix}, \quad \begin{pmatrix} 0 \\ 0 \\ -3 \\ -3 \\ -1 \end{pmatrix}$$

(此处我们将向量竖写为列向量. 究竟是像此处一样竖写为列向量还是横写为行向量, 是个习惯问题. 这里写成列向量的理由是, 尽管我们称 $\text{Ran } A^T$ 是行空间, 但我们其实将它定义为 A^T 的列空间)

为计算零空间 $\text{Ker } A$ 的基, 我们需要解方程 $A\mathbf{x} = \mathbf{0}$. 计算 A 的简化阶梯形, 对于本例是

$$\begin{pmatrix} \boxed{1} & 1 & 0 & 0 & 1/3 \\ 0 & 0 & \boxed{1} & 1 & 1/3 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{pmatrix}.$$

注意, 在求解齐次方程 $A\mathbf{x} = \mathbf{0}$ 时, 并不需要写出完整的增广矩阵. 的确, 此时增广矩阵的最后一列全为 0, 在行变换中不会改变. 因此, 我们不需要真的写出它, 而只需记得有这一列, 则可从上述简化阶梯形中看出解为

$$\begin{cases} x_1 = -x_2 - \frac{1}{3}x_5, \\ x_2 \text{ 是自由变量,} \\ x_3 = -x_4 - \frac{1}{3}x_5 \\ x_4 \text{ 是自由变量,} \\ x_5 \text{ 是自由变量,} \end{cases}$$

或写成向量形式

$$(7.1) \quad \mathbf{x} = \begin{pmatrix} -x_2 - \frac{1}{3}x_5 \\ x_2 \\ -x_4 - \frac{1}{3}x_5 \\ x_4 \\ x_5 \end{pmatrix} = x_2 \begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} + x_4 \begin{pmatrix} 0 \\ 0 \\ -1 \\ 1 \\ 0 \end{pmatrix} + x_5 \begin{pmatrix} -1/3 \\ 0 \\ -1/3 \\ 0 \\ 1 \end{pmatrix}$$

每个自由变量之后的向量, 也即向量

$$\begin{pmatrix} -1 \\ 1 \\ 0 \\ 0 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} 0 \\ 0 \\ -1 \\ 1 \\ 0 \end{pmatrix}, \quad \begin{pmatrix} -1/3 \\ 0 \\ -1/3 \\ 0 \\ 1 \end{pmatrix}$$

形成 $\text{Ker } A$ 的基.

遗憾的是, 求出 $\text{Ker } A^T$ 的基并没有捷径——必须求解方程 $A^T \mathbf{x} = \mathbf{0}$. 已知 A 的阶梯形并无帮助.

7.2. 基本子空间的基的计算方式的解释

所以, 为什么以上方法确实能给出基本子空间的基呢?

7.2.1. 零空间 $\text{Ker } A$

零空间 $\text{Ker } A$ 的基的求法解释起来可能最容易: 因为我们求解了方程 $A\mathbf{x} = \mathbf{0}$, 即求出它所有的解, 那么 $\text{Ker } A$ 中所有向量都是我们所得各向量的线性组合. 因此, 我们所得各向量形成了 $\text{Ker } A$ 的张成组. 要看出这个向量组是线性无关的, 将每个向量都乘以对应的自由变量并求和——见 (7.1). 那么对于任意自由变量 x_k , 求和结果的第 k 项恰为 x_k (同样可见 (7.1)), 因此该结果 (线性组合) 为 $\mathbf{0}$ 只有一种可能, 就是所有自由变量都为 0.

7.2.2. 列空间 $\text{Ran } A$

下面我们解释列空间 $\text{Ran } A$ 的基的求法为何奏效. 首先, 注意到 A 的**简化阶梯形** A_{re} 的主元列形成 $\text{Ran } A_{\text{re}}$ 的基 (并不是原矩阵列空间的基, 而是其简化阶梯形列空间的基!). 因为行变换仅仅是左乘可逆矩阵, 所以它并不改变线性无关关系. 因此, **原**矩阵 A 的主元列也是线性无关的.

现在我们说明 A 的主元列张成 A 的列空间. 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是 A 的主元列, 并令 $\mathbf{v}$ 是 A 的任意一列. 我们要证明: $\mathbf{v}$ 可表示成主元列 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 的线性组合

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_r \mathbf{v}_r.$$

简化阶梯形 A_{re} 是由 A 左乘初等矩阵得到的:

$$A_{\text{re}} = EA$$

其中 E 是一系列初等矩阵的积, 因此 E 是可逆矩阵. 向量 $E\mathbf{v}_1, E\mathbf{v}_2, \dots, E\mathbf{v}_r$ 是 A_{re} 的主元列, 而 A 的其中一列 $\mathbf{v}$ 被变换为 A_{re} 的一列 $E\mathbf{v}$. 因为 A_{re} 的主元列形成 $\text{Ran } A_{\text{re}}$ 的基, 所以向量 $E\mathbf{v}$ 可表示为它们的线性组合

$$E\mathbf{v} = \alpha_1 E\mathbf{v}_1 + \alpha_2 E\mathbf{v}_2 + \dots + \alpha_r E\mathbf{v}_r.$$

将该等式两端同时左乘 E^{-1} , 可得如下表达式

$$\mathbf{v} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_r \mathbf{v}_r,$$

因此 A 的主元列的确张成 $\text{Ran } A$.

7.2.3. 行空间 $\text{Ran } A^T$

容易看出, A 的**阶梯形** A_e 的主元行是线性无关的. 的确如此: 令 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 是 A_e 的主元行的转置 (因为我们总将这些向量写成列向量). 假设

$$\alpha_1 \mathbf{w}_1 + \alpha_2 \mathbf{w}_2 + \dots + \alpha_r \mathbf{w}_r = \mathbf{0}.$$

考虑 $\mathbf{w}_1$ 的第一个非零项. 因为其他所有向量 $\mathbf{w}_2, \mathbf{w}_3, \dots, \mathbf{w}_r$ 的对应项都等于 0 (由阶梯形的定义), 我们可得 $\alpha_1 = 0$. 因此可以直接忽略求和式的第一项.

现在考虑 $\mathbf{w}_2$ 的第一个非零项. 向量 $\mathbf{w}_3, \dots, \mathbf{w}_r$ 的对应项都为 0, 因此 $\alpha_2 = 0$. 重复此过程, 我们可得 $\alpha_k = 0 \ \forall k = 1, 2, \dots, r$.

要看出 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 张成行空间, 请注意**行变换并不改变行空间**. 直接分析行变换过程就能看出这一点, 不过此处我们给出一种更为正式的证法.

对于变换 A 和集合 X , 我们记 $A(X)$ 是所有可被表示成 $y = A(x)$, $x \in X$ 的元素 y 所成的集合

$$A(X) := \{y = A(x) : x \in X\}.$$

若 A 是 $m \times n$ 矩阵, A_e 是其阶梯形, 由 A 左乘初等矩阵得到:

$$A_e = EA$$

其中 E 是 $m \times m$ 可逆矩阵 (初等矩阵的积). 那么

$$\text{Ran } A_e^T = \text{Ran}(A^T E^T) = A^T(\text{Ran } E^T) = A^T(\mathbb{R}^m) = \text{Ran } A^T,$$

因此, 的确有 $\text{Ran } A^T = \text{Ran } A_e^T$.

7.3. 秩定理、基本子空间的维数

在许多实际应用中, 都要求出矩阵列空间或零空间的基. 例如, 如上所示, 求解齐次方程组 $A\mathbf{x} = \mathbf{0}$ 就是求出零空间 $\text{Ker } A$ 的基. 求出列空间的基也就意味着从张成组中“提取”出一个基 (通过移除不必需的列向量).

然而, 上述基本子空间的基的计算方法的最重要应用, 就是得出这些子空间的维数关系.

定理 7.1 (秩定理). 对于矩阵 A ,

$$\text{rank } A = \text{rank } A^T.$$

该定理常表述为:

矩阵的**列秩**等于**行秩**.

该定理的证明很简单, 因为 $\text{Ran } A$ 和 $\text{Ran } A^T$ 的维数都等于 A 的阶梯形的主元的个数.

下面定理给出了基本子空间的维数之间的重要关系, 它也常被称为秩定理.

定理 7.2. 令 A 是 $m \times n$ 矩阵, 即从 $\mathbb{F}^n$ 到 $\mathbb{F}^m$ 的线性变换. 那么

1. $\dim \text{Ker } A + \text{rank } A = n$ (A 的定义域的维数);
2. $\dim \text{Ker } A^T + \text{rank } A = m$ (A 的目标空间的维数).

证明: 利用上述基本子空间的基的求法, 本证明非常简单. 第一个结论就是, 自由变量的数目 ($\dim \text{Ker } A$) 加上基本变量的数目 (主元的数目, 即 $\text{rank } A$) 等于列数 (n).

而对于第二个结论, 只需注意到 $\text{rank } A = \text{rank } A^T$, 就可知道它仅是将第一个结论应用于 A^T 的结果. $\square$

为演示上述定理的应用, 考虑第 6 节的例子. 彼时我们考虑了线性方程组

$$\begin{pmatrix} 2 & 3 & 1 & 4 & -9 \\ 1 & 1 & 1 & 1 & -3 \\ 1 & 1 & 1 & 2 & -5 \\ 2 & 2 & 2 & 3 & -8 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 17 \\ 6 \\ 8 \\ 14 \end{pmatrix}.$$

并求出了其通解表达式

$$\mathbf{x} = \begin{pmatrix} 3 \\ 1 \\ 0 \\ 2 \\ 0 \end{pmatrix} + x_3 \begin{pmatrix} -2 \\ 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + x_5 \begin{pmatrix} 2 \\ -1 \\ 0 \\ 2 \\ 1 \end{pmatrix}, \quad x_3, x_5 \in \mathbb{F}.$$

或

$$\mathbf{x} = \begin{pmatrix} 3 \\ 1 \\ 0 \\ 2 \\ 0 \end{pmatrix} + s \begin{pmatrix} -2 \\ 1 \\ 1 \\ 0 \\ 0 \end{pmatrix} + t \begin{pmatrix} 0 \\ 0 \\ 1 \\ 2 \\ 1 \end{pmatrix}, \quad s, t \in \mathbb{F}$$

在第 6 节中我们检验了这两个式子给出的向量 $\mathbf{x}$ 都确实是原方程的解. 但是, 我们如何保证这两个式子给出了**所有**解呢?

首先, 我们知道这两个式子中, 最后 2 个向量 (前面乘了参数的向量) 属于 $\text{Ker } A$. 容易看出, 两式中的这两个向量都是线性无关的 (两个向量线性相关, 当且仅当其中一个向量是另一个的若干倍).

现在计算维数: 交换前两行并做一轮行变换

$$\begin{matrix} -2R_1 \\ -R_1 \\ -2R_1 \end{matrix} \begin{pmatrix} 1 & 1 & 1 & 1 & -3 \\ 2 & 3 & 1 & 4 & -9 \\ 1 & 1 & 1 & 2 & -5 \\ 2 & 2 & 2 & 3 & -8 \end{pmatrix} \sim \begin{pmatrix} 1 & 1 & 1 & 1 & -3 \\ 0 & 1 & -1 & 2 & -3 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 1 & -2 \end{pmatrix}$$

从中已能看出有三个主元, 因此 $\text{rank } A \geq 3$. (其实我们已经能看出秩为 3, 但是此处只需要推到这个不等式就够了). 由定理 7.2, $\text{rank } A + \dim \text{Ker } A = 5$, 于是 $\dim \text{Ker } A \leq 2$, 因此 $\text{Ker } A$ 中不会有超过 2 个向

量线性无关. 因此, 上面表达式中的最后两个向量都形成 $\text{Ker } A$ 的基, 则这两个表达式都给出了原方程的所有解.

秩定理的一个重要推论, 就是下面这个将线性方程组解的存在性和唯一性关联起来的定理.

定理 7.3. 令 A 是 $m \times n$ 矩阵. 那么方程

$$A\mathbf{x} = \mathbf{b}$$

对于任一 $\mathbf{b} \in \mathbb{R}^m$ 都有解, 当且仅当对偶方程

$$A^T \mathbf{x} = \mathbf{0}$$

具有唯一解 (仅有平凡解). (注意, 第二个方程中是 A^T , 不是 A)

证明: 由定理 7.2 可立即得证 (只需计算维数). 我们将证明的细节留给读者作为习题. $\square$

第二个秩定理 (定理 7.2) 有一个非常优美的几何解释: 该定理的第一条是说, 如果变换 $A: \mathbb{F}^n \rightarrow \mathbb{F}^m$ 具有平凡的核 ($\text{Ker } A = \{\mathbf{0}\}$), 那么定义域 $\mathbb{F}^n$ 和值域 $\text{Ran } A$ 的维数相同. 如果核不是平凡的, 那么该变换会 “消掉” $\dim \text{Ker } A$ 维, 从而 $\dim \text{Ran } A = n - \dim \text{Ker } A$.

7.4. 将线性无关组补全为基

如之前第 5 节的命题 5.4 所述, 任意线性无关组都可补全为基, 即给定有限维向量空间 V 中的线性无关组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$, 可以找到 $\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n$, 使得向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的基.

理论上说, 该命题的证明给出了求向量 $\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_n$ 的算法, 但此算法并不实用.

本小节给出补全为基的一种更为实用的方法.

首先, 注意到如果 $m \times n$ 矩阵具有阶梯形, 那么它的非零行 (显然线性无关) 很容易被补全为整个空间 $\mathbb{F}^n$ 的基: 只需在合适位置加入几行², 使所得矩阵仍然具有阶梯形并在每列都有主元.

这样, 新矩阵的非零行就形成一个基, 并且我们还可以按任意次序列出它们, 因为向量组是否为基并不取决于向量的次序.

²并且不考虑零行, 就是将所有零行全部去掉. 后续向 A (原矩阵) 加入向量时, 也要把对应的非主元行去掉. ——译者注

现假设有线性无关向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r \in \mathbb{F}^n$. 考虑各行是 $\mathbf{v}_1^T, \mathbf{v}_2^T, \dots, \mathbf{v}_r^T$ 的矩阵 A , 做行变换得到其阶梯形 A_e . 前面我们讨论过, 很容易将 A_e 的行补全为 $\mathbb{F}^n$ 的基. 而且, 用于将 A_e 的行补全为基的向量也能将原向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 补全为基.

为看出这一点, 令向量 $\mathbf{v}_{r+1}, \dots, \mathbf{v}_n$ 将 A_e 的行补全为 $\mathbb{F}^n$ 的基. 那么, 如果我们向矩阵 A_e 加入行向量 $\mathbf{v}_{r+1}^T, \dots, \mathbf{v}_n^T$, 就能得到可逆矩阵. 称该矩阵为 $\tilde{A}_e$, 并令 $\tilde{A}$ 为向 A 加入行向量 $\mathbf{v}_{r+1}^T, \dots, \mathbf{v}_n^T$ 所得的矩阵. 矩阵 $\tilde{A}_e$ 可由 $\tilde{A}$ 通过行变换得到, 因此

$$\tilde{A}_e = E\tilde{A},$$

其中 E 是行变换对应初等矩阵的积. 那么 $\tilde{A} = E^{-1}\tilde{A}_e$, 则 $\tilde{A}$ 是一系列可逆矩阵的积, 故可逆.

这就意味着 $\tilde{A}$ 的行形成 $\mathbb{F}^n$ 的基, 即满足了我们的需求.

注. 补全为基的上述方法可能不是最为简单的, 但它有个主要优势: 适用于任意域上的向量空间.

习题

7.1. 判断正误:

- 矩阵的秩等于其非零列的数目;
- $m \times n$ 零矩阵是唯一秩为 0 的 $m \times n$ 矩阵;
- 初等行变换不改变秩;
- 初等列变换可能改变秩;
- 矩阵的秩等于该矩阵中线性无关列数目的最大值;
- 矩阵的秩等于该矩阵中线性无关行数目的最大值;
- $n \times n$ 矩阵的秩至多为 n ;
- 秩为 n 的 $n \times n$ 矩阵是可逆的.

7.2. 一个 54×37 矩阵的秩为 31. 它的四个基本子空间维数是多少?

7.3. 计算下列矩阵的四个基本子空间的秩和基:

$$\begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix}, \quad \begin{pmatrix} 1 & 2 & 3 & 1 & 1 \\ 1 & 4 & 0 & 1 & 2 \\ 0 & 2 & -3 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 \end{pmatrix}.$$

7.4. 证明: 若 $A: X \rightarrow Y$, 且 V 是 X 的子空间, 那么 $\dim AV \leq \text{rank } A$. (AV 此处表示将子空间 V 经 A 变换, 即 AV 中的任意向量都可表示为 $A\mathbf{v}, \mathbf{v} \in V$) 据此推导 $\text{rank}(AB) \leq \text{rank } A$.

注. 此处可用结论: 若 $V \subset W$ 则 $\dim V \leq \dim W$. 你理解这为什么成立吗?

- 7.5. 证明: 若 $A: X \rightarrow Y$, 且 V 是 X 的子空间, 那么 $\dim AV \leq \dim V$. 据此推导 $\text{rank}(AB) \leq \text{rank } B$.
- 7.6. 证明如果两个 $n \times n$ 矩阵 A 和 B 的乘积 AB 可逆, 那么 A 和 B 都可逆. 即便你知道行列式, 也不要——我们还没讲到那里. **提示:** 利用上面两题的结论.
- 7.7. 证明: 若 $A\mathbf{x} = \mathbf{0}$ 有唯一解, 那么方程 $A^T\mathbf{x} = \mathbf{b}$ 对于任意右端项 $\mathbf{b}$ 都有解. **提示:** 数主元的个数.
- 7.8. 写出具有对应性质的矩阵, 或者解释这样的矩阵为什么不存在:
 a) 列空间包含 $(1, 0, 0)^T, (0, 0, 1)^T$, 行空间包含 $(1, 1)^T, (1, 2)^T$;
 b) 列空间由 $(1, 1, 1)^T$ 张成, 零空间由 $(1, 2, 3)^T$ 张成;
 c) 列空间是 $\mathbb{R}^4$, 行空间是 $\mathbb{R}^3$.
提示: 首先检验维数关系.
- 7.9. A 和 B 的四个基本子空间相同, 是否意味着 $A = B$?
- 7.10. 将下列矩阵的行补全为 $\mathbb{R}^7$ 的基:

$$\begin{pmatrix} e^3 & 3 & 4 & 0 & -\pi & 6 & -2 \\ 0 & 0 & 2 & -1 & \pi^e & 1 & 1 \\ 0 & 0 & 0 & 0 & 3 & -3 & 2 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

- 7.11. 求出下列矩阵的列空间和行空间的基

$$\begin{pmatrix} 1 & 2 & -1 & 2 & 3 \\ 2 & 2 & 1 & 5 & 5 \\ 3 & 6 & -3 & 0 & 24 \\ -1 & -4 & 4 & -7 & 11 \end{pmatrix}$$

- 7.12. 对上题中的矩阵, 将它的行补全为 $\mathbb{R}^5$ 的基.
- 7.13. 对矩阵

$$A = \begin{pmatrix} 1 & i \\ i & -1 \end{pmatrix}$$

计算 $\text{Ran } A$ 和 $\text{Ker } A$. 关于这些子空间的关系, 可得出什么结论?

- 7.14. $\text{Ran } A = \text{Ker } A^T$ 可能对于实矩阵 A 成立吗? 复矩阵呢?
- 7.15. 将向量 $(1, 2, -1, 2, 3)^T, (2, 2, 1, 5, 5)^T, (-1, -4, 4, 7, -11)^T$ 补全为 $\mathbb{R}^5$ 的基.

8. 线性变换在任意基下的表示、坐标变换公式

我们现在学习的有关线性变换及其矩阵的知识, 很容易拓展到具备有限基的抽象向量空间上的线性变换. 在本节中, 我们会把线性变换 T 与其矩阵区分开, 这是因为我们会考虑不同的基, 进而线性变换可能有不同的矩阵表示.

8.1. 坐标向量

令 V 是向量空间, 具有基 $\mathcal{B} := \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$. 任意向量 $\mathbf{v} \in V$ 都可唯一表示为线性组合

$$\mathbf{v} = x_1 \mathbf{b}_1 + x_2 \mathbf{b}_2 + \dots + x_n \mathbf{b}_n = \sum_{k=1}^n x_k \mathbf{b}_k.$$

数 $x_1, x_2, \dots, x_n$ 称为向量 $\mathbf{v}$ 在基 $\mathcal{B}$ 下的**坐标**. 将 $\mathbf{v}$ 相应于基 $\mathcal{B}$ 的坐标组合成所谓**坐标向量**是很方便的. 该向量为列向量

$$[\mathbf{v}]_{\mathcal{B}} := \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{F}^n.$$

注意, 映射

$$\mathbf{v} \mapsto [\mathbf{v}]_{\mathcal{B}}$$

是 V 和 $\mathbb{F}^n$ 之间的同构. 它将基 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$ 变换为 $\mathbb{F}^n$ 的标准基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$.

8.2. 线性变换的矩阵

令 $T : V \rightarrow W$ 是线性变换, 并令 $\mathcal{A} = \{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}, \mathcal{B} := \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_m\}$ 分别为 V 和 W 的基.

变换 T 相应于基 $\mathcal{A}$ 和 $\mathcal{B}$ 的矩阵是一个 $m \times n$ 矩阵, 记为 $[T]_{\mathcal{B}\mathcal{A}}$, 它将坐标向量 $[T\mathbf{v}]_{\mathcal{B}}$ 与 $[\mathbf{v}]_{\mathcal{A}}$ 联系起来:

$$[T\mathbf{v}]_{\mathcal{B}} = [T]_{\mathcal{B}\mathcal{A}} [\mathbf{v}]_{\mathcal{A}}$$

注意符号 $\mathcal{A}$ 与 $\mathcal{B}$ 的平衡——这就是我们将第一个基 $\mathcal{A}$ 写在第二个位置的原因³.

矩阵 $[T]_{\mathcal{B}\mathcal{A}}$ 很容易求: 它的第 k 列就是坐标向量 $[T\mathbf{a}_k]_{\mathcal{B}}$ (对照 $\mathbb{F}^n$ 到 $\mathbb{F}^m$ 的线性变换的矩阵的求法).

类似于 $\mathbb{F}^n \rightarrow \mathbb{F}^m$ 的线性变换以及标准基的情形, 此处线性变换的复合也等价于它们矩阵的乘积, 只需稍微留意这些矩阵是关于哪些基. 即, 令 $T_1 : X \rightarrow Y$ 及 $T_2 : Y \rightarrow Z$ 是线性变换, 并令 $\mathcal{A}, \mathcal{B}$ 和 $\mathcal{C}$ 分别为 X, Y 和 Z 的基. 那么对复合变换 $T = T_2 T_1$

$$T : X \rightarrow Z, \quad T\mathbf{x} := T_2(T_1(\mathbf{x}))$$

³矩阵的第二个下标 $\mathcal{A}$ 与输入向量的下标 $\mathcal{A}$ 匹配, 作用之后就像“消去”了这个下标并留下第一个下标 $\mathcal{B}$, 而这与输出向量的下标 $\mathcal{B}$ 匹配. ——译者注

我们有

$$(8.1) \quad [T]_{\mathcal{CA}} = [T_2 T_1]_{\mathcal{CA}} = [T_2]_{\mathcal{CB}} [T_1]_{\mathcal{BA}}$$

(再次注意下标的平衡⁴)

这里的证明与针对带有标准基的 $\mathbb{F}^n$ 的证明完全一致, 所以此处我们就不赘述了. 还可以将此处的问题通过坐标同构 $\mathbf{v} \mapsto [\mathbf{v}]_{\mathcal{B}}$ 转化至 $\mathbb{F}^n$, 这样就无需任何证明, 只需将有关矩阵乘法的结论迁移过来即可.

8.3. 坐标变换矩阵

设向量空间 V 有两个基 $\mathcal{A} = \{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 和 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$. 考虑恒等变换 $I = I_V$ 及其关于这些基的矩阵 $[I]_{\mathcal{BA}}$. 根据定义有

$$[\mathbf{v}]_{\mathcal{B}} = [I]_{\mathcal{BA}} [\mathbf{v}]_{\mathcal{A}}, \quad \forall \mathbf{v} \in V,$$

也即, 对于任意向量 $\mathbf{v} \in V$, 矩阵 $[I]_{\mathcal{BA}}$ 将它在基 $\mathcal{A}$ 中的坐标变换为在基 $\mathcal{B}$ 中的坐标. 矩阵 $[I]_{\mathcal{BA}}$ 常称为 (从基 $\mathcal{A}$ 到基 $\mathcal{B}$ 的) **坐标变换矩阵**.

矩阵 $[I]_{\mathcal{BA}}$ 很容易计算: 根据求解线性变换矩阵的一般规则, 它的第 k 列是基 $\mathcal{A}$ 中第 k 个元素的坐标 $[\mathbf{a}_k]_{\mathcal{B}}$.

注意

$$[I]_{\mathcal{AB}} = ([I]_{\mathcal{BA}})^{-1},$$

(由矩阵乘法法则 (8.1) 可立得) 因此任意坐标变换矩阵都是可逆的.

8.3.1. 从标准基进行坐标变换

令 $V = \mathbb{F}^n$, 并设其中有基 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$, 也有标准基 $\mathcal{S} = \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$. 坐标变换矩阵 $[I]_{\mathcal{SB}}$ 很容易计算:

$$[I]_{\mathcal{SB}} = [\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n] =: B,$$

该矩阵就是第 k 列为列向量 $\mathbf{v}_k$ 的矩阵 B . 另一方向的变换矩阵则是

$$[I]_{\mathcal{BS}} = ([I]_{\mathcal{SB}})^{-1} = B^{-1}.$$

例如, 考虑 $\mathbb{F}^2$ 的基

$$\mathcal{B} = \left\{ \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 2 \\ 1 \end{pmatrix} \right\}$$

⁴ $[T_2]_{\mathcal{CB}}$ 的第二个下标 $\mathcal{B}$ 与 $[T_1]_{\mathcal{BA}}$ 的第一个下标匹配, 作用之后就像“消去”了这个下标, 留下的下标组合为 $\mathcal{CA}$, 而这与所得矩阵的下标匹配. ——译者注

并令 $\mathcal{S}$ 表示其的标准基. 那么

$$[I]_{\mathcal{S}\mathcal{B}} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix} =: B$$

并且

$$[I]_{\mathcal{B}\mathcal{S}} = [I]_{\mathcal{S}\mathcal{B}}^{-1} = B^{-1} = \frac{1}{3} \begin{pmatrix} -1 & 2 \\ 2 & -1 \end{pmatrix}$$

(我们已经知道了逆的计算方法, 并且也容易检验上述矩阵确实为 B 的逆)

8.3.2. 示例: 从标准基“中转”一下

在次数至多为 1 的多项式所构成的向量空间中, 有基

$$\mathcal{A} = \{1, 1+x\} \quad \text{和} \quad \mathcal{B} = \{1+2x, 1-2x\},$$

欲求坐标变换矩阵 $[I]_{\mathcal{B}\mathcal{A}}$.

当然, 可以从基 $\mathcal{A}$ 中取向量并将它分解为基 $\mathcal{B}$ 中向量的线性组合. 此过程涉及解线性方程组, 我们也知道如何求解.

但是, 我认为下面这种方式更简单. $\mathbb{P}_1$ 中还有标准基 $\mathcal{S} = \{1, x\}$, 并且关于该基有

$$[I]_{\mathcal{S}\mathcal{A}} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} =: A, \quad [I]_{\mathcal{S}\mathcal{B}} = \begin{pmatrix} 1 & 1 \\ 2 & -2 \end{pmatrix} =: B,$$

求其逆有

$$[I]_{\mathcal{A}\mathcal{S}} = A^{-1} = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix}, \quad [I]_{\mathcal{B}\mathcal{S}} = B^{-1} = \frac{1}{4} \begin{pmatrix} 2 & 1 \\ 2 & -1 \end{pmatrix}.$$

那么

$$[I]_{\mathcal{B}\mathcal{A}} = [I]_{\mathcal{B}\mathcal{S}} [I]_{\mathcal{S}\mathcal{A}} = B^{-1}A = \frac{1}{4} \begin{pmatrix} 2 & 1 \\ 2 & -1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$$

并且

注意下标的平衡.

$$[I]_{\mathcal{A}\mathcal{B}} = [I]_{\mathcal{A}\mathcal{S}} [I]_{\mathcal{S}\mathcal{B}} = A^{-1}B = \begin{pmatrix} 1 & -1 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & -2 \end{pmatrix}$$

8.4. 变换在不同基下的矩阵与坐标变换

令 $T: V \rightarrow W$ 为线性变换, 并令 $\mathcal{A}, \tilde{\mathcal{A}}$ 为 V 的两个基, $\mathcal{B}, \tilde{\mathcal{B}}$ 为 W 的两个基. 设我们已知矩阵 $[T]_{\mathcal{B}\mathcal{A}}$, 并欲求出相应于新基 $\tilde{\mathcal{A}}, \tilde{\mathcal{B}}$ 的矩阵表示, 即矩阵 $[T]_{\tilde{\mathcal{B}}\tilde{\mathcal{A}}}$. 计算方法非常简单:

要得到“新”基下的矩阵, 只需在“旧”基下的矩阵两侧“包上”坐标变换矩阵.

我并未提及需要用何种坐标变换矩阵, 因为如果遵从“下标平衡”规则, 就只有一种选择. 即, 线性变换关于不同基的矩阵表示遵从

$$[T]_{\tilde{\mathcal{B}}\tilde{\mathcal{A}}} = [I]_{\tilde{\mathcal{B}}\mathcal{B}}[T]_{\mathcal{B}\mathcal{A}}[I]_{\mathcal{A}\tilde{\mathcal{A}}}$$

只要明白各矩阵所进行的变换, 就可完成证明.

8.5. 定义域与目标空间共用一个基的情况: 相似矩阵

设 V 是向量空间, $\mathcal{A} = \{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 是 V 的基. 考察线性变换 $T: V \rightarrow V$, 令 $[T]_{\mathcal{A}\mathcal{A}}$ 是此变换相应于该基的矩阵 (对于“输入”和“输出”使用相同的基).

对于“输入”和“输出”使用相同的基这一情形十分重要 (因为在此情形下矩阵可以自乘), 因此我们更细致地研究一下这个情形. 注意, 该情形下, 常用更简单的记号 $[T]_{\mathcal{A}}$ 而不用 $[T]_{\mathcal{A}\mathcal{A}}$. 不过, 有两个下标的记号 $[T]_{\mathcal{A}\mathcal{A}}$ 更符合“下标平衡”规则, 所以我推荐在进行坐标变换时使用它 (至少要对它有印象).

令 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$ 是 V 的另一个基. 由前述坐标变换规则

$$[T]_{\mathcal{B}\mathcal{B}} = [I]_{\mathcal{B}\mathcal{A}}[T]_{\mathcal{A}\mathcal{A}}[I]_{\mathcal{A}\mathcal{B}}$$

回想一下:

$$[I]_{\mathcal{B}\mathcal{A}} = [I]_{\mathcal{A}\mathcal{B}}^{-1}$$

并记 $Q := [I]_{\mathcal{A}\mathcal{B}}$, 可将上面公式写为

$$[T]_{\mathcal{B}\mathcal{B}} = Q^{-1}[T]_{\mathcal{A}\mathcal{A}}Q.$$

这启发我们得到如下定义:

定义 8.1. 称矩阵 A 相似于矩阵 B , 如果存在可逆矩阵 Q , 使得 $A = Q^{-1}BQ$.

因为可逆矩阵必为方阵, 考虑维数即知, 相似矩阵 A 和 B 一定是大小相同的方阵. 若 A 相似于 B , 即 $A = Q^{-1}BQ$, 那么

$$B = QAQ^{-1} = (Q^{-1})^{-1}A(Q^{-1})$$

(因 Q^{-1} 可逆), 因此 B 相似于 A . 因此我们可以说 A 与 B 相似.

上面的推理说明, Q 和 Q^{-1} 的位置无关紧要: 也可以用式 $A = QBQ^{-1}$ 作为相似的定义.

上面的讨论还说明, 可以将相似矩阵当作同一线性算子 (变换) 的不同矩阵表示.

习题

8.1. 判断正误:

- a) 每个坐标变换矩阵都是方阵;
- b) 每个坐标变换矩阵都可逆;
- c) 称矩阵 A 和 B 相似, 若存在矩阵 Q 使得 $B = Q^T A Q$;
- d) 称矩阵 A 和 B 相似, 若存在矩阵 Q 使得 $B = Q^{-1} A Q$;
- e) 相似矩阵不一定是方阵.

8.2. 考虑向量组

$$(1, 2, 1, 1)^T, \quad (0, 1, 3, 1)^T, \quad (0, 3, 2, 0)^T, \quad (0, 1, 0, 0)^T.$$

- a) 证明: 它是 $\mathbb{F}^4$ 的基. 尽量少做计算.
- b) 求坐标变换矩阵, 将在这个基中的坐标变为 $\mathbb{F}^4$ 中的标准坐标 (即标准基 $\mathbf{e}_1, \dots, \mathbf{e}_4$ 中的坐标).

8.3. 求坐标变换矩阵, 将在 $\mathbb{P}_1$ 的基 $1, 1+t$ 中的坐标变为在基 $1-t, 2t$ 中的坐标.

8.4. 设 T 是 $\mathbb{F}^2$ 中的线性算子, 定义为 (标准坐标下)

$$T \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 3x + y \\ x - 2y \end{pmatrix}$$

求出 T 在标准基以及在下面这个基中的坐标.

$$(1, 1)^T, \quad (1, 2)^T$$

8.5. 证明: 若 A 和 B 为相似矩阵, 那么 $\text{trace } A = \text{trace } B$. **提示:** 回忆 $\text{trace}(XY)$ 和 $\text{trace}(YX)$ 的联系.

8.6. 矩阵

$$\begin{pmatrix} 1 & 3 \\ 2 & 2 \end{pmatrix} \quad \text{和} \quad \begin{pmatrix} 0 & 2 \\ 4 & 2 \end{pmatrix}$$

是否相似? 论证之.

第 3 章 行列式

1. 引入

读者大概已在微积分或代数课中接触了行列式（至少接触过 2×2 与 3×3 矩阵的行列式）。对于 2×2 矩阵

$$\begin{pmatrix} a & b \\ c & d \end{pmatrix}$$

其行列式为 $ad - bc$ ； 3×3 矩阵的行列式可用“大卫之星”法则¹求得。

在本章中，我们期望引入 $n \times n$ 矩阵的行列式。我不想仅仅给出正式的定义，而想首先给个引子，再导出行列式应具备的一些性质。接着，我们如果要使行列式具备这些性质，就必须按照若干（彼此等价的）方式来定义它，而没有别的选择。

从向量组的行列式出发，会比从矩阵的行列式出发更为方便。而这两者并无实质差别——我们总能将向量（视作列向量）组合成矩阵。

设我们有 $\mathbb{R}^n$ 中的 n 个向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ （注意各向量的长度与向量的个数相等），并且我们想求出由这些向量所确定的平行多面体的 n 维体积。

由向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 所确定的平行多面体，可定义为所有表示如下的向量 $\mathbf{v} \in \mathbb{R}^n$ 的集合：

$$\mathbf{v} = t_1 \mathbf{v}_1 + t_2 \mathbf{v}_2 + \dots + t_n \mathbf{v}_n, \quad 0 \leq t_k \leq 1 \quad \forall k = 1, 2, \dots, n.$$

$n = 2$ 与 $n = 3$ 的情况很容易可视化——分别为平行四边形和平行六面体。那么， n 维体积是什么呢？

$n = 2$ 时，即为面积； $n = 3$ 时，即为体积。维数为 1 时，即为长度。

¹对于 3×3 行列式

$$a = \begin{vmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & a_{3,3} \end{vmatrix}$$

有

$$a = \underbrace{a_{1,1}a_{2,2}a_{3,3} + a_{1,2}a_{2,3}a_{3,1} + a_{2,1}a_{3,2}a_{1,3}}_{\text{三条从左往右下的对角项之积}} - \underbrace{(a_{1,3}a_{2,2}a_{3,1} + a_{1,2}a_{2,1}a_{3,3} + a_{2,3}a_{3,2}a_{1,1})}_{\text{三条从右上往左下的对角项之积}}$$

——译者注

最后, 引入一些记号. 对于一组 (列) 向量 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$, 我们记其行列式 (这是我们将构造的概念) 为 $D(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$. 如果我们将这些向量组成一个矩阵 A (其中第 k 列为 $\mathbf{a}_k$), 那么我们使用记号 $\det A$:

$$\det A = D(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$$

并且, 对矩阵

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & \dots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{n,1} & a_{n,2} & \dots & a_{n,n} \end{pmatrix}$$

其行列式常记为:

$$\begin{vmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ a_{2,1} & a_{2,2} & \dots & a_{2,n} \\ \vdots & \vdots & & \vdots \\ a_{n,1} & a_{n,2} & \dots & a_{n,n} \end{vmatrix}.$$

2. 行列式应具备的性质

我们知道, 对于 2 维和 3 维情况, 平行多面体的“体积”是由“底面积乘高”规则确定的: 任取一向量, 则高等于从这个向量到剩余向量张成的子空间的距离, 底面积则由由剩余向量所确定的平行多面体的 $(n-1)$ 维体积.

现在, 我们将此处的思想推广到更高维度. 我们暂时不关心高和底面积的具体计算, 而是说明, 如果假设底面积和高满足一些自然的性质, 那么我们就能够唯一定义体积 (行列式), 而别无选择.

2.1. 对每个自变量的线性

首先, 如果我们将向量 $\mathbf{v}_1$ 乘以正数 a , 那么高 (即到线性张成空间 $\mathcal{L}\{\mathbf{v}_2, \dots, \mathbf{v}_n\}$ 的距离) 会被乘以 a . 如果我们允许负的高 (以及负的体积) 存在, 那么这个性质就会对所有标量 a 都成立, 因此向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的行列式 $D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n)$ 就应满足

$$D(a\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = aD(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n).$$

当然, 向量 $\mathbf{v}_1$ 并无任何特别之处, 所以对于任意下标 k 都有

$$(2.1) \quad D(\mathbf{v}_1, \dots, \underset{k}{a\mathbf{v}_k}, \dots, \mathbf{v}_n) = aD(\mathbf{v}_1, \dots, \underset{k}{\mathbf{v}_k}, \dots, \mathbf{v}_n)$$

接下来推导下个性. 注意到, 如果我们将 (某位置上的) 两向量相加, 那么所得结果的“高”应等于每个求和项的“高”之和, 即

$$(2.2) \quad D(\mathbf{v}_1, \dots, \underbrace{\mathbf{u}_k + \mathbf{v}_k}_k, \dots, \mathbf{v}_n) = \\ D(\mathbf{v}_1, \dots, \underbrace{\mathbf{u}_k}_k, \dots, \mathbf{v}_n) + D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_k}_k, \dots, \mathbf{v}_n)$$

换言之，上述两个性质表明， n 个向量的行列式**对每个自变量（向量）是线性的**，意即如果固定 $n-1$ 个向量而将剩余的那个向量视作自变量，我们就得到了一个线性函数。

注. 我们已经了解到，**线性**是一个绝佳的性质，它在很多情况下都大有用处。因此，允许负的高（从而允许负的体积）存在，只是为了得到线性而付出的微不足道的代价。后续如有必要，我们总可以加上绝对值。

事实上，我们并不因允许负的高存在而有任何损失！恰恰相反，我们反而得到了新东西——行列式的符号包含向量组的信息（取向）。

2.2. 如果两向量重合，则行列式为 0

若 $\mathbf{v}_j = \mathbf{v}_k$ ($j \neq k$)，那么向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是线性相关的，因此

$$\dim \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\} < n.$$

不过这样一来体积就一定为 0 【可这样理解：从 $\mathbf{v}_j$ 到 $\text{span}\{\mathbf{v}_r : r \neq j\}$ 的距离（“高”）是 0】。因此可以很自然地假设

$$(2.3) \quad D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = 0 \quad \text{若 } \mathbf{v}_j = \mathbf{v}_k (j \neq k).$$

后续我们还会用到行列式的这条性质。

注. 有个更强的性质是： $D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = 0$ 对于线性相关向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 成立。该性质也很自然。

然而，容易从更弱的假设 (2.3) 以及线性 (2.1) 和 (2.2) 推出此性质。详见命题 3.1。

2.3. 对“列替换”保持原值

接下来的性质看上去也很自然。它就是：如果我们取一向量（比如 $\mathbf{v}_j$ ），并且将它加上另一向量 $\mathbf{v}_k$ 的若干倍，那么“高”不变，因此

$$(2.4) \quad D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_j + \alpha \mathbf{v}_k}_j, \dots, \underbrace{\mathbf{v}_k}_k, \dots, \mathbf{v}_n) \\ = D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_j}_j, \dots, \underbrace{\mathbf{v}_k}_k, \dots, \mathbf{v}_n).$$

换言之，若施加第三类**列变换**，行列式不变。

不过, 该性质并不独立——它是式 (2.3) 以及线性 (2.1) 和 (2.2) 的简单推论. 也即

$$\begin{aligned}
 & D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_j + \alpha \mathbf{v}_k}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n) + \alpha D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n);
 \end{aligned}$$

此处第一个等号源于线性 (2.1) 和 (2.2), 而第二个等号即源于式 (2.3).

2.4. 反对称性

行列式应具备的下个性质是, 如果我们交换两个向量, 那么行列式

称多变量函数是**反对称的**, 若交换其任意两个自变量会导致函数值变号.

$$(2.5) \quad D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, \mathbf{v}_j, \dots, \mathbf{v}_n) = -D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n).$$

这个性质一眼看上去并不自然, 但其可由之前的性质推导出来. 即, 应用 (2.4) 三次, 再利用式 (2.1) 即得

$$\begin{aligned}
 & D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_j, \dots, \underbrace{\mathbf{v}_k - \mathbf{v}_j}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_j + (\mathbf{v}_k - \mathbf{v}_j)}_j, \dots, \underbrace{\mathbf{v}_k - \mathbf{v}_j}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, \underbrace{\mathbf{v}_k - \mathbf{v}_j}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, \underbrace{(\mathbf{v}_k - \mathbf{v}_j) - \mathbf{v}_k}_k, \dots, \mathbf{v}_n) \\
 &= D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, -\mathbf{v}_j, \dots, \mathbf{v}_n) \\
 &= -D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, \mathbf{v}_j, \dots, \mathbf{v}_n).
 \end{aligned}$$

回想一下, 性质 (2.4) 源于 (2.3) 和线性 (2.1)、(2.2), 因此反对称性 (2.5) 也源于那些性质.

2.5. 归一化

最后一个性质是最简单的一个. 对于 $\mathbb{R}^n$ 的标准基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$, 对应的平行多面体是 n 维单位立方体, 所以

$$(2.6) \quad D(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n) = 1.$$

用矩阵记号书写就是

$$\det(I) = 1$$

3. 构造行列式

接下来的安排是: 利用我们在第 2 节中所确定的行列式应具备的性质, 来导出行列式的其余性质 (其中有些是相当复杂的). 我们将展示如何用这些性质结合我们的惯用手段——行化简——来计算行列式.

然后, 在第 4 节中, 我们将展示行列式 (就是具有我们所需性质的一个函数) 是存在且唯一的. 毕竟, 我们需要确保我们计算与研究的对象是存在的.

我们起初以几何作为引子来引入行列式及其性质, 这源于考虑实向量空间 $\mathbb{R}^n$ 中的向量, 因此都只能关联到各项为实数的矩阵. 尽管如此, 以下的构造都只运用代数运算 (加法、乘法和除法), 因而适用于各项为复数的矩阵, 甚至是各项属于任意的域的矩阵.

因此, 接下来, 我们不仅仅是为实矩阵构造行列式, 而同样也为复矩阵 (及各项属于任意的域的矩阵) 进行构造. 从几何出发的引子很优美却只适用于实数情形, 但在我们选定了行列式的性质 (见下性质 1-3) 后, 所有讨论都适用于一般的情形.

3.1. 基本性质

我们将采用行列式的如下基本性质:

1. 行列式对于每列都是线性的, 用向量记号表述即对于任一下标 k , 对所有标量 α, β 都有

$$\begin{aligned} D(\mathbf{v}_1, \dots, \underbrace{\alpha \mathbf{u}_k + \beta \mathbf{v}_k}_k, \dots, \mathbf{v}_n) \\ = \alpha D(\mathbf{v}_1, \dots, \mathbf{u}_k, \dots, \mathbf{v}_n) + \beta D(\mathbf{v}_1, \dots, \mathbf{v}_k, \dots, \mathbf{v}_n) \end{aligned}$$

2. 行列式是**反对称的**, 即如果交换两列, 行列式变号;
3. 归一化性质: $\det I = 1$.

所有这些性质都在第 2 节中讨论了. 第一个性质就是结合了 (2.1) 和 (2.2), 第二个是式 (2.5), 而最后一个是式 (2.6). 注意, 我们并未用性质 (2.3) 和 (2.4)——它们可由上面三个性质推导出来. 由这三个性质就能完全定义行列式!

3.2. 由基本性质推导出的行列式性质

接下来, $\det A = D(\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$ 就是满足上面 3.1 节中所述三个性质的函数.

命题 3.1. 对于方阵 A , 下面结论成立:

1. 若 A 有一列是零, 那么 $\det A = 0$;
2. 若 A 有两列相等, 那么 $\det A = 0$;
3. 若 A 的其中一列是另一列的若干倍, 那么 $\det A = 0$;
4. 若 A 的各列线性相关, 即若该矩阵不可逆, 那么 $\det A = 0$.

证明: 结论 1 由线性立即可得——如果我们将为零的列乘以零, 我们并不会改变矩阵及其行列式. 而由上节所述性质 1, 我们应得到 0.

行列式的反对称性蕴涵了结论 2. 的确如此: 如果我们交换两个相等的列, 我们并没有改变向量组或矩阵 (行列式的自变量), 因此行列式保持不变; 另一方面, 交换两列会使行列式变号, 因此

$$\det A = -\det A$$

该式成立仅当 $\det A = 0$.

结论 3 是结论 2 和线性的一个很显然的推论.

为证明最后一个结论, 首先我们假设第一个向量 $\mathbf{v}_1$ 是其余向量的线性组合:

$$\mathbf{v}_1 = \alpha_2 \mathbf{v}_2 + \alpha_3 \mathbf{v}_3 + \cdots + \alpha_n \mathbf{v}_n = \sum_{k=2}^n \alpha_k \mathbf{v}_k.$$

然后由线性可知 (以向量记号表示)

$$\begin{aligned} D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) &= D\left(\left(\sum_{k=2}^n \alpha_k \mathbf{v}_k\right), \mathbf{v}_2, \mathbf{v}_3, \dots, \mathbf{v}_n\right) \\ &= \sum_{k=2}^n \alpha_k D(\mathbf{v}_k, \mathbf{v}_2, \mathbf{v}_3, \dots, \mathbf{v}_n) \end{aligned}$$

求和号中的每个行列式都等于零, 因为它们都含有两个相等的列.

让我们考虑一般的情况, 即考虑向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 线性相关的情形. 那么其中有一个向量, 比如说 $\mathbf{v}_k$, 可被表示成其他向量的线性组合. 将该向量和 $\mathbf{v}_1$ 交换, 我们就得到了刚刚讨论过的情形, 因此

$$D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_k, \dots}_{k}, \mathbf{v}_n) = -D(\mathbf{v}_k, \dots, \underbrace{\mathbf{v}_1, \dots}_{k}, \mathbf{v}_n) = -0 = 0,$$

故该情况中的行列式也是 0. $\square$

接下来的命题推广了性质 (2.4). 如我们之前所述, 该性质可从我们在本节所用的行列式的三大“基本”性质推导出来.

命题 3.2. 如果我们向其中一列加上其余列的线性组合 (并保持其余列不变), 那么行列式不变. 特别地, 行列式在“列替换” (第三类列变换) 下是保持原值的.

注意, 此处向一列加入自身的若干倍是不允许的, 我们只能加入其他列的倍数.

证明: 取定向量 $\mathbf{v}_k$, 并令 $\mathbf{u}$ 是其余向量的线性组合

$$\mathbf{u} = \sum_{j \neq k} \alpha_j \mathbf{v}_j.$$

于是由线性可得

$$\begin{aligned} D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_k + \mathbf{u}}_k, \dots, \mathbf{v}_n) \\ = D(\mathbf{v}_1, \dots, \underbrace{\mathbf{v}_k}_k, \dots, \mathbf{v}_n) + D(\mathbf{v}_1, \dots, \underbrace{\mathbf{u}}_k, \dots, \mathbf{v}_n), \end{aligned}$$

由命题 3.1 可得, 最后一项等于 0. $\square$

3.3. 对角矩阵与三角矩阵的行列式

下面我们准备计算几类重要的特殊矩阵的行列式. 第一类是所谓的**对角矩阵**. 回想一下, 称方阵 $A = \{a_{j,k}\}_{j,k=1}^n$ 是**对角的**, 若其**主对角线**之外的项全部为零, 也即对于所有 $j \neq k$ 有 $a_{j,k} = 0$. 我们常用记号 $\text{diag}\{a_1, a_2, \dots, a_n\}$ 来表示对角矩阵

$$\begin{pmatrix} a_1 & 0 & \dots & 0 \\ 0 & a_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & a_n \end{pmatrix}.$$

由于对角矩阵 $\text{diag}\{a_1, a_2, \dots, a_n\}$ 可由恒等矩阵将各列乘以常数 (第 k 列乘以 a_k) 得到, 所以

对角矩阵的行列式等于对角线上各项的乘积:

$$\det(\text{diag}\{a_1, a_2, \dots, a_n\}) = a_1 a_2 \dots a_n.$$

下一类重要矩阵是所谓**三角矩阵**. 称方阵 $A = \{a_{j,k}\}_{j,k=1}^n$ 是**上三角的**, 若所有在主对角线之下的项都为 0, 也即对于所有 $k < j$ 有 $a_{j,k} = 0$. 称方阵是**下三角的**, 若所有在主对角线之上的项都为 0, 也即对于所有 $j < k$ 有 $a_{j,k} = 0$. 称一矩阵是**三角的**, 若其是上三角的或是下三角的.

容易看出

三角矩阵的行列式等于对角线上各项的乘积:

$$\det A = a_{1,1}a_{2,2} \cdots a_{n,n}.$$

的确如此: 若一个三角矩阵的主对角线上有项为零, 那么其不可逆 (容易通过列变换来检验之), 因此上式两端都等于零. 若所有对角线上的项都非零, 那么利用列替换 (第三类列变换), 我们可将该矩阵转化成为对角矩阵 (且保持对角项不变): 对于上三角矩阵, 首先将第 $2, 3, \dots, n$ 列减去第一列的适当倍数, 将第一行中 (除第一项外) 全部变成 0, 然后将第 $3, \dots, n$ 列减去第二列的适当倍数, 以此类推.

对于下三角矩阵, 则需要从左到右进行“列化简”, 即首先将第 $n-1, \dots, 2, 1$ 各列减去最后一列的适当倍数, 以此类推.

3.4. 计算行列式

现在可以利用行列式的性质来进行计算: 只需做列化简 (即对 A^T 做行化简), 并且记录所有会使行列式变化的列变换. 好在, 最常用的变换——替换, 即第三类变换——不改变行列式的值. 因此我们只需记录两种变换: 列交换以及将列向量乘以标量.

若 A^T 的阶梯形并不是每列 (每行) 都有主元, 那么 A 不可逆, 因此 $\det A = 0$. 若 A 可逆, 我们就会得到三角矩阵, $\det A$ 就是对角项的乘积, 再乘上一个数用于修正“列交换”和“乘以标量”对行列式的改变.

由上述算法可得, $\det A$ 仅当矩阵 A 不可逆时为零. 将与命题 3.1 的最后一条结合可得

命题 3.3. $\det A = 0$ 当且仅当 A 不可逆. 等价的表述是: $\det A \neq 0$ 当且仅当 A 可逆.

注意, 尽管我们知道了如何计算行列式, 但行列式还是没有定义. 有人可能会问: 为什么不将其定义为上述算法的结果呢? 这样做的问题

在于，正式而言，这样的结果是不完善的——意思是，我们并没有证明用不同的列变换会得出相同的结果。

3.5. 积和转置的行列式、初等矩阵的行列式

定理 3.4 (转置的行列式). 对于方阵 A ,

$$\det A = \det(A^T).$$

该定理表明，我们上面讨论的所有关于列的结论同样适用于行。特别地，行列式在**行变换**和**列变换**下的表现是相同的。所以我们可以用行变换来计算行列式。

定理 3.5 (乘积的行列式). 对于 $n \times n$ 矩阵 A 和 B 有

$$\det(AB) = (\det A)(\det B)$$

换言之

乘积的行列式等于行列式的乘积。

两个定理的证明都要用到下述引理：

引理 3.6. 对方阵 A 和（大小相同的）初等矩阵 E 有

$$\det(AE) = (\det A)(\det E)$$

证明：完成证明只需确认这三件事：特殊（初等）矩阵的行列式（很容易计算）；右乘初等矩阵等同于做列变换；以及列变换对行列式的影响（已知）。

初等矩阵的行列式与对应的列变换效果一致，这看似是个巧合，实则不然：对于列变换，其对应的初等矩阵可通过对恒等矩阵 I 做对应的列变换来获得。因此，其行列式是 1（ I 的行列式）乘以列变换对行列式的改变。

至此，证明就完成了。乍一看有些不可思议，但上面几段就完成了对该引理**完整而严谨**的证明！□

应用引理 3.6 N 次可得下述推论。

推论 3.7. 对于任意矩阵 A ，以及任意一组初等矩阵 $E_1, E_2, \dots, E_N$ （所有矩阵都是 $n \times n$ 的）

$$\det(AE_1E_2 \dots E_N) = (\det A)(\det E_1)(\det E_2) \dots (\det E_N)$$

引理 3.8. 任意可逆矩阵都是一系列初等矩阵的乘积.²

定理 3.4 的证明: 首先, 容易验证, 对于任意初等矩阵都有 $\det E = \det(E^T)$. 注意, 只需对于可逆矩阵 A 证明此定理, 因为若 A 不可逆, 那么 A^T 也不可逆, 则两者的行列式都为零.

由引理 3.8, 矩阵 A 可表示为若干初等矩阵的乘积

$$A = E_1 E_2 \dots E_N,$$

由推论 3.7, A 的行列式等于初等矩阵的行列式之积. 由于取转置只会将每个初等矩阵都变为其转置并将乘的顺序反过来, 所以由推论 3.7 可知 $\det A = \det A^T$. $\square$

定理 3.5 的证明: 首先假设 B 可逆. 那么由引理 3.8 可得, B 可表示为若干初等矩阵之积

$$B = E_1 E_2 \dots E_N,$$

因此由推论 3.7

$$\det(AB) = (\det A)[(\det E_1)(\det E_2) \dots (\det E_N)] = (\det A)(\det B).$$

若 B 不可逆, 那么乘积 AB 也不可逆, 因此该定理也就是 $0 = 0$. 为证明乘积 $AB = C$ 不可逆, 假设其可逆. 那么将等式 $AB = C$ 同时左乘 C^{-1} , 可得 $C^{-1}AB = I$, 则 $C^{-1}A$ 是 B 的左逆, 因此 B 是左可逆的. 又由于 B 是方阵, 所以 B 可逆, 这就出现了矛盾. $\square$

3.6. 行列式性质总结

首先, 重申一遍: **行列式只对方阵有定义!** 由于我们知道了 $\det A = \det(A^T)$, 所以对于列成立的结论对于行也是成立的.

1. 行列式对于各行 (列) 都是线性的 **【将其余各行 (列) 固定】**.
2. 如果交换矩阵 A 的两行 (列), 那么行列式变号.
3. 对于三角矩阵 (特别地, 对角矩阵) 而言, 其行列式为对角项的乘积. 特别地, $\det I = 1$.
4. 若矩阵 A 有零行 (或零列), 则 $\det A = 0$.
5. 若 A 有两行 (列) 相等, 那么 $\det A = 0$.
6. 若 A 的其中一行 (列) 是另一些行 (列) 的线性组合, 也即, 若该矩阵不可逆, 那么 $\det A = 0$.

更一般地,

²这其实是第 2 章的定理 4.1. 故原书此处的证明略去. ——译者注

7. $\det A = 0$ 当且仅当 A 不可逆. 或者等价地说:
8. $\det A \neq 0$ 当且仅当 A 可逆.
9. 若我们向矩阵 A 的一行 (列) 加入其余行 (列) 的线性组合, 那么 $\det A$ 不变. 特别地, 在行 (列) 替换下【也即在第三类行 (列) 变换下】, 行列式保持原值.
10. $\det A^T = \det A$.
11. $\det(AB) = (\det A)(\det B)$.

最后:

12. 若 A 为 $n \times n$ 矩阵, 那么 $\det(aA) = a^n(\det A)$.

最后一个性质源于行列式的线性——回忆一下, 要将矩阵 A 乘以 a , 我们需要将各行都乘以 a , 其中每次乘法都会将行列式乘以 a .

习题

- 3.1. 若 A 为 $n \times n$ 矩阵, 那么行列式 $\det A$ 和 $\det(5A)$ 有什么联系?

注: $\det(5A) = 5 \det A$ 只在 1×1 的平凡情形成立.

- 3.2. 若 A 、 B 如下, 那么行列式 $\det A$ 和 $\det B$ 有什么联系?

a)

$$A = \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix}, \quad B = \begin{pmatrix} 2a_1 & 3a_2 & 5a_3 \\ 2b_1 & 3b_2 & 5b_3 \\ 2c_1 & 3c_2 & 5c_3 \end{pmatrix};$$

b)

$$A = \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix}, \quad B = \begin{pmatrix} 3a_1 & 4a_2 + 5a_1 & 5a_3 \\ 3b_1 & 4b_2 + 5b_1 & 5b_3 \\ 3c_1 & 4c_2 + 5c_1 & 5c_3 \end{pmatrix}.$$

- 3.3. 利用行变换或列变换来计算下列行列式:

$$\begin{vmatrix} 0 & 1 & 2 \\ -1 & 0 & -3 \\ 2 & 3 & 0 \end{vmatrix}, \quad \begin{vmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{vmatrix}, \quad \begin{vmatrix} 1 & 0 & -2 & 3 \\ -3 & 1 & 1 & 2 \\ 0 & 4 & -1 & 1 \\ 2 & 3 & 0 & 1 \end{vmatrix}, \quad \begin{vmatrix} 1 & x \\ 1 & y \end{vmatrix}.$$

- 3.4. 称方阵 ($n \times n$ 矩阵) A 是斜对称的 (或反对称的), 若 $A^T = -A$. 证明: 若 A 是斜对称的且 n 为奇数, 那么 $\det A = 0$. 该结论在 n 为偶数时还成立吗?
- 3.5. 称方阵 A 是**幂零的**, 若对某正整数 k 有 $A^k = \mathbf{0}$. 证明: 对幂零矩阵 A 有 $\det A = 0$.
- 3.6. 证明: 若矩阵 A 和 B 相似, 则 $\det A = \det B$.
- 3.7. 称实方阵 Q 为正交的, 若 $Q^T Q = I$. 证明: 若 Q 为正交矩阵, 则 $\det Q = \pm 1$.
- 3.8. 证明:

$$\begin{vmatrix} 1 & x & x^2 \\ 1 & y & y^2 \\ 1 & z & z^2 \end{vmatrix} = (z-x)(z-y)(y-x).$$

这是所谓范德蒙行列式的一个特例.

- 3.9. 设平面 $\mathbb{R}^2$ 中的点 A 、 B 和 C 的坐标分别为 (x_1, y_1) 、 (x_2, y_2) 和 (x_3, y_3) . 证明: 三角形 ABC 的面积是

$$\frac{1}{2} \begin{vmatrix} 1 & x_1 & y_1 \\ 1 & x_2 & y_2 \\ 1 & x_3 & y_3 \end{vmatrix}.$$

的绝对值.

提示: 利用行变换与 2×2 行列式的几何意义 (面积).

- 3.10. 令 A 为方阵. 证明分块三角矩阵

$$\begin{pmatrix} I & * \\ \mathbf{0} & A \end{pmatrix}, \quad \begin{pmatrix} A & * \\ \mathbf{0} & I \end{pmatrix}, \quad \begin{pmatrix} I & \mathbf{0} \\ * & A \end{pmatrix}, \quad \begin{pmatrix} A & \mathbf{0} \\ * & I \end{pmatrix}$$

的行列式都等于 $\det A$. 此处 $*$ 为任意矩阵.

下面这几题展示了分块矩阵记号的强大用处.

- 3.11. 利用上一题的结论证明: 若 A 和 C 是方阵, 那么

$$\det \begin{pmatrix} A & B \\ \mathbf{0} & C \end{pmatrix} = \det A \det C.$$

$$\text{提示: } \begin{pmatrix} A & B \\ \mathbf{0} & C \end{pmatrix} = \begin{pmatrix} I & B \\ \mathbf{0} & C \end{pmatrix} \begin{pmatrix} A & \mathbf{0} \\ \mathbf{0} & I \end{pmatrix}.$$

- 3.12. 令 A 是 $m \times n$ 矩阵, B 是 $n \times m$ 矩阵. 证明:

$$\det \begin{pmatrix} \mathbf{0} & A \\ -B & I \end{pmatrix} = \det(AB).$$

提示: 尽管可以通过做行变换将该矩阵转化为容易计算行列式的形式, 最简单的方法还是将该矩阵右乘 $\begin{pmatrix} I & \mathbf{0} \\ B & I \end{pmatrix}$.

4. 正式定义、行列式的存在性与唯一性

本节我们介绍行列式的正式定义. 我们说明, 满足第3节中基本性质 1、2 和 3 的函数存在, 此外, 它还是唯一的, 也即, 我们构造行列式时没有其他可选余地.

考虑 $n \times n$ 矩阵 $A = \{a_{j,k}\}_{j,k=1}^n$, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是它的列, 也即

$$\mathbf{v}_k = \begin{pmatrix} a_{1,k} \\ a_{2,k} \\ \vdots \\ a_{n,k} \end{pmatrix} = a_{1,k}\mathbf{e}_1 + a_{2,k}\mathbf{e}_2 + \dots + a_{n,k}\mathbf{e}_n = \sum_{j=1}^n a_{j,k}\mathbf{e}_j.$$

利用行列式的线性, 对第一列 $\mathbf{v}_1$ 展开:

$$(4.1) \quad D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) =$$

$$D\left(\sum_{j=1}^n a_{j,1}\mathbf{e}_j, \mathbf{v}_2, \dots, \mathbf{v}_n\right) = \sum_{j=1}^n a_{j,1}D(\mathbf{e}_j, \mathbf{v}_2, \dots, \mathbf{v}_n).$$

接着对第二列、第三列……展开, 可得

$$D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = \sum_{j_1=1}^n \sum_{j_2=1}^n \cdots \sum_{j_n=1}^n a_{j_1,1} a_{j_2,2} \cdots a_{j_n,n} D(\mathbf{e}_{j_1}, \mathbf{e}_{j_2}, \dots, \mathbf{e}_{j_n}).$$

注意, 我们需要对每列的求和采用不同的下标——记作 $j_1, j_2, \dots, j_n$, 下标 j_1 就是 (4.1) 中的下标 j .

这个求和式非常长——包含 n^n 项. 好在, 其中有些项是零. 即, 如果下标 $j_1, j_2, \dots, j_n$ 中任意两个是相同的, 那么行列式 $D(\mathbf{e}_{j_1}, \mathbf{e}_{j_2}, \dots, \mathbf{e}_{j_n})$ 等于零, 因为其中有两列相等.

因此, 我们重写一下这个求和, 将所有为零的项都略去. 为此最便利的方法要利用**置换**的概念. 非正式地说, 有序集合 $\{1, 2, \dots, n\}$ 的置换是对其各项的重排. 这种重排的一种简捷却正式的表达法, 是用函数

$$\sigma: \{1, 2, \dots, n\} \rightarrow \{1, 2, \dots, n\},$$

其中 $\sigma(1), \sigma(2), \dots, \sigma(n)$ 给出了集合 $1, 2, \dots, n$ 的新顺序. 换言之, 置换 σ 将有序集合 $1, 2, \dots, n$ 重排为 $\sigma(1), \sigma(2), \dots, \sigma(n)$.

这样的函数 σ 必须是一一对一 (对不同的输入产生不同的输出) 且满的 (可取目标空间的所有值). 一一对一且满的函数称为**双射**, 它们给出了定义域和目标空间之间的一一对应关系.³

插句题外话: 注意, 集合 $\{1, 2, \dots, n\}$ 的所有不同置换的数目恰为 $n!$ (这是组合数学中的知名结论). 集合 $\{1, 2, \dots, n\}$ 的所有不同置换所构成的集合将记为 $\text{Perm}(n)$.

利用置换的概念, 我们可将行列式重写为

$$D(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = \sum_{\sigma \in \text{Perm}(n)} a_{\sigma(1),1} a_{\sigma(2),2} \cdots a_{\sigma(n),n} D(\mathbf{e}_{\sigma(1)}, \mathbf{e}_{\sigma(2)}, \dots, \mathbf{e}_{\sigma(n)}).$$

各列为 $\mathbf{e}_{\sigma(1)}, \mathbf{e}_{\sigma(2)}, \dots, \mathbf{e}_{\sigma(n)}$ 的矩阵可从恒等矩阵经有限多次列交换得到, 所以行列式

$$D(\mathbf{e}_{\sigma(1)}, \mathbf{e}_{\sigma(2)}, \dots, \mathbf{e}_{\sigma(n)})$$

等于 1 或 -1 , 取决于列交换的次数.

³通过双射 σ 表示置换还有一种典型的写法, 在这种写法中, $\sigma(k)$ 给出了第 k 项经排序后的位置, 则 σ 将 $\sigma(1), \sigma(2), \dots, \sigma(n)$ 重排为 $1, 2, \dots, n$.

尽管在已知集合 $1, 2, \dots, n$ 的重排结果时用第一种表示更容易写出函数, 但是第二种表示更适合表达置换的复合——置换的复合与函数的复合是一致的. 即, 如果我们首先进行相应于函数 σ 的置换, 再进行相应于 τ 的置换, 最终置换将对应于 $\tau \circ \sigma$.

为给出形式化的表达, 我们(不严格地)定义置换 σ 的**符号**(记为 $\text{sign } \sigma$): 如果将 n 元组 $1, 2, \dots, n$ 重排为 $\sigma(1), \sigma(2), \dots, \sigma(n)$ 需要做偶数次交换, 那么置换的符号为 1; 若交换次数为奇数, 那么 $\text{sign } \sigma = -1$.

组合数学中有个知名的结论: 置换的符号是定义完善的. 也即, 尽管从 $1, 2, \dots, n$ 得到同一 n 元组 $\sigma(1), \sigma(2), \dots, \sigma(n)$ 的方式有无穷多种, 但是所做交换的次数要么总是偶数要么总是奇数.

说明这点的一种方法, 是引入符号的另一种定义. 令 $K = K(\sigma)$ 是 σ 的**逆序数**, 即满足 $\sigma(j) > \sigma(k)$ 的数对 (j, k) ($j, k \in \{1, 2, \dots, n\}, j < k$) 的数量, 然后观察数 K 是偶数还是奇数. 若 K 为奇数, 则称置换 σ 是**奇置换**, 否则称其为**偶置换**. 那么定义 $\text{sign } \sigma := (-1)^{K(\sigma)}$. 注意, 按这种方式, $\text{sign } \sigma$ 是定义完善的.

我们要证明, $\text{sign } \sigma = (-1)^{K(\sigma)}$ 的确可通过计算将 n 元组 $1, 2, \dots, n$ 重排为 $\sigma(1), \sigma(2), \dots, \sigma(n)$ 中所做交换的次数得到 (如前所述).

若 $\sigma(k) = k \forall k$, 那么**逆序数** $K(\sigma)$ 是 0, 所以该**恒等置换**的符号为 1. 并注意, 每次相邻交换 (交换两相邻项) 都改变置换的符号, 因为它将**逆序数**改变 (增加或减少) 1. 因此, 从一个置换得到另一个的过程中, 如果做了偶数次相邻交换, 则前后两个置换的符号相同, 否则不同.

最后, 交换任意两项都可通过进行奇数次相邻交换完成. 这就表明, 交换任意两项都会改变置换的**符号**. 所以, 从 $1, 2, \dots, n$ 得到偶置换 (符号为正) 总是需要进行偶数次交换, 而要得到奇置换 (符号为负) 则需要奇数次交换.

因此, 如果我们希望行列式满足第 3 节中基本性质 1-3, 我们须将其定义为

$$(4.2) \quad \det A = \sum_{\sigma \in \text{Perm}(n)} a_{\sigma(1),1} a_{\sigma(2),2} \dots a_{\sigma(n),n} \text{sign}(\sigma),$$

其中求和会遍历集合 $\{1, 2, \dots, n\}$ 的所有置换.

若我们将行列式定义如上, 则容易检验它满足第 3 节中基本性质 1-3. 的确, 它对于每列都是线性的, 因为对于每列来说, 求和中的每项 (乘积) 都只包含该列的一项.

交换 A 的两列仅仅是对每个置换都额外做了一次交换, 所以 (4.2) 的右端改变符号. 最后, 对于恒等矩阵 I , (4.2) 的右端是 1 (仅有一项非零).

习题

- 4.1. 假设置换 σ 将 $(1, 2, 3, 4, 5)$ 对应到 $(5, 4, 1, 2, 3)$.
- 求出 σ 的符号;
 - $\sigma^2 := \sigma \circ \sigma$ 作用于 $(1, 2, 3, 4, 5)$ 会得到什么?
 - 逆置换 σ^{-1} 作用于 $(1, 2, 3, 4, 5)$ 会得到什么?
 - σ^{-1} 的符号是什么?
- 4.2. 令 P 为置换矩阵, 即包含 0 和 1 的 $n \times n$ 矩阵, 并且在每行和每列中都恰有一个 1.
- 你能描述这个矩阵对应的线性变换吗? 这就能解释其名称的来历.
 - 证明: P 可逆. 你可否描述 P^{-1} ?
 - 证明: 对于某个 $N > 0$ 有

$$P^N := \underbrace{PP \cdots P}_{N \text{ 个}} = I.$$

利用结论: 置换的个数是有限的.

- 4.3. 为什么 $(1, 2, \dots, 9)$ 的置换有偶数个, 并且其中奇置换恰好占一半? 提示: 该问题用置换的知识可能很难解答, 但利用行列式就很容易.
- 4.4. 若 σ 是奇置换, 解释为何 σ^2 是偶置换, 而 σ^{-1} 是奇置换.
- 4.5. 利用正式定义 (4.2) 来计算 $n \times n$ 矩阵的行列式需要多少次乘法和加法? 不考虑 $\text{sign } \sigma$ 的计算过程.

5. 余子式展开

对 $n \times n$ 矩阵 $A = \{a_{j,k}\}_{j,k=1}^n$, 令 $A_{j,k}$ 表示将 A 的第 j 行和第 k 列划去后得到的 $(n-1) \times (n-1)$ 矩阵.

定理 5.1 (行列式的余子式⁴展开). 令 A 是 $n \times n$ 矩阵. 对每个 $j, 1 \leq j \leq n$, A 的行列式可按第 j 行展开成

$$\begin{aligned} \det A &= a_{j,1}(-1)^{j+1} \det A_{j,1} + a_{j,2}(-1)^{j+2} \det A_{j,2} + \cdots + a_{j,n}(-1)^{j+n} \det A_{j,n} \\ &= \sum_{k=1}^n a_{j,k}(-1)^{j+k} \det A_{j,k}. \end{aligned}$$

类似地, 对每个 $k, 1 \leq k \leq n$, 行列式可按第 k 列展开成

$$\det A = \sum_{j=1}^n a_{j,k}(-1)^{j+k} \det A_{j,k}.$$

证明: 首先证明按第 1 行展开的公式. 然后通过交换第 1、2 行得到按第 2 行展开的公式, 接着交换第 2、3 行可得按第 3 行展开的公式,

⁴本节所述“余子式”(cofactor)在国内教材中常称作“代数余子式”. ——译者注

以此类推.

因为 $\det A = \det A^T$, 所以按列展开无需额外证明.

首先考虑一种特殊情况, 就是第一行只有一个非零项 $a_{1,1}$. 对第 $2, 3, \dots, n$ 列进行列变换, 可将 A 变为下三角形. 则 A 的行列式可按下列式计算:

$$\boxed{\text{三角矩阵对角项的乘积}} \times \boxed{\text{因列变换所致行列式变化的“修正系数”}}$$

除了第一个对角项 ($a_{1,1}$) 以外的所有对角项之积乘以“修正系数”, 恰好是 $\det A_{1,1}$. 因此, 在这个特例中 $\det A = a_{1,1} \det A_{1,1}$.

现在考虑第一行只有一个非零项 $a_{1,2}$ 的情况. 只需交换第 1、2 列, 即可将这种情况变为上面那种, 所以这种情况的 $\det A = (-1)a_{1,2} \det A_{1,2}$.

第一行只有一个非零项 $a_{1,3}$ 的情况, 只需通过交换第 2、3 列, 即可变为上段所述情形, 所以这种情况的 $\det A = a_{1,3} \det A_{1,3}$.

重复这一过程即得, 当 $a_{1,k}$ 是第一行的唯一非零项时, $\det A = (-1)^{1+k} a_{1,k} \det A_{1,k}$.⁵

在一般情形下, 由行列式对每行的线性可得

$$\det A = \det A^{(1)} + \det A^{(2)} + \dots + \det A^{(n)} = \sum_{k=1}^n \det A^{(k)}$$

其中矩阵 $A^{(k)}$ 是由 A 将除了 $a_{1,k}$ 以外的首行项都替换为 0 所得. 我们刚刚讨论过

$$\det A^{(k)} = (-1)^{1+k} a_{1,k} \det A_{1,k},$$

因此

$$\det A = \sum_{k=1}^n (-1)^{1+k} a_{1,k} \det A_{1,k}.$$

为得到按第二行的展开式, 我们可以交换第一、二行并运用上述公式: 行交换会导致变号, 因此可得

$$\det A = - \sum_{k=1}^n (-1)^{1+k} a_{2,k} \det A_{2,k} = \sum_{k=1}^n (-1)^{2+k} a_{2,k} \det A_{2,k}.$$

⁵在“ $a_{1,k}$ 是第一行的唯一非零项”这种情况下, 你可能想交换第 1 列和第 k 列以将此情形转化为 $a_{1,1} \neq 0$ 的情况. 然而, 当交换第 1 列和第 k 列时, 我们还改变了其他列的顺序: 在划掉第 k 列时, 第 1 列是剩余列中的第一列; 但如果交换了第 1 列和第 k 列, 再划掉第 k 列 (现在它是第 1 列了), 则第 1 列是剩余列中的第 $k-1$ 列. 为了避免因考虑列的顺序而带来的麻烦, 我们可以像上面那样交换第 k 与第 $k-1$ 列, 从而将现有情形转化为前一步中处理过的情形. 这样做变换就不会改变剩余列的顺序.

交换第 3 行和第 2 行, 并按第二行展开, 可得

$$\det A = \sum_{k=1}^n (-1)^{3+k} a_{3,k} \det A_{3,k},$$

以此类推.

要将行列式 $\det A$ 按列展开, 只需对 A^T 运用按行展开公式. $\square$

定义. 数

$$C_{j,k} = (-1)^{j+k} \det A_{j,k}$$

称为**余子式**.

利用这个记号, 行列式按第 j 行展开的公式可重写为

$$\det A = a_{j,1}C_{j,1} + a_{j,2}C_{j,2} + \cdots + a_{j,n}C_{j,n} = \sum_{k=1}^n a_{j,k}C_{j,k}.$$

类似地, 按第 k 列展开的公式可重写为

$$\det A = a_{1,k}C_{1,k} + a_{2,k}C_{2,k} + \cdots + a_{n,k}C_{n,k} = \sum_{j=1}^n a_{j,k}C_{j,k}$$

注. 常用余子式展开公式作为行列式的定义. 不难证明, 这公式给出的量满足行列式的基本性质: 归一化性质是平凡的, 而反对称性的证明也很容易. 然而, 线性的证明有些冗长 (尽管并不难).

注. 尽管形式优美, 但余子式展开公式并不适合计算大于 3×3 的矩阵的行列式.

可以算一下, 利用余子式展开来计算行列式需要超过 $n!$ 次乘法 (准确地说是 $\sum_{k=1}^{n-1} n!/k!$ 次乘法), 而 $n!$ 增长得很快. 例如, 对 20×20 矩阵进行余子式展开, 需要超过 $20! \approx 2.433 \cdot 10^{18}$ 次乘法. 使用每秒可进行**十亿次**乘法的计算机来计算 $20!$ 次乘法需要超过 77 年, 而计算 20×20 矩阵的行列式进行余子式展开所需的乘法更是需要超过 132 年⁶.

另一方面, 利用**行化简**计算 $n \times n$ 矩阵的行列式需要做 $(n^3 + 2n - 3)/3$ 次乘法 (加法的次数也差不多). 使用每秒可进行**百万次**计算的计算机 (按如今的标准来看, 已经非常慢了) 通过行化简来计算 100×100 矩阵的行列式, 也只需要不到一秒钟.

在高维情形中, 只有矩阵的一行 (或一列) 中有很多零的时候, 使用余子式展开公式才切实可行.

然而, 余子式展开公式具有很大的理论意义, 如下节所示.

⁶读者可借助诸如 WolframAlpha 之类的工具来检验这些数字.

5.1. 余子式求逆公式

称矩阵 $C = \{C_{j,k}\}_{j,k=1}^n$ (各项是给定矩阵 A 的余子式) 为 A 的余子式矩阵.

定理 5.2. 令 A 为可逆矩阵, C 为其余子式矩阵. 那么

$$A^{-1} = \frac{1}{\det A} C^T.$$

证明: 我们求乘积 AC^T . 它的第 j 个对角项是通过将 A 的第 j 行和 C^T 的第 j 列 (也就是 C 的第 j 行) 相乘得到的, 因此根据余子式展开公式

$$(AC^T)_{j,j} = a_{j,1}C_{j,1} + a_{j,2}C_{j,2} + \dots + a_{j,n}C_{j,n} = \det A,$$

为了得到不在对角线上的项, 我们需要将 A 的第 k 行乘以 C^T 的第 j 列 ($j \neq k$), 得到

$$a_{k,1}C_{j,1} + a_{k,2}C_{j,2} + \dots + a_{k,n}C_{j,n}.$$

根据余子式展开公式 (按第 j 行展开) 可知, 上式等于将 A 的第 j 行换成第 k 行 (其余各行不变) 所得矩阵的行列式. 但这样的矩阵中第 j 行和第 k 行是相同的, 因此它的行列式是 0. 因此, AC^T 的非对角项均为零 (而所有对角项等于 $\det A$), 因此

$$AC^T = (\det A) I.$$

这意味着矩阵 $\frac{1}{\det A} C^T$ 是 A 的右逆, 又因为 A 可逆, 所以它就是 A 的逆. □

回忆一下, 对于可逆矩阵 A , 方程 $A\mathbf{x} = \mathbf{b}$ 有唯一解

$$\mathbf{x} = A^{-1}\mathbf{b} = \frac{1}{\det A} C^T \mathbf{b},$$

从而可得上述定理的如下推论:

推论 5.3 (克拉默法则). 对于可逆矩阵 A , 方程 $A\mathbf{x} = \mathbf{b}$ 的解的第 k 项由下式给出

$$x_k = \frac{\det B_k}{\det A},$$

其中矩阵 B_k 是由 A 将第 k 列换成向量 $\mathbf{b}$ 得到的.

5.2. 余子式求逆公式的几例应用

例 (求 2×2 矩阵的逆). 需要求 2×2 矩阵

$$A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}.$$

的逆时, 余子式公式非常好用. 该矩阵的余子式可根据各项 (1×1 矩阵) 直接得到, 则余子式矩阵是

$$\begin{pmatrix} d & -c \\ -b & a \end{pmatrix},$$

因此逆矩阵 A^{-1} 由下式给出

$$A^{-1} = \frac{1}{\det A} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}.$$

尽管余子式求逆公式对高于 3 维的情况并不实用, 它仍有重要理论价值, 如下面例子所示.

例 (逆的项都是整数的矩阵). 假设我们想构建具有整数项的 A , 并使它的逆也具有整数项 (求这种矩阵的逆会是道很好的作业题——没有分式的烦扰). 如果 $\det A = 1$ 且 A 的项都是整数, 那么余子式求逆公式就表明, A^{-1} 也具有整数项.

注意, 很容易构造各项均为整数的矩阵 A 使得 $\det A = 1$: 只需要从主对角线上都是 1 的三角矩阵开始进行若干次行替换或列替换 (第三类变换), 得到一个看起来很一般的矩阵即可.

例 (多项式矩阵的逆). 另一个例子是, 考虑**多项式矩阵** $A(x)$, 即各项不是数而是关于变量 x 的多项式 $a_{j,k}(x)$ 的矩阵. 如果 $\det A(x) \equiv 1$, 那么逆矩阵 $A^{-1}(x)$ 也是多项式矩阵.

如果 $\det A(x) = p(x) \neq 0$, 那么根据余子式展开, $p(x)$ 是多项式, 因此 $A^{-1}(x)$ 的各项是有理分式. 并且, $p(x)$ 是各项分母的多项式倍.

习题

5.1. 求下列行列式的值, 方法不限.

$$\begin{vmatrix} 0 & 1 & 1 \\ 1 & 2 & -5 \\ 6 & -4 & 3 \end{vmatrix}, \quad \begin{vmatrix} 1 & -2 & 3 & -12 \\ -5 & 12 & -14 & 19 \\ -9 & 22 & -20 & 31 \\ -4 & 9 & -14 & 15 \end{vmatrix}.$$

5.2. 利用行 (列) 展开求下列行列式的值. 注意, 你不必使用第一行 (第一列) ——选择含有很多零的行或列有助于简化计算.

$$\begin{vmatrix} 1 & 2 & 0 \\ 1 & 1 & 5 \\ 1 & -3 & 0 \end{vmatrix}, \quad \begin{vmatrix} 4 & -6 & -4 & 4 \\ 2 & 1 & 0 & 0 \\ 0 & -3 & 1 & 3 \\ -2 & 2 & -3 & -5 \end{vmatrix}.$$

5.3. 对于 $n \times n$ 矩阵

$$A = \begin{pmatrix} 0 & 0 & 0 & \cdots & 0 & a_0 \\ -1 & 0 & 0 & \cdots & 0 & a_1 \\ 0 & -1 & 0 & \cdots & 0 & a_2 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & 0 & a_{n-2} \\ 0 & 0 & 0 & \cdots & -1 & a_{n-1} \end{pmatrix}$$

计算 $\det(A+tI)$, 其中 I 是 $n \times n$ 恒等矩阵. 你应该会得到一个包含 $a_0, a_1, \dots, a_{n-1}$ 和 t 的优美的表达式. 最佳做法应该是按行展开并用归纳法.

5.4. 利用余子式公式, 求出下列矩阵的逆.

$$\begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad \begin{pmatrix} 19 & -17 \\ 3 & -2 \end{pmatrix}, \quad \begin{pmatrix} 1 & 0 \\ 3 & 5 \end{pmatrix}, \quad \begin{pmatrix} 1 & 1 & 0 \\ 2 & 1 & 2 \\ 0 & 1 & 1 \end{pmatrix}.$$

5.5. 令 D_n 为下列 $n \times n$ 三对角矩阵的行列式

$$\begin{pmatrix} 1 & -1 & & & 0 \\ 1 & 1 & -1 & & \\ & 1 & \ddots & \ddots & \\ & & \ddots & 1 & -1 \\ 0 & & & 1 & 1 \end{pmatrix}.$$

利用余子式展开证明: $D_n = D_{n-1} + D_{n-2}$. 这说明, D_n 所成序列就是斐波那契序列 $1, 2, 3, 5, 8, 13, 21, \dots$

5.6. 范德蒙行列式再讨论——目标是证明 $(n+1) \times (n+1)$ 范德蒙行列式的如下公式

$$\begin{vmatrix} 1 & c_0 & c_0^2 & \cdots & c_0^n \\ 1 & c_1 & c_1^2 & \cdots & c_1^n \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & c_n & c_n^2 & \cdots & c_n^n \end{vmatrix} = \prod_{0 \leq j < k \leq n} (c_k - c_j)$$

我们将运用归纳法. 为此

- 检验: 该公式适用于 $n=1, n=2$ 的情形.
- 记最后一行的变量 c_n 为 x , 并证明原行列式是 n 次多项式 $A_0 + A_1x + A_2x^2 + \dots + A_nx^n$, 其中系数 A_k 取决于 $c_0, c_1, \dots, c_{n-1}$.
- 证明: 上问的多项式有零点 $x = c_0, c_1, \dots, c_{n-1}$, 因此它可表示为 $A_n \cdot (x - c_0)(x - c_1) \dots (x - c_{n-1})$, 其中 A_n 如上问所示.
- 假设范德蒙行列式的公式对于 $n-1$ 的情形成立, 计算 A_n 并证明公式对 n 的情形成立.

5.7. 利用余子式展开计算 $n \times n$ 矩阵的行列式需要做多少次乘法? 求出表达式.

6. 子式与秩

对于矩阵 A , 考虑由取出其 k 行和 k 列而得到的 $k \times k$ 子矩阵. 该矩阵的行列式称为 k 阶子式. 注意, $m \times n$ 矩阵有 $\binom{m}{k} \cdot \binom{n}{k}$ 个不同的

$k \times k$ 子矩阵, 因此它具有 $\binom{m}{k} \cdot \binom{n}{k}$ 个 k 阶子式.

定理 6.1. 非零矩阵 A 的秩等于非零子式的最大阶数 k .

证明: 首先证明, 若 $k > \text{rank } A$, 那么所有 k 阶子式都为 0. 的确如此: 因为列空间 $\text{Ran } A$ 的维数是 $\text{rank } A < k$, 所以 A 的任意 k 列都是线性相关的. 因此 A 的任意 $k \times k$ 子矩阵的各列都线性相关, 进而所有 k 阶子式都为 0.

为完成证明, 还需要说明 $k = \text{rank } A$ 阶非零子式存在. 这种子式可能有很多, 但要得到它, 最容易的构造方法大概是, 取出主元行和主元列 (即原矩阵中包含主元的行和列). 这个 $k \times k$ 矩阵和原矩阵的主元相同, 因此它可逆 (因其在每行和每列中都有主元), 且行列式非零. $\square$

这个定理看似不太有用, 因为做行化简比起计算所有子式要容易得多. 然而, 它有很大的理论意义, 如下面推论所示.

推论 6.2. 令 $A = A(x)$ 是 $m \times n$ 多项式矩阵 (矩阵的各项是关于 x 的多项式). 那么 $\text{rank } A(x)$ 对于任意 x 都是常数 (除了可能在有限多个点处变小).

证明: 令 r 为整数, 其为 $\text{rank } A(x) = r$ 的最大值 (在某点 x 处取得). 为了证明这样的 r 存在, 我们从 $r = \min\{m, n\}$ 开始. 如果存在 x 满足 $\text{rank } A(x) = r$, 那么我们就找到了满足条件的 r ; 否则就将 r 替换成 $r - 1$ 并再次尝试. 在有限多步后, 我们要么停止, 要么得到 0. 所以 r 存在.

令 x_0 是使得 $\text{rank } A(x_0) = r$ 的点, 并令 M 是满足 $M(x_0) \neq 0$ 的 r 阶子式. 因为 $M(x)$ 是 $r \times r$ 多项式矩阵的行列式, 所以 $M(x)$ 是多项式. 因为 $M(x_0) \neq 0$, 所以它不恒为 0, 进而它只能在有限多个点等于零. 因此, $\text{rank } A(x) \geq r$ 在有限多个点处之外都成立. 又由 r 的定义——对于所有 x 均有 $\text{rank } A(x) \leq r$, 即得证. $\square$

7. 第 3 章复习题

7.1. 判断正误:

- 行列式只对方阵有定义.
- 如果 A 的两行或两列相同, 那么 $\det A = 0$.
- 如果 B 是由 A 经过交换两行 (或两列) 得到的, 那么 $\det B = \det A$.
- 如果 B 是由 A 将其某行 (或某列) 乘以 α 得到的, 那么 $\det B = \det A$.

- e) 如果 B 是由 A 通过将一行的若干倍加到另一行得到的, 那么 $\det B = \det A$.
- f) 三角矩阵的行列式是其对角项的积.
- g) $\det(A^T) = -\det A$.
- h) $\det(AB) = \det(A)\det(B)$.
- i) 矩阵 A 可逆, 当且仅当 $\det A \neq 0$.
- j) 若 A 为可逆矩阵, 那么 $\det(A^{-1}) = 1/\det(A)$.
- 7.2. 设 A 为 $n \times n$ 矩阵. $\det(3A)$, $\det(-A)$ 和 $\det(A^2)$ 与 $\det A$ 分别是什么关系?
- 7.3. 若 A 和 A^{-1} 的各项都是整数, $\det A = 3$ 是否可能? **提示:** $\det(A)\det(A^{-1})$ 是多少?
- 7.4. 令 $\mathbf{v}_1, \mathbf{v}_2$ 是 $\mathbb{R}^2$ 中的向量, 并令 A 是各列为 $\mathbf{v}_1, \mathbf{v}_2$ 的 2×2 矩阵. 证明: $|\det A|$ 是两边为 $\mathbf{v}_1, \mathbf{v}_2$ 的平行四边形的面积.
- 首先考虑 $\mathbf{v}_1 = (x_1, 0)^T$ 的情形. 为推广到一般情形 $\mathbf{v}_1 = (x_1, y_1)^T$, 将 A 左乘旋转矩阵从而将向量 $\mathbf{v}_1$ 变换为 $(\tilde{x}_1, 0)^T$.
- 提示:** 旋转矩阵的行列式是多少?

下面这题展示了行列式的符号与一组向量的所谓**取向**之间的关系.

- 7.5. 令 $\mathbf{v}_1, \mathbf{v}_2$ 是 $\mathbb{R}^2$ 中的向量. 证明: $D(\mathbf{v}_1, \mathbf{v}_2) > 0$, 当且仅当存在旋转 T_α 使得向量 $T_\alpha \mathbf{v}_1$ 平行于 $\mathbf{e}_1$ (且同向) 并且向量 $T_\alpha \mathbf{v}_2$ 处于上半平面 $x_2 > 0$ 中 (即处于 $\mathbf{e}_2$ 所在的半平面中).
- 提示:** 旋转矩阵的行列式是多少?

第 4 章 谱理论初步（特征值与特征向量）

谱理论是帮助我们理解线性算子之结构的主要工具. 本章中, 我们仅考虑从向量空间至其本身的算子 (或与之等价的 $n \times n$ 矩阵). 对于一个这样的线性变换 $A: V \rightarrow V$, 我们可以将其乘以自身, 或取其任意次幂, 以至将其放进多项式.

谱理论的主要思想是将算子分为简单的几块, 并分别分析每块.

为了解释这一主要思想, 我们来考虑**差分方程**. 许多过程可用下面这类方程来描述:

$$\mathbf{x}_{n+1} = A\mathbf{x}_n, \quad n = 0, 1, 2, \dots,$$

其中 $A: V \rightarrow V$ 是线性变换, $\mathbf{x}_n$ 是时刻 n 处的系统状态. 给定初始状态 $\mathbf{x}_0$, 我们想要知道时刻 n 处的状态 $\mathbf{x}_n$ 、分析 $\mathbf{x}_n$ 的长期演变, 等等¹.

乍一看, 此问题很简单: 用公式 $\mathbf{x}_n = A^n \mathbf{x}_0$ 即可得解 $\mathbf{x}_n$. 但是, 如果 n 很大, 有几千甚至几百万呢? 又, 如果我们要分析 $n \rightarrow \infty$ 时 $\mathbf{x}_n$ 的演变呢?

此处, **特征值和特征向量**的思想应运而生. 假设 $A\mathbf{x}_0 = \lambda\mathbf{x}_0$, 其中 λ 为某标量. 那么 $A^2\mathbf{x}_0 = \lambda^2\mathbf{x}_0, A^3\mathbf{x}_0 = \lambda^3\mathbf{x}_0, \dots, A^n\mathbf{x}_0 = \lambda^n\mathbf{x}_0$. 这样, 解的演变就很容易理解了.

本节我们仅考虑有限维向量空间上的算子. 无限维情况下的谱理论要复杂得多, 并且此处展示的大多数结论在无限维情况下都不成立.

1. 主要定义

1.1. 特征值、特征向量、谱

称标量 λ 为算子 $A: V \rightarrow V$ 的**特征值**, 若存在**非零**向量 $\mathbf{v} \in V$ 使得

$$A\mathbf{v} = \lambda\mathbf{v}.$$

向量 $\mathbf{v}$ 称为 A (相应于特征值 λ 的) **特征向量**.

¹差分方程类似于“离散时间下的**微分方程** $\mathbf{x}'(t) = A\mathbf{x}(t)$ ”. 为求解微分方程, 我们需要计算 $e^{tA} := \sum_{k=0}^{\infty} t^k A^k / k!$, 而谱理论也能帮助我们进行该计算.

如果我们知道 λ 是特征值, 则很容易求出特征向量: 只需求解方程 $A\mathbf{x} = \lambda\mathbf{x}$, 或与之等价的

$$(A - \lambda I)\mathbf{x} = \mathbf{0}.$$

所以, 求出**所有**相应于特征值 λ 的特征向量, 就是求出 $A - \lambda I$ 的零空间. 这个零空间 $\text{Ker}(A - \lambda I)$, 即所有特征向量及 $\mathbf{0}$ 向量所成的集合, 称为**特征空间**.

算子 A 的全体特征值构成的集合称为 A 的**谱**, 常记为 $\sigma(A)$.

1.2. 求出特征值: 特征多项式

标量 λ 为特征值当且仅当零空间 $\text{Ker}(A - \lambda I)$ 是非平凡的 (因此方程 $(A - \lambda I)\mathbf{x} = \mathbf{0}$ 有非平凡解).

设 A 作用在 $\mathbb{F}^n$ 上 (即 $A: \mathbb{F}^n \rightarrow \mathbb{F}^n$). 因为 A 的矩阵是方阵, 所以 $A - \lambda I$ 有非平凡零空间, 当且仅当它不可逆. 我们知道方阵不可逆当且仅当其行列式为 0. 因此

$$\lambda \in \sigma(A), \text{ 即 } \lambda \text{ 为 } A \text{ 的特征值} \iff \det(A - \lambda I) = 0$$

若 A 为 $n \times n$ 矩阵, 那么行列式 $\det(A - \lambda I)$ 是关于变量 λ 的 n 次多项式. 该多项式称为 A 的**特征多项式**. 因此, 要求出 A 的所有特征值, 只需计算特征多项式并求出它的所有根.

算子的谱的这种求法在维数较高时不太实用: 求出高次多项式的根可能非常困难, 并且高于 4 次的多项式没有求根公式. 因此, 在高维下, 求特征值和特征向量会用到各种数值方法.

1.3. 求出抽象的算子的特征多项式和特征值

现在我们知道如何求出矩阵的谱了. 但是, 对于作用于抽象的向量空间的算子, 我们如何求出其特征值呢? 方法其实很简单:

取任意一个基, 并计算该算子关于这个基的矩阵的特征值.

可是, 我们怎么确保所得结果不会随着基的选取而改变呢?

对此, 有多种解释. 其中一种解释基于**相似矩阵**这一概念. 回想一下, 称方阵 A 和 B 是相似的, 如果存在可逆矩阵 S 使得

$$A = SBS^{-1}.$$

注意, 相似矩阵的行列式是相同的. 的确: 因为 $\det S^{-1} = 1/\det S$, 所以

$$\det A = \det(SBS^{-1}) = \det S \det B \det S^{-1} = \det B$$

注意, 如果 $A = SBS^{-1}$ 那么

$$A - \lambda I = SBS^{-1} - \lambda SIS^{-1} = S(BS^{-1} - \lambda IS^{-1}) = S(B - \lambda I)S^{-1},$$

因此矩阵 $A - \lambda I$ 和 $B - \lambda I$ 是相似的. 因此

$$\det(A - \lambda I) = \det(B - \lambda I),$$

即

相似矩阵的特征多项式是一样的.

若 $T: V \rightarrow V$ 是线性变换, 并且 $\mathcal{A}$ 和 $\mathcal{B}$ 是 V 中的两个基, 那么

$$[T]_{\mathcal{A}\mathcal{A}} = [I]_{\mathcal{A}\mathcal{B}} [T]_{\mathcal{B}\mathcal{B}} [I]_{\mathcal{B}\mathcal{A}}$$

又因为 $[I]_{\mathcal{B}\mathcal{A}} = ([I]_{\mathcal{A}\mathcal{B}})^{-1}$, 所以矩阵 $[T]_{\mathcal{A}\mathcal{A}}$ 和 $[T]_{\mathcal{B}\mathcal{B}}$ 相似.

换言之, 同一线性变换关于不同基的矩阵是相似的.

因此, 我们可定义算子的特征多项式为这个算子在某个基下的矩阵的特征多项式. 如上所讨论的, 这并不依赖于基的选取, 因此这样定义算子的特征多项式是完善的.

1.4. 复向量空间 VS 实向量空间

代数基本定理表明, 任意 (次数至少为 1) 的多项式都有复根. 这就意味着, 有限维复向量空间上的算子至少有一个特征值, 所以它的谱一定非空.

而另一方面, 在实向量空间中, 很容易构造一个不具有实特征值的线性变换, 例子之一是 $\mathbb{R}^2$ 中的旋转 $R_\alpha, \alpha \neq \pi n$. 这样的算子的谱是空集, 因为通常假设特征值属于标量域 (如果算子作用于 $\mathbb{F}$ 上的向量空间, 那么特征值就应属于 $\mathbb{F}$).

因此, 复数情形 (算子作用于复向量空间) 似乎更适于研究谱理论. 因为 $\mathbb{R} \subset \mathbb{C}$, 所以我们总可以将 $n \times n$ 实矩阵视为 $\mathbb{C}^n$ 上的算子, 从而允许复特征值存在. 将实矩阵视为 $\mathbb{C}^n$ 上的算子是谱理论研究中的惯常做法, 并且我们将遵从这一惯例. 除非另有说明, 求矩阵的特征值都是指求出所有复特征值, 而不仅限于实特征值.

注意, 抽象的实向量空间上的算子也总能被看成复向量空间上的算子. 一种简易的处理方式是, 取定一个基 (回忆一下: 本章中的所有向量空间都是有限维的), 然后围绕关于这个基的坐标向量展开讨论, 并且允许坐标中出现复数——这其实就是完成从 $\mathbb{R}^n$ 中算子到 $\mathbb{C}^n$ 中算子的迁移 (上段所述内容).

这迁移过程其实就展现了实向量空间的所谓**复化**, 而且它还不依赖于基的选取. 复化的一种“高端”而又抽象的建构方式可以解释它为什么不依赖于基的选取, 这将在第 5 章第 8.2 节详述.

1.5. 特征值的重数

请注意, 若 p 为多项式, λ 是它的根 (即 $p(\lambda) = 0$), 那么 $z - \lambda$ 整除 $p(z)$, 也即 p 可由 $p(z) = (z - \lambda)q(z)$ 表示, 其中 q 为多项式. 如果 $q(\lambda) = 0$, 那么 q 同样可被 $z - \lambda$ 整除, 所以 $(z - \lambda)^2$ 整除 p , 以此类推.

使得 $(z - \lambda)^k$ 整除 $p(z)$ 的最大正整数 k 称为 λ 这个根的重数.

如果 λ 是算子 (矩阵) A 的特征值, 那么它是特征多项式 $p(z) = \det(A - zI)$ 的根. 此根的重数称为特征值 λ 的**(代数)重数**.

任意次数为 n 的多项式 $p(z) = \sum_{k=0}^n a_k z^k$ 都恰有 n 个复根 (以重数计). “**以重数计**”的意思是, 如果一个根的重数为 d , 就需要列出它 d 次, 并且在计数时重复数 d 次. 换言之, p 可表示为

$$p(z) = a_n(z - \lambda_1)(z - \lambda_2) \cdots (z - \lambda_n).$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是复根 (以重数计).

特征值还有另一种重数: 特征空间 $\text{Ker}(A - \lambda I)$ 的维数称为特征值 λ 的**几何重数**.

几何重数不如代数重数运用得广泛. 所以, 当仅提及“重数”时, 通常是指**代数重数**.

顺带说一句: 特征值的代数重数和几何重数可能不等.

命题 1.1. 特征值的几何重数不超过其代数重数.

证明: 见下方习题 1.9. □

1.6. 迹与行列式

定理 1.2. 令 A 为 $n \times n$ 矩阵, 并令 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是它的 (复) 特征值 (以重数计). 那么

$$1. \operatorname{trace} A = \lambda_1 + \lambda_2 + \dots + \lambda_n.$$

$$2. \det A = \lambda_1 \lambda_2 \dots \lambda_n.$$

证明: 见下方习题 1.10、1.11. □

1.7. 三角矩阵的特征值

计算特征值等价于求出矩阵的特征多项式的根 (有可能利用数值方法), 而这或许非常耗时. 然而, 在一种特殊情况中, 我们可以直接从矩阵里读出特征值. 即

三角矩阵的特征值 (以重数计) 恰为对角项
 $a_{1,1}, a_{2,2}, \dots, a_{n,n}.$

“三角” 此处可指上三角也可指下三角. 因为对角矩阵是三角矩阵的一个特例 (它既是上三角的又是下三角的), 所以

对角矩阵的特征值是其对角项.

这个有关三角矩阵的结论很容易证明: 只需将三角矩阵的对角项减去 λ , 再利用 “三角矩阵的行列式等于对角项之积”, 即得到特征多项式

$$\det(A - \lambda I) = (a_{1,1} - \lambda)(a_{2,2} - \lambda) \dots (a_{n,n} - \lambda)$$

而它的根恰为 $a_{1,1}, a_{2,2}, \dots, a_{n,n}.$

习题

1.1. 判断正误:

- a) n 维向量空间中的每个线性算子都有 n 个互异的特征值;
- b) 一矩阵如果有一个特征向量, 就有无数个特征向量;
- c) 存在没有实特征值的实方阵;
- d) 存在没有 (复) 特征值的方阵;
- e) 相似矩阵的特征值总相同;
- f) 相似矩阵的特征向量总相同;
- g) 矩阵 A 的两个特征向量的和 (非零) 总是特征向量;
- h) 矩阵 A 的相应于同一特征值 λ 的两个特征向量的和 (非零) 总是特征向量.

1.2. 求出下列矩阵的特征多项式、特征值和特征向量:

$$\begin{pmatrix} 4 & -5 \\ 2 & -3 \end{pmatrix}, \quad \begin{pmatrix} 2 & 1 \\ -1 & 4 \end{pmatrix}, \quad \begin{pmatrix} 1 & 3 & 3 \\ -3 & -5 & -3 \\ 3 & 3 & 1 \end{pmatrix}.$$

1.3. 求出旋转矩阵

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}.$$

的特征值和特征向量. 注意, 特征值 (以及特征向量) 不一定是实的.

1.4. 求出下列矩阵的特征多项式和特征值:

$$\begin{pmatrix} 1 & 2 & 5 & 67 \\ 0 & 2 & 3 & 6 \\ 0 & 0 & -2 & 5 \\ 0 & 0 & 0 & 3 \end{pmatrix}, \begin{pmatrix} 2 & 1 & 0 & 2 \\ 0 & \pi & 43 & 2 \\ 0 & 0 & 16 & 1 \\ 0 & 0 & 0 & 54 \end{pmatrix}, \begin{pmatrix} 4 & 0 & 0 & 0 \\ 1 & 3 & 0 & 0 \\ 2 & 4 & e & 0 \\ 3 & 3 & 1 & 1 \end{pmatrix}, \begin{pmatrix} 4 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 2 & 4 & 0 & 0 \\ 3 & 3 & 1 & 1 \end{pmatrix}.$$

请勿展开特征多项式——保留为因式乘积的形式.

1.5. 证明: 三角矩阵的特征值 (以重数计) 恰为其对角项.

1.6. 称算子 A 是**幂零的**, 若对某 k 有 $A^k = \mathbf{0}$. 证明: 若 A 是幂零的, 那么 $\sigma(A) = \{0\}$ (即 0 是 A 唯一的特征值).

1.7. 证明分块三角矩阵

$$\begin{pmatrix} A & * \\ \mathbf{0} & B \end{pmatrix},$$

(其中 A 和 B 为方阵) 的特征多项式等于 $\det(A - \lambda I) \det(B - \lambda I)$. (利用第 3 章的习题 3.11)

1.8. 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是向量空间 V 的基. 又假设前 k 个基向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k$ 是算子 A 的特征向量, 且对应于同一特征值 λ (即 $A\mathbf{v}_j = \lambda\mathbf{v}_j, j = 1, 2, \dots, k$). 证明: 在该基下, 算子 A 的矩阵具有分块三角形式

$$\begin{pmatrix} \lambda I_k & * \\ \mathbf{0} & B \end{pmatrix},$$

其中 I_k 是 $k \times k$ 恒等矩阵, B 为某 $(n - k) \times (n - k)$ 矩阵.

1.9. 利用上面两题的结论证明: 特征值的几何重数不超过其代数重数.

1.10. 证明: 矩阵 A 的行列式是其特征值之积 (以重数计).

提示: 首先证明 $\det(A - \lambda I) = (\lambda_1 - \lambda)(\lambda_2 - \lambda) \dots (\lambda_n - \lambda)$, 其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是特征值 (以重数计). 然后比照常数项 (不含 λ 的项) 或令 $\lambda = 0$ 以得出结论.

1.11. 按以下三步骤证明: 矩阵的迹等于特征值之和. 首先, 计算下列等式右侧 λ^{n-1} 的系数:

$$\det(A - \lambda I) = (\lambda_1 - \lambda)(\lambda_2 - \lambda) \dots (\lambda_n - \lambda).$$

然后证明 $\det(A - \lambda I)$ 可表示为

$$\det(A - \lambda I) = (a_{1,1} - \lambda)(a_{2,2} - \lambda) \dots (a_{n,n} - \lambda) + q(\lambda)$$

其中 $q(\lambda)$ 是次数最高为 $n - 2$ 的多项式. 最后比照 λ^{n-1} 的系数以得出结论.

2. 对角化

谱理论的应用之一, 是对算子做对角化——求出一个基, 使得算子关于该基的矩阵是对角矩阵. 这样的基并不总是存在, 也就是说并非所

有算子都可对角化. 可对角化的重要性, 源于对角矩阵的幂、乃至关于对角矩阵的更一般的函数很容易计算, 所以如果我们将算子对角化, 就很容易计算关于它的函数.

本节我们将解释如何计算关于可对角化算子的函数. 我们还将给出算子可对角化的充分必要条件以及一些简单的充分条件.

注意, $\mathbb{F}^n$ 上的算子 (矩阵) A 可对角化, 意为它可被表示成 $A = SDS^{-1}$, 其中 D 是对角矩阵 (S 是可逆的). 我们将简要解释这一点.

除非另作说明, 本节所有结论对于实向量空间和复向量空间 (乃至任意域上的空间) 都成立.

2.1. 预备知识

设向量空间 V 上的算子 A 满足 V 有由 A 的特征向量构成的基 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$, $\lambda_1, \lambda_2, \dots, \lambda_n$ 是它们对应的特征值. 那么 A 关于这个基的矩阵就是对角项为 $\lambda_1, \lambda_2, \dots, \lambda_n$ 的对角矩阵

$$(2.1) \quad [A]_{\mathcal{B}\mathcal{B}} = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\} = \begin{pmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{pmatrix}.$$

另一方面, 如果算子 A 关于基 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$ 的矩阵由 (2.1) 给出, 那么自然有 $A\mathbf{b}_k = \lambda_k\mathbf{b}_k$, 即 λ_k 是特征值, $\mathbf{b}_k$ 是对应的特征向量.

注意, 上述论证对于实向量空间和复向量空间 (乃至任意域上的向量空间) 都成立.

将上述论证应用到 $\mathbb{F}^n$ 上的算子 (矩阵) 立即可得下述定理. 注意, 虽然在这本书中 $\mathbb{F}$ 指代 $\mathbb{C}$ 或 $\mathbb{R}$, 但是这个定理对任意的域 $\mathbb{F}$ 都成立.

定理 2.1. 矩阵 A (各项属于 $\mathbb{F}$) 可表示为 $A = SDS^{-1}$, 其中 D 是对角矩阵、 S 是可逆的 (两矩阵的各项都属于 $\mathbb{F}$), 当且仅当 $\mathbb{F}^n$ 中存在由 A 的特征向量构成的基.

此外, 在这种情况下, D 的对角项是特征值, S 的各列是对应的特征向量 (第 k 列对应 D 的第 k 个对角项).

证明: 令 $D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$, 并令 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$ 是 S 的列 (注意因为 S 可逆, 所以它的列形成 $\mathbb{F}^n$ 的基). 那么, 等式 $A = SDS^{-1}$ 意味着 $D = [A]_{\mathcal{B}\mathcal{B}}$.

的确如此: $S = [I]_{\mathcal{B}\mathcal{B}}$ 是从 $\mathcal{B}$ 到标准基 $\mathcal{S}$ 的坐标变换矩阵, 因此从 $A = SDS^{-1}$ 我们可得 $D = S^{-1}AS = [I]_{\mathcal{B}\mathcal{S}}A[I]_{\mathcal{S}\mathcal{B}}$, 这就说明 $D = [A]_{\mathcal{B}\mathcal{B}}$.

然后, 可以结合我们上面讨论过的内容: $[A]_{\mathcal{B}\mathcal{B}} = D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ 当且仅当各 λ_k 是特征值, 而 $\mathbf{b}_k$ 是 A 的对应的特征向量. $\square$

注. 注意, 如果矩阵可表示为 $A = SDS^{-1}$ (D 为对角矩阵), 那么可据此直接计算得 S 的各列是 A 的特征向量, D 的对角项是对应的特征值. 这是定理 2.1 中对应结论的另一种证明方式.

前面我们讨论过, 可对角化算子 $A: V \rightarrow V$ 恰有 $n = \dim V$ 个特征值 (以重数计). 复向量空间 V 中的任意算子都有 n 个特征值 (以重数计); 另一方面, 实向量空间上的算子可能没有实特征值.

我们会按照谱理论中的惯例, 将实矩阵视为复向量空间 $\mathbb{C}^n$ 上的算子, 因此允许特征值和特征向量是复的. 除非另有说明, 矩阵的对角化都意为复对角化, 即表达式 $A = SDS^{-1}$ 中矩阵 S 和 D 可能含有复数.

实矩阵何时能进行实对角化 ($A = SDS^{-1}$ 中 S 和 D 都为实矩阵) 这一问题其实很容易回答——见下定理 2.9.

2.2. 研究对角化的动机之一: 关于算子的函数

令算子 A 关于基 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$ 的矩阵是由 (2.1) 给出的对角矩阵. 那么很容易求出算子 A 的 N 次幂. 即, A^N 关于基 $\mathcal{B}$ 的矩阵是

$$[A^N]_{\mathcal{B}\mathcal{B}} = \text{diag}\{\lambda_1^N, \lambda_2^N, \dots, \lambda_n^N\} = \begin{pmatrix} \lambda_1^N & & 0 \\ & \lambda_2^N & \\ & & \ddots \\ 0 & & & \lambda_n^N \end{pmatrix}.$$

并且, 关于算子的函数也很容易计算: 例如, 算子 (矩阵) 的指数 e^{tA} 定义为 $e^{tA} = I + tA + \frac{t^2 A^2}{2!} + \frac{t^3 A^3}{3!} + \dots = \sum_{k=0}^{\infty} \frac{t^k A^k}{k!}$, 该算子在基 $\mathcal{B}$ 下的矩阵是

$$[e^{tA}]_{\mathcal{B}\mathcal{B}} = \text{diag}\{e^{\lambda_1 t}, e^{\lambda_2 t}, \dots, e^{\lambda_n t}\} = \begin{pmatrix} e^{\lambda_1 t} & & 0 \\ & e^{\lambda_2 t} & \\ & & \ddots \\ 0 & & & e^{\lambda_n t} \end{pmatrix}.$$

现设 A 是 $\mathbb{F}^n$ 上的算子. 为求出算子 A^N 和 e^{tA} 在标准基 $\mathcal{S}$ 下的矩阵, 回想一下坐标变换矩阵 $[I]_{\mathcal{S}\mathcal{B}}$ 是各列为 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$ 的矩阵. 称该

矩阵为 S , 那么根据坐标变换公式可得

$$A = [A]_{SS} = S \begin{pmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_n \end{pmatrix} S^{-1} = SDS^{-1}$$

其中用 D 指代中间的对角矩阵.

类似地,

$$A^N = SD^N S^{-1} = S \begin{pmatrix} \lambda_1^N & & & 0 \\ & \lambda_2^N & & \\ & & \ddots & \\ 0 & & & \lambda_n^N \end{pmatrix} S^{-1}$$

e^{tA} 的矩阵表达式也类似.

另一种看待可对角化算子的幂 (以及关于可对角化算子的其他函数) 的方式是, 如果算子 A 可表示成 $A = SDS^{-1}$, 那么

$$A^N = \underbrace{(SDS^{-1})(SDS^{-1}) \cdots (SDS^{-1})}_{N \text{ 个}} = SD^N S^{-1}$$

而对角矩阵的 N 次幂很容易计算.

2.3. n 个互异特征值的情形

现在我们给出算子可对角化的一个很简单的**充分**条件, 见下推论 2.3.

定理 2.2. 令 $\lambda_1, \lambda_2, \dots, \lambda_r$ 是 A 的相异特征值, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是对应的特征向量. 那么向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是线性无关的.

证明: 我们将对 r 用归纳法. $r = 1$ 的情形是平凡的, 因为根据定义, 特征向量是非零的, 而仅包含一个非零向量的向量组是线性无关的.

假设定理对于 $r - 1$ 的情形成立. 设存在非平凡线性组合

$$(2.2) \quad c_1 \mathbf{v}_1 + c_2 \mathbf{v}_2 + \cdots + c_r \mathbf{v}_r = \sum_{k=1}^r c_k \mathbf{v}_k = \mathbf{0}.$$

向 (2.2) 作用 $A - \lambda_r I$, 并且利用 $(A - \lambda_r I) \mathbf{v}_r = \mathbf{0}$, 可得

$$\sum_{k=1}^{r-1} c_k (\lambda_k - \lambda_r) \mathbf{v}_k = \mathbf{0}.$$

由归纳假设, 向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{r-1}$ 线性无关, 所以 $c_k (\lambda_k - \lambda_r)$ 对 $k = 1, 2, \dots, r - 1$ 成立. 因为 $\lambda_k \neq \lambda_r$, 我们可知 $c_k = 0$ 对 $k < r$ 成立. 于是, 由 (2.2) 得 $c_r = 0$, 即此式实为平凡线性组合. $\square$

推论 2.3. 若算子 $A: V \rightarrow V$ 恰有 $n = \dim V$ 个互异特征值, 那么它可对角化. 这个结论虽简单却十分重要且常用. 请记住它!

证明: 对每个特征值 λ_k , 令 $\mathbf{v}_k$ 是对应的特征向量 (即对每个特征值选取一个特征向量). 由定理 2.2, 向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 线性无关, 又因为它恰好包含 $n = \dim V$ 个向量, 所以它是基. $\square$

2.4. 子空间构成的基 (又名子空间的直和)

为描述可对角化算子, 我们需要引入一些新的定义.

令 $V_1, V_2, \dots, V_p$ 是向量空间 V 的子空间. 称这组子空间是 V 的基, 如果任意向量 $\mathbf{v} \in V$ 都可唯一写成下面和的形式

$$(2.3) \quad \mathbf{v} = \mathbf{v}_1 + \mathbf{v}_2 + \dots + \mathbf{v}_p = \sum_{k=1}^p \mathbf{v}_k, \quad \mathbf{v}_k \in V_k.$$

此外, 我们称一组子空间 $V_1, V_2, \dots, V_p$ 是线性无关的, 若方程

$$\mathbf{v}_1 + \mathbf{v}_2 + \dots + \mathbf{v}_p = \mathbf{0}, \quad \mathbf{v}_k \in V_k$$

只有平凡解 ($\mathbf{v}_k = \mathbf{0} \forall k = 1, 2, \dots, p$). 另一种表述方式是, 称一组子空间 $V_1, V_2, \dots, V_p$ 是线性无关的, 当且仅当任意非零向量 $\mathbf{v}_k, \mathbf{v}_k \in V_k$ 构成的向量组是线性无关的.

称一组子空间 $V_1, V_2, \dots, V_p$ 是生成组 (或完备组、张成组), 若任意向量 $\mathbf{v} \in V$ 都能写成 (2.3) 的形式 (不一定唯一).

注 2.4. 根据上述定义可立即发现: 定理 2.2 实际上表明算子 A 的各特征空间

$$E_k := \text{Ker}(A - \lambda_k I), \quad \lambda_k \in \sigma(A),$$

线性无关.

注 2.5. 容易看出, 类似于由向量构成的基, 一组子空间 $V_1, V_2, \dots, V_p$ 是基当且仅当它既是生成组又是线性无关的. 我们将此结论的证明留给读者作为习题.

子空间构成的基有个简单的例子: 设 V 是向量空间, 具有基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$. 将下标 $1, 2, \dots, n$ 分成 p 个子集 $\Lambda_1, \Lambda_2, \dots, \Lambda_p$, 并定义子空间 $V_k := \text{span}\{\mathbf{v}_j : j \in \Lambda_k\}$. 显然各子空间 V_k 形成 V 的基.

下面定理表明, 在有限维的情形下, 由子空间构成的基总是上段示例中的情况.

定理 2.6. 令 $V_1, V_2, \dots, V_p$ 是子空间构成的基, 并令每个子空间 V_k 都有 (由向量构成的) 基 $\mathcal{B}_k$ ². 那么这些基的并 $\cup_k \mathcal{B}_k$ 是 V 的基.

为证明该定理, 我们需要下面的引理:

引理 2.7. 令 $V_1, V_2, \dots, V_p$ 是线性无关的子空间, 并设在每个子空间 V_k 中都有线性无关向量组 $\mathcal{B}_k$ ³. 那么 $\mathcal{B} := \cup_k \mathcal{B}_k$ 是线性无关向量组.

证明: 这个定理的证明只需稍加思索就能作出. 书写证明主要的难点在于选用合适的记号.

我们不用双下标【一个用于编号 $\mathcal{B}_k$, 另一个用于编号 $\mathcal{B}_k$ 中的向量】, 而只用一个下标. 令 n 为 $\mathcal{B} := \cup_k \mathcal{B}_k$ 中的向量个数, 并且将 $\mathcal{B}$ 中的向量排列成: 首先是 $\mathcal{B}_1$ 中的向量, 然后是 $\mathcal{B}_2$ 中的向量……最后是 $\mathcal{B}_p$ 中的向量. 这样一来, 我们将 $\mathcal{B}$ 中的所有向量的下标编为 $1, 2, \dots, n$. 下标集合 $\{1, 2, \dots, n\}$ 分成 p 个子集 $\Lambda_1, \Lambda_2, \dots, \Lambda_p$, 使得 $\mathcal{B}_k$ 包含向量 $\mathbf{b}_j : j \in \Lambda_k$.

设存在非平凡线性组合

$$(2.4) \quad c_1 \mathbf{b}_1 + c_2 \mathbf{b}_2 + \dots + c_n \mathbf{b}_n = \sum_{j=1}^n c_j \mathbf{b}_j = \mathbf{0}.$$

记

$$\mathbf{v}_k = \sum_{j \in \Lambda_k} c_j \mathbf{b}_j.$$

那么 (2.4) 可写为

$$\mathbf{v}_1 + \mathbf{v}_2 + \dots + \mathbf{v}_p = \mathbf{0}.$$

因为 $\mathbf{v}_k \in V_k$, 并且各子空间 V_k 线性无关, 所以 $\mathbf{v}_k = \mathbf{0} \forall k$. 这意味着对每个 k 都有

$$\sum_{j \in \Lambda_k} c_j \mathbf{b}_j = \mathbf{0}$$

又因为向量组 $\mathbf{b}_j : j \in \Lambda_k$ (即 $\mathcal{B}_k$) 线性无关, 所以对所有 $j \in \Lambda_k$, 有 $c_j = 0$. 因为该结论对于所有 Λ_k 都成立, 所以对所有 j 也有 $c_j = 0$. $\square$

定理 2.6 的证明: 本定理的证明中, 我们将用与引理 2.7 中相同的记号, 即向量组 $\mathcal{B}_k$ 包含向量 $\mathbf{b}_j, j \in \Lambda_k$.

引理 2.7 表明, 向量组 $\mathbf{b}_j, j = 1, 2, \dots, n$ 线性无关, 因此只需证明这个组是完备的.

²我们不列出 $\mathcal{B}_k$ 中的向量, 只需记住每个 $\mathcal{B}_k$ 都包含 V_k 中的有限多个向量.

³同样地, 我们不逐一列出 $\mathcal{B}_k$ 中的向量, 只需记住每个 $\mathcal{B}_k$ 都包含有限多个向量.

因为子空间构成的组 $V_1, V_2, \dots, V_p$ 是基, 所以任意向量 $\mathbf{v} \in V$ 可表示为

$$\mathbf{v} = \mathbf{v}_1 + \mathbf{v}_2 + \dots + \mathbf{v}_p = \sum_{k=1}^p \mathbf{v}_k, \quad \mathbf{v}_k \in V_k.$$

因为向量 $\mathbf{b}_j, j \in \Lambda_k$ 形成 V_k 的基, 所以向量 $\mathbf{v}_k$ 可表示为

$$\mathbf{v}_k = \sum_{j \in \Lambda_k} c_j \mathbf{b}_j,$$

因此 $\mathbf{v} = \sum_{j=1}^n c_j \mathbf{b}_j$. □

2.5. 可对角化的判据

先给出一个简单的必要条件. 因为对角阵 $D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ 的特征值 (以重数计) 恰为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 所以我们可见若算子 $A: V \rightarrow V$ 可对角化, 则它恰有 $n = \dim V$ 个特征值 (以重数计).

下面定理对于实向量空间和复向量空间 (乃至任意域上的空间) 都成立.

定理 2.8. 令算子 $A: V \rightarrow V$ 恰有 $n = \dim V$ 个特征值 (以重数计)⁴. 那么 A 可对角化, 当且仅当对每个特征值 λ , 特征空间 $\text{Ker}(A - \lambda I)$ 的维数 (即 λ 的几何重数) 等于 λ 的代数重数.

证明: 首先, 注意到对于对角矩阵, 特征值的代数重数和几何重数是相等的, 因此可对角化算子也是如此.

下面证明另一方向的蕴涵关系. 令 $\lambda_1, \lambda_2, \dots, \lambda_p$ 是 A 的特征值, 并令 $E_k := \text{Ker}(A - \lambda_k I)$ 是对应的特征空间. 根据注 2.4, 子空间 $E_k, k = 1, 2, \dots, p$ 线性无关.

令 $\mathcal{B}_k$ 是 E_k 的基. 由引理 2.7, $\mathcal{B} = \cup_k \mathcal{B}_k$ 是线性无关向量组.

我们知道每个 $\mathcal{B}_k$ 包含 $\dim E_k$ (等于 λ_k 的重数) 个向量. 所以 $\mathcal{B}$ 中的向量个数等于各特征值 λ_k 的重数之和. 但是特征值的重数之和, 就是所有特征值的数量 (以重数计), 而这恰为 $n = \dim V$. 所以我们得到了 $n = \dim V$ 个特征向量构成的线性无关向量组, 也就得到了特征向量构成的基. □

⁴因为复向量空间上的任意算子都恰有 $n = \dim V$ 个特征值 (以重数计), 所以这个假设在复数情形下是多余的.

2.6. 实对角化

下面的定理实际上已经被证明了 (它就是定理 2.8 用于实向量空间的情况). 我们在此处写出它, 以总结对实矩阵进行实对角化的情况.

定理 2.9. $n \times n$ 实矩阵 A 能进行实对角化 (即能写成表达式 $A = SDS^{-1}$, 其中矩阵 S 和 D 都为实矩阵, D 是对角矩阵, S 是可逆的), 当且仅当 A 能进行复对角化且 A 的所有特征值都是实数.

2.7. 一些例子

2.7.1. 特征值为实数

考虑矩阵

$$A = \begin{pmatrix} 1 & 2 \\ 8 & 1 \end{pmatrix}.$$

它的特征多项式等于

$$\begin{vmatrix} 1-\lambda & 2 \\ 8 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 - 16$$

该多项式的根是 $\lambda = 5$ 和 $\lambda = -3$. 对特征值 $\lambda = 5$

$$A - 5I = \begin{pmatrix} 1-5 & 2 \\ 8 & 1-5 \end{pmatrix} = \begin{pmatrix} -4 & 2 \\ 8 & -4 \end{pmatrix}$$

其零空间的基由单个向量 $(1, 2)^T$ 构成, 所以这就是该特征值对应的特征向量.

类似地, 对于 $\lambda = -3$

$$A - \lambda I = A + 3I = \begin{pmatrix} 4 & 2 \\ 8 & 4 \end{pmatrix}$$

特征空间 $\text{Ker}(A + 3I)$ 由单个向量 $(1, -2)^T$ 张成. 则矩阵 A 可对角化为

$$A = \begin{pmatrix} 1 & 2 \\ 8 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 2 & -2 \end{pmatrix} \begin{pmatrix} 5 & 0 \\ 0 & -3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 2 & -2 \end{pmatrix}^{-1}$$

2.7.2. 特征值为复数

考虑矩阵

$$A = \begin{pmatrix} 1 & 2 \\ -2 & 1 \end{pmatrix}.$$

其特征多项式为

$$\begin{vmatrix} 1-\lambda & 2 \\ -2 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 + 2^2$$

且其特征值（特征多项式的根）为 $\lambda = 1 \pm 2i$. 对 $\lambda = 1 + 2i$

$$A - \lambda I = \begin{pmatrix} -2i & 2 \\ -2 & -2i \end{pmatrix}$$

该矩阵的秩为 1, 所以特征空间 $\text{Ker}(A - \lambda I)$ 由一个向量张成, 比如 $(1, i)^T$.

因为 A 为实矩阵, 我们不要求 $\lambda = 1 - 2i$ 的特征向量, 而是只需取上面特征向量的复共轭 (见下习题 2.2). 所以, 对应于 $\lambda = 1 - 2i$ 的特征向量是 $(1, -i)^T$, 所以矩阵 A 可对角化为

$$A = \begin{pmatrix} 1 & 1 \\ i & -i \end{pmatrix} \begin{pmatrix} 1+2i & 0 \\ 0 & 1-2i \end{pmatrix} \begin{pmatrix} 1 & 1 \\ i & -i \end{pmatrix}^{-1}.$$

2.7.3. 不可对角化的矩阵

考虑矩阵

$$A = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}.$$

其特征多项式为

$$\begin{vmatrix} 1-\lambda & 1 \\ 0 & 1-\lambda \end{vmatrix} = (1-\lambda)^2,$$

所以 A 的特征值为 1, 且其重数为 2. 但很容易看出 $\dim \text{Ker}(A - I) = 1$ ($A - I$ 有 1 个主元, 所以有 $2 - 1 = 1$ 个自由变量). 所以, 特征值 1 的几何重数不等于代数重数, 故 A 不可对角化.

还有一种不用定理 2.8 的解释: 特征空间 $\text{Ker}(A - 1I)$ 的特征空间是一维的 (由向量 $(1, 0)^T$ 张成). 如果 A 可对角化, 那么它应关于某个基具有对角阵 $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ ⁵, 则特征空间的维数应为 2. 因此 A 不可对角化.

习题

2.1. 令 A 为 $n \times n$ 矩阵. 判断正误:

- a) A^T 和 A 的特征值相同;
- b) A^T 和 A 的特征向量相同;
- c) 若 A 可对角化, 那么 A^T 也可对角化.

证明你的结论.

2.2. 令 A 为各项为实数的方阵, 并令 λ 为它的复特征值. 令 $\mathbf{v} = (v_1, v_2, \dots, v_n)^T$ 是对应的特征向量, $A\mathbf{v} = \lambda\mathbf{v}$. 证明: $\bar{\lambda}$ 是 A 的特征值, 且 $A\bar{\mathbf{v}} = \bar{\lambda}\bar{\mathbf{v}}$, 此处 $\bar{\mathbf{v}}$ 是向量 $\mathbf{v}$ 的复共轭, $\bar{\mathbf{v}} := (\bar{v}_1, \bar{v}_2, \dots, \bar{v}_n)^T$.

⁵注意, 关于某个基具有对角阵 $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ 的唯一线性变换是恒等变换 I . 因为 A 肯定不是恒等变换, 所以我们可以断定 A 不可对角化, 所以其实没有必要计算特征空间的维数.

2.3. 令

$$A = \begin{pmatrix} 4 & 3 \\ 1 & 2 \end{pmatrix}.$$

通过对角化 A , 求 A^{2004} .

2.4. 构造矩阵 A , 其特征值为 1 和 3, 对应的特征向量分别是 $(1, 2)^T$ 和 $(1, 1)^T$. 这样的矩阵是唯一的吗?

2.5. 将下列的矩阵对角化 (如果可以的话)

a) $\begin{pmatrix} 4 & -2 \\ 1 & 1 \end{pmatrix};$

b) $\begin{pmatrix} -1 & -1 \\ 6 & 4 \end{pmatrix};$

c) $\begin{pmatrix} -2 & 2 & 6 \\ 5 & 1 & -6 \\ -5 & 2 & 9 \end{pmatrix}$ ($\lambda = 2$ 是它的一个特征值).

2.6. 考虑矩阵

$$A = \begin{pmatrix} 2 & 6 & -6 \\ 0 & 5 & -2 \\ 0 & 0 & 4 \end{pmatrix}.$$

a) 求它的特征值. 是否可以无需计算就求出特征值?

b) 该矩阵可对角化吗? 不要通过计算得出答案.

c) 如果该矩阵可对角化, 则将它对角化.

2.7. 将下列矩阵对角化

$$\begin{pmatrix} 2 & 0 & 6 \\ 0 & 2 & 4 \\ 0 & 0 & 4 \end{pmatrix}.$$

2.8. 求出下列矩阵的所有平方根

$$A = \begin{pmatrix} 5 & 2 \\ -3 & 0 \end{pmatrix}$$

即求出所有满足 $B^2 = A$ 的矩阵 B . **提示:** 求出对角矩阵的平方根很容易. 你可以将答案保留为乘积形式.

2.9. 回忆一下, 著名的斐波那契序列

$$0, 1, 1, 2, 3, 5, 8, 13, 21$$

定义如下: 置 $\varphi_0 = 0, \varphi_1 = 1$, 并定义

$$\varphi_{n+2} = \varphi_{n+1} + \varphi_n.$$

现要求 φ_n 的公式. 为此

a) 求 2×2 矩阵 A 满足

$$\begin{pmatrix} \varphi_{n+2} \\ \varphi_{n+1} \end{pmatrix} = A \begin{pmatrix} \varphi_{n+1} \\ \varphi_n \end{pmatrix}$$

提示: 将一个看似显然的公式 $\varphi_{n+1} = \varphi_{n+1}$ 和斐波那契递推关系 $\varphi_{n+2} = \varphi_{n+1} + \varphi_n$ 联立.

b) 对角化 A , 并求出 A^n 的公式.

c) 注意到

$$\begin{pmatrix} \varphi_{n+1} \\ \varphi_n \end{pmatrix} = A^n \begin{pmatrix} \varphi_1 \\ \varphi_0 \end{pmatrix} = A^n \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

求出 φ_n 的公式. (此处你需要计算逆和乘法)

d) 证明: 向量 $(\varphi_{n+1}/\varphi_n, 1)^T$ 收敛到 A 的一个特征向量.

你觉得这是巧合吗?

2.10. 令 A 为 5×5 矩阵, 具有 3 个特征值 (此处不按重数计). 假设我们知道其中一个特征空间是三维的, 能否确定 A 是否可对角化?

2.11. 举出一例不可对角化的 3×3 矩阵. 在构造出这个矩阵后, 你能否使其看上去“一般化”, 即看不出该矩阵的特殊结构?

2.12. 令非零矩阵 A 满足 $A^5 = \mathbf{0}$. 证明: A 不可对角化. 更一般地, 任何非零的幂零矩阵, 即满足 $A^N = \mathbf{0}$ 的非零矩阵 A 都不可对角化.

2.13. 转置变换的特征值:

a) 考虑由 2×2 矩阵构成的向量空间 $M_{2 \times 2}$ 中的变换 T , $T(A) = A^T$. 求出它的所有特征值和特征向量. 这个变换可对角化吗? **提示:** 尽管可以通过写出这个线性变换关于某个基的矩阵, 再计算特征多项式……的常规方法计算, 但更为简单的办法是直接从定义出发.

b) 将 2×2 换成 $n \times n$, 再求解上述问题.

2.14. 证明: 两个子空间 V_1 和 V_2 线性无关, 当且仅当 $V_1 \cap V_2 = \{\mathbf{0}\}$.

第 5 章 内积空间

内积空间的理论只建立在实向量空间和复向量空间上，所以在本章中 $\mathbb{F}$ 总是 $\mathbb{R}$ 或 $\mathbb{C}$. 本章中的结论通常不能推广到任意域上的向量空间.

本章中的大多数结论和计算过程适用于实数和复数情形（并且结论的表述相同）. 在极少数情况中，实数和复数情形有差异，此时我们会说明考虑的是哪种情形，否则就是对两种情形都成立.

最后，当结论和计算过程适用于实数和复数情形时，我们用复数情形下的公式，它们在实数情形下也正确，虽然有时会复杂一点.

1. $\mathbb{R}^n$ 和 $\mathbb{C}^n$ 上的内积、内积空间

1.1. $\mathbb{R}^n$ 上的内积和范数

在 2 维和 3 维中，我们利用毕达哥拉斯法则¹定义向量 $\mathbf{x}$ 的长度（即从其终点到原点的距离），例如在 $\mathbb{R}^3$ 中向量的长度定义为

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + x_3^2}.$$

将该公式推广到所有的 n 是很自然的——向量 $\mathbf{x} \in \mathbb{R}^n$ 的**范数**定义为

$$\|\mathbf{x}\| = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}.$$

“**范数**”这个花哨的词用于替代“长度”.

$\mathbb{R}^3$ 上的**点积**定义为 $\mathbf{x} \cdot \mathbf{y} = x_1 y_1 + x_2 y_2 + x_3 y_3$ ，其中 $\mathbf{x} = (x_1, x_2, x_3)^T$ ， $\mathbf{y} = (y_1, y_2, y_3)^T$.

尽管内积也表示为 $\mathbf{x} \cdot \mathbf{y}$ 并且称作点积，我们更倾向于使用 $(\mathbf{x}, \mathbf{y})$ （后面会说明原因）.

类似地，在 $\mathbb{R}^n$ 上我们可定义两向量 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$, $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ 的**内积** $(\mathbf{x}, \mathbf{y})$ 为

$$(\mathbf{x}, \mathbf{y}) := x_1 y_1 + x_2 y_2 + \dots + x_n y_n = \mathbf{y}^T \mathbf{x},$$

故 $\|\mathbf{x}\| = \sqrt{(\mathbf{x}, \mathbf{x})}$.

注意， $\mathbf{y}^T \mathbf{x} = \mathbf{x}^T \mathbf{y}$ ，而我们都使用记号 $\mathbf{y}^T \mathbf{x}$ 只是为了统一起见.

¹即勾股定理. ——译者注

1.2. $\mathbb{C}^n$ 上的内积和范数

下面定义 $\mathbb{C}^n$ 上的范数和内积. 如之前所见, 从谱理论的视角来看, 复向量空间 $\mathbb{C}^n$ 是最为自然的: 即便研究的是各项为实数的矩阵 (或者实向量空间上的算子), 特征值也可能是复的, 于是我们就需要在复向量空间中研究.

对于复数 $z = x + iy$, 我们有 $|z|^2 = x^2 + y^2 = z\bar{z}$. 若 $\mathbf{z} \in \mathbb{C}^n$ 形如

$$\mathbf{z} = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix} = \begin{pmatrix} x_1 + iy_1 \\ x_2 + iy_2 \\ \vdots \\ x_n + iy_n \end{pmatrix},$$

就能很自然由下式定义其范数 $\|\mathbf{z}\|$:

$$\|\mathbf{z}\|^2 = \sum_{k=1}^n (x_k^2 + y_k^2) = \sum_{k=1}^n |z_k|^2.$$

现在我们尝试定义 $\mathbb{C}^n$ 上的内积使得 $\|\mathbf{z}\|^2 = (\mathbf{z}, \mathbf{z})$. 一种做法是定义 $(\mathbf{z}, \mathbf{w})$ 为

$$(\mathbf{z}, \mathbf{w}) = z_1 \bar{w}_1 + z_2 \bar{w}_2 + \dots + z_n \bar{w}_n = \sum_{k=1}^n z_k \bar{w}_k,$$

这就是 $\mathbb{C}^n$ 上**标准内积**的定义.

为简化记号, 我们引入一个新概念: 定义矩阵 A 的**埃尔米特伴随** (或简称**伴随**) A^* 为 $A^* = \overline{A^T}$, 意即先取矩阵的转置, 再取各项的复共轭. 注意对于实矩阵 A , 有 $A^* = A^T$.

利用 A^* 的概念, 可以将 $\mathbb{C}^n$ 上的标准内积写成

$$(\mathbf{z}, \mathbf{w}) = \mathbf{w}^* \mathbf{z}.$$

注. 容易看出, 还可以在 $\mathbb{C}^n$ 上定义另一种内积以满足 $\|\mathbf{z}\|^2 = (\mathbf{z}, \mathbf{z})$, 即定义内积为

$$(\mathbf{z}, \mathbf{w})_1 = \bar{z}_1 w_1 + \bar{z}_2 w_2 + \dots + \bar{z}_n w_n = \mathbf{z}^* \mathbf{w}.$$

我们并未指明内积应满足的性质, 但只有 $\mathbf{z}^* \mathbf{w}$ 和 $\mathbf{w}^* \mathbf{z}$ 能满足 $\|\mathbf{z}\|^2 = (\mathbf{z}, \mathbf{z})$.

注意, 上述两种内积的定义实质上是等价的, 唯一的区别仅在于记号, 因为 $(\mathbf{z}, \mathbf{w})_1 = (\mathbf{w}, \mathbf{z})$.

尽管第二种内积定义看上去更为自然, 但第一种 $((\mathbf{z}, \mathbf{w}) = \mathbf{w}^* \mathbf{z})$ 使用得更为广泛, 所以我们将采用它.

1.3. 内积空间

我们定义的 $\mathbb{R}^n$ 和 $\mathbb{C}^n$ 上的内积满足下列性质:

1. (共轭) 对称性: $(\mathbf{x}, \mathbf{y}) = \overline{(\mathbf{y}, \mathbf{x})}$; 注意, 对实向量空间, 该性质简化为对称性, 即 $(\mathbf{x}, \mathbf{y}) = (\mathbf{y}, \mathbf{x})$;
2. 线性: 对于所有向量 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 和所有标量 α, β , 有 $(\alpha\mathbf{x} + \beta\mathbf{y}, \mathbf{z}) = \alpha(\mathbf{x}, \mathbf{z}) + \beta(\mathbf{y}, \mathbf{z})$;
3. 非负性: $(\mathbf{x}, \mathbf{x}) \geq 0 \forall \mathbf{x}$;
4. 非退化性: $(\mathbf{x}, \mathbf{x}) = 0$ 当且仅当 $\mathbf{x} = \mathbf{0}$.

令 V 是 (复或实) 向量空间. V 上的**内积**是一个函数, 它将每对向量 $\mathbf{x}, \mathbf{y}$ 都对应到标量 $(\mathbf{x}, \mathbf{y})$, 且满足上述性质 1-4.

注意对实向量空间 V , 我们假设 $(\mathbf{x}, \mathbf{y})$ 总是实数, 而对于复向量空间, 内积 $(\mathbf{x}, \mathbf{y})$ 可能是复数.

带有定义于其上的内积的向量空间 V 称为**内积空间**. 给定内积空间, 可定义其上的范数为

$$\|\mathbf{x}\| = \sqrt{(\mathbf{x}, \mathbf{x})}.$$

1.3.1. 例子

例 1.1. 设 V 是 $\mathbb{R}^n$ 或 $\mathbb{C}^n$. 我们在前文已经定义了内积 $(\mathbf{x}, \mathbf{y}) = \mathbf{y}^* \mathbf{x} = \sum_{k=1}^n x_k \bar{y}_k$.

该内积称为 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 上的**标准内积**.

我们将用符号 $\mathbb{F}$ 来指代 $\mathbb{R}$ 和 $\mathbb{C}$. 当我们陈述一个有关向量空间 $\mathbb{F}^n$ 的结论时, 该结论适用于 $\mathbb{R}^n$ 和 $\mathbb{C}^n$.

例 1.2. 令 V 是由次数至多为 n 的多项式构成的向量空间 $\mathbb{P}_n$. 定义内积为

$$(f, g) = \int_{-1}^1 f(t) \overline{g(t)} dt.$$

容易验证其满足上述性质 1-4.

这个定义适用于实数和复数情形. 在实数情形下, 我们只考虑实系数多项式, 则上式中的复共轭可去掉.

回忆一下, 方阵 A 的**迹**定义为对角项之和:

$$\text{trace } A := \sum_{k=1}^n a_{k,k}.$$

例 1.3. 对由 $m \times n$ 矩阵所构成的向量空间 $M_{m \times n}$, 定义所谓弗罗贝尼乌斯内积为

$$(A, B) = \text{trace}(B^* A).$$

同样容易验证其满足性质 1-4, 即我们确实定义了一个内积.

注意到

$$\text{trace}(B^* A) = \sum_{j,k} A_{j,k} \overline{B_{j,k}},$$

所以该内积与 $\mathbb{C}^{mn}$ 上的标准内积相同.

1.4. 内积的性质

本节中的结论不仅对于 $\mathbb{F}^n$ 成立, 而且对于任意内积空间都成立. 证明它们只需用到内积的性质 1-4.

首先注意, 性质 1 和 2 蕴涵

$$2' \quad (\mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z}) = \overline{\alpha}(\mathbf{x}, \mathbf{y}) + \overline{\beta}(\mathbf{x}, \mathbf{z}).$$

的确:

$$\begin{aligned} (\mathbf{x}, \alpha \mathbf{y} + \beta \mathbf{z}) &= \overline{(\alpha \mathbf{y} + \beta \mathbf{z}, \mathbf{x})} = \overline{\alpha(\mathbf{y}, \mathbf{x}) + \beta(\mathbf{z}, \mathbf{x})} \\ &= \overline{\alpha(\mathbf{y}, \mathbf{x})} + \overline{\beta(\mathbf{z}, \mathbf{x})} = \overline{\alpha}(\mathbf{x}, \mathbf{y}) + \overline{\beta}(\mathbf{x}, \mathbf{z}) \end{aligned}$$

还要注意, 性质 2 蕴涵对于所有向量 $\mathbf{x}$ 有

$$(\mathbf{0}, \mathbf{x}) = (\mathbf{x}, \mathbf{0}) = 0.$$

引理 1.4. 令 $\mathbf{x}$ 是内积空间 V 中的向量. 那么 $\mathbf{x} = \mathbf{0}$ 当且仅当

$$(1.1) \quad (\mathbf{x}, \mathbf{y}) = 0, \quad \forall \mathbf{y} \in V.$$

证明: 因为 $(\mathbf{0}, \mathbf{y}) = 0$, 我们只需证明 (1.1) 蕴涵 $\mathbf{x} = \mathbf{0}$. 将 $\mathbf{y} = \mathbf{x}$ 代入 (1.1) 可得 $(\mathbf{x}, \mathbf{x}) = 0$, 所以 $\mathbf{x} = \mathbf{0}$. $\square$

对差值 $\mathbf{x} - \mathbf{y}$ 运用上述引理可得

推论 1.5. 令 $\mathbf{x}, \mathbf{y}$ 是内积空间 V 中的向量. 等式 $\mathbf{x} = \mathbf{y}$ 成立当且仅当

$$(\mathbf{x}, \mathbf{z}) = (\mathbf{y}, \mathbf{z}) \quad \forall \mathbf{z} \in V.$$

下面推论很简单却很常用:

推论 1.6. 设两个算子 $A, B: X \rightarrow Y$ 满足

$$(A\mathbf{x}, \mathbf{y}) = (B\mathbf{x}, \mathbf{y}) \quad \forall \mathbf{x} \in X, \forall \mathbf{y} \in Y.$$

那么 $A = B$.

证明: 取定 $\mathbf{x}$ 并取所有可能的 $\mathbf{y}$, 由上一个推论可得 $A\mathbf{x} = B\mathbf{x}$. 因为这对于所有 $\mathbf{x} \in X$ 都成立, 所以变换 A 和 B 相同. $\square$

下面性质将范数和内积联系起来.

定理 1.7 (柯西-施瓦兹不等式).

$$|(\mathbf{x}, \mathbf{y})| \leq \|\mathbf{x}\| \cdot \|\mathbf{y}\|.$$

证明: 我们将呈现的证明并不是最简短的, 但它展示了证明核心思路的由来.

首先考虑实数情形. 如果 $\mathbf{y} = \mathbf{0}$, 该结论是平凡的, 所以可假设 $\mathbf{y} \neq \mathbf{0}$. 由内积的性质, 对于所有标量 t 有

$$0 \leq \|\mathbf{x} - t\mathbf{y}\|^2 = (\mathbf{x} - t\mathbf{y}, \mathbf{x} - t\mathbf{y}) = \|\mathbf{x}\|^2 - 2t(\mathbf{x}, \mathbf{y}) + t^2\|\mathbf{y}\|^2.$$

特别地, 该不等式对 $t = \frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|^2}$ 成立², 该点处不等式变为

$$0 \leq \|\mathbf{x}\|^2 - 2 \frac{(\mathbf{x}, \mathbf{y})^2}{\|\mathbf{y}\|^2} + \frac{(\mathbf{x}, \mathbf{y})^2}{\|\mathbf{y}\|^2} = \|\mathbf{x}\|^2 - \frac{(\mathbf{x}, \mathbf{y})^2}{\|\mathbf{y}\|^2},$$

而这就是我们要证的不等式.

复数情形有多种处理方式. 一种方法是將 $\mathbf{x}$ 换成 $\alpha\mathbf{x}$, 其中 α 是复常数且 $|\alpha| = 1$, 使得 $(\alpha\mathbf{x}, \mathbf{y})$ 是实数, 然后重复对于实数情形的证明.

另一种可行方法是, 再次考虑

$$\begin{aligned} 0 \leq \|\mathbf{x} - t\mathbf{y}\|^2 &= (\mathbf{x} - t\mathbf{y}, \mathbf{x} - t\mathbf{y}) = (\mathbf{x}, \mathbf{x} - t\mathbf{y}) - t(\mathbf{y}, \mathbf{x} - t\mathbf{y}) \\ &= \|\mathbf{x}\|^2 - t(\mathbf{y}, \mathbf{x}) - \bar{t}(\mathbf{x}, \mathbf{y}) + |t|^2\|\mathbf{y}\|^2. \end{aligned}$$

将 $t = \frac{(\mathbf{x}, \mathbf{y})}{\|\mathbf{y}\|^2} = \frac{\overline{(\mathbf{y}, \mathbf{x})}}{\|\mathbf{y}\|^2}$ 代入此不等式, 即得

$$0 \leq \|\mathbf{x}\|^2 - \frac{|(\mathbf{x}, \mathbf{y})|^2}{\|\mathbf{y}\|^2}$$

而这就是我们所需的不等式.

注意, 上面这一段已经可以作为该定理的完整且正式证明. 在它之前作的推导, 只是为了解释我们为什么要取 t 为这个特定值. $\square$

由柯西-施瓦兹不等式可立即推出下述引理.

引理 1.8 (三角不等式). 对一内积空间中的任意向量 $\mathbf{x}, \mathbf{y}$,

$$\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|.$$

²这是上述二次多项式的最小值点. 可以这样计算: 对 t 求导并令导数等于 0.

证明:

$$\begin{aligned}\|\mathbf{x} + \mathbf{y}\|^2 &= (\mathbf{x} + \mathbf{y}, \mathbf{x} + \mathbf{y}) = \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 + (\mathbf{x}, \mathbf{y}) + (\mathbf{y}, \mathbf{x}) \\ &\leq \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 + 2|(\mathbf{x}, \mathbf{y})| \\ &\leq \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 + 2\|\mathbf{x}\| \cdot \|\mathbf{y}\| = (\|\mathbf{x}\| + \|\mathbf{y}\|)^2.\end{aligned}$$

□

下述**极化恒等式**使我们得以由范数重建出内积:

引理 1.9 (极化恒等式). 对 $\mathbf{x}, \mathbf{y} \in V$, 若 V 是实内积空间, 则

$$(\mathbf{x}, \mathbf{y}) = \frac{1}{4} (\|\mathbf{x} + \mathbf{y}\|^2 - \|\mathbf{x} - \mathbf{y}\|^2)$$

若 V 是复内积空间, 则

$$(\mathbf{x}, \mathbf{y}) = \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|\mathbf{x} + \alpha \mathbf{y}\|^2$$

该引理通过直接计算就能证明, 我们将证明留给读者作为习题.

内积空间上范数的另一个重要性质也可以通过直接计算来证明.

引理 1.10 (平行四边形恒等式). 对任意向量 $\mathbf{u}, \mathbf{v}$,

$$\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2(\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2).$$

在 2 维空间中, 该引理将平行四边形的边与对角线联系起来, 其名称即源于此. 这是平面几何中的著名结论.

1.5. 范数、赋范空间

前面我们证明了范数 $\|\mathbf{v}\|$ 满足下列性质:

1. 齐次性: 对于所有向量 $\mathbf{v}$ 和所有标量 α , 有 $\|\alpha \mathbf{v}\| = |\alpha| \cdot \|\mathbf{v}\|$.
2. 三角不等式: $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$.
3. 非负性: 对于所有向量 $\mathbf{v}$, 有 $\|\mathbf{v}\| \geq 0$.
4. 非退化性: $\|\mathbf{v}\| = 0$ 当且仅当 $\mathbf{v} = \mathbf{0}$.

假设向量空间 V 中, 我们将每个向量 $\mathbf{v}$ 都对应到一个数 $\|\mathbf{v}\|$, 并且使得上述性质 1-4 成立. 那么就称函数 $\mathbf{v} \mapsto \|\mathbf{v}\|$ 为范数. 配有范数的向量空间 V 称为**赋范空间**.

任何内积空间都是赋范空间, 因为范数 $\|\mathbf{v}\| = \sqrt{(\mathbf{v}, \mathbf{v})}$ 满足上述性质 1-4. 然而, 还有很多别的赋范空间. 例如, 给定 p ($1 \leq p < \infty$), 可

在 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 上定义范数 $\|\cdot\|_p$ 为

$$\|\mathbf{x}\|_p = (|x_1|^p + |x_2|^p + \dots + |x_n|^p)^{1/p} = \left(\sum_{k=1}^n |x_k|^p \right)^{1/p}.$$

还可以定义范数 $\|\cdot\|_\infty$ ($p = \infty$) 为

$$\|\mathbf{x}\|_\infty = \max\{|x_k| : k = 1, 2, \dots, n\}.$$

$p = 2$ 时的范数 $\|\cdot\|_p$ 就是通常的由内积获得的范数.

要检验 $\|\cdot\|_p$ 的确是范数, 需要检验它满足上述性质 1-4. 性质 1、3 和 4 很容易检验, 留给读者作为习题. 三角不等式 (性质 2) 对于 $p = 1$ 和 $p = \infty$ 很容易验证 (而 $p = 2$ 的情形我们已经证明过了).

p 为其他值时, 三角不等式是成立的, 但是证明不那么容易, 此处就不呈现了. $\|\cdot\|_p$ 的三角不等式有个特殊的名称——**闵可夫斯基不等式**, 它是用德国数学家 H. 闵可夫斯基的名字命名的.

注意, $p \neq 2$ 时的范数 $\|\cdot\|_p$ 不能由内积得到. 容易看出, 该范数不能由 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 上的**标准**内积得到. 但还不止于此——能产生范数 $\|\cdot\|_p, p \neq 2$ 的内积是**无法构造的**!

这个结论其实很容易证明. 由引理 1.10, 任意由内积得到的范数都必满足平行四边形恒等式. 容易看出平行四边形恒等式对于范数 $\|\cdot\|_p, p \neq 2$ 是不成立的——容易找到 $\mathbb{R}^2$ 中的反例, 并由此得到其他所有向量空间中的反例.

事实上, 如下面定理所保证的, 平行四边形恒等式是由内积得到的范数的独有特征.

定理 1.11. 赋范空间上的范数源于某个内积, 当且仅当其满足平行四边形恒等式

$$\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2(\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2) \quad \forall \mathbf{u}, \mathbf{v} \in V.$$

引理 1.10 表明由内积得到的范数满足平行四边形恒等式.

逆命题证明起来复杂些. 如果给定了一个范数, 并且该范数来自内积, 那么该内积一定是由极化恒等式给出 (见引理 1.9). 但我们需要证明由极化恒等式得到的 $(\mathbf{x}, \mathbf{y})$ 的确是内积, 也就是它满足内积的所有性质.

可以验证, 如果范数满足平行四边形恒等式, 那么由极化恒等式得到的内积 $(\mathbf{x}, \mathbf{y})$ 的确是内积 (即满足内积的所有性质). 然而, 该证明略显复杂, 所以此处按下不表.

习题

1.1. 计算:

$$(3+2i)(5-3i), \quad \frac{2-3i}{1-2i}, \quad \operatorname{Re}\left(\frac{2-3i}{1-2i}\right), \quad (1+2i)^3, \quad \operatorname{Im}((1+2i)^3).$$

1.2. 对向量 $\mathbf{x} = (1, 2i, 1+i)^T, \mathbf{y} = (i, 2-i, 3)^T$, 计算

a) $(\mathbf{x}, \mathbf{y}), \|\mathbf{x}\|^2, \|\mathbf{y}\|^2, \|\mathbf{y}\|$;

b) $(3\mathbf{x}, 2i\mathbf{y}), (2\mathbf{x}, i\mathbf{x} + 2\mathbf{y})$;

c) $\|\mathbf{x} + 2\mathbf{y}\|$.

注: 当你完成 a) 后, 可以只运用内积的性质完成 b) 和 c), 而不需要计算出其中所有向量.

1.3. 令 $\|\mathbf{u}\| = 2, \|\mathbf{v}\| = 3, (\mathbf{u}, \mathbf{v}) = 2+i$. 计算:

$$\|\mathbf{u} + \mathbf{v}\|^2, \quad \|\mathbf{u} - \mathbf{v}\|^2, \quad (\mathbf{u} + \mathbf{v}, \mathbf{u} - i\mathbf{v}), \quad (\mathbf{u} + 3i\mathbf{v}, 4i\mathbf{u}).$$

1.4. 证明: 对内积空间中的向量 $\mathbf{x}, \mathbf{y}$

$$\|\mathbf{x} \pm \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 \pm 2\operatorname{Re}(\mathbf{x}, \mathbf{y})$$

回忆一下, $\operatorname{Re} z = \frac{1}{2}(z + \bar{z})$.

1.5. 解释为何下面这些**不是**给定向量空间上的内积:

a) $\mathbb{R}^2$ 上的 $(\mathbf{x}, \mathbf{y}) = x_1y_1 - x_2y_2$;

b) 2×2 实矩阵构成的向量空间上的 $(A, B) = \operatorname{trace}(A + B)$;

c) 多项式构成的向量空间上的 $(f, g) = \int_0^1 f'(t)\overline{g(t)}dt$, 其中 $f'(t)$ 代表导数.

1.6. (柯西-施瓦兹不等式取等的条件) 证明:

$$|(\mathbf{x}, \mathbf{y})| = \|\mathbf{x}\| \cdot \|\mathbf{y}\|$$

当且仅当其中一个向量是另一个的倍数. 提示: 分析柯西-施瓦兹不等式的证明.

1.7. 证明内积空间 V 的平行四边形恒等式:

$$\|\mathbf{x} + \mathbf{y}\|^2 + \|\mathbf{x} - \mathbf{y}\|^2 = 2(\|\mathbf{x}\|^2 + \|\mathbf{y}\|^2).$$

1.8. 设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是内积空间 V 中的张成组 (特别地, 是 V 的基). 证明:

a) 如果 $(\mathbf{x}, \mathbf{v}) = 0$ 对于所有 $\mathbf{v} \in V$ 成立, 那么 $\mathbf{x} = \mathbf{0}$;

b) 如果 $(\mathbf{x}, \mathbf{v}_k) = 0 \forall k$, 那么 $\mathbf{x} = \mathbf{0}$;

c) 如果 $(\mathbf{x}, \mathbf{v}_k) = (\mathbf{y}, \mathbf{v}_k) \forall k$, 那么 $\mathbf{x} = \mathbf{y}$.

1.9. 考虑具有范数 $\|\cdot\|_p$ (1.5 节所述) 的向量空间 $\mathbb{R}^2$. 对 $p = 1, 2, \infty$, 画出范数 $\|\cdot\|_p$ 下的“单位球” B_p :

$$B_p := \{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\|_p \leq 1\}.$$

你能猜出对于其他的 p , 球 B_p 是什么样吗?

2. 正交性、正交基与规范正交基

定义 2.1. 称两向量 $\mathbf{u}$ 和 $\mathbf{v}$ 是**正交的** (或**垂直的**), 若 $(\mathbf{u}, \mathbf{v}) = 0$. 我们用 $\mathbf{u} \perp \mathbf{v}$ 表示两向量正交.

注意, 对于正交向量 $\mathbf{u}$ 和 $\mathbf{v}$, 有所谓的毕达哥拉斯恒等式:

$$\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 \quad \text{若 } \mathbf{u} \perp \mathbf{v}.$$

证明就是简单计算:

$$\|\mathbf{u} + \mathbf{v}\|^2 = (\mathbf{u} + \mathbf{v}, \mathbf{u} + \mathbf{v}) = (\mathbf{u}, \mathbf{u}) + (\mathbf{v}, \mathbf{v}) + (\mathbf{u}, \mathbf{v}) + (\mathbf{v}, \mathbf{u}) = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$$

(由于正交性, $(\mathbf{u}, \mathbf{v}) = (\mathbf{v}, \mathbf{u}) = 0$)

定义 2.2. 称向量 $\mathbf{v}$ 正交于子空间 E , 若 $\mathbf{v}$ 正交于 E 中的所有向量 $\mathbf{w}$.

称子空间 E 和 F 是正交的, 如果 E 中的所有向量都正交于 F , 也即 E 中的所有向量都正交于 F 中的所有向量.

下面引理展示了检验一向量正交于一子空间的方法.

引理 2.3. 令 E 由向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 张成. 那么 $\mathbf{v} \perp E$, 当且仅当

$$\mathbf{v} \perp \mathbf{v}_k, \quad \forall k = 1, 2, \dots, r.$$

证明: 由定义得, 若 $\mathbf{v} \perp E$, 那么 $\mathbf{v}$ 正交于 E 中的所有向量. 特别地, $\mathbf{v} \perp \mathbf{v}_k, k = 1, 2, \dots, r$.

另一方面, 设 $\mathbf{v} \perp \mathbf{v}_k, k = 1, 2, \dots, r$. 因为各向量 $\mathbf{v}_k$ 张成 E , 所以任意向量 $\mathbf{w} \in E$ 都能被表示成线性组合 $\sum_{k=1}^r \alpha_k \mathbf{v}_k$. 那么

$$(\mathbf{v}, \mathbf{w}) = \sum_{k=1}^r \alpha_k (\mathbf{v}, \mathbf{v}_k) = 0,$$

所以 $\mathbf{v} \perp \mathbf{w}$. □

定义 2.4. 称向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是**正交的**, 如果其中任意两个向量都彼此正交 (即如果 $(\mathbf{v}_j, \mathbf{v}_k) = 0, j \neq k$).

如果还有 $\|\mathbf{v}_k\| = 1$ 对所有 k 成立, 就称该向量组是**规范正交的**.

引理 2.5 (广义毕达哥拉斯恒等式). 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是正交向量组. 则

$$\left\| \sum_{k=1}^n \alpha_k \mathbf{v}_k \right\|^2 = \sum_{k=1}^n |\alpha_k|^2 \|\mathbf{v}_k\|^2$$

这个公式对于规范正交向量组 ($\|\mathbf{v}_k\| = 1$) 特别简洁.

引理的证明:

$$\left\| \sum_{k=1}^n \alpha_k \mathbf{v}_k \right\|^2 = \left(\sum_{k=1}^n \alpha_k \mathbf{v}_k, \sum_{j=1}^n \alpha_j \mathbf{v}_j \right) = \sum_{k=1}^n \sum_{j=1}^n \alpha_k \bar{\alpha}_j (\mathbf{v}_k, \mathbf{v}_j).$$

因为正交性 (若 $j \neq k$ 则 $(\mathbf{v}_k, \mathbf{v}_j) = 0$)，所以只需对 $j = k$ 的项求和，这就恰好会给出

$$\sum_{k=1}^n |\alpha_k|^2 (\mathbf{v}_k, \mathbf{v}_k) = \sum_{k=1}^n |\alpha_k|^2 \|\mathbf{v}_k\|^2. \quad \square$$

推论 2.6. 任意由非零向量构成的正交向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 线性无关.

证明: 假设有 $\alpha_1, \alpha_2, \dots, \alpha_n$ 使得 $\sum_{k=1}^n \alpha_k \mathbf{v}_k = \mathbf{0}$. 那么由广义毕达哥拉斯恒等式 (引理 2.5)

$$0 = \|\mathbf{0}\|^2 = \sum_{k=1}^n |\alpha_k|^2 \|\mathbf{v}_k\|^2.$$

因为 $\|\mathbf{v}_k\| \neq 0$ ($\mathbf{v}_k \neq \mathbf{0}$)，所以我们可得

$$\alpha_k = 0 \quad \forall k,$$

所以只有平凡线性组合能得出 $\mathbf{0}$. □

注. 接下来我们提到“正交向量组”的时候，一般是指由非零向量构成的正交向量组. 因为零向量 $\mathbf{0}$ 正交于任何向量，所以它可以被加进任意正交向量组中，但是考虑包含零向量的正交向量组很没意思.

2.1. 正交基与规范正交基

定义 2.7. 正交向量组 (规范正交向量组) $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 如果是基，就称为正交基 (规范正交基).

显然，如果 $\dim V = n$ ，那么任意由 n 个非零向量构成的正交向量组都是正交基.

我们前面讨论过，要求出向量在基下的坐标，需要求解线性方程组. 然而，求出向量关于正交基的坐标要容易得多：设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是正交基，并令

$$\mathbf{x} = \alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_n \mathbf{v}_n = \sum_{j=1}^n \alpha_j \mathbf{v}_j.$$

将此式两端与 $\mathbf{v}_1$ 做内积可得 (所有满足 $j \neq 1$ 的内积 $(\mathbf{v}_j, \mathbf{v}_1) = 0$)

$$(\mathbf{x}, \mathbf{v}_1) = \sum_{j=1}^n \alpha_j (\mathbf{v}_j, \mathbf{v}_1) = \alpha_1 (\mathbf{v}_1, \mathbf{v}_1) = \alpha_1 \|\mathbf{v}_1\|^2$$

所以

$$\alpha_1 = \frac{(\mathbf{x}, \mathbf{v}_1)}{\|\mathbf{v}_1\|^2}.$$

类似地, 两端与 $\mathbf{v}_k$ 做内积可得

$$(\mathbf{x}, \mathbf{v}_k) = \sum_{j=1}^n \alpha_j (\mathbf{v}_j, \mathbf{v}_k) = \alpha_k (\mathbf{v}_k, \mathbf{v}_k) = \alpha_k \|\mathbf{v}_k\|^2$$

所以

$$(2.1) \quad \alpha_k = \frac{(\mathbf{x}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2}$$

因此,

要求出向量在正交基下的坐标, 无需求解线性方程组, 而只需根据 (2.1) 确定坐标.

这个公式对于规范正交基尤其简单 ($\|\mathbf{v}_k\| = 1$).

也就是说, 如果 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是规范正交基, 那么任意向量 $\mathbf{v}$ 可表示为

$$(2.2) \quad \mathbf{v} = \sum_{k=1}^n (\mathbf{v}, \mathbf{v}_k) \mathbf{v}_k.$$

这个公式有时称为**抽象正交傅里叶分解** (的雏形). 经典 (非抽象) 的傅里叶分解用的是一个具体的规范正交向量组 (正余弦或复指数). 我们称上面的公式是**雏形**, 因为真正的傅里叶分解用的是无限的规范正交向量组.

注 2.8. 规范正交基的重要性在于, 如果我们在内积空间 V 中取定规范正交基, 那么我们就可以如同处理 $\mathbb{F}^n$ 中的向量一样处理在这个基下的坐标. 也就是像在本书开头所讨论的那样 (第 1 章注 2.4), 如果我们处理的是 (域 $\mathbb{F}$ 上的) 向量空间 V , 其具有基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 那么可以围绕关于基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的坐标列向量展开讨论, 从而如同对标准坐标空间 $\mathbb{F}^n$ 中的向量那样进行标准向量运算 (向量加法与标量乘法).

这个注记很重要, 它使我们得以将适用于标准内积空间 $\mathbb{F}^n$ 的各种表述迁移至具有规范正交基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的内积空间 V .

下方的习题 2.3 说明, 如果我们有内积空间 V 的**规范正交基**, 那么要计算 V 中两个向量的内积, 就可以首先取它们关于这个规范正交基的坐标列向量, 然后计算这两个列向量 (在 $\mathbb{C}^n$ 或 $\mathbb{R}^n$ 上) 的标准内积.

第 3 节中将证明, 每个有限维内积空间都有规范正交基. 于是, 有限维内积空间本质上就是标准内积空间 $\mathbb{C}^n$ (对于实内积空间, 就是 $\mathbb{R}^n$) 而已.

习题

2.1. 求出 $\mathbb{R}^4$ 中正交于向量 $(1, 1, 1, 1)^T$ 和 $(1, 2, 3, 4)^T$ 的所有向量.

2.2. 令 A 为 $m \times n$ 实矩阵. 描述 $(\text{Ran } A^T)^\perp$, $(\text{Ran } A)^\perp$.

2.3. 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的规范正交基.

a) 证明: 对任意 $\mathbf{x} = \sum_{k=1}^n \alpha_k \mathbf{v}_k, \mathbf{y} = \sum_{k=1}^n \beta_k \mathbf{v}_k$

$$(\mathbf{x}, \mathbf{y}) = \sum_{k=1}^n \alpha_k \bar{\beta}_k.$$

b) 由此推导帕塞瓦尔恒等式

$$(\mathbf{x}, \mathbf{y}) = \sum_{k=1}^n (\mathbf{x}, \mathbf{v}_k) \overline{(\mathbf{y}, \mathbf{v}_k)}$$

c) 假设 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 仅是正交基而不是规范正交基. 你能写出这种情形下的帕塞瓦尔恒等式吗?

这题说明, 如果我们有规范正交基, 那么运用在这个基下的坐标就和运用 $\mathbb{C}^n$ (或 $\mathbb{R}^n$) 中的标准坐标完全一样.

下面这题说明, 我们可以通过使一个基具有规范正交性来定义一个内积.

2.4. 令 V 为向量空间, 并令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的基. 对于 $\mathbf{x} = \sum_{k=1}^n \alpha_k \mathbf{v}_k, \mathbf{y} = \sum_{k=1}^n \beta_k \mathbf{v}_k$ 定义 $\langle \mathbf{x}, \mathbf{y} \rangle := \sum_{k=1}^n \alpha_k \bar{\beta}_k$.

证明: $\langle \mathbf{x}, \mathbf{y} \rangle$ 是 V 上的内积.

2.5. 令 A 为 $m \times n$ 实矩阵. 描述 $\mathbb{F}^m$ 中所有正交于 $\text{Ran } A$ 的向量所成的集合.

3. 正交投影与格拉姆-施密特正交化

回想一下经典平面几何 (2 维几何) 中的正交投影的定义, 可以引入下面的定义. 令 E 是内积空间 V 的子空间.

定义 3.1. 对向量 $\mathbf{v}$, 其往子空间 E 上的正交投影 $P_E \mathbf{v}$ 是满足下面条件的向量 $\mathbf{w}$:

1. $\mathbf{w} \in E$;
2. $\mathbf{v} - \mathbf{w} \perp E$.

我们记正交投影为 $\mathbf{w} = P_E \mathbf{v}$.

在引入一种对象之后, 很自然要问:

1. 这种对象存在吗?
2. 这种对象唯一吗?
3. 如何求出它?

我们首先证明正交投影是唯一的. 然后我们给出正交投影的一种求法, 这也就证明了其存在性.

下面定理展示了为何正交投影很重要,同时也证明了它的唯一性.

定理 3.2. 正交投影 $\mathbf{w} = P_E \mathbf{v}$ 最小化从 $\mathbf{v}$ 到 E 的距离,即对所有 $\mathbf{x} \in E$ 有

$$\|\mathbf{v} - \mathbf{w}\| \leq \|\mathbf{v} - \mathbf{x}\|.$$

此外,如果对某个 $\mathbf{x} \in E$ 有

$$\|\mathbf{v} - \mathbf{w}\| = \|\mathbf{v} - \mathbf{x}\|,$$

那么 $\mathbf{x} = \mathbf{w}$.

证明: 令 $\mathbf{y} = \mathbf{w} - \mathbf{x}$. 那么

$$\mathbf{v} - \mathbf{x} = \mathbf{v} - \mathbf{w} + \mathbf{w} - \mathbf{x} = \mathbf{v} - \mathbf{w} + \mathbf{y}.$$

因为 $\mathbf{v} - \mathbf{w} \perp E$, 所以有 $\mathbf{y} \perp \mathbf{v} - \mathbf{w}$, 故由毕达哥拉斯定理

$$\|\mathbf{v} - \mathbf{x}\|^2 = \|\mathbf{v} - \mathbf{w}\|^2 + \|\mathbf{y}\|^2 \geq \|\mathbf{v} - \mathbf{w}\|^2.$$

注意等号成立仅当 $\mathbf{y} = \mathbf{0}$, 即 $\mathbf{x} = \mathbf{w}$. □

下面命题阐述了已知 E 的正交基的情况下求出正交投影的方法.

命题 3.3. 如果 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是 E 的正交基. 那么向量 $\mathbf{v}$ 的正交投影 $P_E \mathbf{v}$ 由下式给出

$$P_E \mathbf{v} = \sum_{k=1}^r \alpha_k \mathbf{v}_k, \quad \text{其中} \quad \alpha_k = \frac{(\mathbf{v}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2}.$$

换言之

$$(3.1) \quad P_E \mathbf{v} = \sum_{k=1}^r \frac{(\mathbf{v}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2} \mathbf{v}_k.$$

注意, α_k 的公式与 (2.1) 相同, 即将此式应用于正交向量组 (不是基) 会给出往它的张成空间上的投影.

注 3.4. 从公式 (3.1) 中容易看出正交投影 P_E 是线性变换.

也可以从正交投影的定义和唯一性中看出 P_E 的线性. 的确如此: 容易检验对任意 $\mathbf{x}, \mathbf{y}$, 向量 $\alpha \mathbf{x} + \beta \mathbf{y} - (\alpha P_E \mathbf{x} + \beta P_E \mathbf{y})$ 正交于 E 中的所有向量, 所以由定义得 $P_E(\alpha \mathbf{x} + \beta \mathbf{y}) = \alpha P_E \mathbf{x} + \beta P_E \mathbf{y}$.

注 3.5. 回忆 $\mathbb{C}^n$ 和 $\mathbb{R}^n$ 上内积的定义, 可以从上述公式 (3.1) 得到 $\mathbb{C}^n$ 和 $\mathbb{R}^n$ 上往 E 上正交投影 P_E 的矩阵的公式

$$(3.2) \quad P_E = \sum_{k=1}^r \frac{1}{\|\mathbf{v}_k\|^2} \mathbf{v}_k \mathbf{v}_k^*$$

其中列向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 形成 E 的正交基.

命题 3.3 的证明: 令

$$\mathbf{w} := \sum_{k=1}^r \alpha_k \mathbf{v}_k, \quad \text{其中} \quad \alpha_k = \frac{(\mathbf{v}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2}.$$

欲证 $\mathbf{v} - \mathbf{w} \in E$. 由引理 2.3, 只需证明 $\mathbf{v} - \mathbf{w} \perp \mathbf{v}_k, k = 1, 2, \dots, r$. 计算内积即得, 对 $k = 1, 2, \dots, r$ 有

$$\begin{aligned} (\mathbf{v} - \mathbf{w}, \mathbf{v}_k) &= (\mathbf{v}, \mathbf{v}_k) - (\mathbf{w}, \mathbf{v}_k) = (\mathbf{v}, \mathbf{v}_k) - \sum_{j=1}^r \alpha_j (\mathbf{v}_j, \mathbf{v}_k) \\ &= (\mathbf{v}, \mathbf{v}_k) - \alpha_k (\mathbf{v}_k, \mathbf{v}_k) = (\mathbf{v}, \mathbf{v}_k) - \frac{(\mathbf{v}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2} \|\mathbf{v}_k\|^2 = 0. \quad \square \end{aligned}$$

所以, 已知 E 的正交基即可求出往 E 上的正交投影. 特别地, 由于仅包含一个向量的向量组都是正交向量组, 所以我们知道了如何将向量往一维空间上正交投影.

但是, 如果只知道 E 的基, 我们怎么求出正交投影呢? 幸运的是, 有个简单的算法能从基得出正交基.

3.1. 格拉姆-施密特正交化算法

假设我们有线性无关组 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$. 格拉姆-施密特方法能从该组构造正交向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 且满足

$$\text{span}\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} = \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}.$$

此外, 对所有 $r \leq n$ 有

$$\text{span}\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_r\} = \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\}$$

现在叙述该算法.

第 1 步. 置 $\mathbf{v}_1 := \mathbf{x}_1$. 记 $E_1 := \text{span}\{\mathbf{x}_1\} = \text{span}\{\mathbf{v}_1\}$.

第 2 步. 定义 $\mathbf{v}_2$ 为

$$\mathbf{v}_2 = \mathbf{x}_2 - P_{E_1} \mathbf{x}_2 = \mathbf{x}_2 - \frac{(\mathbf{x}_2, \mathbf{v}_1)}{\|\mathbf{v}_1\|^2} \mathbf{v}_1.$$

定义 $E_2 = \text{span}\{\mathbf{v}_1, \mathbf{v}_2\}$. 注意 $\text{span}\{\mathbf{x}_1, \mathbf{x}_2\} = E_2$.

第 3 步. 定义 $\mathbf{v}_3$ 为

$$\mathbf{v}_3 := \mathbf{x}_3 - P_{E_2} \mathbf{x}_3 = \mathbf{x}_3 - \frac{(\mathbf{x}_3, \mathbf{v}_1)}{\|\mathbf{v}_1\|^2} \mathbf{v}_1 - \frac{(\mathbf{x}_3, \mathbf{v}_2)}{\|\mathbf{v}_2\|^2} \mathbf{v}_2$$

取 $E_3 = \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3\}$. 注意 $\text{span}\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\} = E_3$. 同时注意 $\mathbf{x}_3 \notin E_2$, 所以 $\mathbf{v}_3 \neq \mathbf{0}$.

.....

第 $r+1$ 步. 假设已经完成 r 步并得到由非零向量 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 构成的正交向量组, 使得 $E_r := \text{span}\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r\} = \text{span}\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_r\}$. 定义

$$\mathbf{v}_{r+1} := \mathbf{x}_{r+1} - P_{E_r} \mathbf{x}_{r+1} = \mathbf{x}_{r+1} - \sum_{k=1}^r \frac{(\mathbf{x}_{r+1}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2} \mathbf{v}_k$$

注意, $\mathbf{x}_{r+1} \notin E_r$, 所以 $\mathbf{v}_{r+1} \neq \mathbf{0}$.

.....

持续进行该算法, 即可得到正交向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$.

3.2. 例子

假设给定向量

$$\mathbf{x}_1 = (1, 1, 1)^T, \quad \mathbf{x}_2 = (0, 1, 2)^T, \quad \mathbf{x}_3 = (1, 0, 2)^T,$$

并且要用格拉姆-施密特方法来将其正交化. 第一步我们定义

$$\mathbf{v}_1 = \mathbf{x}_1 = (1, 1, 1)^T.$$

第二步我们有

$$\mathbf{v}_2 = \mathbf{x}_2 - P_{E_1} \mathbf{x}_2 = \mathbf{x}_2 - \frac{(\mathbf{x}_2, \mathbf{v}_1)}{\|\mathbf{v}_1\|^2} \mathbf{v}_1.$$

计算得

$$(\mathbf{x}_2, \mathbf{v}_1) = \left(\begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right) = 3, \quad \|\mathbf{v}_1\|^2 = 3,$$

则得

$$\mathbf{v}_2 = \begin{pmatrix} 0 \\ 1 \\ 2 \end{pmatrix} - \frac{3}{3} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix}.$$

最后定义

$$\mathbf{v}_3 = \mathbf{x}_3 - P_{E_2} \mathbf{x}_3 = \mathbf{x}_3 - \frac{(\mathbf{x}_3, \mathbf{v}_1)}{\|\mathbf{v}_1\|^2} \mathbf{v}_1 - \frac{(\mathbf{x}_3, \mathbf{v}_2)}{\|\mathbf{v}_2\|^2} \mathbf{v}_2.$$

计算得

$$\left(\begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \right) = 3, \quad \left(\begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix}, \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} \right) = 1,$$

$$\|\mathbf{v}_1\|^2 = 3, \quad \|\mathbf{v}_2\|^2 = 2$$

($\|\mathbf{v}_1\|^2$ 之前计算过了) 则得

$$\mathbf{v}_3 = \begin{pmatrix} 1 \\ 0 \\ 2 \end{pmatrix} - \frac{3}{3} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} - \frac{1}{2} \begin{pmatrix} -1 \\ 0 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ -1 \\ \frac{1}{2} \end{pmatrix}$$

注. 因为标量乘法不改变正交性, 所以可以将格拉姆-施密特方法得到的向量 $\mathbf{v}_k$ 乘以任意非零的数.

特别地, 在很多理论推导中, 人们会将向量 $\mathbf{v}_k$ 除以对应的范数 $\|\mathbf{v}_k\|$ 来将它归一化. 那么所得向量组是规范正交的, 公式也会更简单.

不过, 在做计算的时候, 人们往往会通过将向量的每项乘上各项分母的最小公倍数来避免得出分数项. 所以上述向量 $\mathbf{v}_3$ 大概会被换成 $(1, -2, 1)^T$.

3.3. 正交补、正交分解 $V = E \oplus E^\perp$

定义. 对子空间 E , 其正交补 $E^\perp$ 是所有正交于 E 的向量所成的集合

$$E^\perp := \{\mathbf{x} : \mathbf{x} \perp E\}.$$

若 $\mathbf{x}, \mathbf{y} \perp E$, 则任意线性组合 $\alpha\mathbf{x} + \beta\mathbf{y} \perp E$ (你能看出为什么吗?). 所以 $E^\perp$ 是子空间.

由正交投影的定义, 内积空间 V 中的任意向量可唯一表示为

$$\mathbf{v} = \mathbf{v}_1 + \mathbf{v}_2, \quad \mathbf{v}_1 \in E, \mathbf{v}_2 \perp E (\text{等价于 } \mathbf{v}_2 \in E^\perp)$$

(其中显然有 $\mathbf{v}_1 = P_E \mathbf{v}$)

这一结论常写为 $V = E \oplus E^\perp$, 意为任意向量都可唯一分解成上述形式.

下面命题是正交补的一个重要性质.

命题 3.6. 对于子空间 E ,

$$(E^\perp)^\perp = E.$$

证明留作习题 (见下习题 3.12).

习题

3.1. 对向量组 $(1, 2, -2)^T, (1, -1, 4)^T, (2, 1, 1)^T$ 应用格拉姆-施密特正交化.

3.2. 对向量组 $(1, 2, 3)^T, (1, 3, 1)^T$ 应用格拉姆-施密特正交化. 写出往这些向量张成的 2 维子空间上正交投影的矩阵.

- 3.3. 将上题所得正交向量组补全为 $\mathbb{R}^3$ 的正交基, 即向其中加入若干个 (多少个?) 向量以得到正交基.
你能描述在 $\mathbb{R}^n$ 或 $\mathbb{C}^n$ 的一般情形下, 如何将正交向量组补全为正交基吗?
- 3.4. 求出从向量 $(2, 3, 1)^T$ 到由向量 $(1, 2, 3)^T, (1, 3, 1)^T$ 张成的子空间的距离. 注意, 只要求到子空间的距离, 而不要求正交投影.
- 3.5. 求出向量 $(1, 1, 1, 1)^T$ 往由向量 $\mathbf{v}_1 = (1, 3, 1, 1)^T, \mathbf{v}_2 = (2, -1, 1, 0)^T$ 张成的子空间上的正交投影 (注意 $\mathbf{v}_1 \perp \mathbf{v}_2$).
- 3.6. 求出从向量 $(1, 2, 3, 4)^T$ 到由向量 $\mathbf{v}_1 = (1, -1, 1, 0)^T, \mathbf{v}_2 = (1, 2, 1, 1)^T$ 张成的子空间的距离 (注意 $\mathbf{v}_1 \perp \mathbf{v}_2$). 你能不计算投影就求出距离吗? 这将简化计算.
- 3.7. 判断正误: 若 E 是 V 的子空间, 那么 $\dim E + \dim(E^\perp) = \dim V$. 论证之.
- 3.8. 令 P 是往内积空间 V 的子空间 E 的正交投影, $\dim V = n, \dim E = r$. 求其特征值和特征向量 (特征空间), 并求每个特征值的代数重数和几何重数.
- 3.9. (利用特征值来计算行列式)
- 求往 $\mathbb{R}^n$ 的由向量 $(1, 1, \dots, 1)^T$ 张成的一维子空间的正交投影的矩阵;
 - 令 A 是所有项都等于 1 的 $n \times n$ 矩阵. 计算其特征值和对应的重数 (利用前一题的结论);
 - 计算矩阵 $A - I$ (即主对角项都为 0 而其他项都为 1 的矩阵) 的特征值 (及其重数).
 - 计算 $\det(A - I)$.
- 3.10. (勒让德多项式) 令多项式所成的向量空间上的内积定义为 $(f, g) = \int_{-1}^1 f(t)\overline{g(t)}dt$. 对向量组 $1, t, t^2, t^3$ 应用格拉姆-施密特正交化. 勒让德多项式是所谓正交多项式的一个特例, 后者在数学的许多分支都有重要用途.
- 3.11. 令 $P = P_E$ 是往子空间 E 的正交投影的矩阵. 证明:
- 矩阵 P 是**自伴的**, 意即 $P^* = P$.
 - $P^2 = P$.
- 提示:** 上述两条性质能完全刻画正交投影, 即任意满足上述性质的矩阵 P 都是某正交投影的矩阵. 我们后续会对此进行讨论.
- 3.12. 证明: 对子空间 E 有 $(E^\perp)^\perp = E$. **提示:** 容易看出 E 正交于 $E^\perp$ (为什么?). 为证明**任意**正交于 $E^\perp$ 的向量 $\mathbf{x}$ 都属于 E , 利用上面 3.3 节的分解 $V = E \oplus E^\perp$.
- 3.13. 设 P 是往子空间 E 上的正交投影, Q 是往正交补 $E^\perp$ 上的正交投影.
- $P + Q$ 和 PQ 分别是什么?
 - 证明: $P - Q$ 是它自身的逆.

4. 最小平方解、正交投影的公式

如在第 2 章中所讨论的, 方程 $A\mathbf{x} = \mathbf{b}$ 有解, 当且仅当 $\mathbf{b} \in \text{Ran } A$. 但是, 如何求解一个无解的方程组呢?

这看起来是个蠢问题——如果无解的话，那就无解呀。但其实，要求解一个无解的方程组的情况会很自然地出现。比如，当我们的方程是从实验数据得到的时候。如果没有任何误差，那么右端项 $\mathbf{b}$ 就属于列空间 $\text{Ran } A$ ，并且方程组是相容的；但是，现实中测量误差是不可避免的，所以理论上无解的方程组在现实中也可能有解。那么，这种情况下我们怎么办呢？

4.1. 最小平方解

最简单的想法就是写出误差

$$\|A\mathbf{x} - \mathbf{b}\|$$

并尝试求出使其最小的 $\mathbf{x}$ 。如果可以求出使得误差为 0 的 $\mathbf{x}$ ，那么方程组是相容的，并且我们得出了精确解。否则，我们就得到了所谓**最小平方解**³。

术语**最小平方**的来历是：最小化 $\|A\mathbf{x} - \mathbf{b}\|$ 就等价于最小化

$$\|A\mathbf{x} - \mathbf{b}\|^2 = \sum_{k=1}^m |(A\mathbf{x})_k - b_k|^2 = \sum_{k=1}^m \left| \sum_{j=1}^n A_{k,j} x_j - b_k \right|^2$$

即最小化线性函数的平方和。

求出最小平方解有多种方式。如果我们在 $\mathbb{R}^n$ 中讨论，所有数都是实数，那么我们就可以去掉绝对值，从而对各 x_j 求偏导数，并且求出使这些偏导数都为 0 的 x_j ，从而得到最小值点。

4.1.1. 几何方法

然而，求出最小值点有一种更简单的方法。即，如果取遍向量 $\mathbf{x}$ ，那么 $A\mathbf{x}$ 给出 $\text{Ran } A$ 中的所有向量，所以 $\|A\mathbf{x} - \mathbf{b}\|$ 的最小值恰为从 $\mathbf{b}$ 到 $\text{Ran } A$ 的距离。因此 $\|A\mathbf{x} - \mathbf{b}\|$ 取得最小值，当且仅当 $A\mathbf{x} = P_{\text{Ran } A} \mathbf{b}$ ，其中 $P_{\text{Ran } A}$ 表示往列空间 $\text{Ran } A$ 上的正交投影。

所以，为求最小平方解，只需解方程

$$A\mathbf{x} = P_{\text{Ran } A} \mathbf{b}.$$

如果已知 $\text{Ran } A$ 的正交基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ ，则可通过下式求出向量 $P_{\text{Ran } A} \mathbf{b}$

$$P_{\text{Ran } A} \mathbf{b} = \sum_{k=1}^n \frac{(\mathbf{b}, \mathbf{v}_k)}{\|\mathbf{v}_k\|^2} \mathbf{v}_k.$$

³本术语国内多译为“最小二乘”，实从日文“最小二乘”，比较生硬，本书将“square”按照“平方”来翻译，不从通行译法。——译者注

如果仅仅知道 $\text{Ran } A$ 的基, 则需要用格拉姆-施密特正交化来从中得到正交基.

那么理论上说, 问题已经解决. 但是这个解法还不够简单: 它包含格拉姆-施密特正交化, 后者的计算开销可能很大. 好在, 还有一种更简单的解法.

4.1.2. 法方程

$A\mathbf{x}$ 是正交投影 $P_{\text{Ran } A}\mathbf{b}$ 当且仅当 $\mathbf{b} - A\mathbf{x} \perp \text{Ran } A$ ($A\mathbf{x} \in \text{Ran } A$ 对所有 $\mathbf{x}$ 都成立).

若 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ 是 A 的列, 那么 $\mathbf{b} - A\mathbf{x} \perp \text{Ran } A$ 可重写为

$$\mathbf{b} - A\mathbf{x} \perp \mathbf{a}_k, \quad \forall k = 1, 2, \dots, n.$$

这意味着

$$0 = (\mathbf{b} - A\mathbf{x}, \mathbf{a}_k) = \mathbf{a}_k^*(\mathbf{b} - A\mathbf{x}) \quad \forall k = 1, 2, \dots, n.$$

将 $\mathbf{a}_k^*$ 写在一起即知这些方程等价于

$$A^*(\mathbf{b} - A\mathbf{x}) = \mathbf{0},$$

这等价于所谓的**法方程**⁴

$$A^*A\mathbf{x} = A^*\mathbf{b}$$

该方程的解就给出了 $A\mathbf{x} = \mathbf{b}$ 的最小平方解.

注意, 最小平方解唯一, 当且仅当 A^*A 可逆.

4.2. 正交投影的公式

如我们之前已讨论的, 如果 $\mathbf{x}$ 是**法方程** $A^*A\mathbf{x} = A^*\mathbf{b}$ 的解 (即 $A\mathbf{x} = \mathbf{b}$ 的最小平方解), 那么 $A\mathbf{x} = P_{\text{Ran } A}\mathbf{b}$. 所以, 为求 $\mathbf{b}$ 往列空间 $\text{Ran } A$ 上的正交投影, 需要求解法方程 $A^*A\mathbf{x} = A^*\mathbf{b}$, 然后将所得的解乘以 A .

如果算子 A^*A 可逆, 那么法方程 $A^*A\mathbf{x} = A^*\mathbf{b}$ 的解是 $\mathbf{x} = (A^*A)^{-1}A^*\mathbf{b}$, 所以正交投影 $P_{\text{Ran } A}\mathbf{b}$ 可按下式计算

$$P_{\text{Ran } A}\mathbf{b} = A(A^*A)^{-1}A^*\mathbf{b}$$

因为这对于所有 $\mathbf{b}$ 都成立, 所以往 $\text{Ran } A$ 上正交投影的矩阵的公式是

$$P_{\text{Ran } A} = A(A^*A)^{-1}A^*$$

⁴英文为 normal equation, 也常译为“正规方程”, 此处译法更侧重表示“垂直”含义, 即残差 $\mathbf{b} - A\mathbf{x}$ 须垂直于 A 的列空间. ——译者注

由下面定理可推出, 对于 $m \times n$ 矩阵 A , 矩阵 A^*A 可逆当且仅当 $\text{rank } A = n$.

定理 4.1. 对于 $m \times n$ 矩阵 A ,

$$\text{Ker } A = \text{Ker}(A^*A).$$

的确如此: 由秩定理, $\text{Ker } A = \{\mathbf{0}\}$ 当且仅当 $\text{rank } A$ 为 n . 则由上述定理, $\text{Ker } A^*A = \{\mathbf{0}\}$ 当且仅当 $\text{rank } A = n$. 因为 A^*A 是方阵, 所以它可逆当且仅当 $\text{rank } A = n$.

我们将上述定理的证明留作习题. 要证明 $\text{Ker } A = \text{Ker}(A^*A)$, 需要证明两个包含关系 $\text{Ker}(A^*A) \subset \text{Ker } A$ 和 $\text{Ker } A \subset \text{Ker}(A^*A)$. 其中一个包含关系很平凡, 而证明另一个要用到

$$\|A\mathbf{x}\|^2 = (A\mathbf{x}, A\mathbf{x}) = (A^*A\mathbf{x}, \mathbf{x}).$$

4.3. 例子之一: 拟合直线

我们介绍几个例子, 这几个例子会很自然地用到最小平方解. 假设我们知道两个量 x 和 y 的关系是 $y = a + bx$. 系数 a 和 b 是未知的, 并且我们想根据实验数据求出它们.

假设我们进行了 n 次实验并得到 n 个数对 $(x_k, y_k), k = 1, 2, \dots, n$. 理想情况下, 所有点 (x_k, y_k) 都应该在一条直线上, 但是由于测量误差, 这往往不会发生——各点会接近一条直线但不会恰好上面. 这里最小平方解就会有用处了!

理想情况下, 系数 a 与 b 应满足方程

$$a + bx_k = y_k, \quad k = 1, 2, \dots, n$$

(注意, x_k 和 y_k 是固定的数, 而未知数是 a 和 b) 如果能求出满足条件的 a 和 b , 那是我们走运; 如果求不出, 通行的做法是最小化总的二次误差

$$\sum_{k=1}^n |a + bx_k - y_k|^2.$$

而最小化这个误差恰恰就是求出下列方程组的最小平方解:

$$\begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

(回想一下, x_k 和 y_k 是给定的数, 而未知数是 a 和 b)

4.3.1. 例子

假设数据 (x_k, y_k) 由下列数对构成

$$(-2, 4), (-1, 2), (0, 1), (2, 1), (3, 1)$$

那么我们需要求出下列方程组的最小平方解

$$\begin{pmatrix} 1 & -2 \\ 1 & -1 \\ 1 & 0 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 1 \\ 1 \\ 1 \end{pmatrix}$$

那么

$$A^*A = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -2 & -1 & 0 & 2 & 3 \end{pmatrix} \begin{pmatrix} 1 & -2 \\ 1 & -1 \\ 1 & 0 \\ 1 & 2 \\ 1 & 3 \end{pmatrix} = \begin{pmatrix} 5 & 2 \\ 2 & 18 \end{pmatrix}$$

并且

$$A^*\mathbf{b} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -2 & -1 & 0 & 2 & 3 \end{pmatrix} \begin{pmatrix} 4 \\ 2 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 9 \\ -5 \end{pmatrix}$$

所以法方程 $A^*Ax = A^*\mathbf{b}$ 可写为

$$\begin{pmatrix} 5 & 2 \\ 2 & 18 \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} 9 \\ -5 \end{pmatrix}$$

此方程的解是

$$a = 2, b = -1/2,$$

所以最佳拟合直线是

$$y = 2 - 1/2x.$$

4.4. 更多例子：曲线和平面

最小平方拟合并不只适用于直线，它还能应用于更为一般的曲线，以及更高维情形中的平面。

唯一的约束就是，待求的参数需要以线性的形式被容纳进来。通用的算法如下：

1. 求出你的数据应该满足的方程（如果能精确匹配）；

2. 将这些方程写成线性方程组, 其中未知量是你要求的参数. 注意, 该方程组不需要是相容的 (通常也不是);
3. 求出方程组的最小平方解.

4.4.1. 曲线拟合的例子

假设我们知道 x 和 y 之间的关系由二次式 $y = a + bx + cx^2$ 给出, 因此我们需要用这些数据拟合抛物线 $y = a + bx + cx^2$. 那么未知数 a, b, c 应满足方程

$$a + bx_k + cx_k^2 = y_k, \quad k = 1, 2, \dots, n$$

或写成矩阵形式

$$\begin{pmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}$$

例如, 根据上个例子中的数据, 我们需要求出如下线性方程组的最小平方解

$$\begin{pmatrix} 1 & -2 & 4 \\ 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \\ 1 \\ 1 \\ 1 \end{pmatrix}.$$

那么

$$A^*A = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -2 & -1 & 0 & 2 & 3 \\ 4 & 1 & 0 & 4 & 9 \end{pmatrix} \begin{pmatrix} 1 & -2 & 4 \\ 1 & -1 & 1 \\ 1 & 0 & 0 \\ 1 & 2 & 4 \\ 1 & 3 & 9 \end{pmatrix} = \begin{pmatrix} 5 & 2 & 18 \\ 2 & 18 & 26 \\ 18 & 26 & 114 \end{pmatrix}$$

并且

$$A^*\mathbf{b} = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ -2 & -1 & 0 & 2 & 3 \\ 4 & 1 & 0 & 4 & 9 \end{pmatrix} \begin{pmatrix} 4 \\ 2 \\ 1 \\ 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 9 \\ -5 \\ 31 \end{pmatrix}.$$

因此法方程 $A^*Ax = A^*\mathbf{b}$ 为

$$\begin{pmatrix} 5 & 2 & 18 \\ 2 & 18 & 26 \\ 18 & 26 & 114 \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} 9 \\ -5 \\ 31 \end{pmatrix}$$

其有唯一解

$$a = 86/77, \quad b = -62/77, \quad c = 43/154.$$

因此,

$$y = 86/77 - 62x/77 + 43x^2/154$$

是最佳拟合抛物线.

4.4.2. 平面拟合

另一个例子是, 将数据

$$(x_k, y_k, z_k) \in \mathbb{R}^3, \quad k = 1, 2, \dots, n.$$

拟合成平面 $z = a + bx + cy$. 在精确匹配的情况下, 数据应满足方程

$$a + bx_k + cy_k = z_k, \quad k = 1, 2, \dots, n,$$

或写成矩阵形式

$$\begin{pmatrix} 1 & x_1 & y_1 \\ 1 & x_2 & y_2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & y_n \end{pmatrix} \begin{pmatrix} a \\ b \\ c \end{pmatrix} = \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{pmatrix}.$$

因此, 要求出最佳拟合平面, 就需要写出该方程组的最小平方解 (未知数是 a, b, c).

习题

4.1. 求出下列方程组的最小平方解

$$\begin{pmatrix} 1 & 0 \\ 0 & 1 \\ 1 & 1 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}$$

4.2. 求出矩阵

$$\begin{pmatrix} 1 & 1 \\ 2 & -1 \\ -2 & 4 \end{pmatrix}.$$

的列空间的正交投影 P 的矩阵. 用两种方法完成: 格拉姆-施密特正交化和投影的公式. 比较两个结果.

4.3. 求出点 $(-2, 4), (-1, 3), (0, 1), (2, 0)$ 的最佳直线拟合 (最小平方解).

4.4. 将四个点 $(1, 1, 3), (0, 3, 6), (2, 1, 5), (0, 0, 0)$ 拟合成平面 $z = a + bx + cy$. 为此

- 求出有 3 个未知数 a, b, c 的 4 个方程, 满足平面经过全部 4 个点 (这个方程组不一定有解);
- 求出方程组的最小平方解.

4.5. **最小范数解.** 令方程 $A\mathbf{x} = \mathbf{b}$ 有解, 并令 A 有非平凡的核 (因而解是不唯一的). 证明:

a) $A\mathbf{x} = \mathbf{b}$ 存在唯一能使得范数 $\|\mathbf{x}\|$ 最小的解 $\mathbf{x}_0$, 即存在唯一的 $\mathbf{x}_0$, 使得 $A\mathbf{x}_0 = \mathbf{b}$ 且 $\|\mathbf{x}_0\| \leq \|\mathbf{x}\|$ 对所有满足 $A\mathbf{x} = \mathbf{b}$ 的 $\mathbf{x}$ 成立.

b) 对于所有满足 $A\mathbf{x} = \mathbf{b}$ 的 $\mathbf{x}$, 有 $\mathbf{x}_0 = P_{(\text{Ker } A)^\perp} \mathbf{x}$.

4.6. **最小范数最小平方解.** 将上述问题的结论应用于方程 $A\mathbf{x} = P_{\text{Ran } A} \mathbf{b}$ 以证明:

a) 方程 $A\mathbf{x} = \mathbf{b}$ 存在唯一能使得范数 $\|\mathbf{x}\|$ 最小的最小平方解 $\mathbf{x}_0$.

b) 对于 $A\mathbf{x} = \mathbf{b}$ 的所有最小平方解 $\mathbf{x}$, 有 $\mathbf{x}_0 = P_{(\text{Ker } A)^\perp} \mathbf{x}$.

5. 线性变换的伴随、再探基本子空间

5.1. 伴随矩阵和伴随变换

回忆一下, $m \times n$ 矩阵 A 的**埃尔米特伴随** (或简称**伴随**) 定义为 $A^* := \overline{A^T}$. 换言之, 矩阵 A^* 是通过将转置矩阵 A^T 的各项取复共轭得到的.

下列恒等式是伴随矩阵的核心性质:

$$(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, A^*\mathbf{y}) \quad \forall \mathbf{x} \in \mathbb{C}^n, \forall \mathbf{y} \in \mathbb{C}^m.$$

在证明这个恒等式之前, 我们先介绍一些有用的公式. 首先, 回想一下, 对转置矩阵有恒等式 $(AB)^T = B^T A^T$. 因为对于复数 z 和 w 有 $\overline{zw} = \overline{z}\overline{w}$, 所以对于伴随成立下述恒等式

$$(AB)^* = B^* A^*$$

并且, 因为 $(A^T)^T = A$ 且 $\overline{\overline{z}} = z$, 所以

$$(A^*)^* = A.$$

有了这些准备, 我们即可证明核心的恒等式:

$$(A\mathbf{x}, \mathbf{y}) = \mathbf{y}^* A\mathbf{x} = (A^*\mathbf{y})^* \mathbf{x} = (\mathbf{x}, A^*\mathbf{y});$$

第一个和最后一个等号源于 $\mathbb{F}^n$ 上内积的定义, 中间的等号则源于

$$(A^*\mathbf{x})^* = \mathbf{x}^* (A^*)^* = \mathbf{x}^* A.$$

5.1.1. 伴随的唯一性

上述核心的恒等式 $(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, A^*\mathbf{y})$ 常用作伴随变换的定义. 首先要注意, 伴随变换是唯一的: 若矩阵 B 满足

$$(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, B\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y},$$

那么 $B = A^*$. 的确如此: 由 A^* 的定义, 对给定的 $\mathbf{y}$ 我们有

$$(\mathbf{x}, A^*\mathbf{y}) = (\mathbf{x}, B\mathbf{y}) \quad \forall \mathbf{x},$$

因而由推论 1.5, $A^*\mathbf{y} = B\mathbf{y}$. 因为它对于所有 $\mathbf{y}$ 都成立, 所以线性变换 A^* 和 B ——进而也是矩阵 A^* 和 B ——相同.

5.1.2. 抽象情形下的伴随变换

上述核心的恒等式 $(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, A^*\mathbf{y})$ 可用于在抽象情形下定义伴随变换, 此时 $A: V \rightarrow W$ 是从一内积空间到另一内积空间的变换: 定义 $A^*: W \rightarrow V$ 为满足下式的变换

$$(A\mathbf{x}, \mathbf{y}) = (\mathbf{x}, A^*\mathbf{y}) \quad \forall \mathbf{x} \in V, \forall \mathbf{y} \in W.$$

为什么这样的变换存在呢? 我们可以构造它来说明这点. 考虑 V 的规范正交基 $\mathcal{A} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 和 W 的规范正交基 $\mathcal{B} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m\}$. 若 $[A]_{\mathcal{B}\mathcal{A}}$ 是 A 关于这些基的矩阵, 则变换 A^* 可通过定义其矩阵 $[A^*]_{\mathcal{A}\mathcal{B}}$ 如下来实现:

$$[A^*]_{\mathcal{A}\mathcal{B}} = ([A]_{\mathcal{B}\mathcal{A}})^*.$$

证明此式确实能给出伴随变换, 留给读者作为习题.

注意, 上述 5.1.1 节中的推理表明, 伴随变换是唯一的.

5.1.3. 有用的公式

伴随变换 (矩阵) 的常用性质如下. 我们将证明留给读者作为习题.

1. $(A + B)^* = A^* + B^*$;
2. $(\alpha A)^* = \bar{\alpha} A^*$;
3. $(AB)^* = B^* A^*$;
4. $(A^*)^* = A$;
5. $(\mathbf{y}, A\mathbf{x}) = (A^*\mathbf{y}, \mathbf{x})$.

5.2. 基本子空间之间的关系

定理 5.1. 令 $A: V \rightarrow W$ 是从一内积空间到另一内积空间的变换. 那么

1. $\text{Ker } A^* = (\text{Ran } A)^\perp$;
2. $\text{Ker } A = (\text{Ran } A^*)^\perp$;
3. $\text{Ran } A = (\text{Ker } A^*)^\perp$;
4. $\text{Ran } A^* = (\text{Ker } A)^\perp$.

注. 早先, 在第2章第7节中定义基本子空间时, 用的是 A^T 而不是 A^* (一般的文献中也这样定义). 当然, 对于实矩阵来说这两者并无差异, 所以在实数情形下, 上述定理能给出之前定义的基本子空间的几何描述.

利用 A^T 定义的基本子空间的几何阐释见于后面的第8章 (见第3节定理3.7). 该定理中的公式和此处定理5.1中的本质上一样, 只是表述略有区别.

定理5.1的证明: 首先, 注意到因为对于子空间 E 有 $(E^\perp)^\perp = E$, 所以结论1和3等价. 同理, 结论2和4也等价. 最后, 结论2就是将结论1应用到变换 A^* 的结果 (此处我们运用了 $(A^*)^* = A$).

所以要证明这个定理, 只需证明结论1.

我们将呈现该结论的两种证法: 用矩阵的证法, 以及“不变式”证法——即不依赖于基和坐标的证法.

在用矩阵的证法中, 假设 A 是 $m \times n$ 矩阵, 即 $A: \mathbb{F}^n \rightarrow \mathbb{F}^m$. 一般情形总可以化归到这种情形: 选取 V 和 W 中的规范正交基, 并考虑 A 关于这两个基的矩阵即可.

令 $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ 是 A 的列. 注意, $\mathbf{x} \in (\text{Ran } A)^\perp$ 当且仅当 $\mathbf{x} \perp \mathbf{a}_k$ (即 $(\mathbf{x}, \mathbf{a}_k) = 0$) $\forall k = 1, 2, \dots, n$.

由 $\mathbb{F}^n$ 上内积的定义, 这意味着

$$0 = (\mathbf{x}, \mathbf{a}_k) = \mathbf{a}_k^* \mathbf{x} \quad \forall k = 1, 2, \dots, n.$$

由于 $\mathbf{a}_k^*$ 是 A^* 的第 k 行, 所以上述 n 个等式等价于方程

$$A^* \mathbf{x} = \mathbf{0}.$$

所以我们证明了 $\mathbf{x} \in (\text{Ran } A)^\perp$ 当且仅当 $A^* \mathbf{x} = \mathbf{0}$, 而这就是结论1.

现在展示不依赖于基和坐标的证法. $\mathbf{x} \in (\text{Ran } A)^\perp$ 意味着 $\mathbf{x}$ 正交于所有形如 $A\mathbf{y}$ 的向量, 即

$$(\mathbf{x}, A\mathbf{y}) = 0 \quad \forall \mathbf{y}.$$

因为 $(\mathbf{x}, A\mathbf{y}) = (A^* \mathbf{x}, \mathbf{y})$, 所以此恒等式等价于

$$(A^* \mathbf{x}, \mathbf{y}) = 0 \quad \forall \mathbf{y},$$

而由引理1.4, 这等价于 $A^* \mathbf{x} = \mathbf{0}$. 所以我们证明了 $\mathbf{x} \in (\text{Ran } A)^\perp$ 当且仅当 $A^* \mathbf{x} = \mathbf{0}$, 而这恰好就是本定理结论1. $\square$

5.3. 线性变换的“本质”部分

上述定理让变换 A 的结构和基本子空间的几何特性更清晰了. 由该定理可得, 变换 A 可表示为两变换的复合: 往 $\text{Ran } A^*$ 上的正交投影与从 $\text{Ran } A^*$ 到 $\text{Ran } A$ 的同构.

的确如此: 将 A 限制在定义域 $\text{Ran } A^*$ 和目标空间 $\text{Ran } A$, 得到 $\tilde{A}: \text{Ran } A^* \rightarrow \text{Ran } A$, 则

$$\tilde{A}\mathbf{x} = A\mathbf{x}, \quad \forall \mathbf{x} \in \text{Ran } A^*.$$

因为 $\text{Ker } A = (\text{Ran } A^*)^\perp$, 所以有

$$A\mathbf{x} = AP_{\text{Ran } A^*}\mathbf{x} = \tilde{A}P_{\text{Ran } A^*}\mathbf{x} \quad \forall \mathbf{x} \in X;$$

这里用到了 $\mathbf{x} - P_{\text{Ran } A^*}\mathbf{x} \in (\text{Ran } A^*)^\perp = \text{Ker } A$. 于是我们可写出

$$(5.1) \quad A\mathbf{x} = \tilde{A}P_{\text{Ran } A^*}\mathbf{x} \quad \forall \mathbf{x} \in X,$$

或者等价地说, $A = \tilde{A}P_{\text{Ran } A^*}$.

还请注意, $\tilde{A}: \text{Ran } A^* \rightarrow \text{Ran } A$ 是可逆变换. 首先注意到 $\text{Ker } \tilde{A} = \{\mathbf{0}\}$: 若 $\mathbf{x} \in \text{Ran } A^*$ 满足 $\tilde{A}\mathbf{x} = A\mathbf{x} = \mathbf{0}$, 那么 $\mathbf{x} \in \text{Ker } A = (\text{Ran } A^*)^\perp$, 所以 $\mathbf{x} \in \text{Ran } A^* \cap (\text{Ran } A^*)^\perp$, 于是 $\mathbf{x} = \mathbf{0}$. 于是, 要证明 $\tilde{A}$ 可逆, 只需证明 $\tilde{A}$ 是满射. 而这可由 (5.1) 立得:

$$\text{Ran } \tilde{A} = \tilde{A}\text{Ran } A^* = AP_{\text{Ran } A^*}X = AX = \text{Ran } A.$$

同构 $\tilde{A}$ 有时称为算子 A 的“本质部分”(这是个不规范的用语).

A 的“本质部分” $\tilde{A}: \text{Ran } A^* \rightarrow \text{Ran } A$ 是同构, 蕴涵了“复”秩定理: $\text{rank } A = \text{rank } A^*$. 不过, 这个定理当然也可由一个简单的观察得到——复共轭不会改变矩阵的秩, 即 $\text{rank } A = \text{rank } \bar{A}$.

习题

5.1. 证明: 对于方阵 A , 等式 $\det(A^*) = \overline{\det(A)}$ 成立.

5.2. 求出往下列矩阵的四个基本子空间上正交投影的矩阵.

$$A = \begin{pmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 2 & 4 & 3 \end{pmatrix}.$$

注意, 你只要求其中两个投影: 如果你选择适当的两个来求, 就很容易从中得到另外两个 (回忆一下往 E 和 $E^\perp$ 上的投影的关系).

5.3. 令 A 为 $m \times n$ 矩阵. 证明: $\text{Ker } A = \text{Ker}(A^*A)$.

为此你需要证明两个包含关系: $\text{Ker}(A^*A) \subset \text{Ker } A$ 和 $\text{Ker } A \subset \text{Ker}(A^*A)$. 其中一个包含关系很平凡, 而证明另一个要用到

$$\|A\mathbf{x}\|^2 = (A\mathbf{x}, A\mathbf{x}) = (A^*A\mathbf{x}, \mathbf{x}).$$

5.4. 利用等式 $\text{Ker } A = \text{Ker}(A^*A)$ 证明:

a) $\text{rank } A = \text{rank}(A^*A)$;

b) 若 $A\mathbf{x} = \mathbf{0}$ 仅有平凡解, 那么 A 是左可逆的. (可以写出左逆的公式)

5.5. 假设对矩阵 A 有矩阵 A^*A 可逆, 因此往 $\text{Ran } A$ 上的正交投影由公式 $A(A^*A)^{-1}A^*$ 给出. 你能写出往其他三个基本子空间 ($\text{Ker } A, \text{Ker } A^*, \text{Ran } A^*$) 正交投影的公式吗?

5.6. 令 P 是自伴的 ($P^* = P$) 并令 $P^2 = P$. 证明: P 是一个正交投影的矩阵. 提示: 考虑分解 $\mathbf{x} = \mathbf{x}_1 + \mathbf{x}_2$, $\mathbf{x}_1 \in \text{Ran } P$, $\mathbf{x}_2 \perp \text{Ran } P$, 并证明 $P\mathbf{x}_1 = \mathbf{x}_1$, $P\mathbf{x}_2 = \mathbf{0}$. 证明等式之一需要用到自伴性质, 而证明另一个需要用到 $P^2 = P$.

6. 等距变换和幺正变换、幺正矩阵和正交矩阵

6.1. 主要定义

定义. 称变换 $U: X \rightarrow Y$ 是**等距变换**, 如果它保持范数:

$$\|U\mathbf{x}\| = \|\mathbf{x}\| \quad \forall \mathbf{x} \in X.$$

下述定理说明等距变换保持内积.

定理 6.1. 变换 $U: X \rightarrow Y$ 是等距变换, 当且仅当其保持内积, 即当且仅当

$$(\mathbf{x}, \mathbf{y}) = (U\mathbf{x}, U\mathbf{y}) \quad \forall \mathbf{x}, \mathbf{y} \in X.$$

证明: 利用极化恒等式 (引理 1.9) 来证明. 例如, 若 X 是复向量空间, 则

$$\begin{aligned} (U\mathbf{x}, U\mathbf{y}) &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|U\mathbf{x} + \alpha U\mathbf{y}\|^2 \\ &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|U(\mathbf{x} + \alpha\mathbf{y})\|^2 \\ &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|\mathbf{x} + \alpha\mathbf{y}\|^2 = (\mathbf{x}, \mathbf{y}). \end{aligned}$$

类似地, 对于实向量空间 X 有

$$\begin{aligned} (U\mathbf{x}, U\mathbf{y}) &= \frac{1}{4} (\|U\mathbf{x} + U\mathbf{y}\|^2 - \|U\mathbf{x} - U\mathbf{y}\|^2) \\ &= \frac{1}{4} (\|U(\mathbf{x} + \mathbf{y})\|^2 - \|U(\mathbf{x} - \mathbf{y})\|^2) \\ &= \frac{1}{4} (\|\mathbf{x} + \mathbf{y}\|^2 - \|\mathbf{x} - \mathbf{y}\|^2) = (\mathbf{x}, \mathbf{y}). \quad \square \end{aligned}$$

引理 6.2. 变换 $U: X \rightarrow Y$ 是等距的, 当且仅当 $U^*U = I$.

证明: 若 $U^*U = I$, 那么由伴随变换的定义

$$(\mathbf{x}, \mathbf{x}) = (U^*U\mathbf{x}, \mathbf{x}) = (U\mathbf{x}, U\mathbf{x}) \quad \forall \mathbf{x} \in X.$$

因此 $\|\mathbf{x}\| = \|U\mathbf{x}\|$, 所以 U 是等距变换.

另一方面, 若 U 是等距变换, 那么由伴随变换的定义和定理 6.1, 可得对所有 $\mathbf{x} \in X$

$$(U^*U\mathbf{x}, \mathbf{y}) = (U\mathbf{x}, U\mathbf{y}) = (\mathbf{x}, \mathbf{y}) \quad \forall \mathbf{y} \in X,$$

因此由推论 1.5 知 $U^*U\mathbf{x} = \mathbf{x}$. 因为此式对所有 $\mathbf{x} \in X$ 都成立, 所以 $U^*U = I$. $\square$

上述引理意味着等距变换总是左可逆的 (U^* 就是左逆).

定义. 称等距变换 $U: X \rightarrow Y$ 是**么正变换**⁵, 若其可逆.

命题 6.3. 等距变换 $U: X \rightarrow Y$ 是么正变换, 当且仅当 $\dim X = \dim Y$.

证明: 因为 U 是等距变换, 所以它是左可逆的, 又因为 $\dim X = \dim Y$, 所以它可逆 (左可逆的方阵是可逆的).

另一方面, 若 $U: X \rightarrow Y$ 是可逆的, 那么 $\dim X = \dim Y$ (只有方阵才可逆, 而同构向量空间的维数相同). $\square$

称方阵 U 是**么正的**, 若 $U^*U = I$, 即么正矩阵是作用于 $\mathbb{F}^n$ 的么正算子的矩阵.

各项为实数的么正矩阵称为**正交矩阵**. 正交矩阵可理解为作用于实向量空间 $\mathbb{R}^n$ 的么正算子的矩阵.

么正变换有几个性质:

1. 对么正变换 U , 有 $U^{-1} = U^*$;
2. 如果 U 是么正的, 那么 $U^* = U^{-1}$ 也是么正的;
3. 如果 U 是等距变换, $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是规范正交基, 那么 $U\mathbf{v}_1, U\mathbf{v}_2, \dots, U\mathbf{v}_n$ 是规范正交向量组. 进一步, 如果 U 是么正变换, 那么 $U\mathbf{v}_1, U\mathbf{v}_2, \dots, U\mathbf{v}_n$ 是规范正交基.
4. 一系列么正变换的乘积也是么正变换.

⁵unitary 也常音译作“酉”. 采用“么正”, 是因为该词中, “么”既从音, 也从义 (“么”即“一”), 而“正”即“正规”. 而“么正”算子是特征值绝对值均为“一”的“正规”算子. ——译者注.

6.2. 例子

首先, 注意到

矩阵 U 是等距的, 当且仅当它的列形成规范正交向量组.

直接计算乘积 U^*U 即可检验该结论.

容易检验, 旋转矩阵

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}$$

的各列彼此正交, 并且各列的范数都是 1. 因此, 旋转矩阵是等距的, 又因为它是方阵, 所以它是幺正的. 又因为旋转矩阵的各项都是实数, 所以它是正交矩阵.

下个例子要更抽象一些. 令 X 和 Y 是内积空间, $\dim X = \dim Y = n$, 并令 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 和 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$ 分别为 X 和 Y 的规范正交基. 定义变换 $U: X \rightarrow Y$ 为

$$U\mathbf{x}_k = \mathbf{y}_k, \quad k = 1, 2, \dots, n.$$

因为对于向量 $\mathbf{x} = c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \dots + c_n\mathbf{x}_n$ 有

$$\|\mathbf{x}\|^2 = |c_1|^2 + |c_2|^2 + \dots + |c_n|^2$$

且有

$$\|U\mathbf{x}\|^2 = \left\| U \left(\sum_{k=1}^n c_k \mathbf{x}_k \right) \right\|^2 = \left\| \sum_{k=1}^n c_k \mathbf{y}_k \right\|^2 = \sum_{k=1}^n |c_k|^2,$$

所以对所有 $\mathbf{x} \in X$ 有 $\|U\mathbf{x}\| = \|\mathbf{x}\|$, 所以 U 是幺正变换.

6.3. 幺正变换的性质

命题 6.4. 令 U 是幺正矩阵. 那么

1. $|\det U| = 1$. 特别地, 对正交矩阵有 $\det U = \pm 1$;
2. 若 λ 是 U 的特征值, 那么 $|\lambda| = 1$.

注. 注意, 正交矩阵的特征值不一定为实数 (行列式则不是这样). 我们熟悉的旋转矩阵就是一个例子.

命题 6.4 的证明: 令 $\det U = z$. 因为 $\det(U^*) = \overline{\det(U)}$ (见习题 5.1), 所以有

$$|z|^2 = \bar{z}z = \det(U^*U) = \det I = 1,$$

因此 $|\det U| = |z| = 1$. 结论 1 得证.

为证明结论 2, 注意到如果 $U\mathbf{x} = \lambda\mathbf{x}$ 那么

$$\|U\mathbf{x}\| = \|\lambda\mathbf{x}\| = |\lambda| \cdot \|\mathbf{x}\|,$$

故 $|\lambda| = 1$. □

6.4. 么正等价变换

定义. 称变换 (矩阵) A 和 B 是**么正等价的**, 若存在么正变换 U 使得 $A = UBU^*$.

因为对于么正变换 U 有 $U^{-1} = U^*$, 所以任意两个么正等价矩阵都是相似的.

逆命题则不成立: 很容易构造一对相似但不么正等价的矩阵.

下述命题给出了一种构造反例的方法.

命题 6.5. 矩阵 A 么正等价于对角矩阵, 当且仅当存在由它的特征向量构成的正交 (或规范正交) 基.

证明: 令 $A = UBU^*$, 并令 $B\mathbf{x} = \lambda\mathbf{x}$. 那么 $AU\mathbf{x} = UBU^*U\mathbf{x} = UB\mathbf{x} = U(\lambda\mathbf{x}) = \lambda U\mathbf{x}$, 即 $U\mathbf{x}$ 是 A 的特征向量.

因此, 令 A 么正等价于对角矩阵 D , 即令 $A = UDU^*$. 标准基向量 $\mathbf{e}_k$ 是 D 的特征向量, 所以向量 $U\mathbf{e}_k$ 是 A 的特征向量. 因为 U 是么正的, 所以向量组 $U\mathbf{e}_1, U\mathbf{e}_2, \dots, U\mathbf{e}_n$ 是规范正交基.

现今 A 的特征向量构成正交基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$. 如有需要, 可将各向量 $\mathbf{u}_k$ 除以其范数, 于是总可假设向量组 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 是**规范正交基**. 令 D 是 A 关于基 $\mathcal{B} = \{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$ 的矩阵. 显然, D 是对角矩阵.

记 U 是各列为 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 的矩阵. 因为各列构成规范正交基, 所以 U 是么正的. 由坐标变换公式得

$$A = [A]_{SS} = [I]_{SB} [A]_{BB} [I]_{BS} = UDU^{-1}$$

又由于 U 是么正的, 所以 $A = UDU^*$. □

习题

6.1. 正交分解下列矩阵:

$$\begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}, \quad \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad \begin{pmatrix} 0 & 2 & 2 \\ 2 & 0 & 2 \\ 2 & 2 & 0 \end{pmatrix}$$

即, 对每个矩阵 A , 求出么正矩阵 U 和对角矩阵 D 使得 $A = UDU^*$.

6.2. 判断正误: 矩阵么正等价于对角矩阵, 当且仅当存在它的特征向量构成的正交 (或规范正交) 基.

6.3. 证明极化恒等式

$$(A\mathbf{x}, \mathbf{y}) = \frac{1}{4} [(A(\mathbf{x} + \mathbf{y}), \mathbf{x} + \mathbf{y}) - (A(\mathbf{x} - \mathbf{y}), \mathbf{x} - \mathbf{y})] \quad (\text{实数情形, } A = A^*),$$

与

$$(A\mathbf{x}, \mathbf{y}) = \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha (A(\mathbf{x} + \alpha\mathbf{y}), \mathbf{x} + \alpha\mathbf{y}) \quad (\text{复数情形, } A \text{ 可任取})$$

6.4. 证明: 一系列么正 (正交) 矩阵的乘积仍是么正 (正交) 矩阵.

6.5. 令 $U: X \rightarrow X$ 是有限维内积空间上的线性变换. 判断正误:

a) 若对所有 $\mathbf{x} \in X$ 有 $\|U\mathbf{x}\| = \|\mathbf{x}\|$, 那么 U 是么正的;

b) 若对规范正交基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 有 $\|U\mathbf{e}_k\| = \|\mathbf{e}_k\|$, 那么 U 是么正的.

证明你的结论, 或举出反例.

6.6. 令 A 和 B 是么正等价的 $n \times n$ 矩阵.

a) 证明: $\text{trace}(A^*A) = \text{trace}(B^*B)$;

b) 利用 a) 证明:

$$\sum_{j,k=1}^n |A_{j,k}|^2 = \sum_{j,k=1}^n |B_{j,k}|^2.$$

c) 利用 b) 证明: 矩阵

$$\begin{pmatrix} 1 & 2 \\ 2 & i \end{pmatrix} \quad \text{和} \quad \begin{pmatrix} i & 4 \\ 1 & 1 \end{pmatrix}$$

不是么正等价的.

6.7. 下列各对矩阵中, 哪些是么正等价的?

a) $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$ 和 $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$.

b) $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$ 和 $\begin{pmatrix} 0 & 1/2 \\ 1/2 & 0 \end{pmatrix}$.

c) $\begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ 和 $\begin{pmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 0 \end{pmatrix}$.

d) $\begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$ 和 $\begin{pmatrix} 1 & 0 & 0 \\ 0 & -i & 0 \\ 0 & 0 & i \end{pmatrix}$.

e) $\begin{pmatrix} 1 & 1 & 0 \\ 0 & 2 & 2 \\ 0 & 0 & 3 \end{pmatrix}$ 和 $\begin{pmatrix} 1 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{pmatrix}$.

提示: 很容易排除不是么正等价的矩阵: 请记住, 么正等价矩阵是相似的, 而相似矩阵的迹、行列式和特征值都是一样的.

另外, 前一题的结论也有助于排除不是么正等价的矩阵.

最后, 矩阵么正等价于对角矩阵, 当且仅当存在它的特征向量构成的正交基.

6.8. 令 U 是 2×2 正交矩阵, $\det U = 1$. 证明: U 是旋转矩阵.

6.9. 令 U 是 3×3 正交矩阵, $\det U = 1$. 证明:

- a) 1 是 U 的特征值.
- b) 若 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 是规范正交基, 并满足 $U\mathbf{v}_1 = \mathbf{v}_1$ (记住, 1 是特征值之一), 那么 U 关于该基的矩阵是

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha \\ 0 & \sin \alpha & \cos \alpha \end{pmatrix},$$

其中 α 是一个角度值.

提示: 先证明, 因为 $\mathbf{v}_1$ 是 U 的特征向量, 所以在 1 之下的所有项都必为零; 因为 $\mathbf{v}_1$ 也是 U^* 的特征向量 (为什么?), 所以在 1 右侧的所有项也都必为零. 然后证明右下角的 2×2 矩阵是行列式为 1 的正交矩阵, 再利用前一题的结论.

7. $\mathbb{R}^n$ 中的刚体运动

内积空间 V 中的刚体运动, 是保持间距的变换 $f: V \rightarrow V$, 即

$$\|f(\mathbf{x}) - f(\mathbf{y})\| = \|\mathbf{x} - \mathbf{y}\| \quad \forall \mathbf{x}, \mathbf{y} \in V.$$

注意, 在这个定义里, 我们并未假设变换 f 是线性的.

显然, 任意么正变换都是刚体运动. 刚体运动的另一个例子是平移量为 $\mathbf{a} \in V$ 的平移, 即 $f(\mathbf{x}) = \mathbf{x} + \mathbf{a}$.

本节的主要结论是下述定理, 它指出, **实**内积空间中的任意刚体运动都是正交变换和平移的复合.

定理 7.1. 令 f 是实内积空间 X 中的刚体运动, 并令 $T(\mathbf{x}) := f(\mathbf{x}) - f(\mathbf{0})$. 那么 T 是正交变换.

为证明该定理, 我们需要下面这个简单的引理.

引理 7.2. 令 T 定义如定理 7.1. 那么对于所有 $\mathbf{x}, \mathbf{y} \in X$:

1. $\|T\mathbf{x}\| = \|\mathbf{x}\|$;
2. $\|T(\mathbf{x}) - T(\mathbf{y})\| = \|\mathbf{x} - \mathbf{y}\|$;
3. $(T(\mathbf{x}), T(\mathbf{y})) = (\mathbf{x}, \mathbf{y})$.

证明: 为证明结论 1, 注意到

$$\|T(\mathbf{x})\| = \|f(\mathbf{x}) - f(\mathbf{0})\| = \|\mathbf{x} - \mathbf{0}\| = \|\mathbf{x}\|.$$

结论 2 可通过下面这串等式得到:

$$\begin{aligned} \|T(\mathbf{x}) - T(\mathbf{y})\| &= \|(f(\mathbf{x}) - f(\mathbf{0})) - (f(\mathbf{y}) - f(\mathbf{0}))\| \\ &= \|f(\mathbf{x}) - f(\mathbf{y})\| = \|\mathbf{x} - \mathbf{y}\|. \end{aligned}$$

还有一种解释是, T 是两个刚体运动的复合 (首先是 f , 再接上平移量为 $\mathbf{a} = -f(\mathbf{0})$ 的平移), 而容易看出, 刚体运动的复合还是刚体运动. 因为 $T(\mathbf{0}) = \mathbf{0}$, 则 $\|T(\mathbf{x})\| = \|T(\mathbf{x}) - T(\mathbf{0})\|$, 进而结论 1 可视为结论 2 的特例.

为证明结论 3, 注意到在实内积空间中有

$$\|T(\mathbf{x}) - T(\mathbf{y})\|^2 = \|T(\mathbf{x})\|^2 + \|T(\mathbf{y})\|^2 - 2(T(\mathbf{x}), T(\mathbf{y})),$$

以及

$$\|\mathbf{x} - \mathbf{y}\|^2 = \|\mathbf{x}\|^2 + \|\mathbf{y}\|^2 - 2(\mathbf{x}, \mathbf{y}).$$

回想一下 $\|T(\mathbf{x}) - T(\mathbf{y})\| = \|\mathbf{x} - \mathbf{y}\|$ 以及 $\|T(\mathbf{x})\| = \|\mathbf{x}\|, \|T(\mathbf{y})\| = \|\mathbf{y}\|$, 可立即得到待证结论. $\square$

定理 7.1 的证明: 首先注意到对所有 $\mathbf{x} \in X$, 有

$$\|T(\mathbf{x})\| = \|f(\mathbf{x}) - f(\mathbf{0})\| = \|\mathbf{x} - \mathbf{0}\| = \|\mathbf{x}\|,$$

所以 T 保持范数, 即 $\|T\mathbf{x}\| = \|\mathbf{x}\|$.

我们想要从等式 $\|T\mathbf{x}\| = \|\mathbf{x}\|$ 得出 T 为等距变换, 但为此我们需要证明 T 是线性变换.

为此, 取定 X 的规范正交基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$, 并令 $\mathbf{b}_k := T(\mathbf{e}_k), k = 1, 2, \dots, n$. 因为 T 保持内积 (引理 7.2 的结论 3), 所以 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$ 是规范正交向量组. 事实上, 因为 $\dim X = n$ ($\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 共有 n 个向量), 所以可得 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$ 是规范正交基.

令 $\mathbf{x} = \sum_{k=1}^n \alpha_k \mathbf{e}_k$. 回忆一下抽象正交傅里叶分解 (2.2), 可得 $\alpha_k = (\mathbf{x}, \mathbf{e}_k)$. 将抽象正交傅里叶分解 (2.2) 应用于 $T(\mathbf{x})$ 和规范正交基 $\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n$, 可得

$$T(\mathbf{x}) = \sum_{k=1}^n (T(\mathbf{x}), \mathbf{b}_k) \mathbf{b}_k.$$

因为

$$(T(\mathbf{x}), \mathbf{b}_k) = (T(\mathbf{x}), T(\mathbf{e}_k)) = (\mathbf{x}, \mathbf{e}_k) = \alpha_k,$$

故可得

$$T\left(\sum_{k=1}^n \alpha_k \mathbf{e}_k\right) = \sum_{k=1}^n \alpha_k \mathbf{b}_k.$$

这就意味着 T 是线性变换, 其关于基 $\mathcal{S} := \{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n\}$ 和 $\mathcal{B} := \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$ 的矩阵是恒等矩阵, 即 $[T]_{\mathcal{B}\mathcal{S}} = I$.

另一种证明 T 是线性变换的方法是进行以下计算:

$$\begin{aligned}
 \|T(\mathbf{x} + \alpha\mathbf{y}) - (T(\mathbf{x}) + \alpha T(\mathbf{y}))\|^2 &= \|(T(\mathbf{x} + \alpha\mathbf{y}) - T(\mathbf{x})) - \alpha T(\mathbf{y})\|^2 \\
 &= \|T(\mathbf{x} + \alpha\mathbf{y}) - T(\mathbf{x})\|^2 + \alpha^2 \|T(\mathbf{y})\|^2 - 2\alpha(T(\mathbf{x} + \alpha\mathbf{y}) - T(\mathbf{x}), T(\mathbf{y})) \\
 &= \|\mathbf{x} + \alpha\mathbf{y} - \mathbf{x}\|^2 + \alpha^2 \|\mathbf{y}\|^2 - 2\alpha(T(\mathbf{x} + \alpha\mathbf{y}), T(\mathbf{y})) + 2\alpha(T(\mathbf{x}), T(\mathbf{y})) \\
 &= \alpha^2 \|\mathbf{y}\|^2 + \alpha^2 \|\mathbf{y}\|^2 - 2\alpha(\mathbf{x} + \alpha\mathbf{y}, \mathbf{y}) + 2\alpha(\mathbf{x}, \mathbf{y}) \\
 &= 2\alpha^2 \|\mathbf{y}\|^2 - 2\alpha(\mathbf{x}, \mathbf{y}) - 2\alpha^2(\mathbf{y}, \mathbf{y}) + 2\alpha(\mathbf{x}, \mathbf{y}) = 0
 \end{aligned}$$

因此

$$T(\mathbf{x} + \alpha\mathbf{y}) = T(\mathbf{x}) + \alpha T(\mathbf{y}),$$

这就意味着 T 是线性的 (取 $\mathbf{x} = \mathbf{0}$ 或 $\alpha = 1$, 可分别得到线性变换定义中的两条性质).

因此 T 是满足 $\|T\mathbf{x}\| = \|\mathbf{x}\|$ 的线性变换, 即 T 是等距变换. 因为 $T: X \rightarrow X$, 所以 T 是幺正变换 (见命题 6.3). 这就完成了证明, 因为正交变换就是实内积空间上的幺正变换. $\square$

习题

7.1. 给出 $\mathbb{C}^n$ 上的一刚体运动 T , $T(\mathbf{0}) = \mathbf{0}$, 且 T 不是线性变换.

8. 复化和实化

8.1. 实化

8.2. 复化

第 6 章 内积空间上算子的结构

本章我们仍然假设所有向量空间都是有限维的, 并且仍然只处理实向量空间或复向量空间——内积空间的理论不适用于一般的域上的向量空间. 如未指明向量空间, 则有关表述对实向量空间和复向量空间都成立.

为了避免重复书写实质上相同的公式, 我们都用复数情形下的公式, 它们在实数情形下也正确, 虽然有时会复杂一点.

1. 算子的上三角(舒尔)表示

定理 1.1. 令 $A: X \rightarrow X$ 是作用于复内积空间的算子. 那么存在 X 的规范正交基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$, 使得 A 关于该基的矩阵是上三角的.

换言之, 任意 $n \times n$ 矩阵 A 都可表示为 $A = UTU^*$, 其中 U 是幺正的, T 是上三角矩阵.

证明: 我们通过对 $\dim X$ 用归纳法来证明本定理. 若 $\dim X = 1$, 则该定理是平凡的, 这是因为任意 1×1 矩阵都是上三角的.

假设我们证明了该定理在 $\dim X = n - 1$ 时是成立的, 并要证明它在 $\dim X = n$ 时也成立.

令 λ_1 是 A 的特征值, 并令 $\mathbf{u}_1$ ($\|\mathbf{u}_1\| = 1$) 是对应的特征向量, $A\mathbf{u}_1 = \lambda_1\mathbf{u}_1$. 记 $E = \mathbf{u}_1^\perp$, 并令 $\mathbf{v}_2, \dots, \mathbf{v}_n$ 是 E 的规范正交基(显然 $\dim E = \dim X - 1 = n - 1$), 因此 $\mathbf{u}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 X 的规范正交基. 在该基下, A 的矩阵形如

$$(1.1) \quad \left(\begin{array}{c|c} \lambda_1 & * \\ \hline 0 & \\ \vdots & A_1 \\ 0 & \end{array} \right);$$

此处 λ_1 之下的所有项都是零, $*$ 表示我们不在意第一行中位于 λ_1 右侧的项.

我们在意的是右下角 $(n - 1) \times (n - 1)$ 的块, 记其为 A_1 .

注意, A_1 确定了 E 上的一个线性变换, 又由于 $\dim E = n - 1$, 所以由归纳假设可得, 存在规范正交基(不妨记其为 $\mathbf{u}_2, \dots, \mathbf{u}_n$) 使得 A_1

关于该基的矩阵是上三角的.

因此 A 关于规范正交基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 的矩阵形如 (1.1), 其中矩阵 A_1 是上三角的. 因此 A 关于该基的矩阵也是上三角的. $\square$

注. 注意, 此证明中引入的子空间 $E = \mathbf{u}_1^\perp$ 在 A 下不是不变的¹, 即 $AE \subset E$ 并不一定成立. 这意味着 A_1 不是 A 的一部分, 而是由 A 构造出来的算子.

还请注意, $AE \subset E$ 当且仅当记作 $*$ 的所有项 (即第一行中除了 λ_1 以外的项) 都是零.

注. 注意, 即便 A 是实矩阵, 矩阵 U 和 T 还是可能有复数项. 比如, 旋转矩阵

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}, \quad \alpha \neq k\pi, k \in \mathbb{Z}$$

就不么正等价于实上三角矩阵 (甚至不会与之相似). 的确如此: 该矩阵的特征值是复数, 而上三角矩阵的特征值恰为对角项.

注. 有个类似于定理 1.1 的结论, 可在任意向量空间 (不需要有内积) 上成立并被证明. 该结论是说, 任意算子都关于某个基具有上三角矩阵. 为证明之, 可以仿照定理 1.1 的证明, 也可以为 V 配以内积 (取 V 的基, 并使其具有规范正交性, 见第 5 章的习题 2.4).

注意, 适用于内积空间的版本 (定理 1.1) 比适用于一般向量空间的版本更强, 因为它指出总可以找到满足条件的规范正交基, 而不仅仅是基.

下面定理是定理 1.1 在实数情形下的版本.

定理 1.2. 令 $A: X \rightarrow X$ 是作用于实内积空间的算子. 假设 A 的所有特征值都是实数【即 A 恰存在 $n = \dim X$ 个实特征值 (以重数计)】. 那么存在 X 的规范正交基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$, 使得 A 关于该基的矩阵是上三角的.

换言之, 任意特征值全为实数的 $n \times n$ 实矩阵 A 都可表示为 $A = UTU^* = UTU^T$, 其中 U 是正交的, T 是实上三角矩阵.

注 1.3. 回忆一下, 我们在第 4 章第 1.4 节中讨论过, “实向量空间 X 上算子 A 的特征值” 总是指 $X_{\mathbb{C}}$ (X 的复化) 上的 $A_{\mathbb{C}}$ (A 的复化) 的特征值.

¹不变子空间的概念在本书第 9 章第 3.1 节介绍. ——译者注.

如果 $X = \mathbb{R}^n$, 那么允许各坐标为复数, 即得到其复化 $\mathbb{C}^n$. $\mathbb{R}^n$ 上算子 A (即与实矩阵 A 的乘法) 的复化仍是与同一实矩阵的乘法, 只不过所乘向量属于 $\mathbb{C}^n$.

有关复化的更多细节, 详见第 4 章第 1.4 节和第 5 章第 8.2 节.

定理 1.2 的证明: 为证明该定理, 只需分析定理 1.1 的证明. 不失一般性, 假设算子 (矩阵) A 作用于 $\mathbb{R}^n$.

假设定理对于 $(n-1) \times (n-1)$ 矩阵成立. 如定理 1.1 的证明, 令 λ_1 是 A 的实特征值, $\mathbf{u}_1 \in \mathbb{R}^n$ ($\|\mathbf{u}_1\| = 1$) 是对应的特征向量, 并令 $\mathbf{v}_2, \dots, \mathbf{v}_n$ 是 ($\mathbb{R}^n$ 中的) 规范正交向量组, 使得 $\mathbf{u}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 $\mathbb{R}^n$ 的规范正交基.

在该基下, A 的矩阵形如 (1.1), 其中 A_1 是实矩阵.

如果我们能证明矩阵 A_1 只有实特征值, 即可完成整个证明. 的确如此: 这样一来, 由归纳假设, 存在 $E = \mathbf{u}_1^\perp$ 的规范正交基 $\mathbf{u}_2, \dots, \mathbf{u}_n$, 使得 A_1 关于该基的矩阵是上三角的, 所以 A 关于基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 的矩阵也是上三角的.

为证明 A_1 只有实特征值, 注意到

$$\det(A - \lambda I) = (\lambda_1 - \lambda) \det(A_1 - \lambda I)$$

(可按第一行进行余子式展开) 于是 A_1 的任意特征值也是 A 的特征值, 而 A 只有实特征值! $\square$

习题

- 1.1. 利用算子的上三角表示来重新证明: 行列式是特征值的积, 迹是特征值的和 (特征值均按重数计).

2. 自伴算子和正规算子的谱定理

本节中, 我们讨论么正等价于对角矩阵的矩阵 (算子).

回忆一下, 称算子 A 是自伴的, 若 $A = A^*$. 自伴算子 (关于规范正交基) 的矩阵, 即满足 $A^* = A$ 的矩阵, 称为埃尔米特矩阵.

术语**自伴**与**埃尔米特**本质上同义. 人们通常在提及算子时用自伴而在提及矩阵时用埃尔米特. 我们尽量遵循此惯例, 但因为我们通常不区分算子及其矩阵, 所以有时会混用这两个术语.

定理 2.1. 令 $A = A^*$ 是内积空间 X 上的自伴算子 (X 可以是实的也可以是复的). 那么 A 的所有特征值都是实数, 并且 X 存在由 A 的特征向量构成的规范正交基.

该定理可按矩阵形式重述如下:

定理 2.2. 令 $A = A^*$ 是自伴矩阵 (从而是方阵). 那么 A 可表示为

$$A = UDU^*$$

其中 U 是么正矩阵, D 是实对角矩阵.

此外, 若 A 是实矩阵, 那么 U 可选为实矩阵 (即正交矩阵).

证明: 为证明复内积空间 X 中的定理 2.1 和 2.2, 首先应用定理 1.1, 找出 X 的一个规范正交基, 使得 A 关于该基的矩阵是上三角的. 现在问: 什么样的上三角矩阵是自伴的?

答案显而易见: 上三角矩阵是自伴的, 当且仅当其为实对角矩阵. 定理 2.1 得证 (从而也有定理 2.2).

为处理实向量空间的情形, 首先注意到由刚刚证明的复数情形, A 的特征值都是实数². 那么, 只需应用定理 1.2, 并再次注意到自伴的上三角矩阵仅有对角阵即可. $\square$

注. 许多教材只考虑实矩阵, 则定理 2.2 常称为“**对称**矩阵的谱定理”. 然而要强调, 定理 2.2 对**复**对称矩阵是不成立的: 该定理是对埃尔米特矩阵成立, 特别地, 也对**实**对称矩阵成立.

现在给出“自伴算子的特征值为实数”的不依赖于基的证明. 令 $A = A^*$, $A\mathbf{x} = \lambda\mathbf{x}$, $\mathbf{x} \neq \mathbf{0}$. 那么

$$(A\mathbf{x}, \mathbf{x}) = (\lambda\mathbf{x}, \mathbf{x}) = \lambda(\mathbf{x}, \mathbf{x}) = \lambda\|\mathbf{x}\|^2.$$

另一方面,

$$(A\mathbf{x}, \mathbf{x}) = (\mathbf{x}, A^*\mathbf{x}) = (\mathbf{x}, A\mathbf{x}) = (\mathbf{x}, \lambda\mathbf{x}) = \bar{\lambda}(\mathbf{x}, \mathbf{x}) = \bar{\lambda}\|\mathbf{x}\|^2,$$

因此 $\lambda\|\mathbf{x}\|^2 = \bar{\lambda}\|\mathbf{x}\|^2$. 因为 $\|\mathbf{x}\| \neq 0$ ($\mathbf{x} \neq \mathbf{0}$), 所以 $\lambda = \bar{\lambda}$, 故 λ 为实数.

根据定理 2.1, 自伴算子的特征空间是正交的. 下面给出该结论的另一种证明.

²回想一下 (见上方的注 1.3), “实向量空间 X 上算子的特征值”总是指 $X_{\mathbb{C}}$ (X 的复化) 上原算子的**复化**的特征值.

命题 2.3. 令 $A = A^*$ 是自伴算子, 并令 $\mathbf{u}, \mathbf{v}$ 是它的特征向量, $A\mathbf{u} = \lambda\mathbf{u}, A\mathbf{v} = \mu\mathbf{v}$. 那么, 若 $\lambda \neq \mu$, 那么特征向量 $\mathbf{u}$ 和 $\mathbf{v}$ 正交.

证明: 该命题可由谱定理 (定理 2.1) 得到, 但此处我们直接证明之. 我们有

$$(A\mathbf{u}, \mathbf{v}) = (\lambda\mathbf{u}, \mathbf{v}) = \lambda(\mathbf{u}, \mathbf{v}).$$

另一方面,

$$(A\mathbf{u}, \mathbf{v}) = (\mathbf{u}, A^*\mathbf{v}) = (\mathbf{u}, A\mathbf{v}) = (\mathbf{u}, \mu\mathbf{v}) = \bar{\mu}(\mathbf{u}, \mathbf{v}) = \mu(\mathbf{u}, \mathbf{v})$$

(最后一个等式成立, 是因为自伴算子的特征值是实数) 因此 $\lambda(\mathbf{u}, \mathbf{v}) = \mu(\mathbf{u}, \mathbf{v})$. 若 $\lambda \neq \mu$, 则只能 $(\mathbf{u}, \mathbf{v}) = 0$. $\square$

现在我们尝试找出什么样的矩阵么正等价于对角矩阵. 容易检验, 对角矩阵 D 满足

$$D^*D = DD^*.$$

因此如果算子 A 关于某个规范正交基具有对角矩阵, 那么 $A^*A = AA^*$.

定义. 算子 (矩阵) N 称为**正规**的, 若 $N^*N = NN^*$.

显然, 任意自伴算子 ($A = A^*$) 都是正规的. 并且, 任意么正算子 $U: X \rightarrow X$ 也是正规的, 因为 $U^*U = UU^* = I$.

注意, 正规算子是一向量空间到其自身的变换, 而不是从一向量空间到另一向量空间的. 所以, 如果 U 是从一向量空间到另一向量空间的么正变换, 那么不能说 U 是正规的.

定理 2.4. 复向量空间上的任意正规算子 N 的特征向量能构成规范正交基.

换言之, 任意满足 $N^*N = NN^*$ 的矩阵 N 能表示为

$$N = UDU^*$$

其中 U 是么正矩阵, D 是对角阵.

注. 注意, 上述定理中即便 N 是实矩阵, 也不能断定矩阵 U 和 D 是实的. 此外, 很容易证明如果 D 是实的, 那么 N 一定是自伴的.

定理 2.4 的证明: 要证明定理 2.4, 先应用定理 1.1, 从而得到一个规范正交基, N 关于该基的矩阵是上三角的. 为完成该定理的证明, 只需证明上三角的正规矩阵一定是对角的.

我们将对矩阵的维数用归纳法来证明. 1×1 矩阵的情形是平凡的, 因为任意 1×1 矩阵都是对角阵.

假设我们已经证明任意 $(n-1) \times (n-1)$ 上三角正规矩阵都是对角的, 现在要证明这对于 $n \times n$ 矩阵也是成立的. 令 N 是 $n \times n$ 上三角正规矩阵. 可将其写为

$$\left(\begin{array}{c|ccc} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ \hline 0 & & & \\ \vdots & & N_1 & \\ 0 & & & \end{array} \right)$$

其中 N_1 是 $(n-1) \times (n-1)$ 上三角矩阵.

我们来比较 N^*N 和 NN^* 左上角 (第一行第一列) 的项. 直接计算表明

$$(N^*N)_{1,1} = \bar{a}_{1,1}a_{1,1} = |a_{1,1}|^2$$

且有

$$(NN^*)_{1,1} = |a_{1,1}|^2 + |a_{1,2}|^2 + \dots + |a_{1,n}|^2.$$

因此, $(N^*N)_{1,1} = (NN^*)_{1,1}$ 当且仅当 $a_{1,2} = \dots = a_{1,n} = 0$. 因此, 矩阵 N 形如

$$\left(\begin{array}{c|ccc} a_{1,1} & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & N_1 & \\ 0 & & & \end{array} \right)$$

从上述表达式可得

$$N^*N = \left(\begin{array}{c|ccc} |a_{1,1}|^2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & N_1^*N_1 & \\ 0 & & & \end{array} \right), \quad \left(\begin{array}{c|ccc} |a_{1,1}|^2 & 0 & \dots & 0 \\ \hline 0 & & & \\ \vdots & & N_1N_1^* & \\ 0 & & & \end{array} \right),$$

因此 $N_1^*N_1 = N_1N_1^*$, 这意味着矩阵 N_1 是正规的, 由归纳假设可得它是对角的. 于是矩阵 N 也是对角的. $\square$

下面命题给出了正规算子的一个很有用的刻画.

命题 2.5. 算子 $N: X \rightarrow X$ 是正规的, 当且仅当

$$\|N\mathbf{x}\| = \|N^*\mathbf{x}\| \quad \forall \mathbf{x} \in X.$$

证明: 令 N 是正规的, $N^*N = NN^*$. 那么

$$\|N\mathbf{x}\|^2 = (N\mathbf{x}, N\mathbf{x}) = (N^*N\mathbf{x}, \mathbf{x}) = (NN^*\mathbf{x}, \mathbf{x}) = (N^*\mathbf{x}, N^*\mathbf{x}) = \|N^*\mathbf{x}\|^2$$

所以 $\|N\mathbf{x}\| = \|N^*\mathbf{x}\|$.

现在令

$$\|N\mathbf{x}\| = \|N^*\mathbf{x}\| \quad \forall \mathbf{x} \in X.$$

由极化恒等式 (第 5 章引理 1.9) 可得对所有 $\mathbf{x}, \mathbf{y} \in X$

$$\begin{aligned} (N^*N\mathbf{x}, \mathbf{y}) &= (N\mathbf{x}, N\mathbf{y}) = \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|N\mathbf{x} + \alpha N\mathbf{y}\|^2 \\ &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|N(\mathbf{x} + \alpha\mathbf{y})\|^2 \\ &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|N^*(\mathbf{x} + \alpha\mathbf{y})\|^2 \\ &= \frac{1}{4} \sum_{\alpha=\pm 1, \pm i} \alpha \|N^*\mathbf{x} + \alpha N^*\mathbf{y}\|^2 \\ &= (N^*\mathbf{x}, N^*\mathbf{y}) = (NN^*\mathbf{x}, \mathbf{y}) \end{aligned}$$

因此 (见第 5 章推论 1.6), $N^*N = NN^*$. □

习题

2.1. 判断正误:

- 每个么正算子 $U: X \rightarrow X$ 都是正规的.
- 一矩阵是么正的, 当且仅当其可逆.
- 如果两个矩阵是么正等价的, 则这两个矩阵也是相似的.
- 自伴算子之和仍然自伴.
- 么正算子的伴随是么正的.
- 正规算子的伴随是正规的.
- 如果线性算子的所有特征值是 1, 那么该算子必为么正或正交的.
- 如果正规算子的所有特征值是 1, 那么该算子是恒等算子.
- 线性算子可能只保持范数而不保持内积.

2.2. 判断正误: 正规算子之和仍然正规. 论证你的结论.

2.3. 证明: 么正等价于对角矩阵的算子是正规的.

2.4. 正交分解下列矩阵

$$A = \begin{pmatrix} 3 & 2 \\ 2 & 3 \end{pmatrix}$$

求出 A 的所有平方根, 即求出所有满足 $B^2 = A$ 的矩阵 B . 注意, A 的所有平方根都是自伴的.

2.5. 判断正误: 任意自伴矩阵有自伴的平方根. 论证之.

2.6. 正交分解下列矩阵

$$A = \begin{pmatrix} 7 & 2 \\ 2 & 4 \end{pmatrix}$$

即将其表示为 $A = UDU^*$, 其中 D 是对角阵, U 是幺正的.

在 A 的所有平方根 (即所有满足 $B^2 = A$ 的矩阵 B) 中, 找出具有正特征值的那个. 你可将 B 保留为矩阵乘积.

2.7. 判断正误:

- a) 两个自伴矩阵的乘积仍是自伴的;
 - b) 若 A 是自伴的, 那么 A^k 是自伴的.
- 论证你的结论.

2.8. 令 A 是 $m \times n$ 矩阵. 证明:

- a) A^*A 是自伴的;
- b) A^*A 的所有特征值都非负;
- c) $A^*A + I$ 可逆.

2.9. 对于下列结论, 如果正确则证明之, 如果不正确则给出反例:

- a) 若 $A = A^*$, 那么 $A + iI$ 是可逆的;
- b) 若 U 是幺正的, 那么 $U + \frac{3}{4}I$ 是可逆的;
- c) 若 A 是实矩阵, 那么 $A - iI$ 是可逆的.

2.10. 正交分解旋转矩阵

$$R_\alpha = \begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}$$

其中 α 不是 π 的整数倍. 注意, 此处你会得到复特征值.

2.11. 正交分解矩阵

$$A = \begin{pmatrix} \cos \alpha & \sin \alpha \\ \sin \alpha & -\cos \alpha \end{pmatrix}$$

提示: 此处你会得到实特征值. 三角函数的恒等式 $\sin 2x = 2 \sin x \cos x$, $\sin^2 x = (1 - \cos 2x)/2$, $\cos^2 x = (1 + \cos 2x)/2$ (应用于 $x = \alpha/2$) 有助于简化特征向量的表达式.

2.12. 你能从几何角度描述上题中矩阵 A 所确定的线性变换吗? 它的几何描述特别简单.

2.13. 证明: 具有单位模长特征值 (即所有特征值都满足 $|\lambda_k| = 1$) 的正规算子是幺正的. **提示:** 考虑对角化.

2.14. 证明: 具有实特征值的正规算子是自伴的.

2.15. 举例说明: 定理 2.2 的结论对于复对称矩阵不成立. 即

- a) 构造一个 (可对角化的) 2×2 复对称矩阵, 其特征向量不能构成正交基;
- b) 构造一个 2×2 复对称矩阵, 其不能被对角化.

3. 极分解和奇异值分解

3.1. 正定算子、平方根

定义. 称自伴算子 $A: X \rightarrow X$ 是**正定的**, 若

$$(Ax, x) > 0 \quad \forall x \neq 0,$$

称其为**正半定的**，若

$$(A\mathbf{x}, \mathbf{x}) \geq 0 \quad \forall \mathbf{x} \in X,$$

我们将用记号 $A > 0$ 指代正定算子，并用记号 $A \geq 0$ 指代正半定算子。

下述定理描述了正定和正半定算子。

定理 3.1. 令 $A = A^*$. 则

1. $A > 0$ 当且仅当 A 的所有特征值都是正数.
2. $A \geq 0$ 当且仅当 A 的所有特征值都是非负数.

证明: 选取一个规范正交基，使得 A 关于该基的矩阵是对角的（见定理 2.1）。为完成证明，只需留意，对角矩阵是正定（正半定）的，当且仅当其所有对角项都是正的（非负的）。□

推论 3.2. 令 $A = A^* \geq 0$ 是正半定算子。存在唯一的正半定算子 B 使得 $B^2 = A$ 。

这样的 B 称为 A 的（正）平方根，并记作 $\sqrt{A}$ 或 $A^{1/2}$ 。

证明: 首先证明 $\sqrt{A}$ 存在。令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是由 A 的特征向量构成的规范正交基，并令 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是对应的特征值。注意，因为 $A \geq 0$ ，所以全体 $\lambda_k \geq 0$ 。

关于基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ ， A 的矩阵是对角项为 $\lambda_1, \lambda_2, \dots, \lambda_n$ 的对角矩阵 $\text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ 。定义算子 B ，其关于同一个基的矩阵为 $\text{diag}\{\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n}\}$ 。

显然， $B = B^* \geq 0$ ，并且 $B^2 = A$ 。

为证明 B 是唯一的，假设存在算子 $C = C^* \geq 0$ 使得 $C^2 = A$ 。令 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 是由 C 的特征向量构成的规范正交基，并令 $\mu_1, \mu_2, \dots, \mu_n$ 是对应的特征值（注意 $\mu_k \geq 0 \quad \forall k$ ）。 C 关于基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 的矩阵是对角阵 $\text{diag}\{\mu_1, \mu_2, \dots, \mu_n\}$ ，因而 $A = C^2$ 关于相同基的矩阵是 $\text{diag}\{\mu_1^2, \mu_2^2, \dots, \mu_n^2\}$ 。这意味着， A 的任意特征值 λ 都形如 μ_k^2 ，并且如果 $A\mathbf{x} = \lambda\mathbf{x}$ ，那么 $C\mathbf{x} = \sqrt{\lambda}\mathbf{x}$ 。

因此，关于上面的基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ ，算子 C 的矩阵是对角矩阵 $\text{diag}\{\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n}\}$ ，即 $B = C$ 。□

3.2. 变换的模、极分解

考虑变换 $A: X \rightarrow Y$. 其埃尔米特平方 A^*A 是 X 上的正半定算子. 的确如此:

$$(A^*A)^* = A^*(A^*)^* = A^*A$$

并且

$$(A^*Ax, x) = (Ax, Ax) = \|Ax\|^2 \geq 0 \quad \forall x \in X.$$

因此, 存在 (唯一的) 正半定平方根 $R = \sqrt{A^*A}$. 该算子 R 称为变换 A 的模, 常记为 $|A|$.

A 的模显示了变换 A 的 “大小”:

命题 3.3. 对线性变换 $A: X \rightarrow Y$,

$$\| |A|x \| = \| Ax \| \quad \forall x \in X.$$

证明: 对任意 $x \in X$,

$$\begin{aligned} \| |A|x \|^2 &= (|A|x, |A|x) = (|A|^*|A|x, x) = (|A|^2x, x) \\ &= (A^*Ax, x) = (Ax, Ax) = \| Ax \|^2 \end{aligned} \quad \square$$

推论 3.4.

$$\text{Ker } A = \text{Ker } |A| = (\text{Ran } |A|)^\perp.$$

证明: 第一个等号可直接由命题 3.3 得到, 第二个等号源于 $\text{Ker } T = (\text{Ran } T^*)^\perp$ ($|A|$ 是自伴的). $\square$

定理 3.5 (算子的极分解). 令 $A: X \rightarrow X$ 是算子 (方阵). 那么 A 可表示为

$$A = U|A|,$$

其中 U 是么正算子.

注. 上述么正算子 U 通常不唯一. 从定理的证明中, 我们将发现 U 唯一当且仅当 A 可逆.

注. 极分解 $A = U|A|$ 对从一个空间到另一个空间的变换 $A: X \rightarrow Y$ 也成立. 不过在这种情况下, 只能保证 U 是从 $\text{Ran } |A| = (\text{Ker } A)^\perp$ 到 Y 的等距变换.

若 $\dim X \leq \dim Y$, 那么这个等距变换扩展为从整个 X 到 Y 的等距变换 (而若 $\dim X = \dim Y$, 这个变换就成为么正算子).

定理 3.5 的证明: 考虑向量 $\mathbf{x} \in \text{Ran } |A|$. 那么向量 $\mathbf{x}$ 可表示为 $\mathbf{x} = |A|\mathbf{v}$ ($\mathbf{v} \in X$).

定义 $U_0\mathbf{x} := A\mathbf{v}$. 由命题 3.3,

$$\|U_0\mathbf{x}\| = \|A\mathbf{v}\| = \||A|\mathbf{v}\| = \|\mathbf{x}\|$$

这样看来, U_0 是从 $\text{Ran } |A|$ 到 X 的等距变换.

但首先, 我们需要证明 U_0 是定义完善的. 设另一个向量 $\mathbf{v}_1$ 满足 $\mathbf{x} = |A|\mathbf{v}_1$. 这样, 由 $\mathbf{x} = |A|\mathbf{v} = |A|\mathbf{v}_1$ 可得, $\mathbf{v} - \mathbf{v}_1 \in \text{Ker } |A| = \text{Ker } A$ (据推论 3.4), 所以 $A\mathbf{v} = A\mathbf{v}_1$, 这意味着 $U_0\mathbf{x}$ 是定义完善的.

则构造出了 $A = U_0|A|$. 验证 U_0 是线性变换, 留给读者作为习题.

要将 U_0 延拓为么正算子 U , 我们求么正变换 $U_1 : \text{Ker } A \rightarrow (\text{Ran } A)^\perp = \text{Ker } A^*$. 这总可以实现, 因为对于方阵 A 有 $\dim \text{Ker } A = \dim \text{Ker } A^*$ (秩定理).

容易验证, $U = U_0 + U_1$ 是么正算子, 且有 $A = U|A|$. □

3.3. 奇异值、施密特分解

定义. $|A|$ 的特征值称为 A 的**奇异值**. 换言之, 如果 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 A^*A 的特征值, 那么 $\sqrt{\lambda_1}, \sqrt{\lambda_2}, \dots, \sqrt{\lambda_n}$ 是 A 的奇异值.

注. 文献中往往将奇异值定义为 A^*A 的特征值的算术平方根, 而并不借助 $|A|$.

我认为变换的模这一概念很重要, 所以在上面介绍了它. 不过, 变换的模的概念在后文 (定义施密特和奇异值分解) 并不会再被用到. 并且, 下面会说明, A 的模很容易从奇异值分解中构造出来.

考虑变换 $A : X \rightarrow Y$, 并令 $\sigma_1, \sigma_2, \dots, \sigma_n$ 是 A 的奇异值 (以重数计). 假设 $\sigma_1, \sigma_2, \dots, \sigma_r$ 是 A 的**非零**奇异值 (以重数计). 特别地, 这意味着 $\sigma_k = 0, k > r$.

根据奇异值的定义, $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ 是 A^*A 的特征值. 令 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是由 A^*A 的特征向量构成的规范正交基³, $A^*A\mathbf{v}_k = \sigma_k^2\mathbf{v}_k$.

命题 3.6. 向量组

$$\mathbf{w}_k := \frac{1}{\sigma_k} A\mathbf{v}_k, \quad k = 1, 2, \dots, r$$

是规范正交向量组.

³我们知道, 对于自伴算子 (此处是 A^*A), 存在由其特征向量构成的规范正交基.

证明: 因为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是规范正交向量组, 所以

$$(A\mathbf{v}_j, A\mathbf{v}_k) = (A^*A\mathbf{v}_j, \mathbf{v}_k) = (\sigma_j^2\mathbf{v}_j, \mathbf{v}_k) = \sigma_j^2(\mathbf{v}_j, \mathbf{v}_k) = \begin{cases} 0, & j \neq k \\ \sigma_j^2, & j = k \end{cases} \quad \square$$

用上述命题的记号, 变换 A 可表示为

$$(3.1) \quad A = \sum_{k=1}^r \sigma_k \mathbf{w}_k \mathbf{v}_k^*,$$

或等价地说

$$(3.2) \quad A\mathbf{x} = \sum_{k=1}^r \sigma_k (\mathbf{x}, \mathbf{v}_k) \mathbf{w}_k.$$

的确如此: 我们知道 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 X 的规范正交基, 那么将 $\mathbf{x} = \mathbf{v}_j$ 代入 (3.2) 可得

$$\sum_{k=1}^r \sigma_k (\mathbf{v}_j, \mathbf{v}_k) \mathbf{w}_k = \sigma_j (\mathbf{v}_j, \mathbf{v}_j) \mathbf{w}_j = \sigma_j \mathbf{w}_j = A\mathbf{v}_j \quad \text{若 } j = 1, 2, \dots, r,$$

且有

$$\sum_{k=1}^r \sigma_k (\mathbf{v}_k^* \mathbf{v}_j) \mathbf{w}_k = \mathbf{0} = A\mathbf{v}_j \quad \text{对于 } j > r.$$

所以 (3.1) 的左右两侧对基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 的作用相同, 因此它们相同.

定义. 上述分解 (3.1) 或 (3.2) 称为变换 A 的**施密特分解**.

注. 一个变换的施密特分解不唯一. 为什么?

引理 3.7. 令 A 可表示为

$$A = \sum_{k=1}^r \sigma_k \mathbf{w}_k \mathbf{v}_k^*$$

其中 $\sigma_k > 0$, $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r, \mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 是规范正交向量组.

那么该表达式给出了 A 的一个施密特分解.

证明: 我们只需证明 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是 A^*A 的特征向量, $A^*A\mathbf{v}_k = \sigma_k^2\mathbf{v}_k$.

因为 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 是规范正交向量组, 所以

$$\mathbf{w}_k^* \mathbf{w}_j = (\mathbf{w}_j, \mathbf{w}_k) = \delta_{k,j} := \begin{cases} 0, & j \neq k \\ 1, & j = k, \end{cases}$$

因此

$$A^*A = \sum_{k=1}^r \sigma_k^2 \mathbf{v}_k \mathbf{v}_k^*.$$

因为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 是规范正交向量组, 所以

$$A^* A \mathbf{v}_j = \sum_{k=1}^r \sigma_k^2 \mathbf{v}_k \mathbf{v}_k^* \mathbf{v}_j = \sigma_j^2 \mathbf{v}_j$$

所以各 $\mathbf{v}_j$ 是 $A^* A$ 的特征向量. □

推论 3.8. 令

$$A = \sum_{k=1}^r \sigma_k \mathbf{w}_k \mathbf{v}_k^*$$

是 A 的施密特分解. 那么

$$A^* = \sum_{k=1}^r \sigma_k \mathbf{v}_k \mathbf{w}_k^*$$

是 A^* 的施密特分解.

3.4. 施密特分解的矩阵表示、奇异值分解

施密特分解可以写成优美的矩阵形式. 我们假设 $A: \mathbb{F}^n \rightarrow \mathbb{F}^m$, 其中 $\mathbb{F}$ 是 $\mathbb{C}$ 或 $\mathbb{R}$ (取定 X 和 Y 的规范正交基, 并围绕关于这些基的坐标展开讨论, 总能化归到这种情况). 令 $\sigma_1, \sigma_2, \dots, \sigma_r$ 是 A 的非零奇异值, 并令

$$A = \sum_{k=1}^r \sigma_k \mathbf{w}_k \mathbf{v}_k^*$$

是 A 的施密特分解.

容易看出此式可改写为

$$(3.3) \quad A = \widetilde{W} \widetilde{\Sigma} \widetilde{V}^*$$

其中 $\widetilde{\Sigma} = \text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_r\}$, $\widetilde{V}$ 和 $\widetilde{W}$ 分别是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 的矩阵. (你能确定各矩阵的大小吗?)

注意, 因为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 是规范正交向量组, 所以 $\widetilde{V}$ 和 $\widetilde{W}$ 是等距矩阵. 还请注意, $r = \text{rank } A$ (见下习题 3.1).

若矩阵 A 可逆, 那么 $m = n = r$, 矩阵 $\widetilde{V}$ 和 $\widetilde{W}$ 是幺正的, $\widetilde{\Sigma}$ 是可逆的对角矩阵.

其实, 总可以用幺正的 V 和 W (而不仅是 $\widetilde{V}$ 和 $\widetilde{W}$) 来写出类似 (3.3) 的表达式, 并且在许多情形下使用这种表达式更加便利. 要写出这样的表达式, 首先需要将向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_r$ 分别补全为 $\mathbb{F}^n$ 和 $\mathbb{F}^m$ 的规范正交基.

回忆一下, 为了将 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 补全为 $\mathbb{F}^n$ 的规范正交基, 只需求出 $\text{Ker } V^*$ 的规范正交基 $\mathbf{v}_{r+1}, \dots, \mathbf{v}_n$, 从而向量组 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 就是 $\mathbb{F}^n$ 的规范正交基. 而从一般的基得到规范正交基, 总可以通过格拉姆-施密特正交化来完成.

这样一来, A 可表示为

$$(3.4) \quad A = W\Sigma V^*$$

其中 $V \in M_{n \times n}^{\mathbb{F}}$ 和 $W \in M_{m \times m}^{\mathbb{F}}$ 分别是各列为 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 和 $\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m$ 的么正矩阵, 且 Σ 是 $m \times n$ “对角” 矩阵

$$(3.5) \quad \Sigma_{j,k} = \begin{cases} \sigma_k & j = k \leq r; \\ 0 & \text{其他.} \end{cases}$$

换言之, 向对角矩阵 $\text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_r\}$ 的右下角补零, 使其扩充为 $m \times n$ 大小, 就得到了矩阵 Σ .

定义 3.9. 矩阵 $A \in M_{m \times n}^{\mathbb{F}}$ (回忆一下, $\mathbb{F}$ 是 $\mathbb{C}$ 或 $\mathbb{R}$) 的**奇异值分解** (SVD) 是形如 (3.4) 的分解, 即 $A = W\Sigma V^*$, 其中 $W \in M_{m \times m}^{\mathbb{F}}$ 和 $V \in M_{n \times n}^{\mathbb{F}}$ 是么正矩阵, $\Sigma \in M_{m \times n}^{\mathbb{R}_+}$ 是“对角” 矩阵 (意为对于所有 $k = 1, 2, \dots, \min\{m, n\}$ 有 $\sigma_{k,k} \geq 0$, 而对于所有 $j \neq k$ 有 $\sigma_{j,k} = 0$).

表达式 (3.3) 常称为**简化或紧凑 SVD**. 更确切地说, 简化 SVD 的表达式为 $A = \widetilde{W}\widetilde{\Sigma}\widetilde{V}^*$, 其中 $\widetilde{\Sigma} \in M_{r \times r}^{\mathbb{R}_+}$, $r \leq \min\{m, n\}$ 是对角矩阵且各对角项严格大于零, $\widetilde{W} \in M_{m \times r}^{\mathbb{F}}$ 和 $\widetilde{V} \in M_{n \times r}^{\mathbb{F}}$ 是等距矩阵. 此外, 我们还需要 $\widetilde{W}$ 和 $\widetilde{V}$ 中至少有一个不是方阵.

注 3.10. 容易看出, 如果 $A = W\Sigma V^*$ 是 A 的奇异值分解, 那么 $\sigma_k := \sigma_{k,k}$ 是 A 的奇异值, 即 σ_k^2 是 A^*A 的特征值. 此外, V 的各列 $\mathbf{v}_k$ 是 A^*A 的对应特征向量, 即 $A^*A\mathbf{v}_k = \sigma_k^2\mathbf{v}_k$. 又注意到, 若 $\sigma_k \neq 0$, 那么 $\mathbf{w}_k = \frac{1}{\sigma_k}A\mathbf{v}_k$.

所有这些都意味着, 按照本节前面叙述的方法, 可由施密特分解 (3.2) 构造出奇异值分解 $A = W\Sigma V^*$.

简化奇异值分解可解释为对不可逆矩阵 A 的施密特分解 (3.2) 的矩阵形式. 对可逆矩阵 A , 施密特分解的矩阵形式是 (非简化的) 奇异值分解.

注 3.11. 奇异值分解 $A = W\Sigma V^*$ 的另一种解释是, Σ 是 A 在 (规范正交) 基 $\mathcal{A} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 和 $\mathcal{B} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_m\}$ 下的矩阵, 即 $\Sigma = [A]_{\mathcal{B}\mathcal{A}}$.

我们将在后文用到这种解释.

3.4.1. 从奇异值分解到极分解

注意, 如果我们知道方阵 A 的奇异值分解 $A = W\Sigma V^*$, 就可由此写出 A 的极分解:

$$(3.6) \quad A = W\Sigma V^* = (WV^*)(V\Sigma V^*) = U|A|$$

其中 $|A| = V\Sigma V^*$, $U = WV^*$.

为说明这的确是极分解, 注意到 $V\Sigma V^*$ 是自伴且正半定的算子, 且有

$$A^*A = V\Sigma W^*W\Sigma V^* = V\Sigma\Sigma V^* = V\Sigma V^*V\Sigma V^* = (V\Sigma V^*)^2.$$

故根据 $|A|$ 的定义 (A^*A 的唯一正半定平方根), 可见 $|A| = V\Sigma V^*$. 变换 WV^* 是两个么正变换的乘积, 自然是么正的, 所以 (3.6) 确实是 A 的极分解.

注意, 此处的推证过程只适用于方阵, 因为如果 A 不是方阵, 那么乘积 $V\Sigma$ 没有定义 (维数不匹配, 你能看出来是怎么回事吗?).

习题

3.1. 证明: 矩阵 A 的非零奇异值的数量 (以重数计) 等于它的秩.

3.2. 求下列矩阵 A 的施密特分解 $A = \sum_{k=1}^r s_k \mathbf{w}_k \mathbf{v}_k^*$:

$$\begin{pmatrix} 2 & 3 \\ 0 & 2 \end{pmatrix}, \quad \begin{pmatrix} 7 & 1 \\ 0 & 0 \\ 5 & 5 \end{pmatrix}, \quad \begin{pmatrix} 1 & 1 \\ 0 & 1 \\ -1 & 1 \end{pmatrix}.$$

3.3. 令 A 是可逆矩阵, 并令 $A = W\Sigma V^*$ 是它的奇异值分解. 求出 A^* 和 A^{-1} 的奇异值分解.

3.4. 求下列矩阵的奇异值分解 $A = W\Sigma V^*$, 其中 V 和 W 是么正矩阵:

$$\text{a) } A = \begin{pmatrix} -3 & 1 \\ 6 & -2 \\ 6 & -2 \end{pmatrix};$$

$$\text{b) } A = \begin{pmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \end{pmatrix}.$$

3.5. 求下列矩阵的奇异值分解

$$A = \begin{pmatrix} 2 & 3 \\ 0 & 2 \end{pmatrix}$$

利用它求出

a) $\max_{\|\mathbf{x}\| \leq 1} \|A\mathbf{x}\|$, 以及使之取得最大值的向量;

b) $\min_{\|\mathbf{x}\|=1} \|A\mathbf{x}\|$, 以及使之取得最小值的向量;

c) $\mathbb{R}^2$ 中闭单位球的像 $A(B)$, $B = \{\mathbf{x} \in \mathbb{R}^2 : \|\mathbf{x}\| \leq 1\}$. 从几何角度描述 $A(B)$.

3.6. 证明: 对方阵 A , $|\det A| = \det |A|$.

3.7. 判断正误:

- a) 矩阵的奇异值也是该矩阵的特征值.
- b) 矩阵 A 的奇异值是 A^*A 的特征值.
- c) 如果 s 是矩阵 A 的奇异值, c 是标量, 那么 $|c|s$ 是 cA 的奇异值.
- d) 任意线性算子的奇异值都是非负的.
- e) 自伴矩阵的奇异值与其特征值相同.

3.8. 令 A 是 $m \times n$ 矩阵. 证明: 矩阵 A^*A 和 AA^* 的非零特征值 (以重数计) 相同. 你能指出, 何时 A^*A 和 AA^* 的零特征值具有相同的重数吗?

3.9. 令 s 是算子 A 的最大奇异值, 并令 λ 是 A 的特征值中绝对值最大的一个. 证明 $|\lambda| \leq s$.

3.10. (即为第一题, 从略)

3.11. (移至习题 4.7)

3.12. 对矩阵 A

$$A = \begin{pmatrix} 2 & -3 \\ 0 & 2 \end{pmatrix},$$

描述单位球的逆像, 即所有满足 $\|A\mathbf{x}\| \leq 1$ 的 $\mathbf{x} \in \mathbb{R}^2$. 利用奇异值分解.

4. 奇异值分解的应用

如前面所讨论的, 奇异值分解就是关于两个不同的规范正交基的对角化. 因为我们用了两个不同的基, 所以从奇异值分解不太能看出算子在特征值方面的性质. 例如, 奇异值分解中的 Σ (3.5) 的对角项不是 A 的特征值. 又注意到, 对 (3.4) 所示的 $A = W\Sigma V^*$, 一般有 $A^n \neq W\Sigma^n V^*$, 所以这种对角化无助于计算关于该矩阵的函数.

然而, 如下面几个例子所示, 奇异值能给出大量有关线性变换的所谓**度量性质**的信息.

注: 进行奇异值分解, 需要求出埃尔米特 (自伴) 矩阵 A^*A 的特征值和特征向量. 要求特征值, 通常要先计算特征多项式, 再求根, 云云. 这看起来是个复杂的过程——尤其是考虑到 5 次及以上的多项式没有求根公式.

然而, 求出埃尔米特矩阵的特征值和特征向量, 已有很高效的数值方法, 它们能达到要求的任意精度. 这些方法并不涉及计算特征多项式以及求根, 而是通过迭代直接计算特征值和特征向量的近似值. 因为埃尔米特矩阵的特征向量能构成正交基, 所以这些方法特别适用于它们.

此处我们将不会讨论这些方法——这超出了本书的范围. 然而, 请你相信, 计算埃尔米特矩阵的特征值和特征向量, 进而求出奇异值分解, 都有很高效的数值方法. 这些方法非常高效, 计算开销只比解线性方程组稍大一点点.

4.1. 单位球的像

以下面问题为例. 令 $A: \mathbb{R}^n \rightarrow \mathbb{R}^m$ 是线性变换, 并令 $B = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| \leq 1\}$ 是 $\mathbb{R}^n$ 中的闭单位球. 现要描述 $A(B)$, 即要得出单位球在线性变换下被变成了什么.

我们首先考虑最简单的情况—— A 是对角阵 $\text{diag}\{\sigma_1, \sigma_2, \dots, \sigma_n\}$, $\sigma_k > 0, k = 1, 2, \dots, n$. 那么, 对 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 和 $\mathbf{y} = A\mathbf{x} = (y_1, y_2, \dots, y_n)^T$, 有 $y_k = \sigma_k x_k$ (等价地说, $x_k = y_k/\sigma_k$) 对 $k = 1, 2, \dots, n$ 成立. 因此

$$\mathbf{y} = (y_1, y_2, \dots, y_n)^T = A\mathbf{x} \quad \text{对 } \|\mathbf{x}\| \leq 1,$$

当且仅当各坐标 $y_1, y_2, \dots, y_n$ 满足下列不等式

$$\frac{y_1^2}{\sigma_1^2} + \frac{y_2^2}{\sigma_2^2} + \dots + \frac{y_n^2}{\sigma_n^2} = \sum_{k=1}^n \frac{y_k^2}{\sigma_k^2} \leq 1$$

(这其实就是不等式 $\|\mathbf{x}\|^2 = \sum_k x_k^2 \leq 1$).

$\mathbb{R}^n$ 中满足上述不等式的点构成的集合称为椭球. 若 $n = 2$, 那么它是半长轴为 σ_1 和 σ_2 的椭圆; 而若 $n = 3$, 它是半长轴为 σ_1, σ_2 和 σ_3 的椭球. 在 $\mathbb{R}^n$ 中, 这个集合的几何也很容易可视化, 并且我们称该集合是半长轴为 $\sigma_1, \sigma_2, \dots, \sigma_n$ 的椭球. 向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$, 或更准确地说, 这些向量所在的直线, 称为该椭球的主轴.

奇异值分解本质上是说, 内积空间上的任意算子都可关于一对规范正交基进行对角化 (见注 3.11). 也就是说, 考虑奇异值分解 (3.4) 中的规范正交基 $\mathcal{A} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 和 $\mathcal{B} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n\}$ ⁴, 那么 A 关于这些基的矩阵是对角阵

$$[A]_{\mathcal{B}\mathcal{A}} = \text{diag}\{\sigma_k : k = 1, 2, \dots, n\}.$$

假设所有 $\sigma_k > 0$, 并重复前述的推理过程, 容易说明, 任意的点 $\mathbf{y} = A\mathbf{x} \in A(B)$ 当且仅当该点满足不等式

$$\frac{y_1^2}{\sigma_1^2} + \frac{y_2^2}{\sigma_2^2} + \dots + \frac{y_n^2}{\sigma_n^2} = \sum_{k=1}^n \frac{y_k^2}{\sigma_k^2} \leq 1$$

其中 $y_1, y_2, \dots, y_n$ 是 $\mathbf{y}$ 在规范正交基 $\mathcal{B} = \{\mathbf{w}_1, \mathbf{w}_2, \dots, \mathbf{w}_n\}$ (而不仅是标准基) 下的坐标. 类似地, $(x_1, x_2, \dots, x_n)^T = [\mathbf{x}]_{\mathcal{A}}$.

而这实质上就是之前的椭球, 只不过旋转了 (主轴与之前不同, 但仍然正交)!

⁴注意此处讨论的是算子, 故 $\mathcal{A}$ 和 $\mathcal{B}$ 中有相同数量的向量. ——译者注

下面展示另一种解释.

考虑一般情形: 矩阵 A 不一定是方阵, 且 (或) 并非所有的奇异值都是非零的. 首先考虑 A 是形如 (3.5) 的“对角”矩阵 Σ 的情况. 容易看出, 单位球 B 的像 ΣB 是半长轴为 $\sigma_1, \sigma_2, \dots, \sigma_r$ 的椭球 (不在整个空间中, 而仅在 $\text{Ran } \Sigma$ 中).

现在考虑更一般的情况, 即 $A = W\Sigma V^*$, 其中 V, W 是幺正算子. 首先, 幺正变换不会改变单位球 (因为它保持范数), 因此 $V^*(B) = B$. 然后, 我们已知 $\Sigma(B)$ 是 $\text{Ran } \Sigma$ 中的半长轴为 $\sigma_1, \sigma_2, \dots, \sigma_r$ 的椭球. 接着, 又由于幺正变换不改变几何形状, 所以 $W(\Sigma(B))$ 仍是具有相同半长轴的椭球. 由于 W 和 V^* 都可逆, 所以从 $A = W\Sigma V^*$ 不难看出 W 将 $\text{Ran } \Sigma$ 变换为 $\text{Ran } A$, 因此我们可得出结论:

闭单位球 B 的像 $A(B)$ 是 $\text{Ran } A$ 中的椭球, 半长轴为 $\sigma_1, \sigma_2, \dots, \sigma_r$. 此处 r 是 A 的非零奇异值的个数, 即 A 的秩.

4.2. 线性变换的算子范数

给定线性变换 $A: X \rightarrow Y$, 考虑以下最优化问题: 求出闭单位球 $B = \{\mathbf{x} \in X: \|\mathbf{x}\| \leq 1\}$ 上 $\|A\mathbf{x}\|$ 的最大值.

同样, 可借助奇异值分解来解决此问题. 对于各项非负的“对角”矩阵 A (类似奇异值分解的定义中的矩阵 Σ), 上述最大值恰为最大的对角项. 的确如此: 令 $s_1, s_2, \dots, s_r$ 是 A 的非零对角项, 并令 s_1 是其中的最大者. 由于对 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 有

$$(4.1) \quad A\mathbf{x} = \sum_{k=1}^r s_k x_k \mathbf{e}_k,$$

故可得

$$\|A\mathbf{x}\|^2 = \sum_{k=1}^r s_k^2 |x_k|^2 \leq s_1^2 \sum_{k=1}^r |x_k|^2 = s_1^2 \cdot \|\mathbf{x}\|^2,$$

因此 $\|A\mathbf{x}\| \leq s_1 \|\mathbf{x}\|$. 另一方面, $\|A\mathbf{e}_1\| = \|s_1 \mathbf{e}_1\| = s_1 \|\mathbf{e}_1\|$, 所以 s_1 确实是闭单位球 B 上 $\|A\mathbf{x}\|$ 的最大值. 注意, 在上面的论证中, 我们并未假设矩阵 A 是方阵, 而仅仅假设“主对角线”之外的所有项都是 0, 因此 (4.1) 成立.

为处理一般情形, 我们考虑奇异值分解 (3.4) $A = W\Sigma V^*$, 其中 W, V 是幺正算子, Σ 是各项非负的“对角”矩阵. 因为幺正变换不改变范数, 所以 $\|A\mathbf{x}\|$ 在单位球 B 上的最大值是 Σ 的最大对角项, 即

$\|A\mathbf{x}\|$ 在单位球 B 上的最大值是 A 的最大奇异值.

定义. $\max\{\|A\mathbf{x}\| : \mathbf{x} \in X, \|\mathbf{x}\| \leq 1\}$ 称为 A 的算子范数, 记作 $\|A\|$.

容易看出, $\|A\|$ 满足范数的所有性质 (留作习题):

1. $\|\alpha A\| = |\alpha| \cdot \|A\|$;
2. $\|A + B\| \leq \|A\| + \|B\|$;
3. 对所有 A 均有 $\|A\| \geq 0$;
4. $\|A\| = 0$ 当且仅当 $A = \mathbf{0}$.

所以, 它的确是由 X 到 Y 的线性变换构成的向量空间上的范数.

算子范数的主要性质之一是如下不等式

$$\|A\mathbf{x}\| \leq \|A\| \cdot \|\mathbf{x}\|,$$

从范数 $\|\mathbf{x}\|$ 的齐次性很容易得到.

事实上, 可以证明, 算子范数 $\|A\|$ 是满足

$$\|A\mathbf{x}\| \leq C\|\mathbf{x}\| \quad \forall \mathbf{x} \in X.$$

的最好 (最小) 的 C . 这往往被用于定义算子范数.

在线性变换构成的向量空间上, 我们已经定义过一种范数——弗罗贝尼乌斯范数, 或称希尔伯特-施密特范数 $\|A\|_2$,

$$\|A\|_2^2 = \text{trace}(A^*A).$$

那么, 我们来比较一下这两种范数.

令 $s_1, s_2, \dots, s_r$ 是 A 的非零奇异值 (以重数计), 并令 s_1 是最大的奇异值. 那么 $s_1^2, s_2^2, \dots, s_r^2$ 是 A^*A 的非零特征值 (同样以重数计). 回忆一下, 迹等于特征值的和, 于是

$$\|A\|_2^2 = \text{trace}(A^*A) = \sum_{k=1}^r s_k^2.$$

另一方面, 我们知道 A 的算子范数等于其最大奇异值, 即 $\|A\| = s_1$. 所以我们可得 $\|A\| \leq \|A\|_2$, 也就是

矩阵的算子范数不大于其弗罗贝尼乌斯范数.

这条结论也可以用柯西-施瓦兹不等式直接证明——有些教材中就是用这种方法. 此处这种证明的美妙之处在于, 不需要任何计算, 还揭示了该不等式背后的深层次原因.

4.3. 矩阵的条件数

假设有可逆矩阵 A ，欲求解方程 $A\mathbf{x} = \mathbf{b}$ 。该方程的解自然是 $\mathbf{x} = A^{-1}\mathbf{b}$ ，但我们要分析，如果方程中的数据仅仅是粗略的，会发生什么。

这在现实中是会发生的——比如数据是从实验中得到的。即便我们得到了确切的数据，计算机运算时产生的舍入误差也可能使数据产生相同的失真。

我们考虑一个简单的失真模型——假设方程右侧有微小误差。这就意味着我们不是求解 $A\mathbf{x} = \mathbf{b}$ ，而是求解

$$A\mathbf{x} = \mathbf{b} + \Delta\mathbf{b},$$

其中 $\Delta\mathbf{b}$ 是右端项 $\mathbf{b}$ 的微小扰动。

于是，我们并不是得到 $A\mathbf{x} = \mathbf{b}$ 的精确解 $\mathbf{x}$ ，而是得到 $A(\mathbf{x} + \Delta\mathbf{x}) = \mathbf{b} + \Delta\mathbf{b}$ 的近似解 $\mathbf{x} + \Delta\mathbf{x}$ 。我们假设 A 可逆，从而 $\Delta\mathbf{x} = A^{-1}\Delta\mathbf{b}$ 。

我们想知道解的相对误差 $\|\Delta\mathbf{x}\|/\|\mathbf{x}\|$ 相比于右端项的相对误差 $\|\Delta\mathbf{b}\|/\|\mathbf{b}\|$ 有多大。容易看出

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \frac{\|A^{-1}\Delta\mathbf{b}\|}{\|\mathbf{x}\|} = \frac{\|A^{-1}\Delta\mathbf{b}\|}{\|\mathbf{b}\|} \frac{\|\mathbf{b}\|}{\|\mathbf{x}\|} = \frac{\|A^{-1}\Delta\mathbf{b}\|}{\|\mathbf{b}\|} \frac{\|A\mathbf{x}\|}{\|\mathbf{x}\|}.$$

因为 $\|A^{-1}\Delta\mathbf{b}\| \leq \|A^{-1}\| \cdot \|\Delta\mathbf{b}\|$ ，并且 $\|A\mathbf{x}\| \leq \|A\| \cdot \|\mathbf{x}\|$ ，所以可得

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}.$$

$\|A\| \cdot \|A^{-1}\|$ 称为矩阵 A 的**条件数**。它估计了方程的解 $\mathbf{x}$ 的相对误差与右端项 $\mathbf{b}$ 的相对误差的依赖程度。

我们看看这个量和奇异值有何关系。令 A 的奇异值是 $s_1, s_2, \dots, s_n$ ，并设 s_1 和 s_n 分别是最大的和最小的奇异值。我们知道算子的（算子）范数等于其最大奇异值，所以

$$\|A\| = s_1, \quad \|A^{-1}\| = \frac{1}{s_n},$$

因此

$$\|A\| \cdot \|A^{-1}\| = \frac{s_1}{s_n}.$$

换言之

矩阵的条件数等于其最大和最小奇异值之比。

前面我们推得， $\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} \leq \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}$ 。不难看出，这个估计是紧的，即可以选取右端项 $\mathbf{b}$ 和误差 $\Delta\mathbf{b}$ ，使得等号成立：

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \|A^{-1}\| \cdot \|A\| \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|}.$$

只需置 $\mathbf{b} = \mathbf{w}_1$ 和 $\Delta \mathbf{b} = \alpha \mathbf{w}_n$, 其中 $\mathbf{w}_1$ 和 $\mathbf{w}_n$ 分别是奇异值分解 $A = W\Sigma V^*$ 中矩阵 W 的第一列和最后一列, $\alpha \neq 0$ 是任意标量. 此处, 按惯例, 将奇异值按非增顺序排列为 $s_1 \geq s_2 \geq \dots \geq s_n$, 故 s_1 是最大的奇异值, s_n 是最小的奇异值.

我们将细节留给读者作为习题.

称矩阵是**良态的**, 如果它的条件数不太大. 如果条件数很大, 就称矩阵是**病态的**. “大”与“小”依问题而定——与可获得的右端项的精度, 以及所需的解的精度等都有关系.

4.4. 矩阵的有效秩

理论上讲, 矩阵的秩很容易计算: 只需做行化简再数出主元的个数就行了. 然而, 在实际应用中, 并不总这样简单——主要原因是, 我们常常不知道确切的矩阵, 而只知道它达到某个精度的估计.

此外, 即便我们知道确切的矩阵, 大多数的计算程序在运算过程中都会引入舍入误差, 所以实际上我们无法区分“为零的主元”和“很小的主元”.

处理舍入误差的一个朴素的思路是, 当计算秩 (以及与之相关的其他对象, 比如列空间、核等) 时, 设定一个容许值 (很小的数), 若某主元小于这个容许值, 就视其为零. 这个方法的优势就是它很简单, 因为很容易编程实现. 然而, 这个方法有个关键的缺陷: 无法看出容许值会造成什么影响. 比如, 如果将容许值设为 10^{-6} , 我们会损失什么? 设成 10^{-8} 又会有多少改进?

尽管上述方法对良态矩阵很好用, 它在一般情形下并不十分可靠.

一种更好的方法是用奇异值. 这种方法需要做更多计算, 但会给出更好的结果, 解释起来也更清晰. 我们同样设定一个很小的数作为容许值, 然后做奇异值分解. 然后我们只需视小于容许值的奇异值为零. 这种方法的优势在于我们知道自己做什么: 奇异值就是椭球 $A(B)$ (B 是闭单位球) 的半长轴, 所以设定容许值就是在确定多“薄”的椭球应被视为“平”的.

4.5. 摩尔-彭罗斯 (伪) 逆

如我们在第 5 章第 4 节所讨论的, 最小平方解给出了方程 $A\mathbf{x} = \mathbf{b}$ 无解时的“次优解” (并且在 $A\mathbf{x} = \mathbf{b}$ 有解时也能给出其解).

注意, 最小平方解并未解决唯一性的问题: 法方程 $A^*Ax = A^*b$ 的解未必是唯一的. 其有一个自然的特解——最小范数解. 这样的解是唯一的, 并且可以通过取任意解往 $(\text{Ker } A^*A)^\perp = (\text{Ker } A)^\perp$ 的投影来获得, 见第 5 章习题 4.5 和 4.6.

不难看出, 如果 A 的简化奇异值分解是 $A = \widetilde{W}\widetilde{\Sigma}\widetilde{V}^*$, 那么最小范数最小平方解 x_0 由下式给出:

$$(4.2) \quad x_0 = \widetilde{V}\widetilde{\Sigma}^{-1}\widetilde{W}^*b.$$

的确如此—— x_0 是 $Ax = b$ 的最小平方解 (即 $Ax = P_{\text{Ran } A}b$ 的解):

$$Ax_0 = \widetilde{W}\widetilde{\Sigma}\widetilde{V}^*\widetilde{V}\widetilde{\Sigma}^{-1}\widetilde{W}^*b = \widetilde{W}\widetilde{\Sigma}\widetilde{\Sigma}^{-1}\widetilde{W}^*b = \widetilde{W}\widetilde{W}^*b = P_{\text{Ran } A}b;$$

最后一个等号, 是由于 $\widetilde{W}\widetilde{W}^* = P_{\text{Ran } \widetilde{W}}$ ($P_{\text{Ran } \widetilde{W}} = \widetilde{W}(\widetilde{W}^*\widetilde{W})^{-1}\widetilde{W}^* = \widetilde{W}\widetilde{W}^*$) 并且 $\text{Ran } \widetilde{W} = \text{Ran } A$ (见下习题 4.4).

方程 $Ax = P_{\text{Ran } A}b$ 的通解是

$$x = x_0 + y, \quad y \in \text{Ker } A,$$

所以 x_0 的确是 $Ax = P_{\text{Ran } A}b$ 的唯一最小范数解, 或者等价地说, 是 $Ax = b$ 的最小范数最小平方解.

定义 4.1. 变换 $A^+ := \widetilde{V}\widetilde{\Sigma}^{-1}\widetilde{W}^*$ (其中 A 的简化奇异值分解为 $A = \widetilde{W}\widetilde{\Sigma}\widetilde{V}^*$) 称为变换 A 的**摩尔-彭罗斯逆** (或**摩尔-彭罗斯伪逆**). 换言之, **摩尔-彭罗斯逆**是能给出 $Ax = b$ 的唯一最小平方解的变换.

注 4.2. 在文献中, 摩尔-彭罗斯逆常定义为满足下列性质的矩阵 A^+ :

1. $AA^+A = A$;
2. $A^+AA^+ = A^+$;
3. $(AA^+)^* = AA^+$;
4. $(A^+A)^* = A^+A$.

很容易检验, 变换 $A^+ := \widetilde{V}\widetilde{\Sigma}^{-1}\widetilde{W}^*$ 满足上述性质 1-4.

还可以证明, 满足上述性质 1-4 的变换 A^+ 是唯一的, 尽管证明稍有些难度. 的确如此: 将等式 1 右乘和左乘 A^+ , 可分别得到 $(A^+A)^2 = A^+A$ 和 $(AA^+)^2 = AA^+$, 再结合性质 3 和 4, 即得 A^+A 和 AA^+ 都是正交投影 (见第 5 章习题 5.6).

$\text{Ker } A \subset \text{Ker } A^+A$ 是平凡的, 而由等式 1, $\text{Ker } A^+A \subset \text{Ker } A$ (为什么?), 所以 $\text{Ker } A^+A = \text{Ker } A$. 而这就意味着 A^+A 是往 $(\text{Ker } A)^\perp = \text{Ran } A^*$ 的正交投影:

$$A^+A = P_{\text{Ran } A^*}.$$

性质 1 还意味着, 对所有 $\mathbf{y} \in \text{Ran } A$, 有 $AA^+\mathbf{y} = \mathbf{y}$. 因为 AA^+ 是正交投影, 所以 $\text{Ran } A \subset \text{Ran } AA^+$. 反方向的包含关系 $\text{Ran } AA^+ \subset \text{Ran } A$ 是平凡的, 所以 AA^+ 是往 $\text{Ran } A$ 的正交投影:

$$AA^+ = P_{\text{Ran } A}.$$

已知 A^+A 和 AA^+ , 可重写性质 2 为

$$P_{\text{Ran } A^*}A^+ = A^+ \quad \text{或} \quad A^+P_{\text{Ran } A} = A^+.$$

结合两式得到

$$P_{\text{Ran } A^*}A^+P_{\text{Ran } A} = A^+.$$

最后, 对 A 的目标空间中的任意 $\mathbf{b}$ 有

$$\mathbf{x}_0 := A^+\mathbf{b} = P_{\text{Ran } A^*}A^+\mathbf{b} \in \text{Ran } A^*$$

以及

$$A\mathbf{x}_0 = AA^+\mathbf{b} = P_{\text{Ran } A}\mathbf{b},$$

即 $\mathbf{x}_0$ 是 $A\mathbf{x} = \mathbf{b}$ 的最小平方解. 因为 $\mathbf{x}_0 \in \text{Ran } A^* = (\text{Ker } A)^\perp$, 所以根据我们之前的讨论, $\mathbf{x}_0$ 是最小范数最小平方解. 但是, 如我们之前证明的, 这样的最小平方解由 (4.2) 给出, 因此必有 $A^+ = \widetilde{V}\widetilde{\Sigma}^{-1}\widetilde{W}^*$. $\square$

习题

4.1. 求出下列矩阵的范数和条件数:

a) $A = \begin{pmatrix} 4 & 0 \\ 1 & 3 \end{pmatrix}.$

b) $A = \begin{pmatrix} 5 & 3 \\ -3 & 3 \end{pmatrix}.$

对 a) 问中的矩阵 A , 给出一个右端项 $\mathbf{b}$ 和误差 $\Delta\mathbf{b}$ 使得

$$\frac{\|\Delta\mathbf{x}\|}{\|\mathbf{x}\|} = \|A\| \cdot \|A^{-1}\| \cdot \frac{\|\Delta\mathbf{b}\|}{\|\mathbf{b}\|};$$

这里 $A\mathbf{x} = \mathbf{b}$ 且 $A\Delta\mathbf{x} = \Delta\mathbf{b}$.

4.2. 令 A 是正规算子, 并令 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是它的特征值 (以重数计). 证明: A 的奇异值是 $|\lambda_1|, |\lambda_2|, \dots, |\lambda_n|$.

4.3. 求出矩阵

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

的奇异值、范数和条件数. 如果你利用上题的结论并能回答下列问题, 可以不用任何计算就得出答案:

- 往某子空间 E 上正交投影 P_E 的奇异值 (特征值) 是什么?
- 往由向量 $(1, 1, 1)^T$ 张成的子空间上正交投影的矩阵是什么?
- 算子 T 与 $aT + bI$ (a, b 为标量) 的特征值有什么关系?

4.4. 令 A 的简化奇异值分解为 $A = \widetilde{W}\widetilde{\Sigma}\widetilde{V}^*$. 证明 $\text{Ran } A = \text{Ran } \widetilde{W}$, 再通过取伴随证明 $\text{Ran } A^* = \text{Ran } \widetilde{V}$.

4.5. 利用奇异值分解 $A = W\Sigma V^*$, 写出摩尔-彭罗斯逆 A^+ 的公式.

4.6. 吉洪诺夫正则化: 证明摩尔-彭罗斯逆 A^+ 可用下述极限计算:

$$A^+ = \lim_{\varepsilon \rightarrow 0+} (A^*A + \varepsilon I)^{-1}A^* = \lim_{\varepsilon \rightarrow 0+} A^*(AA^* + \varepsilon I)^{-1}.$$

4.7. 证明: 矩阵 A 的算子范数与其弗罗贝尼乌斯范数相同, 当且仅当矩阵的秩为 1. 提示: 习题 3.1 可能有用.

5. 正交矩阵的结构

满足 $\det U = 1$ 的正交矩阵 U 常称作**旋转**. 下述定理解释了这个名称的来历.

定理 5.1. 令 U 是 $\mathbb{R}^n$ 上的正交算子, 并令 $\det U = 1$.⁵ 那么存在规范正交基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 使得 U 关于该基的矩阵具有如下分块对角形式

$$\begin{pmatrix} R_{\varphi_1} & & & & 0 \\ & R_{\varphi_2} & & & \\ & & \ddots & & \\ & & & R_{\varphi_k} & \\ 0 & & & & I_{n-2k} \end{pmatrix}.$$

其中 R_{φ_k} 是 2 维旋转,

$$R_{\varphi_k} = \begin{pmatrix} \cos \varphi_k & -\sin \varphi_k \\ \sin \varphi_k & \cos \varphi_k \end{pmatrix}$$

I_{n-2k} 代表大小为 $(n-2k) \times (n-2k)$ 的恒等矩阵.

证明: 我们知道, 如果 p 是实系数多项式, 且 λ 是其复根 ($p(\lambda) = 0$), 那么 $\bar{\lambda}$ 也是 p 的根, 即 $p(\bar{\lambda}) = 0$ (将 $\bar{\lambda}$ 代入 $p(z) = \sum_{k=0}^n a_k z^k$ 即可验证).

因此, 实矩阵的所有复特征值都可按 $\lambda_k, \bar{\lambda}_k$ 成对划分.

我们知道, 么正矩阵的特征值的绝对值都是 1, 因此 A 的所有复特征值都可写为 $\lambda_k = \cos \alpha_k + i \sin \alpha_k$, $\bar{\lambda}_k = \cos \alpha_k - i \sin \alpha_k$.

取定一对复特征值 λ 和 $\bar{\lambda}$, 并令 $\mathbf{u} \in \mathbb{C}^n$ 是 U 的特征向量, $U\mathbf{u} = \lambda\mathbf{u}$. 那么 $U\bar{\mathbf{u}} = \bar{\lambda}\bar{\mathbf{u}}$. 现在将 $\mathbf{u}$ 分成实部和虚部, 即定义

$$\mathbf{x} := \text{Re } \mathbf{u} = (\mathbf{u} + \bar{\mathbf{u}})/2, \quad \mathbf{y} := \text{Im } \mathbf{u} = (\mathbf{u} - \bar{\mathbf{u}})/(2i),$$

⁵对一般的正交矩阵 U , $\det U = \pm 1$.

因此 $\mathbf{u} = \mathbf{x} + i\mathbf{y}$ (注意 $\mathbf{x}, \mathbf{y}$ 都是实向量, 即各项为实数的向量). 那么

$$U\mathbf{x} = U\frac{1}{2}(\mathbf{u} + \bar{\mathbf{u}}) = \frac{1}{2}(\lambda\mathbf{u} + \bar{\lambda}\bar{\mathbf{u}}) = \operatorname{Re}(\lambda\mathbf{u}).$$

类似地,

$$U\mathbf{y} = \frac{1}{2i}U(\mathbf{u} - \bar{\mathbf{u}}) = \frac{1}{2i}(\lambda\mathbf{u} - \bar{\lambda}\bar{\mathbf{u}}) = \operatorname{Im}(\lambda\mathbf{u}).$$

因为 $\lambda = \cos \alpha + i \sin \alpha$, 所以我们有

$$\begin{aligned}\lambda\mathbf{u} &= (\cos \alpha + i \sin \alpha)(\mathbf{x} + i\mathbf{y}) \\ &= ((\cos \alpha)\mathbf{x} - (\sin \alpha)\mathbf{y}) + i((\cos \alpha)\mathbf{y} + (\sin \alpha)\mathbf{x}).\end{aligned}$$

因此

$$U\mathbf{x} = \operatorname{Re}(\lambda\mathbf{u}) = (\cos \alpha)\mathbf{x} - (\sin \alpha)\mathbf{y}, \quad U\mathbf{y} = \operatorname{Im}(\lambda\mathbf{u}) = (\cos \alpha)\mathbf{y} + (\sin \alpha)\mathbf{x}.$$

换言之, U 保持由向量 $\mathbf{x}, \mathbf{y}$ 张成的 2 维子空间 E_λ 不变, 并且限制于该子空间的 U 的矩阵是旋转矩阵

$$R_{-\alpha} = \begin{pmatrix} \cos \alpha & \sin \alpha \\ -\sin \alpha & \cos \alpha \end{pmatrix}$$

注意, 向量 $\mathbf{u}$ 和 $\bar{\mathbf{u}}$ (都是么正矩阵的特征向量, 并且对应于不同的特征值) 是正交的, 故由毕达哥拉斯定理有

$$\|\mathbf{x}\| = \|\mathbf{y}\| = \frac{\sqrt{2}}{2}\|\mathbf{u}\|.$$

容易验证 $\mathbf{x} \perp \mathbf{y}$, 因此 $\mathbf{x}, \mathbf{y}$ 是 E_λ 的正交基. 如果将基向量 $\mathbf{x}, \mathbf{y}$ 都乘以相同的非零数, 那么线性变换的矩阵不会改变. 因此, 不失一般性, 我们可假设 $\|\mathbf{x}\| = \|\mathbf{y}\| = 1$, 即 $\mathbf{x}, \mathbf{y}$ 是 E_λ 的规范正交基.

下面将规范正交向量组 $\mathbf{v}_1 = \mathbf{x}, \mathbf{v}_2 = \mathbf{y}$ 补全为 $\mathbb{R}^n$ 的规范正交基. 因为 $UE_\lambda \subset E_\lambda$, 即 E_λ 是 U 的不变子空间, 所以 U 关于该基的矩阵具有如下分块三角形式

$$\left(\begin{array}{c|c} R_{-\alpha} & * \\ \hline \mathbf{0} & U_1 \end{array} \right)$$

其中 $\mathbf{0}$ 代表由零构成的 $(n-2) \times 2$ 的块.

因为旋转矩阵 $R_{-\alpha}$ 是可逆的, 所以 $UE_\lambda = E_\lambda$. 因此

$$U^*E_\lambda = U^{-1}E_\lambda = E_\lambda,$$

因此 U 关于该基的矩阵事实上是分块对角的:

$$\left(\begin{array}{c|c} R_{-\alpha} & \mathbf{0} \\ \hline \mathbf{0} & U_1 \end{array} \right)$$

因为 U 是幺正的, 所以

$$I = U^*U = \left(\begin{array}{c|c} I & \mathbf{0} \\ \hline \mathbf{0} & U_1^*U_1 \end{array} \right)$$

则因为 U_1 是方阵, 所以 U_1 也是幺正的.

如果 U_1 有复特征值, 我们可以对其应用上述步骤, 将其大小减少 2, 直至剩余的块只有实特征值. 实特征值只能是 +1 或 -1, 因此关于某规范正交基, U 的矩阵形如

$$\begin{pmatrix} R_{-\alpha_1} & & & & & & 0 \\ & R_{-\alpha_2} & & & & & \\ & & \ddots & & & & \\ & & & R_{-\alpha_d} & & & \\ 0 & & & & -I_r & & \\ & & & & & -I_l & \end{pmatrix}.$$

其中 I_r 和 I_l 分别是大小为 $r \times r$ 和 $l \times l$ 的恒等矩阵. 因为 $\det U = 1$, 所以特征值 -1 的重数 (即 r) 必为偶数.

注意, 2×2 矩阵 $-I_2$ 可解释为旋转 π . 因此, 上述矩阵具有定理陈述中的形式, 其中 $\varphi_k = -\alpha_k$ 或 $\varphi = \pi$. $\square$

我们给出定理 5.1 的一种不同的解释. 定义 T_j 是在由向量 $\mathbf{v}_j, \mathbf{v}_{j+1}$ 张成的向量空间中旋转 φ_j . 那么定理 5.1 其实表明, U 是旋转 $T_j, j = 1, 2, \dots, k$ 的复合. 注意, 因为各旋转 T_j 是作用在互相正交的向量空间上, 所以它们是可交换的, 也即复合的顺序是无关紧要的. 因此, 该定理可解释为:

$\mathbb{R}^n$ 上的任意旋转可表示为至多 $n/2$ 个可交换的平面旋转的复合.

如果正交矩阵的行列式是 -1, 那么其结构由下面定理描述.

定理 5.2. 令 U 是 $\mathbb{R}^n$ 上的正交算子, 并令 $\det U = -1$. 那么存在规范正交基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 使得 U 关于该基的矩阵具有如下分块对角形式

$$\begin{pmatrix} R_{\varphi_1} & & & & 0 \\ & R_{\varphi_2} & & & \\ & & \ddots & & \\ & & & R_{\varphi_k} & \\ 0 & & & & I_r \\ & & & & & -1 \end{pmatrix}.$$

其中 $r = n - 2k - 1$, R_{φ_k} 是 2 维旋转,

$$R_{\varphi_k} = \begin{pmatrix} \cos \varphi_k & -\sin \varphi_k \\ \sin \varphi_k & \cos \varphi_k \end{pmatrix}$$

I_{n-2k} 代表大小为 $(n - 2k) \times (n - 2k)$ 的恒等矩阵.

我们将证明留给读者作为习题. 需要对定理 5.1 的证明作出修改, 而这修改是很显然的.

注意, 由上述定理可得, 行列式为 -1 的 2×2 正交矩阵 U 必为反射.

下面, 取定规范正交基 (比如 $\mathbb{R}^n$ 的标准基). 我们称 x_j - x_k 平面中的旋转为**初等旋转**⁶, 即仅仅改变坐标 x_j 和 x_k , 并且对这两个坐标的作用等同于平面旋转的线性变换.

定理 5.3. 任意旋转 U (即 $\det U = 1$ 的正交变换 U) 都可表示为至多 $n(n-1)/2$ 个初等旋转的乘积.

为证明该定理, 我们需要下面这几个简单的引理.

引理 5.4. 令 $\mathbf{x} = (x_1, x_2)^T \in \mathbb{R}^2$. 存在 $\mathbb{R}^2$ 上的旋转 R_α , 将向量 $\mathbf{x}$ 转到 $(a, 0)^T$, 其中 $a = \sqrt{x_1^2 + x_2^2}$.

该引理的证明很简单, 留给读者作为习题, 只需画出 R_α 的图形或者写出其公式.

引理 5.5. 令 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \mathbb{R}^n$. 存在 $n-1$ 个初等旋转 $R_1, R_2, \dots, R_{n-1}$, 使得 $R_{n-1} \dots R_2 R_1 \mathbf{x} = (a, 0, 0, \dots, 0)^T$, 其中 $a = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$.

证明: 该引理的证明思想很简单. 首先用 x_{n-1} - x_n 平面上的初等旋转 R_1 来“消去” $\mathbf{x}$ 的最后一个坐标 (引理 5.4 保证了此旋转的存在性), 然后用 x_{n-2} - x_{n-1} 平面上的初等旋转 R_2 来“消去” $R_1 \mathbf{x}$ 的第 $n-1$ 个坐标

⁶这个术语并未被广泛采用.

(旋转 R_2 不会改变最后一个坐标, 所以 $R_2 R_1 \mathbf{x}$ 的最后一个坐标保持为零), 依次类推.

下面呈现正式的证明, 对 n 用归纳法. $n = 1$ 的情形是平凡的, 因为 $\mathbb{R}^1$ 中的任意向量都具有期望的形式, 而 $n = 2$ 的情况由引理 5.4 解决.

现假设本引理对 $n - 1$ 情形成立, 要证它对 n 的情形成立. 由引理 5.4, 存在 2×2 矩阵 R_α , 使得

$$R_\alpha \begin{pmatrix} x_{n-1} \\ x_n \end{pmatrix} = \begin{pmatrix} a_{n-1} \\ 0 \end{pmatrix},$$

其中 $a_{n-1} = \sqrt{x_{n-1}^2 + x_n^2}$. 所以, 如果定义 $n \times n$ 初等旋转 R_1 为

$$R_1 = \begin{pmatrix} I_{n-2} & \mathbf{0} \\ \mathbf{0} & R_\alpha \end{pmatrix}$$

(I_{n-2} 是 $(n - 2) \times (n - 2)$ 恒等矩阵), 那么

$$R_1 \mathbf{x} = (x_1, x_2, \dots, x_{n-2}, a_{n-1}, 0)^T.$$

我们假设了本引理对 $n - 1$ 情形成立, 所以存在 $n - 2$ 个 $\mathbb{R}^{n-1}$ 上的初等旋转 (记其为 $R_2, R_3, \dots, R_{n-1}$), 将向量 $(x_1, x_2, \dots, x_{n-2}, a_{n-1})^T \in \mathbb{R}^{n-1}$ 变换为向量 $(a, 0, \dots, 0)^T \in \mathbb{R}^{n-1}$. 换言之,

$$R_{n-1} \dots R_3 R_2 (x_1, x_2, \dots, x_{n-2}, a_{n-1})^T = (a, 0, \dots, 0)^T.$$

我们总可以假设初等旋转 $R_2, R_3, \dots, R_{n-1}$ 作用于 $\mathbb{R}^n$ (只需假设它们不改变最后一个坐标). 那么

$$R_{n-1} \dots R_3 R_2 R_1 \mathbf{x} = (a, 0, \dots, 0)^T \in \mathbb{R}^n.$$

下面证明 $a = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$. 可以直接检验之, 不过我们运用下面的间接论证方法: 已知正交变换保持范数, 并且 $a \geq 0$, 这样 a 就只可能是 $a = \sqrt{x_1^2 + x_2^2 + \dots + x_n^2}$. $\square$

引理 5.6. 令 A 是 $n \times n$ 实矩阵. 存在初等旋转 $R_1, R_2, \dots, R_N, N \leq n(n - 1)/2$, 使得 $B = R_N \dots R_2 R_1 A$ 是上三角的, 此外, 其对角项除了最后一个 ($B_{n,n}$) 外, 都是非负的.

证明: 我们将对 n 用归纳法. $n = 1$ 的情形是平凡的, 因为可以说所有 1×1 矩阵都具有期望的形式.

现在考虑 $n = 2$ 的情形. 令 $\mathbf{a}_1$ 是 A 的第一列. 由引理 5.4, 存在旋转 R 可“消去” $\mathbf{a}_1$ 的第二个坐标且使第一个坐标非负. 于是矩阵 $B = RA$ 具有期望的形式.

现在假设该引理对 $(n-1) \times (n-1)$ 矩阵成立, 并要证明它对 $n \times n$ 矩阵成立. 令 $\mathbf{a}_1$ 是 $n \times n$ 矩阵 A 的第一列. 由引理 5.5, 可找到 $n-1$ 个初等旋转 (记为 $R_1, R_2, \dots, R_{n-1}$) 将 $\mathbf{a}_1$ 变换为 $(a, 0, \dots, 0)^T$. 因此, 矩阵 $R_{n-1} \dots R_2 R_1 A$ 具有下面的分块三角形式

$$R_{n-1} \dots R_2 R_1 A = \begin{pmatrix} a & * \\ \mathbf{0} & A_1 \end{pmatrix}$$

其中 A_1 是 $(n-1) \times (n-1)$ 的块.

我们假设了该引理对 $n-1$ 的情形成立, 所以 A_1 可由至多 $(n-1)(n-2)/2$ 个旋转变换为所需的上三角形式. 注意, 这些旋转作用于 $\mathbb{R}^{n-1}$ (只对坐标 $x_2, x_3, \dots, x_n$ 有作用), 但我们总可以假设它们作用于整个 $\mathbb{R}^n$ (只需假设它们不改变第一个坐标). 那么, 这些旋转就不会改变向量 $(a, 0, \dots, 0)^T$ ($R_{n-1} \dots R_2 R_1 A$ 的第一列), 因此矩阵 A 可由至多 $n-1 + (n-1)(n-2)/2 = n(n-1)/2$ 个初等旋转化化为所需的上三角形式. $\square$

定理 5.3 的证明: 由引理 5.6, 存在初等旋转 $R_1, R_2, \dots, R_N$ 使得矩阵 $U_1 = R_N \dots R_2 R_1 U$ 是上三角的, 并且所有对角项都是非负的 (除了最后一个可能不是).

注意, 矩阵 U_1 是正交的. 任意正交矩阵都是正规的, 而我们知道任意正规的上三角矩阵都是对角阵. 所以 U_1 是对角阵.

我们知道, 正交矩阵的特征值只能是 1 或 -1 , 所以 U_1 的对角线上只能有 1 或 -1 . 但我们知道 U_1 的所有对角项都是非负的 (除了最后一个可能不是), 所以 U_1 的所有对角项 (除最后一个外) 都是 1, 而最后一个可能是 ± 1 .



因为初等旋转的行列式是 1, 故 $\det U_1 = \det U = 1$, 则最后一个对角项也必为 1. 所以 $U_1 = I$, 因此 U 可表示为一系列初等旋转的乘积 $U = R_1^{-1} R_2^{-1} \dots R_N^{-1}$, 此处用到了 “初等旋转的逆也是初等旋转”. $\square$

6. 取向

6.1. 引入

在下面的图 1 和 2 中, 我们分别看到 $\mathbb{R}^2$ 和 $\mathbb{R}^3$ 的三个规范正交基. 在每张图中, b) 都可由标准基 a) 经旋转得到, 而 c) 则无法由标准基 a) 经旋转得到.

你之前可能已经听过“取向”一词，并且你大概已经知道基 a) 与 b) 的取向为正，而基 c) 的取向为负. 你大概还已经了解过一些判别取向的法则，比如物理学中的右手定则. 所以，如果你能**看到**基（比如说 $\mathbb{R}^3$ 的基），你大概就能判断它的取向.

图 1 $\mathbb{R}^2$ 中的取向图 2 $\mathbb{R}^3$ 中的取向

但是，如果只给出了向量 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 的坐标呢？当然，你总可以绘制这些向量的图形，并据此判断取向. 但这并不总是容易完成. 而且，如何向计算机“解释”它呢？

其实，有种更简单的方法，现在就给出解释. 我们需要检验是否可能通过旋转 $\mathbb{R}^3$ 的标准基 $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$ 来得到基 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$. 存在唯一的线性变换 U 使得

$$U\mathbf{e}_k = \mathbf{v}_k, \quad k = 1, 2, 3;$$

其（关于标准基的）矩阵是各列为 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 的矩阵. 它是正交矩阵（因为它将规范正交基变换成规范正交基），因此只需判断它是否为旋转. 定理 5.1 和 5.2 给出了答案：矩阵 U 是旋转矩阵，当且仅当 $\det U = 1$. 注意，（对 3×3 矩阵而言）若 $\det U = -1$ ，那么 U 是两变换的复合——关于某轴的旋转与关于旋转平面（即正交于旋转轴的平面）的反射.

这就为下面的正式定义提供了动机.

6.2. 正式定义

令 $\mathcal{A}$ 和 $\mathcal{B}$ 是实向量空间 X 的两个基. 称基 $\mathcal{A}$ 和 $\mathcal{B}$ 取向相同，如果坐标变换矩阵 $[I]_{\mathcal{B}\mathcal{A}}$ 的行列式为正；称它们取向相异，如果坐标变换矩阵 $[I]_{\mathcal{B}\mathcal{A}}$ 的行列式为负.

注意, 因为 $[I]_{AB} = [I]_{BA}^{-1}$, 所以上述定义中也可以用矩阵 $[I]_{AB}$.

$\mathbb{R}^n$ 中, 一般假设标准基 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 取向为正. 在抽象的向量空间中, 只需取定一个基, 并假设该基取向为正即可.

如果 $\mathbb{R}^n$ 的规范正交基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 取向为正 (即与标准基取向相同), 那么定理 5.1 和 5.2 就表明, 基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 可由标准基通过旋转得到.

6.3. 基和取向的连续变换

定义. 称基 $\mathcal{A} = \{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 可连续变换为基 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$, 若存在连续的一族基 $\mathcal{V}(t) = \{\mathbf{v}_1(t), \mathbf{v}_2(t), \dots, \mathbf{v}_n(t), t \in [a, b]\}$, 使得

$$\mathbf{v}_k(a) = \mathbf{a}_k, \quad \mathbf{v}_k(b) = \mathbf{b}_k, \quad k = 1, 2, \dots, n.$$

“连续的一族基”意为: 各向量函数 $\mathbf{v}_k(t)$ 是连续的 (它们关于某个基的坐标是连续函数), 并且对于所有 $t \in [a, b]$, 向量组 $\mathbf{v}_1(t), \mathbf{v}_2(t), \dots, \mathbf{v}_n(t)$ 总是基 (这点很重要).

注意, 通过变量代换, 总可假设 (如有必要) $[a, b] = [0, 1]$.

定理 6.1. 两个基 $\mathcal{A} = \{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n\}$ 和 $\mathcal{B} = \{\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_n\}$ 取向相同, 当且仅当其中一个基可被连续变换为另一个.

证明: 假设基 $\mathcal{A}$ 可连续变换为基 $\mathcal{B}$, 并令 $\mathcal{V}(t)$ 为实现该变换的连续的一族基. 考虑矩阵函数 $V(t)$, 其各列是 $\mathbf{v}_k(t)$ 在基 $\mathcal{A}$ 下的坐标向量 $[\mathbf{v}_k(t)]_{\mathcal{A}}$.

显然, $V(t)$ 的各项都是连续函数, 且 $V(a) = I, V(b) = [I]_{AB}$. 注意, 因为 $\mathcal{V}(t)$ 总是基, 所以 $\det V(t)$ 总不为零. 因此, 由介值定理, $\det V(a)$ 和 $\det V(b)$ 符号相同. 因为 $\det V(a) = \det I = 1$, 所以

$$\det[I]_{AB} = \det V(b) > 0,$$

于是基 $\mathcal{A}$ 和 $\mathcal{B}$ 的取向相同.

为证明反方向的蕴涵关系, 即定理的“仅当”部分, 需要证明恒等矩阵 I 能通过可逆矩阵被连续变换为任意满足 $\det B > 0$ 的矩阵. 换言之, 存在区间 $[a, b]$ 上的连续矩阵函数 $V(t)$, 使得对所有 $t \in [a, b]$, 矩阵 $V(t)$ 可逆, 且有

$$V(a) = I, \quad V(b) = B.$$

我们将这个结论的证明留给读者作为习题. 证法有多种, 其中一种示于下面的习题 6.2 至 6.5. □

习题

6.1. 令 R_α 是“旋转 α 弧度”变换, 则其关于标准基的矩阵是

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}.$$

求 R_α 关于基 $\mathbf{v}_1, \mathbf{v}_2$ 的矩阵, 其中 $\mathbf{v}_1 = \mathbf{e}_2, \mathbf{v}_2 = \mathbf{e}_1$.

6.2. 令 R_α 是旋转矩阵

$$\begin{pmatrix} \cos \alpha & -\sin \alpha \\ \sin \alpha & \cos \alpha \end{pmatrix}.$$

证明: 2×2 恒等矩阵 I_2 可通过可逆矩阵连续变换为 R_α .

6.3. 令 U 是 $n \times n$ 正交矩阵, 并令 $\det U > 0$. 证明: $n \times n$ 恒等矩阵 I_n 可通过可逆矩阵连续变换为 U . **提示:** 利用前一题的结论, 以及将 $\mathbb{R}^n$ 中的旋转表示为一系列平面旋转的乘积 (见第 5 节).

6.4. 令 A 是 $n \times n$ 正定埃尔米特矩阵, $A = A^* > 0$. 证明: $n \times n$ 恒等矩阵 I_n 可通过可逆矩阵连续变换为 A . **提示:** 如果 A 是对角矩阵呢?

6.5. 利用极分解和上述习题 6.3、6.4, 完成定理 6.1 “仅当”部分的证明.

第 7 章 双线性型和二次型

诚然，实二次型（即二次齐次多项式）的研究是本章论题的源动机，不过复二次型 $(A\mathbf{x}, \mathbf{x}), \mathbf{x} \in \mathbb{C}^n, A = A^*$ 也相当有趣。因此，除非另有说明，本章的结论和计算过程适用于实数和复数情形。

为了避免重复书写实质上相同的公式，我们都用复数情形下的记号。特别地，在实数情形下，以 A^* 代替 A^T 。

1. 主要定义

1.1. $\mathbb{R}^n$ 上的双线性型

$\mathbb{R}^n$ 上的双线性型是具有两个自变量 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ 的函数 $L = L(\mathbf{x}, \mathbf{y})$ ，它对每个自变量都是线性的，即

1. $L(\alpha\mathbf{x}_1 + \beta\mathbf{x}_2, \mathbf{y}) = \alpha L(\mathbf{x}_1, \mathbf{y}) + \beta L(\mathbf{x}_2, \mathbf{y})$;
2. $L(\mathbf{x}, \alpha\mathbf{y}_1 + \beta\mathbf{y}_2) = \alpha L(\mathbf{x}, \mathbf{y}_1) + \beta L(\mathbf{x}, \mathbf{y}_2)$.

可以考察取值于任意向量空间的双线性型，不过本书中只考察取值于实数的双线性型。

若 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T$ 及 $\mathbf{y} = (y_1, y_2, \dots, y_n)^T$ ，则双线性型可表示成

$$L(\mathbf{x}, \mathbf{y}) = \sum_{j,k=1}^n a_{j,k} x_k y_j,$$

或写为矩阵形式

$$L(\mathbf{x}, \mathbf{y}) = (A\mathbf{x}, \mathbf{y})$$

其中

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{pmatrix}.$$

矩阵 A 由双线性型 L 唯一确定。

1.2. $\mathbb{R}^n$ 上的二次型

二次型有几种等价的定义。

一种是, $\mathbb{R}^n$ 上的二次型是双线性型 L 的“**对角线**”, 即任意二次型 Q 都定义为 $Q[\mathbf{x}] = L(\mathbf{x}, \mathbf{x}) = (A\mathbf{x}, \mathbf{x})$.

另一种更“代数”的定义是, 二次型是**二次齐次多项式**, 即 $Q[\mathbf{x}]$ 是关于 n 个变量 $x_1, x_2, \dots, x_n$ 的多项式, 且其中只含有 2 次的项. 这意味着其中只含形如 ax_k^2 和 cx_jx_k 的项.

要将二次型 $Q[\mathbf{x}]$ 写为 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$ 的形式, 有很多方法 (事实上有无穷多种方法). 例如, 要将 $\mathbb{R}^2$ 上的二次型 $Q[\mathbf{x}] = x_1^2 + x_2^2 - 4x_1x_2$ 表示为 $(A\mathbf{x}, \mathbf{x})$, 则 A 可为下列矩阵之一

$$\begin{pmatrix} 1 & -4 \\ 0 & 1 \end{pmatrix}, \quad \begin{pmatrix} 1 & 0 \\ -4 & 1 \end{pmatrix}, \quad \begin{pmatrix} 1 & -2 \\ -2 & 1 \end{pmatrix}.$$

事实上, 任意形式如下的矩阵 A 都可以.

$$\begin{pmatrix} 1 & a-4 \\ -a & 1 \end{pmatrix}$$

但若要求矩阵 A 是对称的, 那么 A 就是唯一的:

$\mathbb{R}^n$ 上的任意二次型 $Q[\mathbf{x}]$ 可唯一表示为 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$, 其中 A 是 (实) 对称矩阵.

例如, 对于 $\mathbb{R}^3$ 上的二次型

$$Q[\mathbf{x}] = x_1^2 + 3x_2^2 + 5x_3^2 + 4x_1x_2 - 16x_1x_3 + 7x_2x_3$$

对应的对称矩阵 A 是

$$\begin{pmatrix} 1 & 2 & -8 \\ 2 & 3 & 3.5 \\ -8 & 3.5 & 5 \end{pmatrix}.$$

1.3. $\mathbb{C}^n$ 上的二次型

还可以定义 $\mathbb{C}^n$ (乃至任意复内积空间) 上的**二次型**, 只需取自伴变换 $A = A^*$, 并定义 Q 为 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$. 尽管我们主要举 $\mathbb{R}^n$ 上的例子, 但所有定理对于 $\mathbb{C}^n$ 的情况也是成立的. 做好这个心理准备后, 我们总用 A^* 取代 A^T .

复数情形与实数情形的本质区别仅在于, 如果二次型是实的, 那么对应的矩阵一定是埃尔米特 (自伴) 的, 我们没有选择的余地.

注意到, 如果 $A = A^*$, 那么

$$(A\mathbf{x}, \mathbf{x}) = (\mathbf{x}, A^*\mathbf{x}) = (\mathbf{x}, A\mathbf{x}) = \overline{(A\mathbf{x}, \mathbf{x})},$$

所以 $(A\mathbf{x}, \mathbf{x}) \in \mathbb{R}$.

逆命题也是成立的.

引理 1.1. 令 $(A\mathbf{x}, \mathbf{x})$ 对所有 $\mathbf{x} \in \mathbb{C}^n$ 都是实数. 那么 $A = A^*$.

我们将证明留给读者作为习题, 见下习题 1.4.

引理 1.1 的一种可行证法是利用极化恒等式的如下变种.

引理 1.2. 令 A 是内积空间 X 上的算子.

1. 若 X 是复向量空间, 那么对所有 $\mathbf{x}, \mathbf{y} \in X$,

$$(A\mathbf{x}, \mathbf{y}) = \frac{1}{4} \sum_{\alpha \in \mathbb{C}: \alpha^4=1} \alpha(A(\mathbf{x} + \alpha\mathbf{y}), \mathbf{x} + \alpha\mathbf{y}).$$

2. 若 X 是实向量空间且 $A = A^*$, 那么对所有 $\mathbf{x}, \mathbf{y} \in X$,

$$(A\mathbf{x}, \mathbf{y}) = \frac{1}{4} [(A(\mathbf{x} + \mathbf{y}), \mathbf{x} + \mathbf{y}) - (A(\mathbf{x} - \mathbf{y}), \mathbf{x} - \mathbf{y})].$$

引理 1.2 的证明见第 5 章的习题 6.3.

习题

1.1. 求出 $\mathbb{R}^3$ 上的如下双线性型 L 的矩阵.

$$\begin{aligned} L(\mathbf{x}, \mathbf{y}) = & x_1y_1 + 2x_1y_2 + 14x_1y_3 - 5x_2y_1 + 2x_2y_2 \\ & - 3x_2y_3 + 8x_3y_1 + 19x_3y_2 - 2x_3y_3. \end{aligned}$$

1.2. 定义 $\mathbb{R}^2$ 上的双线性 L 为

$$L(\mathbf{x}, \mathbf{y}) = \det[\mathbf{x}, \mathbf{y}],$$

即, 要计算 $L(\mathbf{x}, \mathbf{y})$, 构造各列为 $\mathbf{x}, \mathbf{y}$ 的 2×2 矩阵并计算其行列式. 求 L 的矩阵.

1.3. 求出 $\mathbb{R}^3$ 上的如下二次型 Q 的矩阵

$$Q[\mathbf{x}] = x_1^2 + 2x_1x_2 - 3x_1x_3 - 9x_2^2 + 6x_2x_3 + 13x_3^2.$$

1.4. 证明上述引理 1.1.

提示: 利用极化恒等式 (见引理 1.2). 或者, 你可以考虑表达式 $(A(\mathbf{x} + z\mathbf{y}), \mathbf{x} + z\mathbf{y})$, 证明如果它对所有 $z \in \mathbb{C}$ 都是实数, 则 $(A\mathbf{x}, \mathbf{y}) = \overline{(\mathbf{y}, A^*\mathbf{x})}$.

2. 二次型的对角化

你之前可能已经与二次型相识了——在你学习平面二次曲线的时候. 你甚至可能还学过 $\mathbb{R}^3$ 上的二次曲面.

我们要给出这些对象的通用分类方法. 假设给定 $\mathbb{R}^n$ 中由 $Q[\mathbf{x}] = 1$ 定义的集合, 其中 Q 是二次型. 如果 Q 具有简单的形式, 比如对应的矩阵是对角的, 也即 $Q[\mathbf{x}] = a_1x_1^2 + a_2x_2^2 + \dots + a_nx_n^2$, 那么我们就很容易将这个集合可视化 (尤其是在 $n = 2, 3$ 的情况). 在更高维的情况中, 即便无法可视化, 也可以借此理解该集合的结构.

因此, 如果给定一个一般的且复杂的二次型, 我们希望尽可能地简化它, 比如将它对角化. 通常的做法, 就是变量代换.

2.1. 正交对角化

设有 $\mathbb{F}^n$ ($\mathbb{F}$ 为 $\mathbb{R}$ 或 $\mathbb{C}$) 上的二次型为 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$. 引入新的坐标 $\mathbf{y} = (y_1, y_2, \dots, y_n)^T \in \mathbb{F}^n$, 且有 $\mathbf{y} = S^{-1}\mathbf{x}$, 其中 S 是可逆的 $n \times n$ 矩阵, 因此 $\mathbf{x} = S\mathbf{y}$.

那么

$$Q[\mathbf{x}] = Q[S\mathbf{y}] = (AS\mathbf{y}, S\mathbf{y}) = (S^*AS\mathbf{y}, \mathbf{y}),$$

因此在新变量 $\mathbf{y}$ 下, 二次型的矩阵是 S^*AS .

因此, 我们想求出可逆矩阵 S , 使得 S^*AS 是对角矩阵. 注意, 这不同于我们之前做过的对角化——将矩阵 A 表示为 $A = SDS^{-1}$, 从而 $D = S^{-1}AS$ 是对角矩阵. 然而, 对于幺正矩阵 U , 有 $U^* = U^{-1}$, 并且我们可以将对称矩阵正交对角化. 因此我们可以对二次型应用我们之前学过的正交对角化.

也就是说, 可以将矩阵 A 表示为 $A = UDU^* = UDU^{-1}$. 回忆一下, D 是对角矩阵, 且对角线上是 A 的特征值, 而 U 是由特征向量构成的矩阵 (我们需要选取由特征向量构成的正交基). 于是 $D = U^*AU$, 因此在变量 $\mathbf{y} = U^{-1}\mathbf{x}$ 下, 二次型具有对角矩阵.

现在来分析正交对角化的几何含义. 幺正矩阵 U 的各列 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 形成 $\mathbb{F}^n$ 的规范正交基, 记其为 $\mathcal{B}$. 从该基到标准基的坐标变换矩阵 $[I]_{\mathcal{S}, \mathcal{B}}$ 恰为 U . 我们知道 $\mathbf{y} = (y_1, y_2, \dots, y_n)^T = U^{-1}\mathbf{x}$, 因此各坐标 $y_1, y_2, \dots, y_n$ 可解释成向量 $\mathbf{x}$ 在新基 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 下的坐标.

因此, 正交对角化使我们得以很好地将集合 $Q[\mathbf{x}] = 1$ (或与之类似的集合) 可视化——只要能将对角化的二次型可视化即可.

例. 考虑双变量二次型 (即 $\mathbb{R}^2$ 上的二次型) $Q(x, y) = 2x^2 + 2y^2 + 2xy$. 现在描述满足 $Q(x, y) = 1$ 的点 $(x, y)^T \in \mathbb{R}^2$ 构成的集合.

Q 的矩阵是

$$A = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}.$$

正交对角化该矩阵, 可将其表示为

$$A = U \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} U^*, \quad \text{其中} \quad U = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & -1 \\ 1 & 1 \end{pmatrix},$$

或等价地写为

$$U^*AU = \begin{pmatrix} 3 & 0 \\ 0 & 1 \end{pmatrix} =: D.$$

集合 $\{\mathbf{y} : (D\mathbf{y}, \mathbf{y}) = 1\}$ 是椭圆, 半长轴为 $1/\sqrt{3}$ 和 1. 因此集合 $\{\mathbf{x} \in \mathbb{R}^2 : (A\mathbf{x}, \mathbf{x}) = 1\}$ 是相同的椭圆, 只不过是在基 $(\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})^T, (-\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}})^T$ 下; 或等价地说, 相同的椭圆, 只不过旋转了 $\pi/4$.

2.2. 非正交对角化

正交对角化涉及计算特征值和特征向量, 因此, n 很大时, 不借助计算机可能难以完成. 另一方面, 非正交对角化, 即求出可逆的 S (不要求 $S^{-1} = S^*$) 使得 $D = S^*AS$ 是对角矩阵, 要更容易计算, 并且只通过代数运算 (加减乘除) 就能完成.

下面我们呈现两种最常用的非正交对角化方法.

2.2.1. 通过配方法对角化

第一种方法基于配方. 我们将实二次型 ($\mathbb{R}^n$ 上的二次型) 作为示例. 经过简单的修改, 这一方法可用于复数情形, 不过此处不做讨论. 如有必要, 感兴趣的读者可以自行修改.

再次考虑双变量二次型 $Q[\mathbf{x}] = 2x_1^2 + 2x_1x_2 + 2x_2^2$ (和上面例子中的二次型是一样的, 只不过变量记作 x_1, x_2 而不是 x, y). 由于

$$2\left(x_1 + \frac{1}{2}x_2\right)^2 = 2\left(x_1^2 + 2x_1\frac{1}{2}x_2 + \frac{1}{4}x_2^2\right) = 2x_1^2 + 2x_1x_2 + \frac{1}{2}x_2^2$$

(注意, 前两项与 Q 的前两项相同), 所以我们有

$$2x_1^2 + 2x_1x_2 + 2x_2^2 = 2\left(x_1 + \frac{1}{2}x_2\right)^2 + \frac{3}{2}x_2^2 = 2y_1^2 + \frac{3}{2}y_2^2,$$

其中 $y_1 = x_1 + \frac{1}{2}x_2$ 且 $y_2 = x_2$.

同样的方法可用于含超过 2 个变量的二次型. 例如, 考虑 $\mathbb{R}^3$ 上的二次型

$$Q[\mathbf{x}] = x_1^2 - 6x_1x_2 + 4x_1x_3 - 6x_2x_3 + 8x_2^2 - 3x_3^2.$$

考虑所有包含第一个变量 x_1 的项 (在本例中是前三项), 我们选出一个完全平方 (或其倍数) 使其恰好包含这几项 (可能多出几项).

由于

$$(x_1 - 3x_2 + 2x_3)^2 = x_1^2 - 6x_1x_2 + 4x_1x_3 - 12x_2x_3 + 9x_2^2 + 4x_3^2$$

所以可重写该二次型为

$$(x_1 - 3x_2 + 2x_3)^2 - x_2^2 + 6x_2x_3 - 7x_3^2.$$

注意, 表达式 $-x_2^2 + 6x_2x_3 - 7x_3^2$ 只包含变量 x_2 和 x_3 . 因为

$$-(x_2 - 3x_3)^2 = -(x_2^2 - 6x_2x_3 + 9x_3^2) = -x_2^2 + 6x_2x_3 - 9x_3^2$$

所以有

$$-x_2^2 + 6x_2x_3 - 7x_3^2 = -(x_2 - 3x_3)^2 + 2x_3^2.$$

于是二次型 Q 可写成

$$Q[\mathbf{x}] = (x_1 - 3x_2 + 2x_3)^2 - (x_2 - 3x_3)^2 + 2x_3^2 = y_1^2 - y_2^2 + 2y_3^2$$

其中

$$y_1 = x_1 - 3x_2 + 2x_3, \quad y_2 = x_2 - 3x_3, \quad y_3 = x_3.$$

最后, 还要解决一个问题——细心的读者可能发现: 当表达式中有两个变量的乘积而没有对应的平方怎么办? 比如, 如何对角化 x_1x_2 ? 答案可由下述恒等式直接得出:

$$(2.1) \quad 4x_1x_2 = (x_1 + x_2)^2 - (x_1 - x_2)^2,$$

因为由此可将二次型表示为

$$Q[\mathbf{x}] = y_1^2 - y_2^2, \quad y_1 = (x_1 + x_2)/2, \quad y_2 = (x_1 - x_2)/2.$$

2.2.2. 用行/列变换对角化

还有一种对二次型做非正交对角化的方法. 它的思路是对二次型的矩阵 A 做行变换. 与行化简 (高斯-若当消元法) 的区别在于, 在每次行变换后, 我们还需要做相同的列变换, 因为我们是要让 S^*AS 成为对角矩阵.

我们用一个例子来解释. 假设我们想对角化的二次型具有矩阵

$$A = \begin{pmatrix} 1 & -1 & 3 \\ -1 & 2 & 1 \\ 3 & 1 & 1 \end{pmatrix}.$$

我们向矩阵 A 附上恒等矩阵, 并对增广矩阵 $(A|I)$ 做行/列变换. 在每次行变换后, 我们都需要对矩阵 A 做相同的列变换¹. 由此可得

$$\begin{aligned} & \left(\begin{array}{ccc|ccc} 1 & -1 & 3 & 1 & 0 & 0 \\ -1 & 2 & 1 & 0 & 1 & 0 \\ 3 & 1 & 1 & 0 & 0 & 1 \end{array} \right) + R_1 \sim \left(\begin{array}{ccc|ccc} 1 & -1 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 1 & 1 & 0 \\ 3 & 1 & 1 & 0 & 0 & 1 \end{array} \right) \sim \\ & \left(\begin{array}{ccc|ccc} 1 & 0 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 1 & 1 & 0 \\ 3 & 4 & 1 & 0 & 0 & 1 \end{array} \right) - 3R_1 \sim \left(\begin{array}{ccc|ccc} 1 & 0 & 3 & 1 & 0 & 0 \\ 0 & 1 & 4 & 1 & 1 & 0 \\ 0 & 4 & -8 & -3 & 0 & 1 \end{array} \right) \sim \\ & \left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 4 & 1 & 1 & 0 \\ 0 & 4 & -8 & -3 & 0 & 1 \end{array} \right) - 4R_2 \sim \left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 4 & 1 & 1 & 0 \\ 0 & 0 & -24 & -7 & -4 & 1 \end{array} \right) \sim \\ & \left(\begin{array}{ccc|ccc} 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & -24 & -7 & -4 & 1 \end{array} \right). \end{aligned}$$

注意, 列变换只对扩展后矩阵的左侧进行.

上式左边是对角矩阵 D , 右侧是矩阵 S^* , 因此 $D = S^*AS$,

$$\begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -24 \end{pmatrix} = \begin{pmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ -7 & -4 & 1 \end{pmatrix} \begin{pmatrix} 1 & -1 & 3 \\ -1 & 2 & 1 \\ 3 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & -7 \\ 0 & 1 & -4 \\ 0 & 0 & 1 \end{pmatrix}.$$

我们解释一下为何此种方法可行. 行变换就是左乘初等矩阵, 而对应的列变换就是右乘初等矩阵的转置. 因此, 做行变换 $E_1, E_2, \dots, E_N$ 与相同的列变换后, 我们将矩阵 A 变换为

$$(2.2) \quad E_N \dots E_2 E_1 A E_1^* E_2^* \dots E_N^* = E A E^*.$$

至于右侧的恒等矩阵, 我们只对它做了行变换, 所以它被变换成

$$E_N \dots E_2 E_1 I = EI = E.$$

这样一来, 如果记 $E^* = S$, 则 S^*AS 就是对角矩阵, 而 $E = S^*$ 是扩展的矩阵变换后的右半部分.

在上面的例子中, 其实我们很幸运——因为我们不需要交换两行. 而做这个变换有些技巧性. 要猜出如何做行变换才能实现目的可能有些难度, 但一旦知道了步骤, 你就会发现其实很简单. 例如, 考虑一个二次型, 其矩阵为

$$A = \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

要通过行列变换将其对角化, 最简单的思路是交换 1、2 两行. 但这样就还要做相同的列变换, 即交换 1、2 两列, 最后又得到原先的矩阵.

¹对复埃尔米特矩阵, 在每次行变换后, 我们做的是对应的列变换的共轭, 见下注 2.1.

所以我们需要一些复杂点的方法. 比如, 恒等式 (2.1) 就可用于对角化这个二次型. 然而, 有个更为简单的方法也是可行的: 用行变换使对角线上出现非零项! 比如, 如果要想 $a_{1,1}$ 非零, 就可用以下这一系列行变换 (以及对应的列变换):

$$\begin{aligned} \left(\begin{array}{cc|cc} 0 & 1 & 1 & 0 \\ 1 & 0 & 0 & 1 \end{array} \right) + \frac{1}{2}R_2 &\sim \left(\begin{array}{cc|cc} 1/2 & 1 & 1 & 1/2 \\ 1 & 0 & 0 & 1 \end{array} \right) \sim \\ \left(\begin{array}{cc|cc} 1 & 1 & 1 & 1/2 \\ 1 & 0 & 0 & 1 \end{array} \right) - R_1 &\sim \left(\begin{array}{cc|cc} 1 & 1 & 1 & 1/2 \\ 0 & -1 & -1 & 1/2 \end{array} \right) \sim \\ \left(\begin{array}{cc|cc} 1 & 0 & 1 & 1/2 \\ 0 & -1 & -1 & 1/2 \end{array} \right). \end{aligned}$$

注. 非正交对角化给出了集合 $Q[\mathbf{x}] = 1$ 在非正交基下的简单描述. 比起正交对角化给出的表达式, 此种描述更难以可视化. 然而, 如果我们不在意细节, 比如只需要确定这个集合是个椭球 (或者双曲面之类的), 那么非正交对角化更容易获得答案.

注 2.1. 对于有复数项的二次型 (即对 $(A\mathbf{x}, \mathbf{x}), A = A^*$), 非正交对角化与在实数情形下的步骤相同, 唯一的区别在于, 对应的“列变换”的系数取复共轭.

这是因为, 如果行变换由左乘初等矩阵 E_k 给出, 那么对应的列变换由右乘 E_k^* 给出, 见 (2.2).

注意, 公式 (2.2) 适用于实数和复数情形. 在实数情形下, 我们可以用 E_k^T 替代 E_k^* , 不过这里用到埃尔米特伴随, 以使公式对两种情形保持一致.

习题

2.1. 对角化具有下述矩阵的二次型.

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 2 & 3 & 2 \\ 1 & 2 & 1 \end{pmatrix}.$$

用两种方法: 配方法和行变换法. 你更喜欢哪一种? 你能看出矩阵 A 是否正定吗?

2.2. 对矩阵

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

正交对角化其对应的二次型, 即求出对角矩阵 D 和幺正矩阵 U , 使得 $D = U^*AU$.

3. 西尔维斯特惯性定律

如前面所讨论的, 将二次型对角化的方式有很多种, 并且要注意获得的对角矩阵不唯一. 例如, 如果有对角矩阵

$$D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\},$$

那么总可以取对角矩阵

$$S = \text{diag}\{s_1, s_2, \dots, s_n\}, \quad s_k \in \mathbb{R}, \quad s_k \neq 0$$

而将 D 变换为

$$S^*DS = \text{diag}\{s_1^2\lambda_1, s_2^2\lambda_2, \dots, s_n^2\lambda_n\}.$$

这一变换改变了 D 的对角项, 但它并不改变对角项的**符号**, 而且后者总是成立的!

这也就是著名的西尔维斯特惯性定律:

对埃尔米特矩阵 A (即对二次型 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$) 和其任一对角化 $D = S^*AS$, D 的对角项中正数 (或负数、或零) 的个数仅取决于 A , 而与对角化的过程无关.

这里, 我们仍假设 S 是可逆矩阵, D 是对角矩阵.

西尔维斯特惯性定律的证明思路, 是将对角化 $D = S^*AS$ 的对角项中正数 (或负数、或零) 的个数仅用 A 表达, 而不牵涉 S 和 D .

我们需要下面这个定义.

定义. 给定 $n \times n$ 埃尔米特矩阵 $A = A^*$ ($\mathbb{F}^n$ 上的二次型 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$), 称子空间 $E \subset \mathbb{F}^n$ 是**正性的** (相应地, **负性的**或**中性的**), 若

$$(A\mathbf{x}, \mathbf{x}) > 0 \quad (\text{相应地}, (A\mathbf{x}, \mathbf{x}) < 0, \text{或} (A\mathbf{x}, \mathbf{x}) = 0)$$

对于所有 $\mathbf{x} \in E, \mathbf{x} \neq \mathbf{0}$ 成立.

有时, 为了凸显 A 的重要性, 也说成 A -正性的 (A -负性的、 A -中性的).

定理 3.1. 令 A 为 $n \times n$ 埃尔米特矩阵, 并令 $D = S^*AS$ 是其通过可逆矩阵 S 的对角化. 那么 D 的对角项中, 正数 (相应地, 负数) 的数量等于 A -正性子空间 (相应地, A -负性子空间) 的最大维数.

上述定理指出, 如果 r_+ 是 D 的正对角项的个数, 那么存在维数为 r_+ 的 A -正性子空间 E , 但不存在满足 $\dim E > r_+$ 的正性子空间 E .

我们需要下述引理——可视为上述定理的特例.

引理 3.2. 令 D 是对角矩阵 $D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$. 那么 D 的对角项中, 正数 (相应地, 负数) 的数量等于 D -正性子空间 (相应地, D -负性子空间) 的最大维数.

证明: 通过重排 $\mathbb{F}^n$ 的基 (改改序号), 总可以假设 D 的正对角项是前 r_+ 个对角项, 而不失一般性.

考虑由前 r_+ 个坐标向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{r_+}$ 张成的子空间 E_+ . 显然 E_+ 是 D -正性子空间, 且 $\dim E_+ = r_+$.

下面证明, 任意其余 D -正性子空间 E 都满足 $\dim E \leq r_+$. 考虑正交投影 $P = P_{E_+}$

$$P\mathbf{x} = (x_1, x_2, \dots, x_{r_+}, 0, \dots, 0)^T, \quad \mathbf{x} = (x_1, x_2, \dots, x_n)^T.$$

对 D -正性子空间 E , 定义变换 $T: E \rightarrow E_+$ 为

$$T\mathbf{x} = P\mathbf{x}, \quad \forall \mathbf{x} \in E.$$

换言之, T 是对投影 P 的**限制**: P 定义在整个空间上, 通过将其定义域和目标空间分别限制于 E 和 E_+ , 得到从 E 到 E_+ 的变换, 并用不同的字母将其与 P 区分开.

注意, $\text{Ker } T = \{\mathbf{0}\}$. 的确, 假设对 $\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in E$ 我们有 $T\mathbf{x} = P\mathbf{x} = \mathbf{0}$. 于是由 P 的定义得

$$x_1 = x_2 = \dots = x_{r_+} = 0,$$

因此

$$(D\mathbf{x}, \mathbf{x}) = \sum_{k=r_++1}^n \lambda_k x_k^2 \leq 0 \quad (\lambda_k \leq 0, k > r_+).$$

但是 $\mathbf{x}$ 属于 D -正性子空间 E , 所以不等式 $(D\mathbf{x}, \mathbf{x}) \leq 0$ 只对 $\mathbf{x} = \mathbf{0}$ 成立.

现在应用秩定理 (第 2 章定理 7.1). 首先, $\text{rank } T = \dim \text{Ran } T \leq \dim E_+ = r_+$, 因为 $\text{Ran } T \subset E_+$. 由秩定理, $\dim \text{Ker } T + \text{rank } T = \dim E$. 但我们刚刚证明了 $\text{Ker } T = \{\mathbf{0}\}$, 即 $\dim \text{Ker } T = 0$, 因此

$$\dim E = \text{rank } T \leq \dim E_+ = r_+.$$

为证明关于负对角项的相应结论, 只需将上述论证用于矩阵 $-D$.

□

定理 3.1 的证明: 令 $D = S^*AS$ 是 A 的对角化. 因为

$$(D\mathbf{x}, \mathbf{x}) = (S^*AS\mathbf{x}, \mathbf{x}) = (AS\mathbf{x}, S\mathbf{x})$$

所以对任意 D -正性子空间 E , 子空间 SE 都是 A -正性子空间. 该等式还表明, 对任意 A -正性子空间 F , 子空间 $S^{-1}F$ 都是 D -正性子空间.

因为 S 和 S^{-1} 是可逆变换, 所以 $\dim E = \dim SE$ 且 $\dim F = \dim S^{-1}F$. 所以, 对任意 D -正性子空间 E , 可求出相同维数的 A -正性子空间 (即 SE), 反之亦然: 对任意 A -正性子空间 F , 可求出相同维数的 D -正性子空间 (即 $S^{-1}F$). 因此, A -正性子空间和 D -正性子空间的极大可能维数相同, 定理得证.

对角项为负的情形可类似处理, 留给读者作为习题. $\square$

4. 正定型、特征值的极小极大刻画和西尔维斯特正定性判据

定义. 称二次型 Q 是

- 正定的, 若 $Q[\mathbf{x}] > 0$ 对所有 $\mathbf{x} \neq \mathbf{0}$ 成立.
- 正半定的, 若 $Q[\mathbf{x}] \geq 0$ 对所有 $\mathbf{x}$ 成立.
- 负定的, 若 $Q[\mathbf{x}] < 0$ 对所有 $\mathbf{x} \neq \mathbf{0}$ 成立.
- 负半定的, 若 $Q[\mathbf{x}] \leq 0$ 对所有 $\mathbf{x}$ 成立.
- 不定的, 若它取值可正可负, 即若存在向量 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 使得 $Q[\mathbf{x}_1] > 0$ 及 $Q[\mathbf{x}_2] < 0$.

定义. 埃尔米特矩阵 $A = A^*$ 称为正定的 (负定的, 及其他), 若对应的二次型 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$ 是正定的 (负定的, 及其他).

定理 4.1. 令 $A = A^*$. 那么

1. A 是正定的, 当且仅当 A 的所有特征值都是正的.
2. A 是正半定的, 当且仅当 A 的所有特征值都是非负的.
3. A 是负定的, 当且仅当 A 的所有特征值都是负的.
4. A 是负半定的, 当且仅当 A 的所有特征值都是非正的.
5. A 是不定的, 当且仅当 A 的特征值有正有负.

证明: 由正交分解容易得证. 的确如此: A 关于一个规范正交基的矩阵是对角的, 而对于对角矩阵, 该定理是平凡的. $\square$

注. 注意, 要判断矩阵 (或二次型) 是正定的 (负定的, 及其他), 不需要计算特征值. 根据西尔维斯特惯性定律, 只要进行对角化 (不一定是正交对角化) $D = S^*AS$, 并观察 D 的对角项即可.

4.1. 西尔维斯特正定性判据

容易看出 2×2 矩阵

$$A = \begin{pmatrix} a & b \\ \bar{b} & c \end{pmatrix}$$

是正定的, 当且仅当

$$(4.1) \quad a > 0 \quad \text{且} \quad \det A = ac - |b|^2 > 0$$

的确如此: 若 $a > 0$ 且 $\det A = ac - |b|^2 > 0$, 那么 $c > 0$, 所以 $\text{trace } A = a + c > 0$. 所以我们知道如果 λ_1, λ_2 是 A 的特征值, 那么 $\lambda_1 \lambda_2 > 0$ ($\det A > 0$), 并且 $\lambda_1 + \lambda_2 = \text{trace } A > 0$. 而这只有两个特征值都为正时才成立. 所以我们证明了 (4.1) 能推出 A 是正定的. 反方向的蕴涵关系很简单, 留给读者作为习题.

这个结论可以推广到 $n \times n$ 矩阵. 也就是说, 对于矩阵 A

$$A = \begin{pmatrix} a_{1,1} & a_{1,2} & \cdots & a_{1,n} \\ a_{2,1} & a_{2,2} & \cdots & a_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & a_{n,2} & \cdots & a_{n,n} \end{pmatrix}$$

考虑其所有的**顺序主子阵**

$$A_1 = (a_{1,1}), A_2 = \begin{pmatrix} a_{1,1} & a_{1,2} \\ a_{2,1} & a_{2,2} \end{pmatrix}, A_3 = \begin{pmatrix} a_{1,1} & a_{1,2} & a_{1,3} \\ a_{2,1} & a_{2,2} & a_{2,3} \\ a_{3,1} & a_{3,2} & a_{3,3} \end{pmatrix}, \dots, A_n = A$$

定理 4.2 (西尔维斯特正定性判据). 矩阵 $A = A^*$ 是正定的, 当且仅当

$$\det A_k > 0, \quad \text{对于所有 } k = 1, 2, \dots, n \text{ 成立.}$$

首先我们注意到, 如果 $A > 0$ 那么 $A_k > 0$ (你能解释为何如此吗?). 这样一来, 因为正定矩阵的所有特征值都是正的 (见定理 4.1), 所以 $\det A_k > 0$ 对所有 k 成立.

通过分析利用行列变换的二次型对角化 (在 2.2 节中描述), 可以证明如果 $\det A_k > 0$ 对所有 k 成立, 那么 A 的所有特征值均为正. 关键在于, 观察到如果按照自然的顺序做行/列变换 (即首先将第一行/列从其他所有行/列中减掉, 然后将第二行/列从第 3, 4, $\dots$, n 行/列中减掉, 以此类推), 并且不做行交换, 那么在此过程中我们顺带完成了对二次型 A_k 的对角化. 也即, 在减掉第一、二行/列后, 我们就对角化了 A_2 ; 减掉第三行/列后, 我们就对角化了 A_3 , 以此类推.

因为我们只做行替换，所以行列式不变。此外，由于我们未做行交换，并且以正确的顺序做行变换，所以各 A_k 的行列式也保持不变。因此， $\det A_k > 0$ 这一条件确保了变换后每个对角项都是正的。

当然，我们需要保证可以只用行替换且按正确顺序做变换，即我们不会碰到任何使该流程无法持续的情况。如果我们分析上述算法，就会发现此类情况只有一种：在某一步中主元位置的项是零。换言之，就是在减掉前 k 行和前 k 列并将 A_k 对角化后，第 $k+1$ 行第 $k+1$ 列的项是零。这种情况不可能发生，证明留给读者作为习题。 $\square$

上面概述的证明思路非常简单。不过，下面我们要更细致地呈现另一种证明，这种证明常出现在更为进阶的教材中。我个人更为喜欢这种证明，因为它展示了一些重要的关系。

我们需要对埃尔米特矩阵特征值的如下刻画。

4.2. 特征值的极小极大刻画

首先，引入一个概念：子空间 $E \subset X$ 的**余维数**是其正交补的维数， $\text{codim } E = \dim(E^\perp)$ 。因为对子空间 $E \subset X$ 及 $\dim X = n$ ，我们有 $\dim E + \dim E^\perp = n$ ，所以 $\text{codim } E = \dim X - \dim E$ 。

回忆一下，平凡子空间 $\{0\}$ 的维数是零，因此整个向量空间 X 的余维数是 0。

定理 4.3 (特征值的极小极大刻画). 令 $A = A^*$ 是 $n \times n$ 矩阵，并令 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ 是其特征值，按降序排列。那么

$$\lambda_k = \max_{\substack{E: \\ \dim E = k}} \min_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \min_{\substack{F: \\ \text{codim } F = k-1}} \max_{\substack{\mathbf{x} \in F \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}).$$

我们详细解释一下有 $\max \min$ 和 $\min \max$ 的表达式是什么含义。要计算前者，需考虑所有维数为 k 的子空间 E 。对每个这样的子空间 E ，考虑范数为 1 的所有 $\mathbf{x} \in E$ 构成的集合，并对所有这样的 $\mathbf{x}$ 求出 $(A\mathbf{x}, \mathbf{x})$ 的最小值。这样对每个子空间，我们都能得到一个数，然后我们需要选出一个子空间 E 使得这个数最大。这就是 $\max \min$ 。

$\min \max$ 的定义是类似的。

注. 心思缜密的读者可能留意到一个问题：为什么最大值和最小值存在？众所周知，最大值和最小值不存在这种糟糕情况比比皆是：例如，函数 $f(x) = x$ 在开区间 $(0, 1)$ 上就既无最大值也无最小值。

然而, 在此处这种情形下, 最大值和最小值的确存在. 关于 $(A\mathbf{x}, \mathbf{x})$ 取得最大值和最小值, 有两种可行的解释. 第一种需要熟悉分析学的基本概念: E 中的单位球面, 即集合 $\{\mathbf{x} \in E : \|\mathbf{x}\| = 1\}$ 是紧的, 并且连续函数 (这里是 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x})$) 在紧集上取得最大值和最小值.

另一种解释是, 注意到函数 $Q[\mathbf{x}] = (A\mathbf{x}, \mathbf{x}), \mathbf{x} \in E$ 是 E 上的二次型. 不难关于 E 的规范正交基计算该二次型的矩阵, 不过要注意这个矩阵并不是 A , 而是 $k \times k$ 矩阵, 其中 $k = \dim E$.

容易看出, 二次型在单位球面上的最大值和最小值分别是其矩阵的最大和最小特征值.

至于在所有子空间上取最值, 下面我们将要证明这样的最大值和最小值都是存在的.

定理 4.3 的证明: 首先, 通过选取一个合适的规范正交基, 可假设矩阵 A 是对角的 ($A = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$), 而不失一般性.

选取子空间 E 和 F , $\dim E = k$, $\text{codim } F = k - 1$, 即 $\dim F = n - k + 1$. 因为 $\dim E + \dim F > n$, 所以存在非零向量 $\mathbf{x}_0 \in E \cap F$. 将其规范化, 可假设 $\|\mathbf{x}_0\| = 1$, 而不失一般性. 我们总可将特征值按降序排列, 因此假设 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$.

因为 $\mathbf{x}_0$ 既属于 E 又属于 F , 因此

$$\min_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) \leq (A\mathbf{x}_0, \mathbf{x}_0) \leq \max_{\substack{\mathbf{x} \in F \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}).$$

我们并未作出子空间 E 和 F 的维数之外的假设, 所以上述不等式

$$(4.2) \quad \min_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) \leq \max_{\substack{\mathbf{x} \in F \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}).$$

对维数适当的 E 和 F 都是成立的.

定义

$$E_0 := \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k\}, \quad F_0 := \text{span}\{\mathbf{e}_k, \mathbf{e}_{k+1}, \mathbf{e}_{k+2}, \dots, \mathbf{e}_n\}.$$

由于对自伴矩阵 B , $(B\mathbf{x}, \mathbf{x})$ 在单位球面 $\{\mathbf{x} : \|\mathbf{x}\| = 1\}$ 的最大值和最小值分别是最大和最小的特征值 (容易在对角矩阵上检验), 所以

$$\min_{\substack{\mathbf{x} \in E_0 \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \max_{\substack{\mathbf{x} \in F_0 \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \lambda_k.$$

由 (4.2), 对子空间 E ($\dim E = k$) 有

$$\min_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) \leq \max_{\substack{\mathbf{x} \in F_0 \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \lambda_k.$$

类似地, 对任意余维数是 $k-1$ 的子空间 F 有

$$\max_{\substack{\mathbf{x} \in F \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) \geq \max_{\substack{\mathbf{x} \in E_0 \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \lambda_k.$$

而在子空间 E_0 和 F_0 上, 分别可取得最大和最小值 λ_k , 因此 $\min \max = \max \min = \lambda_k$. $\square$

推论 4.4 (特征值交错排列). 令 $A = A^* = \{a_{j,k}\}_{j,k=1}^n$ 是自伴矩阵, 并令 $\tilde{A} = \{a_{j,k}\}_{j,k=1}^{n-1}$ 是其大小为 $(n-1) \times (n-1)$ 的子矩阵. 令 $\lambda_1, \lambda_2, \dots, \lambda_n$ 和 $\mu_1, \mu_2, \dots, \mu_{n-1}$ 分别是 A 和 $\tilde{A}$ 的特征值, 按降序排列. 那么

$$\lambda_1 \geq \mu_1 \geq \lambda_2 \geq \mu_2 \geq \dots \geq \lambda_{n-1} \geq \mu_{n-1} \geq \lambda_n.$$

也即

$$\lambda_k \geq \mu_k \geq \lambda_{k+1}, \quad k = 1, 2, \dots, n-1$$

证明: 令 $\tilde{X} \subset \mathbb{F}^n$ 是由前 $n-1$ 个基向量张成的子空间, $\tilde{X} = \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{n-1}\}$. 因为 $(\tilde{A}\mathbf{x}, \mathbf{x}) = (A\mathbf{x}, \mathbf{x})$ 对所有 $\mathbf{x} \in \tilde{X}$ 成立, 所以定理 4.3 蕴涵

$$\mu_k = \max_{\substack{E \subset \tilde{X} \\ \dim E = k}} \min_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}).$$

为得到 λ_k , 我们需要在 $\mathbb{F}^n$ 的所有子空间 E ($\dim E = k$) 所构成的集合上取最大值, 即在一个更大的集合上 ($\tilde{X}$ 的任意子空间也是 $\mathbb{F}^n$ 的子空间) 取最大值. 因此

$$\mu_k \leq \lambda_k$$

(如果将集合扩大, 最大值只会扩大)

另一方面, 任意余维数 $k-1$ 的子空间 $E \subset \tilde{X}$ (这里的余维数是就 $\tilde{X}$ 而言的) 的维数是 $n-1-(k-1) = n-k$, 所以其就 $\mathbb{F}^n$ 而言的余维数是 k . 因此

$$\mu_k \geq \min_{\substack{E \subset \tilde{X} \\ \dim E = n-k}} \max_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \min_{\substack{E \subset \mathbb{F}^n \\ \dim E = n-k}} \max_{\substack{\mathbf{x} \in E \\ \|\mathbf{x}\|=1}} (A\mathbf{x}, \mathbf{x}) = \lambda_{k+1}.$$

(如果将集合扩大, 最小值只会更小) $\square$

定理 4.2 的证明: 若 $A > 0$, 那么 $A_k > 0$ 对 $k = 1, 2, \dots, n$ 成立 (你能解释原因吗?). 因为正定矩阵的所有特征值都是正的 (见定理 4.1), 所以 $\det A_k > 0$ 对 $k = 1, 2, \dots, n$ 成立.

现在证明另一方向的蕴涵关系. 令 $\det A_k > 0$ 对所有 k 成立. 我们将通过对 k 用归纳法来证明所有 A_k (进而, $A = A_n$) 都是正定的.

显然 A_1 是正定的 (其为 1×1 矩阵, 所以 $A_1 = \det A_1$). 假设 $A_{k-1} > 0$ (且有 $\det A_k > 0$), 现要证明 A_k 是正定的. 令 $\lambda_1, \lambda_2, \dots, \lambda_k$ 和 $\mu_1, \mu_2, \dots, \mu_{k-1}$ 分别是 A_k 和 A_{k-1} 的特征值. 由推论 4.4, 有

$$\lambda_j \geq \mu_j > 0 \quad \text{对 } j = 1, 2, \dots, k-1 \text{ 成立.}$$

因为 $\det A_k = \lambda_1 \lambda_2 \dots \lambda_{k-1} \lambda_k > 0$, 所以最后一个特征值 λ_k 必为正. 因此, 由于矩阵 A_k 的所有特征值都是正的, 所以其为正定的. $\square$

4.3. 一些注记

首先, 注意到西尔维斯特正定性判据不能推广到 $n \geq 3$ 的正半定矩阵, 意即对 $n \times n$ ($n \geq 3$) 矩阵, 条件 $\det A_k \geq 0$ 不能推出 A 是正半定的, 见下习题 4.6.

不过, 对 2×2 矩阵, 条件 $\det A_k \geq 0$ 能推出 A 是正半定的, 见下习题 4.3. 这有时会导致对 $n \times n$ 矩阵的错误结论.

最后, 我们要稍微提一下负定矩阵的判据. 学生常会误认为条件 $\det A_k < 0$ 蕴涵 A 是负定的. 但这是错的!

要检验矩阵 A 是否负定, 只需检验矩阵 $-A$ 是否正定. 对 $-A$ 应用西尔维斯特正定性判据, 可得 A 负定当且仅当 $(-1)^k \det A_k > 0$ 对所有 $k = 1, 2, \dots, n$ 成立.

习题

4.1. 用西尔维斯特正定性判据来检验一下矩阵是否正定.

$$A = \begin{pmatrix} 4 & 2 & 1 \\ 2 & 3 & -1 \\ 1 & -1 & 2 \end{pmatrix}, \quad B = \begin{pmatrix} 3 & -1 & 2 \\ -1 & 4 & -2 \\ 2 & -2 & 2 \end{pmatrix}$$

矩阵 $-A, A^3$ 及 $A^{-1}, A + B^{-1}, A + B, A - B$ 是正定的吗?

4.2. 判断正误:

- a) 如果 A 正定, 那么 A^5 正定;
- b) 如果 A 负定, 那么 A^8 负定;
- c) 如果 A 负定, 那么 A^{12} 正定;
- d) 如果 A 正定且 B 负半定, 那么 $A - B$ 正定;
- e) 如果 A 不定, 且 B 正定, 那么 $A + B$ 不定.

4.3. 令 A 是 2×2 埃尔米特矩阵, 满足 $a_{1,1} > 0, \det A \geq 0$. 证明: A 是正半定的.

4.4. 求实对称 $n \times n$ 矩阵, 满足 $\det A_k \geq 0$ 对所有 $k = 1, 2, \dots, n$ 成立, 但是矩阵 A 不是正半定的. 试找出 n 最小的反例.

- 4.5. 令 A 是 $n \times n$ 埃尔米特矩阵, 满足 $\det A_k > 0$ 对所有 $k = 1, 2, \dots, n-1$ 成立, 且 $\det A \geq 0$. 证明: A 是正半定的.
- 4.6. 求出 3×3 实对称矩阵 A , 满足 $a_{1,1} > 0$, $\det A_k \geq 0$ 对 $k = 2, 3$ 成立, 但 A 不是正半定的.

5. 正定型和内积

令 V 是内积空间, 并令 $\mathcal{B} = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$ 是 V 的基 (不一定是正交的). 令矩阵 $G = \{g_{j,k}\}_{j,k=1}^n$ 定义为

$$g_{j,k} = (\mathbf{v}_k, \mathbf{v}_j).$$

若 $\mathbf{x} = \sum_k x_k \mathbf{v}_k$ 及 $\mathbf{y} = \sum_k y_k \mathbf{v}_k$, 则

$$\begin{aligned} (\mathbf{x}, \mathbf{y}) &= \left(\sum_k x_k \mathbf{v}_k, \sum_j y_j \mathbf{v}_j \right) = \sum_{k,j=1}^n x_k \bar{y}_j (\mathbf{v}_k, \mathbf{v}_j) \\ &= \sum_{j=1}^n \sum_{k=1}^n g_{j,k} x_k \bar{y}_j = (G[\mathbf{x}]_{\mathcal{B}}, [\mathbf{y}]_{\mathcal{B}})_{\mathbb{C}^n}, \end{aligned}$$

其中 $(\cdot, \cdot)_{\mathbb{C}^n}$ 表示 $\mathbb{C}^n$ 上的标准内积. 容易看出, G 是正定矩阵 (为什么?).

所以, 当处理在内积空间的任意基 (不一定是正交基) 下的坐标时, (关于坐标的) 内积不再如 $\mathbb{C}^n$ 上的标准内积那样计算, 而是借助正定矩阵 G 来计算 (如上所述).

注意, 这种 G -内积和 $\mathbb{C}^n$ 上的标准内积相同当且仅当 $G = I$, 而这又等价于基 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是规范正交的.

反之, 给定正定矩阵 G , 可定义 $\mathbb{C}^n$ 上的非标准内积 (G -内积) 为

$$(\mathbf{x}, \mathbf{y})_G := (G\mathbf{x}, \mathbf{y})_{\mathbb{C}^n}, \quad \mathbf{x}, \mathbf{y} \in \mathbb{C}^n.$$

容易检验, $(\mathbf{x}, \mathbf{y})_G$ 的确是内积, 即它满足第 5 章第 1.3 节的性质 1-4.

第 8 章 对偶空间和张量

1. 对偶空间
2. 内积空间的对偶
3. 伴随（对偶）变换和转置、三探基本子空间
4. 向量空间与其对偶有什么差异？
5. 多重线性函数、张量
6. 张量的坐标变换公式

第 9 章 谱理论进阶

1. 凯莱-哈密尔顿定理

定理 1.1 (凯莱-哈密尔顿定理). 令 A 为方阵, 并令 $p(\lambda) = \det(A - \lambda I)$ 是其特征多项式. 那么 $p(A) = \mathbf{0}$.

一种错误的证明: 这个证明看起来超级简单: 在特征多项式的定义式中代入 A 而不是 λ , 得到

$$p(A) = \det(A - AI) = \det \mathbf{0} = 0.$$

□

但这种证明是错的! 要看出原因, 我们分析一下定理的内容. 定理是说, 如果计算了特征多项式

$$\det(A - \lambda I) = p(\lambda) = \sum_{k=0}^n c_k \lambda^k$$

然后将 λ 换成 A 以得到

$$p(A) := \sum_{k=0}^n c_k A^k = c_0 I + c_1 A + \dots + c_n A^n$$

则此式的结果是零矩阵.

仅仅是将行列式 $\det(A - \lambda I)$ 中的 λ 替换为 A , 并不能清晰地说明为何会得到相同的结果. 并且, 容易看出 (除了 1×1 矩阵的例外情况), 结果甚至不是同类对象. 也即: $A - AI$ 是零矩阵, 且其行列式是数 0; 但 $p(A)$ 是矩阵, 并且该定理说的是这个矩阵是零矩阵. 那么上面的证明就是牛头不对马嘴: 即便定理陈述中和证明中都说的是“零”, 但这些“零”并不相同——分别是数零和零矩阵!

我们呈上另一种证明, 它的思路基于分析学.

一种“连续式”的证明: 本证明是在观察到以下几点的基础上作出的. 第一点是, 该定理对于对角矩阵, 以及相似于对角矩阵的矩阵都是平凡的 (见下习题 1.1).

第二点是, 任意矩阵都能用可对角化的矩阵来近似 (且可以任意接近). 因为任意算子都关于规范正交基具有上三角矩阵 (见第 6 章定理 1.1), 所以可假设 A 是上三角矩阵, 而不失一般性.

本证明展现了一种重要思想: 通常, 考虑一种典型的情况就足够完成证明了. 尽管超出了本书的范围, 但我们还要 (粗略地) 陈述一下这个结论: 一般的矩阵是可对角化的.

我们可以对 A 的对角项施加扰动 (可任意小), 使得它们互不相同, 于是经扰动的矩阵 $\tilde{A}$ 是可对角化的 (三角矩阵的特征值是其对角项, 见第 4 章第 1.7 节, 并且由第 4 章推论 2.3, 有 n 个互异特征值的 $n \times n$ 矩阵是可对角化的).

刚刚提到, 我们可对 A 的对角项施加任意小的扰动, 从而弗罗贝尼乌斯范数 $\|A - \tilde{A}\|_2$ 可任意小. 因此, 可找到一系列可对角化矩阵 A_k , 满足当 $k \rightarrow \infty$ 时 $A_k \rightarrow A$ (比如, 当 $k \rightarrow \infty$ 时 $\|A_k - A\|_2 \rightarrow 0$). 可以证明, 特征多项式 $p_k(\lambda) = \det(A_k - \lambda I)$ 收敛至 A 的特征多项式 $p(\lambda) = \det(A - \lambda I)$. 因此

$$p(A) = \lim_{k \rightarrow \infty} p_k(A_k).$$

而我们在上面讨论过, 凯莱-哈密顿定理对于可对角化矩阵是平凡的, 所以 $p_k(A_k) = \mathbf{0}$. 因此 $p(A) = \lim_{k \rightarrow \infty} \mathbf{0} = \mathbf{0}$. $\square$

这个证明, 是为熟知分析学中诸如连续、收敛之类概念¹的读者准备的. 这样的读者应当能够补全所有的细节, 并且这个证明对于他/她来说应该是极为简单而自然的.

然而, 对于其余尚不熟悉这些概念的读者, 这个证明看上去会很奇怪, 甚至像是“作弊” (不过我还是要重申, 这个证明绝对是正确且严谨的, 只是借助了微分学中几个基本的结论). 那么, 我们呈上该定理的另一种证明, 它是线性代数教材中的“通行”证明.

一种“通行的”证明: 我们知道 (见第 6 章定理 1.1), 任意方阵都么正等价于上三角矩阵. 因为对任意多项式 P , 有 $p(UAU^{-1}) = Up(A)U^{-1}$, 并且么正等价矩阵的特征多项式是相同的, 所以只要对上三角矩阵证明该定理即可.

因此, 令 A 是上三角矩阵. 我们知道三角矩阵的对角项即为其特征值, 所以令 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 A 的特征值 (按照它们在对角线上出现的顺序排列), 因此

$$A = \begin{pmatrix} \lambda_1 & & * \\ & \lambda_2 & \\ & & \ddots \\ \mathbf{0} & & & \lambda_n \end{pmatrix}.$$

¹这里我说的是**分析学**, 即关于连续、收敛之类的概念的严谨学问, 而不是微积分, 后者只教授一系列技巧.

A 的特征多项式 $p(z) = \det(A - zI)$ 可表示为 $p(z) = (\lambda_1 - z)(\lambda_2 - z) \dots (\lambda_n - z) = (-1)^n(z - \lambda_1)(z - \lambda_2) \dots (z - \lambda_n)$, 因此

$$p(A) = (-1)^n(A - \lambda_1 I)(A - \lambda_2 I) \dots (A - \lambda_n I).$$

定义子空间 $E_k := \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k\}$, 其中 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ 是 $\mathbb{C}^n$ 的标准基. 因为 A 的矩阵是上三角的, 所以子空间 E_k 是算子 A 的所谓**不变子空间**, 即 $AE_k \subset E_k$ (即 $A\mathbf{v} \in E_k$ 对所有 $\mathbf{v} \in E_k$ 成立). 此外, 因为对任意 $\mathbf{v} \in E_k$ 与任意 λ 有

$$(A - \lambda I)\mathbf{v} = A\mathbf{v} - \lambda\mathbf{v} \in E_k,$$

(这是因为 $A\mathbf{v}$ 和 $\lambda\mathbf{v}$ 都属于 E_k), 于是 $(A - \lambda I)E_k \subset E_k$, 即 E_k 是 $A - \lambda I$ 的不变子空间.

我们还可进一步描述子空间 $(A - \lambda_k I)E_k$, 即 $(A - \lambda_k I)\mathbf{e}_k \in \text{span}\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_{k-1}\}$, 这是因为矩阵 $(A - \lambda_k I)$ 的第 k 列只有前 $k-1$ 项是非零的. 另一方面, 对 $j < k$ 有 $(A - \lambda_k)\mathbf{e}_j \in E_j \subset E_k$ (因为 E_j 是 $A - \lambda_k I$ 的不变子空间).

任取向量 $\mathbf{v} \in E_k$. 由 E_k 的定义, 其可表示为向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k$ 的线性组合. 因为所有向量 $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k$ 都被 $A - \lambda_k I$ 变换为 E_{k-1} 中的向量, 所以

$$(1.1) \quad (A - \lambda_k I)\mathbf{v} \in E_{k-1}, \quad \forall \mathbf{v} \in E_k$$

任取向量 $\mathbf{x} \in \mathbb{C}^n = E_n$. 依次对 $k = n, n-1, \dots, 1$ 应用 (1.1) 有

$$\mathbf{x}_1 := (A - \lambda_n I)\mathbf{x} \in E_{n-1},$$

$$\mathbf{x}_2 := (A - \lambda_{n-1} I)\mathbf{x}_1 = (A - \lambda_{n-1} I)(A - \lambda_n I)\mathbf{x} \in E_{n-2},$$

...

$$\mathbf{x}_n := (A - \lambda_2 I)\mathbf{x}_{n-1} = (A - \lambda_2 I) \dots (A - \lambda_{n-1} I)(A - \lambda_n I)\mathbf{x} \in E_1.$$

最后一个包含关系意味着 $\mathbf{x}_n = \alpha\mathbf{e}_1$, 然而 $(A - \lambda_1 I)\mathbf{e}_1 = \mathbf{0}$, 因此

$$\mathbf{0} = (A - \lambda_1 I)\mathbf{x}_n = (A - \lambda_1 I)(A - \lambda_2 I) \dots (A - \lambda_n I)\mathbf{x}.$$

因此 $p(A)\mathbf{x} = \mathbf{0}$ 对所有 $\mathbf{x} \in \mathbb{C}^n$ 成立, 这就意味着 $p(A) = \mathbf{0}$. □

习题

1.1. (可对角化矩阵的凯莱-哈密尔顿定理) 在上节中提到, 凯莱-哈密尔顿定理指出, 若 A 是方阵, 且其特征多项式为

$$p(\lambda) = \det(A - \lambda I) = \sum_{k=0}^n c_k \lambda^k$$

那么 $p(A) := \sum_{k=0}^n c_k A^k = \mathbf{0}$ (我们假设 $A^0 = I$).

对 A 相似于对角矩阵的特殊情形 $A = SDS^{-1}$ 证明该定理. **提示:** 若 $D = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_n\}$ 且 p 是任意多项式, 你能计算 $p(D)$ 吗? $p(A)$ 呢?

2. 谱映射定理

2.1. 算子的多项式

回忆一下, 对方阵 (算子) A 和多项式 $p(z) = \sum_{k=1}^N a_k z^k$, 算子 $p(A)$ 定义为将 A 代入 p 的自变量位置

$$p(A) := \sum_{k=1}^N a_k A^k = a_0 I + a_1 A + a_2 A^2 + \cdots + a_N A^N;$$

此处 $A^0 = I$.

我们知道, 一般来说矩阵乘法是不可交换的, 即一般来说 $AB \neq BA$, 所以顺序很重要. 但是,

$$A^k A^j = A^j A^k = A^{k+j},$$

由此易证对任意多项式 p 和 q 有

$$p(A)q(A) = q(A)p(A) = R(A)$$

其中 $R(z) = q(z)p(z)$.

这就意味着, 处理算子 A 的多项式时, 无需担心交换律不成立的问题, 而可将 A 如自变量一般看待. 特别地, 若多项式 $p(z)$ 可表示成单项式的乘积

$$p(z) = a(z - z_1)(z - z_2) \cdots (z - z_N),$$

其中 $z_1, z_2, \dots, z_N$ 是 p 的根, 那么 $p(A)$ 可表示为

$$p(A) = a(A - z_1 I)(A - z_2 I) \cdots (A - z_N I)$$

2.2. 谱映射定理

回忆一下, 方阵 (算子) A 的谱 $\sigma(A)$ 是 A 的所有特征值构成的集合 (不按重数计).

定理 2.1 (谱映射定理). 对方阵 A 和任意多项式 p ,

$$\sigma(p(A)) = p(\sigma(A)).$$

换言之, μ 是 $p(A)$ 的特征值, 当且仅当 $\mu = p(\lambda)$ 对 A 的特征值 λ 成立.

注意, 如前所述, 该定理不涉及特征值的重数.

注. 注意, 其中一个包含关系是显然的. 即, 如果 λ 是 A 的特征值, 即 $A\mathbf{x} = \lambda\mathbf{x}$ 对 $\mathbf{x} \neq \mathbf{0}$ 成立, 那么 $A^k\mathbf{x} = \lambda^k\mathbf{x}$, 且 $p(A)\mathbf{x} = p(\lambda)\mathbf{x}$, 所以 $p(\lambda)$ 是 $p(A)$ 的特征值, 这就意味着包含关系 $p(\sigma(A)) \subset \sigma(p(A))$ 是平凡的.

如果考虑上述定理的 $\mu = 0$ 这一特殊情况, 就会得到下面推论.

推论 2.2. 令 A 是特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ 的方阵, 并令 p 是多项式. 那么 $p(A)$ 是可逆的, 当且仅当

$$p(\lambda_k) \neq 0 \quad \forall k = 1, 2, \dots, n.$$

定理 2.1 的证明: 如上讨论的, 包含关系

$$p(\sigma(A)) \subset \sigma(p(A))$$

是平凡的.

为证明反方向的包含关系 $\sigma(p(A)) \subset p(\sigma(A))$, 取 $\mu \in \sigma(p(A))$. 记 $q(z) = p(z) - \mu$, 因此 $q(A) = p(A) - \mu I$. 因为 $\mu \in \sigma(p(A))$, 所以算子 $q(A) = p(A) - \mu I$ 不可逆.

将 $q(z)$ 表示成单项式的乘积

$$q(z) = a(z - z_1)(z - z_2) \dots (z - z_N).$$

那么, 如之前在 2.1 节中讨论的, 可表出

$$q(A) = a(A - z_1 I)(A - z_2 I) \dots (A - z_N I).$$

算子 $q(A)$ 不可逆, 因此其中必有一项 $(A - z_k I)$ 不可逆 (因为可逆线性变换的乘积总是可逆的). 这就意味着 $z_k \in \sigma(A)$.

另一方面, z_k 又是 q 的根, 因此

$$0 = q(z_k) = p(z_k) - \mu$$

因此 $\mu = p(z_k)$. 因此我们证明了包含关系 $\sigma(p(A)) \subset p(\sigma(A))$. $\square$

习题

2.1. 称算子 A 是**幂零的**, 若 $A^k = \mathbf{0}$ 对某 k 成立. 证明: 如果 A 是幂零的, 那么 $\sigma(A) = \{0\}$ (即 0 是 A 的唯一特征值). 你能不用谱映射定理来证明吗?

3. 广义特征空间、代数重数的几何意义

3.1. 不变子空间

定义. 令 $A: V \rightarrow V$ 是向量空间 V 上的算子 (线性变换). 称向量空间 V 的子空间 E 是算子 A 的不变子空间 (或简称为 A -不变子空间), 若 $AE \subset E$, 即若 $A\mathbf{v} \in E$ 对所有 $\mathbf{v} \in E$ 成立.

若 E 是 A -不变的, 那么

$$A^2E = A(AE) \subset AE \subset E,$$

即 E 是 A^2 -不变的.

类似地, 可以证明 (可用归纳法), 若 $AE \subset E$, 那么

$$A^k E \subset E \quad \forall k \geq 1.$$

这意味着对任意多项式 p 均有 $p(A)E \subset E$, 即

任意 A -不变子空间 E 都是 $p(A)$ 的不变子空间.

若 E 是 A -不变子空间, 那么对所有 $\mathbf{v} \in E$, $A\mathbf{v}$ 同样属于 E . 因此, 可将 A 看成作用于 E (而不是整个向量空间 V) 的算子.

正式而言, 对 A -不变子空间 E , 定义 A 的所谓限制算子 $A|_E: E \rightarrow E$ 为

$$(A|_E)\mathbf{v} = A\mathbf{v} \quad \forall \mathbf{v} \in E.$$

此处我们改变了原算子的定义域和目标空间, 但是自变量和取值之间的对应关系保持不变.

我们会用到下面这个简单的引理.

引理 3.1. 令 p 为多项式, 并令 E 是 A -不变子空间. 那么

$$p(A|_E) = p(A)|_E.$$

证明: 证明很简单. □

若 $E_1, E_2, \dots, E_r$ 是由 A -不变子空间构成的基, 并且 $A_k := A|_{E_k}$ 是对应的限制算子, 那么由于 $AE_k = A_k E_k \subset E_k$, 所以各算子 A_k 的作用是相互独立的 (互不影响), 并且要分析 A 的作用, 只需分别分析各 A_k 的作用.

特别地, 如果在各子空间 E_k 中选取一个基, 并且将它们组合起来以得到 V 的基 (见第 4 章的定理 2.6), 那么算子 A 在该基下的矩阵具有如下分块对角形式

$$\begin{pmatrix} A_1 & & & \mathbf{0} \\ & A_2 & & \\ & & \ddots & \\ \mathbf{0} & & & A_r \end{pmatrix}$$

(当然, 这里 V 的基需要有正确的顺序, 即先取 E_1 的基, 再取 E_2 的基, 以此类推).

我们现在的目标是, 选取由不变子空间 $E_1, E_2, \dots, E_r$ 构成的基, 使得各限制算子 A_k 有简单的结构. 在这种情况下, 我们会得到一个基, 使得 A 关于该基的矩阵有简单的结构.

特征空间 $\text{Ker}(A - \lambda_k I)$ 是个很好的备选项, 因为限制于特征空间 $\text{Ker}(A - \lambda_k I)$ 的 A 就是 $\lambda_k I$. 不幸的是, 特征空间并不总能构成基 (它们能构成基当且仅当 A 可对角化, 见第 4 章的定理 2.1).

不过, 所谓**广义特征空间**可以实现我们的目的.

3.2. 广义特征空间

定义 3.2. 向量 $\mathbf{v}$ 称为 (对应于特征值 λ 的) 广义特征向量, 如果 $(A - \lambda I)^k \mathbf{v} = \mathbf{0}$ 对某 $k \geq 1$ 成立.

对应于特征值 λ 的所有广义特征向量连同 $\mathbf{0}$ 构成的集合 E_λ 称为对应于特征值 λ 的广义特征空间.

换言之, 广义特征空间 E_λ 可表示为

$$(3.1) \quad E_\lambda = \bigcup_{k \geq 1} \text{Ker}(A - \lambda I)^k.$$

序列 $\text{Ker}(A - \lambda I)^k, k = 1, 2, 3, \dots$ 是由一系列递增的子空间构成的, 意即

$$\text{Ker}(A - \lambda I)^k \subset \text{Ker}(A - \lambda I)^{k+1} \quad \forall k \geq 1.$$

表达式 (3.1) 看上去并不简单, 因为它包含无限并集. 然而, 子空间 $\text{Ker}(A - \lambda I)^k$ 会趋于稳定, 即

$$\text{Ker}(A - \lambda I)^k = \text{Ker}(A - \lambda I)^{k+1} \quad \forall k \geq k_\lambda,$$

所以, 表面上的“无限并集”其实是有限并集.

为证明这一系列核会趋于稳定, 首先注意到如果对有限维子空间 E 和 F 有 $E \subsetneq F$ (符号 $E \subsetneq F$ 意为 $E \subset F$ 但 $E \neq F$), 那么 $\dim E < \dim F$.

因为 $\dim \operatorname{Ker}(A - \lambda I)^k \leq \dim V < \infty$, 所以它不会增长至无穷, 而会在某处满足

$$\operatorname{Ker}(A - \lambda I)^k = \operatorname{Ker}(A - \lambda I)^{k+1}.$$

剩余证明由下述引理完成.

引理 3.3. 令对某 k 有

$$\operatorname{Ker}(A - \lambda I)^k = \operatorname{Ker}(A - \lambda I)^{k+1}.$$

那么

$$\operatorname{Ker}(A - \lambda I)^{k+r} = \operatorname{Ker}(A - \lambda I)^{k+r+1} \quad \forall r \geq 0.$$

证明: 令 $\mathbf{v} \in \operatorname{Ker}(A - \lambda I)^{k+r+1}$, 即 $(A - \lambda I)^{k+r+1}\mathbf{v} = \mathbf{0}$. 那么

$$\mathbf{w} := (A - \lambda I)^r \mathbf{v} \in \operatorname{Ker}(A - \lambda I)^{k+1}.$$

但我们知道 $\operatorname{Ker}(A - \lambda I)^k = \operatorname{Ker}(A - \lambda I)^{k+1}$, 所以 $\mathbf{w} \in \operatorname{Ker}(A - \lambda I)^k$, 这也就意味着 $(A - \lambda I)^k \mathbf{w} = \mathbf{0}$. 回顾 $\mathbf{w}$ 的定义可得

$$(A - \lambda I)^{k+r} \mathbf{v} = (A - \lambda I)^k \mathbf{w} = \mathbf{0}$$

因此 $\mathbf{v} \in \operatorname{Ker}(A - \lambda I)^{k+r}$. 我们证明了 $\operatorname{Ker}(A - \lambda I)^{k+r+1} \subset \operatorname{Ker}(A - \lambda I)^{k+r}$. 反方向的包含关系是平凡的. $\square$

定义. 使得序列 $\operatorname{Ker}(A - \lambda I)^k$ 稳定的数 $d = d(\lambda)$, 也即使得下式成立的数 $d = d(\lambda)$

$$\operatorname{Ker}(A - \lambda I)^{d-1} \subsetneq \operatorname{Ker}(A - \lambda I)^d = \operatorname{Ker}(A - \lambda I)^{d+1}$$

称为特征值 λ 的深度.

由深度的定义, 可知对广义特征空间 E_λ 有

$$(3.2) \quad (A - \lambda I)^{d(\lambda)} \mathbf{v} = \mathbf{0} \quad \forall \mathbf{v} \in E_\lambda.$$

现在, 总结一下我们已知的有关广义特征空间的结论:

- a) E_λ 是 A 的不变子空间, $AE_\lambda \subset E_\lambda$.
- b) 若 $d(\lambda)$ 是特征值 λ 的深度, 那么

$$((A - \lambda I)|_{E_\lambda})^{d(\lambda)} = (A|_{E_\lambda} - \lambda I|_{E_\lambda})^{d(\lambda)} = \mathbf{0}.$$

(这仅仅是 (3.2) 的另一种写法)

c) $\sigma(A|_{E_\lambda}) = \{\lambda\}$, 因为算子 $A|_{E_\lambda} - \lambda I|_{E_\lambda}$ 是幂零的【见 b)】, 而幂零算子的谱只包含 0, 见习题 2.1.

这样, 我们就做好了准备, 可以陈述本节的核心结论了. 令 $A: V \rightarrow V$.

定理 3.4. 令 $\sigma(A)$ 包含 r 个值 $\lambda_1, \lambda_2, \dots, \lambda_r$, 并令 $E_k := E_{\lambda_k}$ 是对应的广义特征空间. 那么子空间构成的组 $E_1, E_2, \dots, E_r$ 是 V 的子空间构成的基.

注 3.5. 如果我们将所有广义特征空间 E_k 的基合并起来, 那么由第 4 章定理 2.6, 我们就会得到整个空间的基. 在该基下, 算子 A 的矩阵具有分块对角形式 $A = \text{diag}\{A_1, A_2, \dots, A_r\}$, 其中 $A_k := A|_{E_k}$, $E_k = E_{\lambda_k}$. 还容易从 (3.2) 看出, 算子 $N_k := A_k - \lambda_k I|_{E_k}$ 是幂零的, $N_k^{d_k} = 0$.

定理 3.4 的证明: 令 m_k 是特征值 λ_k 的重数, 所以 $p(z) = \prod_{k=1}^r (z - \lambda_k)^{m_k}$ 是 A 的特征多项式. 定义

$$p_k(z) = p(z)/(z - \lambda_k)^{m_k} = \prod_{j \neq k} (z - \lambda_j)^{m_j}.$$

引理 3.6.

$$(3.3) \quad (A - \lambda_k I)^{m_k}|_{E_k} = 0.$$

证明: 有两种可行的证法. 第一种是, 注意到 $m_k \geq d_k$, 其中 d_k 是特征值 λ_k 的深度, 并应用下述结论

$$(A - \lambda_k I)^{d_k}|_{E_k} = (A_k - \lambda_k I|_{E_k})^{m_k} = 0,$$

其中 $A_k := A|_{E_k}$ (广义特征空间的性质 2). □

为证明该定理, 定义

$$q(z) = \sum_{k=1}^r p_k(z).$$

引理 3.7. □

3.3. 代数重数的几何意义

命题 3.8.

3.4. 一个重要应用

下述推论对研究微分方程十分重要.

推论 3.9.

4. 幂零算子的结构

$$(4.1) \quad \begin{pmatrix} 0 & 1 & & 0 \\ & 0 & 1 & \\ & & 0 & \ddots \\ & & & \ddots & 1 \\ 0 & & & & 0 \end{pmatrix}$$

4.1. 广义特征向量链

4.2. 幂零算子的若当标准型

4.3. 点图、若当标准型的唯一性




图 1 点图及对应的幂零算子的若当标准型

5. 若当分解定理

索引

各条目按照汉语拼音排序. 部分条目下有若干子条目, 子条目中用波浪线“~”指代其所属的条目. 所有条目(含子条目)后附注英文原文. 例如, “基(basis)”条目下的“正交~(orthogonal)”, 即表示“正交基”(orthogonal basis).

B

不变子空间(invariant subspace), 196

G

广义特征空间(generalized eigenspace),
197

广义特征向量(generalized eigenvector), 197

J

基(basis), 5

矩阵(matrix), 3

S

施密特分解(Schmidt decomposition),
152

X

线性组合(linear combination), 5

平凡~(trivial), 7

项(entry, entries)

矩阵的~(of a matrix), 3

Z

转置(transpose), 4

子矩阵(submatrix), 87

子式(minor), 87